

# 《短视频推荐中的两阶段受约束 Actor-Critic》

## 逐段中文翻译

原文作者: Qingpeng Cai, Zhenghai Xue, Chi Zhang, Wanqi Xue, Shuchang Liu, Ruohan Zhan  
Xueliang Wang, Tianyou Zuo, Wentao Xie, Dong Zheng, Peng Jiang, Kun Gai

原文发表于 WWW 2023; 译文整理: 2026 年 4 月

### 译者说明

本文档根据论文 *Two-Stage Constrained Actor-Critic for Short Video Recommendation* 逐段翻译整理。为便于阅读, 公式、表格和算法在译文中使用 LaTeX 重新排版; 原文图像未重绘, 译文保留并翻译图题及其含义说明。英文技术词如 Actor-Critic、WatchTime、Like、Share、Download 等在译文中保留英文, 并给出中文解释。

### 标题

短视频推荐中的两阶段受约束 Actor-Critic

### 摘要

短视频在社交媒体上的广泛流行, 为优化视频分享平台上的推荐系统带来了新的机遇与挑战。用户会与系统进行序列式交互, 并针对多个视频给出复杂且多维的反馈, 包括观看时长 (WatchTime) 以及多种类型的交互行为。一方面, 平台希望长期优化用户的累计 WatchTime (主目标), 这一目标可以通过强化学习有效优化。另一方面, 平台还需要满足多个用户交互反馈 (辅助目标) 的约束, 例如 Like、Follow、Share 等。

本文将短视频推荐问题形式化为受约束马尔可夫决策过程 (CMDP)。我们发现, 传统受约束强化学习算法在该场景下效果并不好。为此, 本文提出一种新的两阶段受约束 Actor-Critic 方法: 第一阶段, 分别学习用于优化每个辅助信号的单独策略; 第二阶段, 学习一个策略, 使其既优化主信号, 又接近第一阶段学到的各个策略, 从而有效保证主策略在辅助目标上的表现。大量离线评估表明, 该方法在优化主目标和平衡其他目标方面均优于替代方案。进一步地, 在线短视频推荐实验显示, 该方法在 WatchTime 和交互指标上均显著优于其他基线。该方法已经在生产系统中全面上线, 用于优化平台用户体验。

## CCS 概念与关键词

信息系统 → 推荐系统；计算方法 → 强化学习。

关键词：受约束强化学习；推荐系统；短视频推荐。

## ACM 引用格式

Qingpeng Cai, Zhenghai Xue, Chi Zhang, Wanqi Xue, Shuchang Liu, Ruohan Zhan, Xueliang Wang, Tianyou Zuo, Wentao Xie, Dong Zheng, Peng Jiang, and Kun Gai. 2023. Two-Stage Constrained Actor-Critic for Short Video Recommendation. In Proceedings of the ACM Web Conference 2023 (WWW '23), May 1–5, 2023, Austin, TX, USA. ACM, New York, NY, USA, 11 pages. <https://doi.org/10.1145/3543507.3583259>

## 1 引言

短视频的迅速流行正在改变社交媒体的现状。短视频消费为相关组织带来了巨大的商业机会。因此，短视频平台推荐策略优化受到越来越多关注。用户通过上下滑动并观看多个视频与平台交互，如图 1(a) 所示。用户会针对每个视频提供多维反馈。如图 1(b) 左侧所示，用户观看一个视频后可能产生的反馈包括 WatchTime，即观看该视频所花费的时间，以及多种交互行为：Follow（关注视频作者）、Like（点赞该视频）、Comment（发表评论）、Collect（收藏该视频）、Share（将视频分享给朋友）等。

**图 1：**一个流行短视频平台（如 TikTok、Kuaishou 等）的示例。图中展示了用户滚动浏览视频以及观看视频后可能产生的关注、点赞、评论、收藏、分享等多种反馈。

一方面，平台的主目标是优化多个视频上的累计 WatchTime，因为 WatchTime 反映用户注意力，并且与日活跃用户数（DAU）高度相关。近年来，越来越多研究关注将强化学习应用于推荐系统，因为强化学习能够提升累计奖励。特别地，WatchTime 可以通过强化学习方法被有效累计最大化，从而增加用户在多个视频上的总停留时间。另一方面，Like、Follow、Share 等其他反馈同样反映用户满意程度。因此，平台还需要满足用户交互方面的约束。由此可见，只优化单一目标的既有推荐系统已经不足，例如电商平台中仅优化 GMV 的系统；实际应用系统应综合考虑用户反馈的各个方面，以优化用户体验。

本文将短视频推荐问题建模为一个受约束马尔可夫决策过程：用户作为环境，推荐算法作为智能体；在每个时间步，智能体采取一个动作，即向用户推荐一个视频；随后环境向智能体返回多个奖励，即用户反馈。智能体目标是在满足其他交互反馈约束（辅助目标）的前提下，最大化累计 WatchTime（主目标）。这不同于帕累托最优，因为帕累托最优旨在寻找一个帕累托最优解，但该解未必优先考虑系统中的主目标。

与无约束策略优化相比，该受约束策略优化问题更具挑战性。一个自然做法是应用标准受约束强化学习算法，即在预先设定拉格朗日乘子的情况下最大化拉格朗日函数。然而，这类方法不能直接适用于本文场景，主要有以下两个原因。

第一，由于用户反馈类型不同，仅使用单个策略评估模型来估计拉格朗日对偶目标是

不充分的。这种反馈组合方式并不合适，尤其当不同反馈具有各自折扣因子时更是如此。基于价值的模型中，时序差分误差通常只允许一个折扣值。即使一个折扣因子足够，单个价值模型也可能难以准确评估策略，尤其当不同反馈以不同频率出现时；这正是短视频推荐的典型情况。WatchTime 是稠密反馈，每次视频曝光都可观察到；而 Like、Follow、Share 等交互信号稀疏得多，可能几十次浏览都不出现。若简单相加，稀疏反馈信号会被稠密反馈削弱。为解决多反馈评估困难，本文为每种反馈分别建立其自身价值模型，从而允许反馈特定的折扣因子，并减轻一种反馈对另一种反馈评估的干扰。第 4.1 节实验验证了该方法有效性。

第二，与只考虑一个约束的既有工作不同，推荐系统尤其是短视频系统中存在多个约束。本文发现，由于多维拉格朗日乘子的搜索空间更大，最大化拉格朗日函数的算法更难优化。强化学习训练耗时较长，因此对拉格朗日乘子网格搜索代价很高。基于此，本文提出先分别学习优化每个辅助反馈的策略，然后以“软约束”方式正则化主反馈策略，使其接近这些辅助策略，而不是搜索最优拉格朗日乘子。本文从理论上证明最优解的闭式形式。离线和在线实验均表明，本文方法能够更好地最大化主反馈并平衡其他反馈。

综上，本文贡献如下。

- **短视频推荐中的受约束优化：**形式化短视频推荐中的受约束策略学习问题，其中不同反馈可能以不同频率被观察到，智能体在平衡其他反馈约束的同时最大化某一主反馈。
- **两阶段受约束 Actor-Critic 算法：**提出新的两阶段受约束 Actor-Critic 算法。其一，多 Critic 策略估计：为每个反馈分别学习价值模型，以适应不同折扣因子与观测频率。其二，两阶段 Actor 学习：先学习用于优化每个辅助反馈的策略，再以软正则化方式约束主反馈策略，使其不要偏离这些辅助策略。
- **离线与在线实验中的显著收益：**在离线实验和在线实验中均证明所提方法有效。
- **真实短视频应用部署：**该方法已经在流行短视频平台全面上线。

## 2 相关工作

**推荐中的强化学习。**由于强化学习能够优化用户长期满意度，将强化学习应用于推荐系统的研究不断增多。基于价值的方法会估计向用户推荐候选集合中某个物品后的用户满意度，并选择预测满意度最大的物品。基于策略的方法直接学习策略，即决定推荐哪个物品，并沿着提升用户满意度的方向优化。近来，研究者开始将强化学习用于更复杂的推荐任务，而不仅是优化单一目标，例如促进内容物品获得公平曝光、提升推荐多样性和新颖性，以及通过表征式奖励塑形刻画更全面的用户动态。面对多维用户反馈，实际系统通常对不同反馈类型有不同偏好，因此本文提出受约束优化问题，而不是追求帕累托最优。

**受约束强化学习。**本文也与受约束强化学习文献密切相关。在这类研究中，序列决策问题被形式化为受约束马尔可夫决策过程，策略学习过程需要满足相应约束。例如，Tessler 等提出交替更新策略与拉格朗日乘子，并证明算法收敛到不动点。然而，该方法只建模一个约束，无法很好扩展到多个约束问题。与此不同，本文针对每个辅助反馈学习一个专门

最大化该反馈的策略，然后以“软约束”方式正则化主策略，使其接近这些辅助策略。实验证明，当推荐系统处理多个反馈时，这是一种更有效的受约束策略学习方式。不同于将学习策略正则化到一个行为策略附近的离线强化学习工作，本文将策略软约束在多个优化辅助反馈的策略附近。

**多目标优化。**多目标优化方法大致可分为两类：帕累托优化，以及使用预设权重的联合优化。帕累托优化目标是寻找一个解，使不存在其他解能同时改进所有目标，这被称为帕累托最优。然而，帕累托最优解未必优先考虑实际应用中最重要目标。另一类方法通过预先指定权重，将不同目标合并为单一目标。但在真实应用中，很难量化出能够准确反映偏好的权重。

### 3 短视频推荐的受约束马尔可夫决策过程

**图 2：**短视频推荐中的 MDP。该图展示用户状态、推荐动作、多维反馈以及状态转移之间的序列决策关系。

我们首先形式化短视频推荐问题。当用户  $u$  打开应用时，一个新会话开始。一个会话包含多个请求。在每个请求  $t$ ，推荐系统（智能体）根据用户当前状态采取动作  $a_t$ ，即向用户推荐一个视频。随后，用户针对展示视频给出多维反馈，如 WatchTime、Like、Share、Follow；这些反馈被智能体接收为向量值奖励信号。当用户离开应用时，会话结束。推荐系统目标是在不显著牺牲其他反馈的约束下，优化主反馈（如 WatchTime）的累计奖励。

上述过程被建模为 CMDP:  $(S, A, P, R, C, \rho_0, \Gamma)$ 。其中  $S$  是用户当前表示  $s_t$  的状态空间； $A$  是动作空间，每个动作  $a_t$  对应一次请求中推荐的一个视频； $P: S \times A \rightarrow \Delta(S)$  表示状态转移； $R: S \times A \rightarrow \mathbb{R}^m$  定义向量值奖励函数，产生  $m$  个不同奖励：

$$r(s_t, a_t) = (r_1(s_t, a_t), \dots, r_m(s_t, a_t)).$$

$\rho_0$  是初始状态分布， $\Gamma = (\gamma_1, \dots, \gamma_m) \in (0, 1)^m$  是每种反馈奖励的折扣因子向量。 $C$  指定辅助反馈上的约束，即其他目标信号总量的下界。

定义向量值折扣累计奖励  $R_t$  为

$$R_t = \sum_{t'=t}^T \Gamma^{t'-t} \cdot r(s_{t'}, a_{t'}),$$

其中  $T$  为会话长度， $\Gamma^b = (\gamma_1^b, \dots, \gamma_m^b)$ ， $x \cdot y$  表示逐点乘积。令

$$V^\pi(s) = (V_1^\pi(s), \dots, V_m^\pi(s))$$

表示按策略  $\pi$  采样动作时的状态价值  $\mathbb{E}_\pi[R_t | s_t = s]$ ；令

$$Q^\pi(s, a) = (Q_1^\pi(s, a), \dots, Q_m^\pi(s, a))$$

表示状态-动作价值  $\mathbb{E}_\pi[R_t | s_t = s, a_t = a]$ 。记  $\rho_\pi$  为策略  $\pi$  诱导的状态分布。不失一般性，将第一个反馈设为主反馈。目标是学习推荐策略  $\pi(\cdot | s)$ ，求解：

$$\begin{aligned} \max_{\pi} \quad & \mathbb{E}_{\rho_\pi} [V_1^\pi(s)] \\ \text{s.t.} \quad & \mathbb{E}_{\rho_\pi} [V_i^\pi(s)] \geq C_i, \quad i = 2, \dots, m, \end{aligned} \tag{1}$$

其中  $C_i$  是辅助反馈  $i$  上的约束。

## 4 两阶段受约束 Actor-Critic

本节提出一种新的两阶段受约束 Actor-Critic 方法，用于应对短视频推荐场景中的学习挑战。

- **多 Critic 策略估计：**分别估计不同反馈，以更好处理稠密信号和稀疏信号。
- **第一阶段：**对于每个辅助反馈，学习一个策略来优化其累计奖励。
- **第二阶段：**对于主反馈，学习一个策略来优化其累计奖励，同时以软约束方式限制该策略，使其接近为优化辅助反馈而学习到的其他策略。

本文首先讨论分别评估不同策略相对于联合估计的优势。随后，在第 4.2 节和第 4.3 节中，详细说明在线学习与随机策略设置下的方法。最后，讨论该方法向离线设置和确定性策略的扩展。

### 4.1 多 Critic 策略估计

本文展示对每个反馈单独评估相对于对相加反馈联合评估的优势。具体而言，考虑每次视频浏览中的两类反馈：WatchTime 和交互行为，其中交互行为是一个指示函数，表示该次浏览中是否发生交互。

对于联合评估，学习一个价值模型  $V_{joint}$ ，其奖励为 WatchTime 与交互行为之和。对于单独评估，分别学习两个价值模型  $V_w$  与  $V_i$ ，其奖励分别为 WatchTime 和交互行为，并定义

$$V_{separate} = V_w + V_i.$$

为公平比较，所有价值模型共享折扣因子 0.95，并使用来自某流行短视频平台一天的数据训练。为评估价值模型在 WatchTime 和交互行为方面的准确性，本文计算模型价值  $V_{joint}$ 、 $V_{separate}$  与每个会话中相应反馈之和的蒙特卡洛价值之间的相关性。相较于  $V_{joint}$ ， $V_{separate}$  在 WatchTime 和交互行为上的相关性分别提升 0.19% 和 0.14%。需要注意，WatchTime 和交互行为上 0.1% 的提升就是显著的。这表明单独评估比联合学习能更好地学习不同奖励反馈。

### 4.2 第一阶段：辅助反馈的策略学习

在这一阶段，分别学习策略以优化每个辅助反馈的累计奖励。为完整起见，本文写出随机策略下的过程。考虑反馈  $i$ ，令所学习的 Actor 和 Critic 分别由  $\pi_{\theta_i}$  与  $V_{\phi_i}$  参数化。在第  $k$  次迭代中，观察由  $\pi_{\theta_i}^{(k)}$  收集到的样本  $(s, a, s')$ ，即  $s \sim \rho_{\pi_{\theta_i}^{(k)}}$ ， $a \sim \pi_{\theta_i}^{(k)}(\cdot | s)$ ， $s' \sim P(\cdot | s, a)$ 。

Critic 更新为最小化 Bellman 方程误差：

$$\phi_i^{(k+1)} \leftarrow \arg \min_{\phi} \mathbb{E}_{\pi_{\theta_i}^{(k)}} \left[ \left( r_i(s, a) + \gamma V_{\phi_i}^{(k)}(s') - V_{\phi}(s) \right)^2 \right]. \quad (2)$$

Actor 更新为最大化优势函数：

$$\theta_i^{(k+1)} \leftarrow \arg \max_{\theta} \mathbb{E}_{\pi_{\theta_i}^{(k)}} \left[ A_i^{(k)} \log(\pi_{\theta}(a | s)) \right], \quad (3)$$

其中

$$A_i^{(k)} = r_i(s, a) + \gamma_i V_{\phi_i}^{(k)}(s') - V_{\phi_i}^{(k)}(s).$$

### 4.3 第二阶段：主反馈的软约束优化

在预训练出用于优化辅助反馈的策略  $\pi_{\theta_2}, \dots, \pi_{\theta_m}$  后，进入第二阶段，学习优化主反馈的策略。本文提出一种新的多约束策略优化方法。

令主反馈的 Actor 和 Critic 分别为  $\pi_{\theta_1}$  和  $V_{\phi_1}$ 。在第  $k$  次迭代中，同样更新 Critic 以最小化 Bellman 方程误差：

$$\phi_1^{(k+1)} \leftarrow \arg \min_{\phi} \mathbb{E}_{\pi_{\theta_1}^{(k)}} \left[ \left( r_1(s, a) + \gamma_1 V_{\phi_1}^{(k)}(s') - V_{\phi}(s) \right)^2 \right]. \quad (4)$$

Actor 更新原则包含两部分：一是最大化优势函数；二是将策略限制在不远离其他策略的区域内。优化问题形式化为

$$\begin{aligned} \max_{\pi} \quad & \mathbb{E}_{\pi} [A_1^{(k)}] \\ \text{s.t.} \quad & D_{KL}(\pi \| \pi_{\theta_i}) \leq \epsilon_i, \quad i = 2, \dots, m, \end{aligned} \quad (5)$$

其中

$$A_1^{(k)} = r_1(s, a) + \gamma_1 V_{\phi_1}^{(k)}(s') - V_{\phi_1}^{(k)}(s).$$

对于式 (5) 的拉格朗日函数，本文给出如下闭式解。证明见附录 A。

**定理 1.** 式 (5) 的拉格朗日函数具有闭式解：

$$\pi^*(a | s) \propto \prod_{i=2}^m (\pi_{\theta_i}(a | s))^{\lambda_i / \sum_{j=2}^m \lambda_j} \exp \left( \frac{A_1^{(k)}}{\sum_{j=2}^m \lambda_j} \right), \quad (6)$$

其中  $\lambda_i$ ,  $i = 2, \dots, m$ , 为拉格朗日乘子。

给定由  $\pi_{\theta_1}^{(k)}$  收集的数据，通过最小化学习策略  $\pi_{\theta_1}$  与最优策略  $\pi^*$  之间的 KL 散度来学习策略：

$$\begin{aligned} \theta_1^{(k+1)} & \leftarrow \arg \min_{\theta} \mathbb{E}_{\pi_{\theta_1}^{(k)}} [D_{KL}(\pi^*(a | s) \| \pi_{\theta}(a | s))] \\ & = \arg \max_{\theta} \mathbb{E}_{\pi_{\theta_1}^{(k)}} \left[ \frac{\prod_{i=2}^m (\pi_{\theta_i}(a | s))^{\lambda_i / \sum_{j=2}^m \lambda_j}}{\pi_{\theta_1}^{(k)}(a | s)} \exp \left( \frac{A_1^{(k)}}{\sum_{j=2}^m \lambda_j} \right) \log \pi_{\theta}(a | s) \right]. \end{aligned} \quad (7)$$

两阶段受约束 Actor-Critic 算法完整过程见附录 B，简称为 TSCAC。式 (7) 中 Actor 更新的直观含义如下： $\pi_{\theta_i}(a | s)$  表示策略  $i$  选择动作的概率，起到重要性权重作用，并以软正则化方式约束学习到的策略  $\pi_{\theta_1}$  接近其他策略  $\pi_{\theta_i}$ 。较小的拉格朗日乘子  $\lambda_i$  表示较弱的约束；当  $\lambda_i = 0$  时，学习策略  $\pi_{\theta_1}$  可以与约束策略  $\pi_{\theta_i}$  无关。本文将所有  $\lambda$  设为相同

值, 这对生产系统更实用。如果对不同拉格朗日乘子取值进一步微调, TSCAC 可能表现更好; 但后续离线和在线实验表明, 相同  $\lambda$  下 TSCAC 仍然有效。

**离线学习。**接下来讨论如何将本文受约束 Actor-Critic 方法适配到固定数据集的离线设置。从在线转向离线时, 主要变化是策略梯度需要偏差校正。Actor 不再使用当前策略收集的数据, 而是使用行为策略  $\pi_\beta$  收集的数据, 这可能造成数据分布不匹配。常见策略是通过重要性采样引入偏差校正比率。给定轨迹  $\tau = (s_1, a_1, s_2, a_2, \dots)$ , 策略  $\pi_{\theta_i}$  的策略梯度偏差校正比率为

$$w(s_t, a_t) = \prod_{t'=1}^t \frac{\pi_{\theta_i}(a_{t'} | s_{t'})}{\pi_\beta(a_{t'} | s_{t'})}.$$

该比率可给出无偏估计, 但方差可能很大。因此, 本文建议使用一阶近似, 并在优化辅助反馈 Actor 时使用当前动作选择比率:

$$\theta_i^{(k+1)} \leftarrow \arg \max_{\theta} \mathbb{E}_{\pi_\beta} \left[ \frac{\pi_{\theta_i}^{(k)}(a | s)}{\pi_\beta(a | s)} A_i^{(k)} \log(\pi_\theta(a | s)) \right]. \quad (8)$$

更新主反馈 Actor 时, 有

$$\theta_1^{(k+1)} \leftarrow \arg \max_{\theta} \mathbb{E}_{\pi_\beta} \left[ \frac{\prod_{i=2}^m (\pi_{\theta_i}(a | s))^{\lambda_i / \sum_{j=2}^m \lambda_j}}{\pi_\beta(a | s)} \exp \left( \frac{A_1^{(k)}}{\sum_{j=2}^m \lambda_j} \right) \log(\pi_\theta(a | s)) \right]. \quad (9)$$

**确定性策略。**下面讨论 TSCAC 向确定性策略的扩展。类似地, 在第一阶段, 对于每个辅助反馈  $i$ , 分别学习 Critic 模型  $Q_{\phi_i}(s, a)$  和 Actor 模型  $\pi_{\theta_i}(s)$ 。在第二阶段, 对于主反馈, 通过时序学习学习 Critic  $Q_{\phi_1}(s, a)$ ; 对于 Actor  $\pi_{\theta_1}(s)$ , 更新规则为

$$\max_{\theta} \prod_{i=2}^m (h(\pi_{\theta_i}(s), \pi_{\theta_1}(s)))^{\lambda_i} Q_{\phi_1}(s, \pi_\theta(s)). \quad (10)$$

其中, 当两个动作  $a_1, a_2$  接近时,  $h(a_1, a_2)$  得分较高, 反之较低。因此,  $h(\pi_{\theta_i}(s), \pi_{\theta_1}(s))$  在策略  $\pi_{\theta_1}$  与  $\pi_{\theta_i}$  选择动作接近时得分较高。 $\lambda_i \geq 0$  作用类似约束拉格朗日乘子, 较大的  $\lambda_i$  表示更强约束。例如, 给定  $n$  维动作空间, 可选择

$$h(a_1, a_2) = \sum_{d=1}^n \exp \left( -\frac{(a_{1d} - a_{2d})^2}{2} \right).$$

TSCAC 的确定性版本可用于连续动作设置, 例如用户偏好 embedding。

表 1: KuaiRand 数据集统计信息

| 维度      | 数量         | 稀疏比例   |
|---------|------------|--------|
| users   | 26,858     | —      |
| items   | 10,221,515 | —      |
| samples | 68,148,288 | —      |
| click   | 25,693,008 | 37.70% |
| like    | 1,094,434  | 1.61%  |
| comment | 163,977    | 0.24%  |
| hate    | 32,449     | 0.048% |

## 5 离线实验

本节在一个短视频推荐公开数据集上，通过大量离线学习仿真评估本文方法。实验表明，与现有基线相比，本文方法在实现主目标和平衡辅助目标方面均更有效。由于篇幅限制，原文还在附录 C 中给出另一个公开推荐数据集上的实验，以测试方法通用性。

### 5.1 实验设置

**数据集。**本文考虑名为 KuaiRand 的短视频推荐公开数据集。该数据集来自一个著名视频分享移动应用，并且适合强化学习方法的离线评估，因为它是无偏的。数据集不仅收集视频整体 WatchTime，还收集用户交互行为，包括 Click、Like、Comment 和 Hate。数据集统计如表 1 所示。可以看到，Like、Comment 和 Hate 是稀疏信号，其中 Hate 极其稀疏。同一用户的日志被拼接成一条轨迹；本文选择被观看次数最多的前 150 个视频。

**MDP。**

- 状态  $s_t$ ：一个 1044 维向量，由用户特征（用户属性）、用户最近观看的 20 个视频特征（用户历史）以及全部 150 个候选视频特征（上下文）拼接而成。
- 动作  $a_t$ ：当前将要推荐的视频 ID。
- 奖励  $r_t$ ：用户针对所观看视频给出的五个分数构成的向量，包括 Click、Like、Comment、Hate 和 WatchTime。
- episode：用户视频观看历史序列。
- 折扣因子  $\gamma$ ：0.99。
- 目标：将最大化视频 WatchTime 设为主目标，将其他反馈视为辅助目标。

**评估。**本文使用归一化截断重要性采样（NCIS）评估不同策略。NCIS 是推荐系统中强化学习方法常用的标准离线评估方式。NCIS 分数定义为

$$N(\pi) = \frac{\sum_{s,a \in D} w(s,a)r(s,a)}{\sum_{s,a \in D} w(s,a)}, \quad w(s,a) = \min \left\{ c, \frac{\pi(a|s)}{\pi_\beta(a|s)} \right\}, \quad (11)$$

其中  $D$  为数据集， $w(s,a)$  为截断后的重要性采样比率， $\pi_\beta$  表示行为策略， $c$  为正常数。

**基线方法。**本文将 TSCAC 与以下基线比较：BC、Wide&Deep、DeepFM、RCPO、RCPO-Multi-Critic、Pareto 和 TSCAC。BC 是监督式行为克隆策略，用于模仿数据集中的推荐策略。Wide&Deep 与 DeepFM 是监督推荐模型，输入用户状态并输出 item ID，样本权重设为该物品所有反馈的加权和。RCPO 是奖励受约束策略优化方法，将奖励定义为  $r = r_0 + \sum_i \lambda_i r_i$ ，其中  $r_0$  是主目标 WatchTime， $r_i$  是其他反馈， $\lambda_i$  是拉格朗日乘子。RCPO-Multi-Critic 分别学习多个 Critic 来评估每个反馈的累计奖励，并用拉格朗日乘子加权组合 Critic 来优化 Actor。Pareto 是用于推荐系统帕累托最优求解的多目标强化学习算法。

## 5.2 整体性能

表 2 展示不同算法在五个分数上的表现。可以看到, TSCAC 显著优于其他算法, 包括受约束强化学习方法和监督学习方法: 对于主目标 WatchTime, TSCAC 达到最高性能 13.14 (2.23%); 对于辅助目标, TSCAC 也在四个分数中的三个 (Click、Like、Comment) 上排名最高。TSCAC 在每个维度都优于 BC 和 RCPO。Pareto 算法确实学到一个帕累托最优解, 并在 Hate 指标上取得最佳表现, 但其 WatchTime 表现最低, 为 11.90 (−7.4%), 不满足以优化 WatchTime 为主目标的设置。RCPO 在 WatchTime 上取得第二高表现 13.07 (1.70%), 但在 Hate 上最差, 因为单一评估模型中稀疏信号被稠密信号主导。与 RCPO 相比, RCPO-Multi-Critic 在 Hate 上更好, 证明多 Critic 策略估计有效。TSCAC 又在每个维度上优于 RCPO-Multi-Critic, 说明两阶段 Actor 学习更能处理多个反馈。

表 2: 不同算法在 KuaiRand 上的性能

| 算法                | Click↑        | Like↑(e-2)    | Comment↑(e-3) | Hate↓(e-4)   | WatchTime↑   |
|-------------------|---------------|---------------|---------------|--------------|--------------|
| BC                | 0.5338        | 1.231         | 3.225         | 2.304        | 12.85        |
| Wide&Deep         | 0.5544        | 1.244         | 3.344         | 2.011        | 12.84        |
| 性能差距              | 3.86%         | 1.07%         | 3.69%         | −12.7%       | −0.08%       |
| DeepFM            | 0.5549*       | 1.388*        | 3.310         | 2.112        | 12.92        |
| 性能差距              | 3.95%*        | 12.76%*       | 2.64%         | −8.31%       | 0.53%        |
| RCPO              | 0.5510        | 1.386         | 3.628*        | 2.951        | 13.07*       |
| 性能差距              | 3.23%         | 12.57%        | 12.5%*        | 28.1%        | 1.70%*       |
| RCPO-Multi-Critic | 0.5519        | 1.367         | 3.413         | 2.108        | 13.00        |
| 性能差距              | 3.41%         | 11.04%        | 5.83%         | −8.49%       | 1.14%        |
| Pareto            | 0.5438        | 1.171         | 3.393         | 0.9915*      | 11.90        |
| 性能差距              | 1.87%         | −4.85%        | 5.22%         | −56.96%*     | −7.4%        |
| <b>TSCAC</b>      | <b>0.5570</b> | <b>1.462</b>  | <b>3.728</b>  | <b>1.870</b> | <b>13.14</b> |
| 性能差距              | <b>4.35%</b>  | <b>18.80%</b> | <b>15.6%</b>  | −18.83%      | <b>2.23%</b> |

表中括号表示列单位; 每个算法第一行是 NCIS 分数。第二行百分比表示相对 BC 的性能差距。带 \* 的数值表示所有基线方法中对应反馈维度的最佳表现。最后一行在 TSCAC 取得最佳表现时用粗体标记。

## 5.3 消融实验

本文研究拉格朗日乘子取值对性能的影响。由于第二阶段中所有约束的  $\lambda$  都设为相同值, 因此令  $\lambda$  在  $[1e-1, 1e-2, 1e-3, 1e-4, 1e-5]$  中变化, 并展示 TSCAC 在所有反馈上的表现。较大的  $\lambda$  表示辅助反馈约束更强。图 3 显示, 随着  $\lambda$  增大, 主目标 WatchTime 下降, 因为辅助反馈约束更强。图 3 也显示, 当  $\lambda$  很小 ( $1e-5$ ) 时, 交互行为性能下降, 因为约束较弱。有趣的是,  $\lambda$  较大时交互行为性能也会下降, 说明过强约束会影响策略学习。  $1e-4$  在交互指标上取得最佳表现, 并显著提升 WatchTime。

**图 3:** 拉格朗日乘子取值对性能的影响。图中分别展示 Click、Like、Comment、Hate 和 WatchTime 随  $\lambda$  变化的趋势。

## 6 在线实验

为证明算法有效性,本文在一个流行短视频平台上通过在线实验测试其性能,并与其他替代方法比较。各算法被嵌入生产环境中的候选排序系统:当用户到来时,算法对候选视频排序,系统向用户推荐排名最高的视频。实验表明,TSCAC 能学习到一种策略,在最大化主目标的同时有效平衡辅助目标。具体而言,主目标设为最大化 WatchTime,辅助目标设为提升用户与视频之间的交互。

### 6.1 实验设置

**评估指标。**本文使用在线指标评估策略性能。主目标为用户在视频上的总观看时间 WatchTime。辅助目标方面,用户可通过分享、下载、评论等方式与视频交互。本文关注三个在线交互指标:Share、Download、Comment 的总次数。

**MDP。**按照第 3 节形式化,短视频推荐 CMDP 细节如下。

- 状态  $s_t$ : 用户历史交互,即此前推荐物品列表及相应反馈;用户属性,如设备和位置;以及时刻  $t$  候选视频的 embedding 和统计特征。
- 动作  $a_t$ : 算法预测的用户在不同视频主题上的偏好向量 embedding。该向量通过排序函数决定实际推荐动作。
- 排序函数: 对每个候选视频,计算预测用户偏好向量  $a_t$  与视频 embedding 之间的点积,并推荐得分最高的视频。
- 奖励  $r_t = (l_t, i_t)$ : 每次推荐后,系统观察用户观看视频的时长 WatchTime,记为  $l_t$ ;以及用户是否与视频发生 Share/Download/Comment 交互,记为  $i_t$ 。
- episode: 轨迹从用户打开应用开始,在用户离开应用时结束。
- 策略: 在线实验中学习高斯策略。动作  $a_t$  从多元高斯分布采样,该分布的均值和方差由 Actor 模型输出。

**图 4:** 生产系统中强化学习 workflow。推理阶段: 用户状态输入 Actor 网络, Actor 采样动作, 排序模块结合动作与候选视频 embedding 输出推荐结果, 并将反馈写入回放缓存。训练阶段: 从回放缓存采样小批量数据, 分别更新 Critic 和 Actor。

**工作流。**强化学习运行如下: 推理时, 当用户到来, 用户状态被发送到 Actor 网络, Actor 根据高斯分布采样动作; 排序函数输入动作和候选视频 embedding, 计算点积作为分数, 并将分数最高物品输出给用户; 随后 (state, action, rewards, next state) 被保存到回放缓存。训练时, 从回放缓存采样小批量数据, 并用其训练 Actor 和 Critic 网络。

**比较算法。**在线实验补充使用监督 learning-to-rank (LTR) 基线, 即平台默认模型。RCPO 按 Tessler 等方法定义组合奖励  $l_t + \lambda i_t$ , 并学习策略最大化折扣因子 0.95 下的累计组合奖励。TSCAC 先学习策略  $\pi_2$  优化辅助目标, 再学习策略  $\pi_1$  优化主目标, 同时以软约束使  $\pi_1$  接近  $\pi_2$ 。Interaction-AC 是第一阶段策略, 最大化交互奖励, Critic 更新遵

循式 (2), Actor 更新遵循式 (3)。第二阶段 TSCAC 学习主策略  $\pi_1$ , 最大化 WatchTime 累计奖励, 并软正则化到  $\pi_2$  附近, Critic 更新遵循式 (4), Actor 更新遵循式 (7)。LTR 基线以用户状态 embedding 和视频 embedding 为输入, 并拟合反馈之和。

**实验细节。**为测试不同算法, 本文将平台用户随机划分为若干桶。第一个桶运行 LTR 基线, 其余桶运行 RCPO、Interaction-AC 和 TSCAC。模型训练若干天后固定, 并在一天内测试性能。

## 6.2 实验结果

表 3 展示不同算法相对于 LTR 基线在 WatchTime、Share、Download 和 Comment 指标上的性能提升。RCPO 相较基线能提升 WatchTime; 但交互信号相对于 WatchTime 过于稀疏, 将这些反馈合并后, RCPO 无法有效平衡交互。Interaction-AC 表现符合预期: 仅使用交互奖励信号时, 它能提升 Share、Download、Comment 等交互指标; 这些交互也会提升用户 WatchTime, 因为系统推荐了更有趣、且更可能引发交互的视频, 从而优化整体体验。

最终, TSCAC 取得最佳表现。与 RCPO 相比, 它的 WatchTime 更好, 并在交互指标上明显更优, 原因是训练过程中的软正则化有效约束主策略不要离 Interaction-AC 策略太远。需要注意, 在短视频平台上, WatchTime 提升 0.1%、交互指标提升 1% 都具有统计显著性。因此, 本文方法相对基线的提升是显著的。所有强化学习方法在 Comment 上均下降, 这是由于 WatchTime 与 Comment 之间存在天然权衡。

表 3: 在线实验中不同算法相对于 LTR 基线的性能比较

| 算法             | WatchTime | Share   | Download | Comment |
|----------------|-----------|---------|----------|---------|
| RCPO           | +0.309%   | -0.707% | +0.153%  | -1.313% |
| Interaction-AC | +0.117%   | +5.008% | +1.952%  | -0.101% |
| TSCAC          | +0.379%   | +3.376% | +1.733%  | -0.619% |

为理解 TSCAC 如何平衡主目标和辅助目标, 图 5 绘制第二阶段相对于 LTR 基线在 WatchTime 和交互指标上的在线性能差距。在 Interaction-AC 策略约束下, 算法开始时快速学习提升 Share 和 Comment 等交互指标。随后, 模型逐渐学习提升 WatchTime, 同时略微牺牲交互指标。TSCAC 在线表现在线上每个维度均显著优于 RCPO, 说明本文方法有效。

**图 5:** 每天 TSCAC 相对于 LTR 基线的在线性能差距。图中分别展示 WatchTime、Share、Download 和 Comment 的逐日变化。

## 7 结论

本文研究短视频平台中, 在多个辅助稀疏约束下优化主累计反馈的问题。为应对多个约束挑战, 本文提出一种新的受约束强化学习方法 TSCAC, 用于优化主目标并平衡其他

目标。该方法包含多 Critic 估计和两个学习阶段。第一阶段，对于每个辅助反馈，分别学习一个策略优化其累计奖励。第二阶段，学习主策略优化累计主反馈，同时加入软约束，使该策略接近为其他反馈最大化而学习到的策略。通过大量离线评估和在线实验，本文证明该方法相对于现有替代方案具有优势。未来，将该方法应用于其他推荐系统是有前景的方向；研究 TSCAC 确定性版本的性能也很有意义。

## 参考文献说明

原文参考文献列表主要用于文献检索与出处定位。译文中保留参考文献的英文题名与作者信息，不逐条改写为中文。核心引用包括强化学习推荐综述、Wide&Deep、DeepFM、RCPO、Pareto 多目标推荐、KuaiRand 数据集、LTR、DDPG、AWAC、REINFORCE 推荐系统、Top-k off-policy correction 等。

## A 定理 1 的证明

**定理 2.** 式 (5) 的拉格朗日函数具有闭式解：

$$\pi^*(a | s) \propto \prod_{i=2}^m (\pi_{\theta_i}(a | s))^{\lambda_i / \sum_{j=2}^m \lambda_j} \exp \left( \frac{A_1^{(k)}}{\sum_{j=2}^m \lambda_j} \right), \quad (12)$$

其中  $\lambda_i$ ,  $i = 2, \dots, m$ , 为拉格朗日乘子。

**证明.** 式 (5) 的拉格朗日函数为

$$\mathcal{L}(\pi, \lambda_2, \dots, \lambda_m) = -\mathbb{E}_{\pi}[A_1^{(k)}] + \sum_{i=2}^m \lambda_i (D_{KL}(\pi \| \pi_{\theta_i}) - \epsilon_i). \quad (13)$$

计算  $\mathcal{L}(\pi, \lambda_2, \dots, \lambda_m)$  关于  $\pi$  的梯度，可得

$$\frac{\partial \mathcal{L}}{\partial \pi} = -A_1^{(k)} + \sum_{i=2}^m \lambda_i (1 + \log(\pi(a | s)) - \log(\pi_{\theta_i}(a | s))). \quad (14)$$

令  $\partial \mathcal{L} / \partial \pi = 0$ ，可得  $\pi^*$  满足

$$\pi^*(a | s) = \frac{1}{Z(s)} \prod_{i=2}^m (\pi_{\theta_i}(a | s))^{\lambda_i / \sum_{j=2}^m \lambda_j} \exp \left( \frac{A_1^{(k)}}{\sum_{j=2}^m \lambda_j} \right), \quad (15)$$

其中  $Z(s)$  为配分函数，用于保证  $\int_a \pi^*(a | s) = 1$ 。证毕。

## B 两阶段受约束 Actor-Critic 算法

**算法 1:** 两阶段受约束 Actor-Critic (TSCAC)

**第一阶段：**对于每个辅助反馈  $i = 2, \dots, m$ ，学习一个策略优化反馈  $i$ ，其中  $\pi_{\theta_i}$  表示 Actor， $V_{\phi_i}$  表示 Critic。

当尚未收敛时，在第  $k$  次迭代中：

$$\begin{aligned}\phi_i^{(k+1)} &\leftarrow \arg \min_{\phi} \mathbb{E}_{\pi_{\theta_i}^{(k)}} \left[ \left( r_i(s, a) + \gamma V_{\phi_i}^{(k)}(s') - V_{\phi}(s) \right)^2 \right], \\ \theta_i^{(k+1)} &\leftarrow \arg \max_{\theta} \mathbb{E}_{\pi_{\theta_i}^{(k)}} \left[ A_i^{(k)} \log(\pi_{\theta}(a | s)) \right].\end{aligned}$$

**第二阶段：**对于主反馈，学习一个策略，使其既优化主反馈，又将策略区域限制在接近辅助反馈策略集合  $\{\pi_{\theta_i}\}_{i=2}^m$  的位置。其中  $\pi_{\theta_1}$  表示 Actor， $V_{\phi_1}$  表示 Critic。

当尚未收敛时，在第  $k$  次迭代中：

$$\begin{aligned}\phi_1^{(k+1)} &\leftarrow \arg \min_{\phi} \mathbb{E}_{\pi_{\theta_1}^{(k)}} \left[ \left( r_1(s, a) + \gamma V_{\phi_1}^{(k)}(s') - V_{\phi}(s) \right)^2 \right], \\ \theta_1^{(k+1)} &\leftarrow \arg \max_{\theta} \mathbb{E}_{\pi_{\theta_1}^{(k)}} \left[ \frac{\prod_{i=2}^m (\pi_{\theta_i}(a | s))^{\lambda_i / \sum_{j=2}^m \lambda_j}}{\pi_{\theta_1}^{(k)}(a | s)} \exp \left( \frac{A_1^{(k)}}{\sum_{j=2}^m \lambda_j} \right) \log \pi_{\theta}(a | s) \right].\end{aligned}$$

**输出：**受约束策略  $\pi_1$ 。

## C TripAdvisor 上的离线实验

原文代码参考 <https://github.com/AIDefender/TSCAC>。

本节在另一个公开数据集上通过大量离线学习仿真评估本文方法。实验表明，与现有基线相比，本文方法在实现主目标和平衡辅助目标方面均有效。

**数据集。**本文考虑名为 TripAdvisor 的酒店评论数据集。该数据集是研究具有多种反馈的推荐系统策略优化的标准数据集。顾客不仅为酒店给出总体评分，还会从服务、商务、清洁度、入住、价值、房间、位置等多个方面打分。同一用户提供的评论按时间顺序拼接成轨迹；过滤长度小于 20 的轨迹后，共有 20,277 名顾客、150 家酒店和 257,932 条评论。

**MDP。**一条轨迹记录一名顾客的酒店评论历史。每条评论中，状态  $s_t$  包括顾客 ID、最近三家被评论酒店 ID 及相应多方面评论分数；动作  $a_t$  为当前被评论酒店 ID；奖励  $r_t$  为顾客给出的八个分数向量，包括服务、商务、清洁度、入住、价值、房间、位置和总体评分；折扣因子  $\gamma = 0.99$ 。本文将最大化累计总体评分设为主目标，将其他评分视为辅助目标。

**性能。**表 4 展示不同算法在八个分数上的结果。TSCAC 在所有算法中表现最好：对于主目标，TSCAC 达到最高总体评分 3.99；对于辅助目标，TSCAC 也在 7 个分数中的 5 个（服务、清洁度、价值、房间、位置）上排名最高。Pareto 算法在入住分数和商务分数上取得最佳表现，但不满足以优化总体评分为主目标的设置。RCPO-Multi-Critic 在 6 个分数上优于 RCPO，验证了多 Critic 估计相较于联合 Critic 估计的作用。RCPO-Multi-Critic 与本文方法取得相同最佳总体评分，但明显牺牲其他分数，尤其位置分数低于 BC。

表 4: 不同算法在 TripAdvisor 上的性能

| 算法                | Service     | Business     | Cleanliness | Check-in     | Value       | Rooms       | Location    | Overall     |
|-------------------|-------------|--------------|-------------|--------------|-------------|-------------|-------------|-------------|
| BC                | 3.38        | -1.86        | 3.57        | -0.73        | 3.32        | 2.92        | 2.93*       | 3.92        |
| Wide&Deep         | 3.41*       | -1.86        | 3.62*       | -0.75        | 3.36*       | 2.96        | 2.88        | 3.98        |
| RCPO              | 3.40        | -1.82        | 3.61        | -0.71        | 3.34        | 2.95        | 2.91        | 3.97        |
| RCPO-Multi-Critic | 3.41*       | -1.82        | 3.62*       | -0.68        | 3.35        | 2.97*       | 2.87        | 3.99*       |
| Pareto            | 3.36        | -1.79*       | 3.57        | -0.62*       | 3.29        | 2.93        | 2.86        | 3.95        |
| <b>TSCAC</b>      | <b>3.43</b> | <b>-1.82</b> | <b>3.64</b> | <b>-0.68</b> | <b>3.37</b> | <b>3.00</b> | <b>2.98</b> | <b>3.99</b> |

带 \* 的结果表示所有基线方法中对应反馈维度上的最佳表现；当 TSCAC 在该维度取得最佳表现时，最后一行用粗体标记。

## D 其他指标下的离线评估

本文还使用折扣累计增益 (DCG) 指标评估 TSCAC 与基线方法，结果如表 5 所示。

表 5: 不同算法在 DCG 指标下的性能

| 算法                | Click↑(e+2)  | Like↑        | Comment↑     | Hate↓(e-2)   | WatchTime↑(e+3) |
|-------------------|--------------|--------------|--------------|--------------|-----------------|
| BC                | 4.617        | 8.492        | 2.320        | 8.137        | 1.079           |
| Wide&Deep         | 4.576        | 8.158        | 2.274        | 7.503        | 1.073           |
| 性能差距              | -0.88%       | -3.93%       | -1.97%       | -7.79%*      | -0.56%          |
| DeepFM            | 4.594        | 8.439        | 2.274        | 8.334        | 1.083           |
| 性能差距              | -0.50%       | -0.63%       | -1.97%       | 2.43%        | 0.41%*          |
| RCPO              | 4.603        | 8.537        | 2.282        | 8.336        | 1.080           |
| 性能差距              | -0.30%       | 0.53%*       | -1.60%       | 2.45%        | 0.12%           |
| RCPO-Multi-Critic | 4.569        | 8.168        | 2.272        | 7.538        | 1.069           |
| 性能差距              | -1.03%       | -3.81%       | -2.09%       | -7.36%       | -0.88%          |
| Pareto            | 4.605        | 8.494        | 2.304        | 8.449        | 1.074           |
| 性能差距              | -0.26%*      | 0.02%        | -0.69%*      | 3.83%        | -0.48%          |
| <b>TSCAC</b>      | <b>4.617</b> | <b>8.652</b> | <b>2.378</b> | <b>8.036</b> | <b>1.083</b>    |
| 性能差距              | <b>0.01%</b> | <b>1.88%</b> | <b>2.49%</b> | -1.24%       | <b>0.39%</b>    |

其中，↑ 表示越高越好，↓ 表示越低越好。括号中数值表示列单位；每个算法第一行是 DCG 分数。第二行百分比表示相对 BC 的性能差距。带 \* 的数值表示所有基线方法中对应反馈维度最佳表现；最后一行在 TSCAC 取得最佳表现时用粗体标记。