

用户响应模型用于改进推荐系统

论文逐段中文翻译稿

说明

本文按照原论文结构逐段翻译。公式、变量符号、图表编号和参考文献编号尽量保留原文形式；图像本身未重新绘制，相关图表以中文说明形式保留，方便后续继续排版。

摘要

强化学习（ RL ）技术一直被视为进一步推动推荐研究领域发展的下一代工具。不同于的经典应用，推荐智能体，尤其是部署在商业推荐平台上的推荐智能体，必须在极大的状态空间和动作空间中运行：它们服务的动态用户群体规模可达数十亿，面对的长尾物品库也可能达到百万级甚至十亿级。回顾历史数据时，可用于训练这类智能体的正向用户反馈极其稀缺。因此，在为推荐系统开发智能体时，提高算法的样本效率至关重要。

在本文中，我们提出一个通用框架，通过引入辅助任务来增强无模型智能体的训练，从而提高样本效率。更具体地说，我们选择加入额外任务，用于预测用户对推荐结果的即时响应（正向或负向），即用户响应建模；这种方式可以增强推荐智能体对状态表示和动作表示的学习。我们还引入一种基于梯度相关性分析的工具，用于指导模型设计。我们在离线实验中展示了该方法的有效性：在数亿条用户轨迹上学习并评估智能体策略。此外，我们还在一个服务数十亿用户、包含数千万物品的工业级推荐平台上开展线上实验，以验证该方法的收益。

关键词：推荐系统；辅助任务；用户响应模型；强化学习。

引言

许多商业推荐平台高度依赖推荐系统来服务其用户群体。支撑这些系统的推荐算法多年来发生了巨大变化：从早期简单的基于协同过滤的方法，发展到基于用户反馈的监督学习方法；近年来，强化学习技术也在推荐研究领域获得了大量关注。关注构建能够在环境中采取动作、并最大化某种长期奖励定义的智能体。在推荐设定下，这等价于构建能够与用户交互的智能体，从而优化用户在推荐平台上的长期体验。

与监督学习方法相比，（或老虎机， MAB ）形式化天然适合真实推荐系统中的部分反馈设定。监督学习方法通常把推荐物品上观察到的即时用户反馈（例如点击、停留时长、点赞和分享）视作真实标签；而在真实推荐系统中，我们只能观察被推荐物品上的反馈，无法观察未被推荐物品上的反馈，尽管后者可能对用户更有价值。的序列规划视角还为推荐系统提供了机会，使其不再只优化即时用户反馈，而是进一步面向用户对平台的长期满意度。

尽管这些特性很有吸引力，但在工业级推荐系统中真正实现仍然很困难。与经典应用不同，推荐系统，尤其是工业推荐系统，需要服务兴趣动态变化的超大规模用户群体，并处理巨大的物品库。换言之，它必须扩展到百万级甚至十亿级的状态空间和动作空间。在如此巨

大的状态动作空间中，用户反馈本身又极度稀疏，这进一步加剧了问题。每个用户只接触过整个物品库中很小的一部分，而其中真正获得正向用户反馈的比例更小。

计算能力的提升使经典应用中的算法，例如机器人和游戏，可以依赖仿真或自博弈生成大量学习轨迹，从而应对样本效率低的问题。然而，推荐应用中的面临不同挑战：构造真实可信的模拟用户交互轨迹非常困难。因此，在推荐平台上收集到的真实交互与反馈数据，实际上是我们可依赖的唯一学习数据来源。

因此，在为推荐平台构建智能体时，改进算法以充分利用可用用户反馈非常关键。文献中已经提出多种方法来解决样本效率不足的问题，大致可分为两类：第一类是基于智能体的感知数据引入辅助任务，直接增强并加速无模型智能体的学习；第二类是学习动力学模型（世界模型）和奖励函数，并将它们用于基于模型的智能体规划，或者用于生成额外轨迹来训练无模型智能体。本文方法更接近第一类。不同于现有工作主要面向图像、视频等感知数据相关的应用，本文关注推荐设定下辅助任务的设计。

本文的贡献包括：提出一个通过辅助任务提升无模型推荐算法样本效率的通用框架；引入预测用户对推荐结果响应的辅助任务，即用户响应建模，以改进状态和动作表示；分享用户响应模型设计中的实践经验，包括结构选择、训练设置、定向处理和计算开销；提出基于策略学习与辅助任务梯度相关性的分析工具，用于指导模型设计；并通过大规模离线实验和商业平台线上实验验证方法有效性。

相关工作

推荐系统中的强化学习。经典强化学习方法大致可分为基于模型的方法和无模型的方法；无模型方法又可进一步分为基于价值的方法，例如，以及基于策略的方法，例如。现代方法将这些技术与高容量函数近似器，即深度神经网络，以及更强计算能力结合起来，并在多个领域取得了巨大成功。深度的潜力激发了将其用于推荐系统的大量兴趣。

等最早提出了推荐系统的马尔可夫决策过程（ MDP ）形式化，并提出一种基于模型的方法。等探索了在新闻推荐中的应用。等关注大动作空间问题，通过在连续物品嵌入空间中建模状态，并用最近邻搜索选择物品。等研究了用于推荐的方法。一些近期工作进一步将深度扩展到集合推荐问题。尽管研究进展令人兴奋，但在真实推荐应用中的成功仍然较少。等通过在历史用户交互数据上学习，并采用离策略校正处理批量学习效应，成功将智能体扩展到极大动作空间。等将排序学习表述为，并通过确定性策略梯度学习排序策略，且在商业平台上进行了测试。

辅助学习。众所周知，神经网络需要大量训练数据才能达到最优性能。由于离策略训练的存在，这一问题在深度中更加突出。提升神经网络样本效率的一种方法，是利用辅助任务帮助构造有用表示。在训练时，除了主任务之外，还同时优化一个或多个辅助目标。需要注意的是，真正关心的只有主任务，辅助任务的目的只是为主任务学习更好的表示；这不同于多任务学习。

辅助学习已在许多领域得到广泛研究，包括序列建模、强化学习、计算机视觉、语音识别和元学习。理想情况下，辅助任务应与主任务保持良好一致性，从而帮助主任务。然而，设计这样的任务并不简单。等提出使用不同任务梯度之间的余弦相似度作为自适应权重，用来判断某个辅助损失何时对主任务有帮助。本文在开发框架和做出不同设计选择时采用了这种分析思路。

持续学习。另一条启发本文辅助任务设计的研究线索来自持续学习文献。在持续学习中，智能体需要在不发生灾难性遗忘的情况下，将从较容易任务中学到的知识迁移到更困难的任务。虽然的长期规划视角对于寻找优化用户长期体验的策略很有吸引力，但它也给智能体

策略学习引入了大量不确定性。本文将“从预测用户即时响应过渡到长期规划”的过程视为持续学习的一个实例。

一个推荐系统

本文工作建立在等提出的推荐系统之上。推荐问题被转化为一个马尔可夫决策过程 $(\mathcal{S}, \mathcal{A}, P, R, \rho_0, \gamma)$ 。其中， $\mathcal{S}$ 是描述用户状态与上下文的连续潜在状态空间； $\mathcal{A}$ 是包含可推荐物品的离散动作空间； $P: \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow \mathbb{R}$ 是状态转移概率； $R: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 是奖励函数，其中 $r(s, a)$ 表示在状态 s 下执行动作 a 获得的即时奖励； ρ_0 是初始状态分布； γ 是未来奖励的折扣因子。推荐智能体通过参数化并学习如下策略来构建：

$$\pi_{\theta}(a|s) = \frac{(\tau_s a / T)}{\sum_{a' \in \mathcal{A}} (\tau_s a' / T)}.$$

该策略定义了给定用户状态 $s \in \mathcal{S}$ 时，物品库 $\mathcal{A}$ 上的概率分布。其中， τ_s 表示学习得到的用户状态潜在表示， a 表示物品表示， $T > 0$ 是用于调节学习策略熵的温度参数。

策略参数 θ 使用学习，以最大化交互轨迹上的期望累积奖励：

$$\mathbb{E}_{\tau \sim \pi_{\theta}}[R(\tau)], R(\tau) = \sum_{t=0}^{|\tau|} r(s_t, a_t).$$

这里，期望是在按照最新学习策略行动所得到的轨迹 $\tau = (s_0, a_0, s_1, \dots)$ 上计算的： $s_0 \sim \rho_0$ ， $a_t \sim \pi_{\theta}(\cdot|s_t)$ ，且 $s_{t+1} \sim P(\cdot|s_t, a_t)$ 。

批量强化学习。如上所述，强化学习最初被设计为一种在线学习范式。智能体策略的学习过程在两个步骤之间迭代：根据最新学习策略与环境交互并收集经验；再利用收集到的经验改进策略。不幸的是，在许多真实应用中，与环境实时交互并不可行。例如在推荐系统中，我们通常部署一个具有固定策略的已学习智能体，让它与用户交互数小时或数天并收集经验。随后，系统使用这些轨迹执行多次更新，然后再部署新版本策略。

因此，收集到的轨迹分布可能与当前策略本应生成的轨迹分布相差很大。在线的交互本质阻碍了其更广泛采用，因此研究者投入了大量精力将这些技术离线化，这通常被称为批量强化学习或离策略强化学习。

离策略下的样本效率不足。处理分布偏移，或者用术语来说处理离策略训练，一个长期使用的技术是引入重要性采样校正。朴素地说，式 () 中定义的期望累积奖励可以用来自另一分布 β 的轨迹来近似；该分布通常称为行为策略：

$$\mathbb{E}_{\tau \sim \beta} \left[\frac{\pi_{\theta}(\tau)}{\beta(\tau)} R(\tau) \right].$$

然而，该估计量的方差会随轨迹长度 $|\tau|$ 指数增长。等通过对 $\pi_{\theta}(\tau)/\beta(\tau)$ 进行一阶近似来降低方差，最终得到如下加权交叉熵损失：

$$\ell_{RL}(\theta) = - \sum_{s_t \sim d_t^{\beta}(s), a_t \sim \beta(\cdot|s_t)} \left[\frac{\pi_{\theta}(a_t|s_t)}{\beta(a_t|s_t)} R_t \pi_{\theta}(a_t|s_t) \right].$$

严格来说，状态只是部分可观测的，因此问题是部分可观测 ()。为简化表述，本文仍沿用记号。

这里， $\beta(\cdot|s)$ 表示收集轨迹中状态 s 条件下的动作分布； $d_t^\beta(s)$ 是行为策略下的折扣状态访问概率； $R_t = \sum_{t'=t}^{\tau} \gamma^{t'-t} r(s_{t'}, a_{t'})$ 是从时间 t 开始的折扣累积奖励。该重要性权重还会进一步适配集合推荐设定，更多细节可参考文献。

即便经过上述简化，当学习策略 π_θ 偏离行为策略 β 时，式（）的损失仍可能遭受高方差问题。已有工作大多通过约束学习策略接近行为策略来降低方差。然而，这种约束也限制了找到能够最大化长期奖励的最优策略的能力。

方法

本文转而关注通过辅助目标增强智能体策略训练，从而提升基础推荐智能体的样本效率。我们首先给出整体框架，说明如何以最小改动将辅助损失引入训练；随后说明在提出（）时所做的若干设计选择。

用于提升样本效率的辅助任务

图展示了整体框架。实线框表示推荐智能体的主要组成部分。用户表示模块负责学习用户状态与上下文的潜在表示，通常基于用户在推荐平台上的历史活动观测来完成。动作表示模块学习可推荐物品的嵌入。给定状态表示和动作表示之后，智能体基于用户轨迹中收集的状态动作奖励三元组 (s_t, a_t, R_t) ，按照式（）学习策略 $\pi_\theta(\cdot|s)$ 。

如上所述，在推荐系统中应用的最大挑战在于极大的状态空间和动作空间，以及用户反馈相对于庞大状态动作空间的极端稀疏性。离策略训练进一步加剧了这一问题，因为随着学习策略偏离用于收集轨迹的行为策略，重要性权重中的大方差会降低学习的有效样本量。

图：通过引入辅助损失来提升无模型样本效率的框架。实线部分为基础推荐智能体，虚线部分为辅助训练目标。

为应对用户反馈稀疏性与离策略的样本效率问题，我们提出加入图中虚线框表示的辅助训练目标，以补充策略参数学习，尤其是补充用户状态表示和动作表示的学习。利用辅助任务提升表示学习已在文献中被广泛探索。不同于大多数既有工作将辅助任务用于改善从图像像素等智能体感知数据中学习到的状态表示，本文允许与主目标联合训练的辅助目标同时影响状态表示和动作表示。

用户响应建模

我们需要决定的最关键设计是辅助目标本身。无监督任务，例如基于重构的辅助损失和对比学习损失，已在游戏、机器人等应用中被广泛采用。在这些应用中，环境状态和状态转移通常由高维图像或视频捕捉。然而，在推荐问题中，为这些无监督学习任务找到直接对应物并不简单。

对于推荐智能体而言，它交互的环境是用户。智能体并不能观察到完整用户状态，因为完整状态可能依赖大量外生因素；相反，它必须从观测中推断用户状态，例如从用户在平台上的历史活动中推断。因此，在没有完全可观测状态的情况下，设计基于重构的损失并不直观。

本文转而采用监督学习任务，确保智能体的状态表示和动作表示能够预测用户在接触到某个推荐结果时的响应。我们将辅助任务的标签限制为即时用户响应，原因有二。第一，这是为了绕开离策略训练的挑战。期望长期奖励 $\mathbb{E}_{\tau \sim \pi}[R(\tau)]$ 依赖于部署策略；而即时用户响应 $\tilde{r}(s, a)$ 不依赖部署策略，只依赖当前状态和动作。第二，这是为了为智能体引入相对更容易的任务，使其逐步走向长期目标。长期规划更加困难，因为智能体不仅需要推理其动作的即时结果，还需要推理动作的长期影响，而后者在学习初期可能非常嘈杂。

因此，我们首先确保智能体的状态表示和动作表示能够预测用户的即时响应，即动作的即时结果，从而帮助智能体更好地规划未来。需要注意的是， $\tilde{r}(s, a)$ 可以与式（）下定义的主头训练所使用的即时奖励 $r(s, a)$ 相同，也可以不同。该任务可以学习预测不同参与度信号，例如点击、停留时长，也可以预测后续参与信号，例如点赞、点踩、分享或问卷反馈。我们将这种用用户响应建模增强无模型训练的方法命名为，简称。

结构概览

图给出了的一个实例。实线框表示智能体的主要组成部分。模型通过循环神经网络（）遍历用户在平台上的历史活动观测，从而捕捉用户状态与状态转移。的输出与标签上下文拼接；标签上下文捕捉做出推荐时的上下文信息，例如时间、设备、页面信息等。二者共同形成用户状态表示。

随后，潜在状态表示会通过多层单元和一个线性投影层，被投影到与动作嵌入 a 相同的维度。状态表示与动作表示的内积 $s_a^\top$ 构成式（）中策略的。

图：用于增强智能体训练的用户响应模型。主头与辅助用户响应建模头共享历史事件嵌入、参数以及动作嵌入。

虚线框对应辅助任务的组成部分。辅助目标将用户状态和上下文嵌入拼接起来，送入线性投影层，再次投影到与动作嵌入相同的维度。辅助目标确保投影后的状态 s' 与动作嵌入 a 一起能够预测用户对该推荐结果的响应：

$$\ell_{AUX}(\theta) = \sum_{s_t \sim d_t^\beta(s), a_t \sim \beta(\cdot | s_t)} \ell \left(s_t^\top a_t, \tilde{r}(s_t, a_t) \right).$$

对于不同响应信号，需要适当选择损失函数 ℓ 。这里说明两种针对不同响应信号的损失实例。令 $h(s, a) = s_a^\top$ ，并令 $p(s, a) = (h(s, a))$ 。当响应信号是点击等二元信号时，即用户点击推荐结果则 $\tilde{r}(s, a) = 1$ ，否则为0，我们使用二元交叉熵损失：

$$\ell_{AUX}(\theta) = \tilde{r}(s_t, a_t) p(s_t, a_t) + (1 - \tilde{r}(s_t, a_t)) (1 - p(s_t, a_t)).$$

当响应信号是可能取较大值的实数，例如停留时长时，我们使用损失以避免对异常值过拟合：

$$\ell_{AUX}(\theta) = L(h(s_t, a_t) - \tilde{r}(s_t, a_t)).$$

在这种情况下，辅助损失只在具有正向响应 $\tilde{r}(s, a)$ 的状态动作对上学习。

辅助头与主头共享大部分参数。如图所示，历史事件的所有嵌入、参数以及动作嵌入都在目标和辅助目标之间共享。辅助目标也有自己的参数；在该具体实例中就是线性投影层，以确保它能够适当地变换来自的隐藏状态、上下文特征和动作嵌入，从而优化一个不同于主头的目标。

辅助任务使用比主更简单的变换（单个线性层，而不是多层加线性投影）的原因有两个。第一，预测即时响应比像目标那样优化长期奖励更容易。第二，通过限制辅助任务特有的额外参数，我们允许辅助目标对共享参数产生更大影响。这样最终可以为智能体学习到更好的状态表示和动作表示，而这正是最终目标。共享参数以及任务特定参数会被联合训练，以最小化损失与辅助损失的组合：

$$\ell_{RL}(\theta) + \lambda \ell_{AUX}(\theta).$$

其中, θ 表示共享参数和任务特定参数, λ 是用于控制辅助任务影响强度的标量。

训练设置

图展示了我们如何切分用户轨迹, 以训练主头和辅助任务。对每个用户, 我们可以访问一段历史交互序列:

$$\tau = \{(s_t, A_t, a_t, r_t, \tilde{r}_t) : t = 0, \dots, T\}.$$

这里, A_t 表示在时间 t 推荐给用户的所有物品, $a_t \in A_t \cup \{\}$ 表示用户实际交互的物品, r_t 是训练使用的即时奖励, $\tilde{r}_t$ 是辅助任务训练使用的用户响应。需要注意, $a_t = \emptyset$ 表示用户没有与 A_t 中任何物品交互, 此时 $r_t = \tilde{r}_t = 0$ 。

我们遵循文献的惯例, 将 A_t 中没有导致直接用户交互的所有物品的即时奖励和长期奖励都设为0。 $R_t(s_t, a) = 0, \forall a \in A_t \setminus \{a_t\}$ 事实上会将这些状态动作对上的梯度置零。因此, $A_t \setminus \{a_t\}$ 中的物品会被排除在式 () 定义的目标之外。

另一方面, 式 () 中定义的辅助损失可以在所有推荐物品上训练, 即 $(s_t, a, \tilde{r}_t), \forall a \in A_t$, 例如在预测点击的场景中。对于停留时长预测, 我们选择只在 (s_t, a_t) 上学习辅助损失, 即与目标使用相同的交互。读者可能会疑惑, 这种情况下辅助损失是否仍然有帮助。我们的观点是, 只要 $\tilde{r}(s, a)$ 与即时奖励 $r(s, a)$ 对齐, 它就可以作为一个更容易的任务, 帮助智能体策略学习启动并最终优化长期奖励。

图: 主头与辅助损失的训练窗口。主头使用最近小时训练窗口, 并在轨迹末尾保留小时缓冲窗口用于计算累积折扣奖励; 辅助损失可使用轨迹上的更多交互。

推荐问题的一个独特之处在于, 用户偏好会随时间变化, 物品库也会随时间变化。为了让智能体及时适应最新的用户动态与物品库, 我们将主头 (式) 的训练窗口限制为轨迹中最近小时内的 (s_t, a_t, R_t) 三元组; 轨迹末端还保留小时缓冲窗口, 用于计算累积折扣奖励 R_t 。相比之下, 辅助损失 (式) 可以在轨迹中任意物品 $(s_t, a, \tilde{r}(s_t, a_t)), a \in A_t$ 上训练。

低活跃用户

虽然我们尽量为不同用户保持相同长度的轨迹, 但对某些用户来说, 整条轨迹可能跨越数月; 而对另一些用户, 轨迹可能不到一天。因此, 在主头的小时训练窗口内, 不同用户可用于训练智能体策略的 (s_t, a_t, R_t) 三元组数量差异很大。

图展示了不同用户在训练步骤 (轴) 上的训练标签数量直方图。虽然部分用户在数小时内可以产生数百个正向交互, 但超过的用户能贡献给头损失的标签少于个。因此, 智能体策略更容易适配高活跃用户, 而不是低活跃用户。

图: 主头中每个用户的训练标签数量。该图显示低活跃用户能够贡献的正向交互非常有限。

为进行补偿, 我们选择只对低活跃用户激活辅助目标。为了确定用户活跃度, 我们回看用户过去两周的活动; 如果某用户每天都访问推荐平台, 则停用该用户上的辅助目标。

计算复杂度

设计辅助任务时, 我们还会考虑计算这些辅助损失的计算成本。式 () 定义的主损失在大动作空间应用中计算成本极高, 因为策略 (式) 需要在整个动作空间上计算配分函数。我们遵循文献, 使用近似该配分函数。

由于动作空间巨大, 我们确实发现采样数量会显著影响近似精度以及学习策略质量。最终, 我们为每个正向动作 a_t 使用个负样本 a' 来近似配分函数。相比之下, 式 () 和式 () 定义的辅助损失不依赖动作空间大小。因此, 与主头相比, 它们只需要很小一部分计算量。

分析

本节提供一种基于梯度信息的分析工具，用于指导实验中各种建模选择的设计。

任务之间的梯度相似度

辅助学习中的一个核心问题是如何设计辅助任务。理想的辅助任务应当与主任务相关，但又不能过度对齐以至于变得冗余。实践者通常依赖领域知识来设计这类辅助任务。然而，并不能保证它们不会伤害主任务。

一种更有原则的任务相似度度量方式，是计算任务梯度之间的余弦相似度。给定两个任务及其对应损失 $\ell_1, \ell_2 \in \mathbb{R}$ ，以及对两个损失都有贡献的一部分模型参数 $\eta \in \mathbb{R}^d$ ， ℓ_1 与 ℓ_2 的“对齐程度”可以通过它们关于 η 的梯度余弦相似度来衡量：

$$(\ell_1, \ell_2, \eta) := \frac{(d\ell_1/d\eta)^\top (d\ell_2/d\eta)}{\|d\ell_1/d\eta\|_2 \cdot \|d\ell_2/d\eta\|_2}.$$

直观地说，如果两个任务是对齐的，那么它们的梯度应当相互强化，并在几何上形成锐角；换句话说，它们的余弦相似度应为正。在极端情况下，如果两个任务完全对齐，余弦相似度为1，则其中一个任务是冗余的。因此，理想的余弦相似度应位于区间(0, 1)内。该相似度度量可以用来指导辅助任务设计。换言之，我们希望找到与主任务具有正向梯度相似度的辅助损失。

与替代结构的比较

除第节给出的模型结构外，我们还考虑了几种替代结构，并应用梯度相似度分析进行比较。考虑的设计选项如下：，即图所示的原始模型结构；带独立层的，即在用户状态和上下文与头的线性投影层之间添加多层，以增加辅助任务特有参数；带拼接结构的，即不再使用潜在状态表示和动作嵌入之间的内积形成预测，而是将二者拼接并送入两层网络得到标量预测。

对于三种结构，我们都使用停留时长作为目标响应信号 $\tilde{r}(s, a)$ ，并采用式（）中的损失。

表不同结构下按折扣累积奖励加权的平均准确率。

	带独立层的	带拼接结构的

图展示了 ℓ_{RL} 与 ℓ_{AUX} 关于式（）和式（）中的物品表示 a 的余弦相似度 $(\ell_{RL}, \ell_{AUX}, a)$ 。换句话说，它衡量了辅助损失与主损失在学习物品表示时的对齐程度，因此可以用于指导结构设计。所有结构训练步。由于实验从冷启动开始，训练早期的梯度相似度噪声较大，因此图中忽略了前个训练步骤。

图：主损失 ℓ_{RL} 与辅助损失 ℓ_{AUX} 关于权重 a 的梯度相似度。

如图所示，以及带独立层的的梯度相似度为正，说明主损失 ℓ_{RL} 与辅助损失 ℓ_{AUX} 对齐良好。对于带拼接结构的，梯度相似度一开始为正，但随后逐渐衰减到零，说明辅助损失在训练后期不再与主头对齐。此外，图表明具有最佳对齐性。表进一步支持了这一点：使用按折扣累积奖励加权的作为离线指标时，在三种结构中，的最终最高，这与梯度相似度分析一致。

离线与线上实验

为了衡量本文方法的有效性，我们在一个大规模数据集上进行离线测试。该数据集包含数亿用户、数千万物品，以及二者之间数十亿级的交互和反馈。我们还在一个服务数十亿用户的商业推荐平台线上实验中验证该方法。

离线实验

数据集。我们从一个商业推荐平台中抽取数亿条用户轨迹。每条轨迹都包含直到训练时间点为止的一系列用户交互： $\tau = \{(s_t, A_t, a_t, r_t, \tilde{r}_t) : t = 0, \dots, T\}$ ，如第节所述。不同用户的轨迹长度可能不同。对每个用户，我们最多保留个至少包含一次正向用户交互（非零 r_t ）的历史页面。在收集到的轨迹中，我们保留作为评估集。我们将动作空间限制为平台上最流行的万件物品。目标是构建一个推荐智能体，使其能够从这万物品库中为用户选择下一个要消费的物品，从而最大化累积长期奖励。

设置。我们比较基础智能体，以及在三种辅助损失设置下训练的智能体：第一，单个辅助损失，用于预测用户是否会点击推荐物品（）；第二，单个辅助损失，用于预测用户会与推荐物品交互多长时间（）；第三，将上述两个任务结合的辅助损失（）。

推荐系统运行在部分反馈设定下，也就是说，我们只能观察由部署策略推荐过的物品上的反馈，而不能观察其他物品的反馈。因此，在评估新策略部署后的性能时，必须考虑离策略效应。给定策略的离线评估本身就是一个具有挑战性的问题。已有工作大多利用逆倾向分数，并配合截断或归一化等方差控制技术，以降低离策略估计中的方差。即便如此，离策略评估往往仍会得到较嘈杂的估计。

因此，我们在离线实验中转而关注在“监督学习”设定下将本文方法与基线方法比较，同时依赖线上实验进行进一步验证。在这里，我们将用户实际交互的物品视为真实标签，忽略部分反馈影响。在学习策略时，我们也不应用离策略校正。因此，任务变为预测用户下一次将与哪个物品交互，并且每个样本都按长期奖励加权。该设定避免了逆倾向加权造成的策略学习和评估高方差。虽然这些实验在预测线上实验结果方面不够准确，但方差降低使我们能够更清楚地理解：引入辅助任务是否能帮助智能体学习更好的状态表示和动作表示，从而更准确地预测用户下一步会交互的物品。

指标。主要离线指标是按折扣累积奖励 R_t 加权的平均准确率。换句话说，我们关注用户下一步选择交互的物品是否出现在智能体返回的 K 结果中。对于保留集小时窗口内的每次交互，我们计算，并用该交互带来的折扣累积奖励进行加权。

结果。我们开展了一系列离线实验，以衡量本文方法对不同超参数的敏感性，以及引入不同辅助任务的效果。我们使用预测用户停留时长的辅助任务来研究超参数敏感性。

图研究了用于权衡主任务和辅助任务重要性的超参数 λ 的影响。在这些实验中，我们将辅助损失训练窗口固定为与主损失相同。如图所示，加入辅助任务确实相比基础智能体提高了准确率。然而，当权重 λ 从增加到时，可以观察到性能下降，这表明如果过度关注短视目标，会干扰智能体策略学习累积长期奖励的能力。

图：式（）中用于权衡主头与辅助任务重要性的超参数 λ 的影响。

图研究了在预测用户停留时长这一辅助任务中使用不同训练窗口长度的影响。虽然将辅助任务训练窗口保持为与主头一致（小时）已经能够提升加权，但当训练窗口被延长到天和天时，我们观察到更好的性能。

图：不同训练窗口长度对辅助任务的影响。

结论

图总结了基础智能体与使用不同辅助任务训练的智能体之间的比较。为简化比较，我们将三种设置下的超参数 λ 都设为。如图所示，引入辅助任务相比基线能够获得更高的加权。预测点击的辅助任务略优于预测停留时长的辅助任务，而二者结合最终获得最高性能。第节提出的梯度相似度分析工具也表明，点击预测辅助任务与主任务之间的梯度相似度高于停留时长预测任务。

图：基础智能体与使用不同辅助任务的比较。该组实验保存了更多训练检查点，因此曲线相对图和图更噪声。

线上实验

我们在一个服务数十亿用户的线上系统中进行了一系列实验，以衡量本文方法的收益。该智能体被构建为：在每次用户请求时，从万物品的语料库中召回数百个候选物品。这些召回候选以及其他来源返回的候选，会由一个独立排序系统打分并排序，然后将顶部结果展示给用户。

智能体按照式()进行训练，并根据文献的建议，将离策略校正适配到集合推荐设定中。长期奖励 R_t 捕捉用户反馈 $r(s, a)$ 在轨迹上的折扣累积和。对照组运行仅使用目标训练的智能体；实验组运行带有额外辅助任务的智能体，该辅助任务用于预测用户在推荐物品上的停留时长 $\tilde{r}(s, a)$ 。实验持续一个月，在此期间，对照组和实验组模型都会持续训练，并将新的交互和反馈用作训练数据。讨论重点放在一个捕捉用户整体满意度的指标上。

图总结了线上实验结果。可以看到，本文方法在全局用户群体上优于基线方法，带来的提升，置信区间为 $[+0.07, +0.18]$ 。进一步考察不同用户切片时，可以看到低活跃用户切片上的提升显著更高()，高活跃用户切片上的提升为。这些结果与本文设计动机一致。

图：基础智能体与在线上系统中的比较，分别展示全局用户、低活跃用户和高活跃用户上的结果。

我们还进行了另一个基线实验：将基础智能体的训练窗口从对照设置中的小时扩展到天。我们发现，朴素地扩展训练窗口会导致性能下降（在所讨论指标上为 -0.12 ，置信区间为 $[-0.15, -0.09]$ ）。我们认为有两个因素导致性能变差。第一，训练窗口扩展会显著减慢训练速度，模型周转时间翻倍；服务一个更新不及时模型或策略会导致性能变差。第二，平台上的用户偏好持续变化，基于过时交互数据学习会导致性能下降。

这一组实验说明，本文提出的方法优于基础智能体，并不只是因为引入了额外学习信号，还因为辅助任务和模型结构经过了精心设计。

结论

本文提出了一个通用框架，通过引入辅助任务来提高先进推荐智能体的样本效率。我们证明，将用户响应建模作为一种监督辅助任务实例，对于推荐问题具有吸引力。我们假设改进来自两个方面：第一，利用了推荐过但用户未交互物品中的信息；第二，引入了中间且更容易的任务，即预测用户对推荐结果的即时响应。这两者共同引导用户表示和物品表示学习，并最终有利于策略学习优化用户对平台的长期满意度。

我们分享了设计用户响应模型多个方面的经验，包括结构与损失选择、定向处理以及计算方面的考虑。我们还引入了一种基于梯度分析的工具，用于指导辅助任务开发，例如结构选择和辅助损失设计。我们在包含数亿用户和数千万物品的大规模离线数据集上，以及服务数十亿用户的线上系统实验中，都证明了本文方法的有效性。我们相信，这些工作是推动强化学习推荐系统提高样本效率、并扩展到商业推荐平台所面对的大规模用户群体和物品语料库的重要步骤。

结论

参考文献说明

原论文共列出条参考文献。本文保留正文中的参考文献编号；参考文献条目通常不作为正文逐段翻译对象，因此完整条目以原论文末尾列表为准。