

监督学习增强的多用户组 Actor-Critic：用于信息流中的直播分配

原文：Supervised Learning-enhanced Multi-Group Actor Critic for Live Stream Allocation in Feed

Jingxin Liu, Xiang Gao, YiSha Li, Xin Li, Haiyang Lu, Ben Wang

快手科技，北京，中国

KDD 2025, Toronto, ON, Canada

摘要

在短视频与直播混合推荐场景中，直播推荐系统需要针对每一次用户请求，决定是否最多向视频信息流中分配一个直播内容。若分配策略不当，尤其是忽略直播分配带来的长期负面影响，就可能显著影响 App 使用时长和用户留存。因此，为了最大化长期用户参与度，确定一种能够准确进行直播分配的最优策略至关重要。

近年来，强化学习已经被广泛应用于推荐系统，用于捕捉长期用户参与度。然而，传统强化学习算法通常面临发散和不稳定问题，这限制了其在大规模工业推荐系统中的应用和部署，尤其是在上述具有挑战性的场景中。为了解决这些挑战，本文提出一种新的监督学习增强的多用户组 Actor-Critic 算法，即 SL-MGAC。

具体而言，本文引入一个监督学习增强的 Actor-Critic 框架，并结合方差缩减技术。其中，多任务监督式奖励学习有助于限制 Critic 学习过程中自举误差的累积。此外，本文为 Actor 网络和 Critic 网络都设计了多用户组状态分解模块，以降低预测方差并提高模型稳定性。本文还提出一种新的奖励函数，用于避免过于贪婪的直播分配。

在实验上，本文使用离线策略评估（Offline Policy Evaluation, OPE）和在线 A/B 测试评估 SL-MGAC 算法。实验结果表明，在平台级约束下，所提出的方法不仅优于基线方法，而且在在线推荐场景中表现出更好的稳定性。

CCS 概念：信息系统 → 推荐系统；计算方法 → 强化学习。

关键词：强化学习，推荐系统，方差缩减。

ACM 引用格式：Jingxin Liu, Xiang Gao, YiSha Li, Xin Li, Haiyang Lu, and Ben Wang. 2025. Supervised Learning-enhanced Multi-Group Actor Critic for Live Stream Allocation in Feed. In Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.2 (KDD '25), August 3--7, 2025, Toronto, ON, Canada. ACM, New York, NY, USA, 12 pages.

图 1 短视频与直播混合推荐系统的结构。SL-MGAC 的决策发生在直播推荐系统的最后阶段。图中包含直播推荐系统、视频推荐系统以及混排服务；SL-MGAC 对直播内容是否注入信息流作出二元动作决策。

引言

本文考虑短视频与直播混合推荐系统中的一个具有挑战性的序列决策场景，如图 1 所示。该系统由三个组成部分构成：直播推荐系统、短视频推荐系统和混排服务。对于带有时间戳 t 的每一次用户请求，直播推荐系统决定是否将推荐直播注入视频信息流，而短视频推荐系统则推荐 B 个视频，其中 $B < 10$ 。随后，混排服务将单个直播内容与 B 个视频混合并重新排列，形成最终推荐列表。本文目标是寻找一种个性化的最优直播分配策略，该策略不仅能够最大化用户对直播的长期参与度，还要满足不对 App 使用时长和用户留存产生负面影响的约束。该问题可以建模为一个无限请求级的约束马尔可夫决策过程（Constrained Markov Decision Process, CMDP）[2]。

目前，深度强化学习在许多研究领域已经展现出学习长期奖励最大化策略的巨大潜力，例如计算机视觉、机器人、自然语言处理、游戏以及推荐系统 [1,25]。在推荐系统中，强化学习被用于优化长期用户参与度 [50] 并提升用户留存 [5]。许多强化学习应用已经被提出并用于真实推荐系统，包括列表推荐 [9,19,28]、个性化搜索排序 [30] 和广告分配 [26]。

然而，传统强化学习算法固有的发散和不稳定问题 [8,11,13,24] 在短视频与直播混合推荐系统中被显著放大。一个主要可能原因是，直播供给规模和用户交互行为都会随时间发生剧烈波动，如附录 B 的图 7 所示。对于这种在时间尺度和用户尺度上都具有高方差的数据，强化学习模型通常难以学习有效策略。在实践中，本文观察到强化学习模型经常出现策略退化或模型崩塌问题 [10]。

更重要的是，如图 1 所示，直播分配智能体是直播推荐系统的最后一个模块。如果该强化学习智能体在在线环境中变得高度不稳定，甚至发生崩塌，就可能导致过量直播内容被注入短视频信息流。进一步地，这会对广告和电商视频的曝光产生负面影响，可能造成严重的系统故障和显著的平台损失。因此，在工业推荐系统中，与已有强化学习方法 [5,46,47] 相比，该应用更加高风险；已有方法通常只用于排序阶段的多路排序分数聚合。

此外，与广告类似，直播并不是所有用户都欢迎的内容。若向某个用户分配过多直播，会显著打断用户对短视频的兴趣，并导致用户 App 使用时长下降，最终影响用户参与度和用户留存。因此，不能只关注单次请求的用户反馈，而应优化长期用户体验。

为了解决上述问题，本文提出一种新的监督学习增强多用户组 Actor-Critic 算法，即 SL-MGAC。考虑到用户对直播内容兴趣差异显著，这会在特征层面和反馈层面引入高方差，本文在 Actor 网络和 Critic 网络中分别引入独立的多用户组状态分解（Multi-Group State Decomposition, MG-SD）模块。此外，本文将多任务监督式奖励学习与传统 Critic 学习结合起来，不仅限制模型训练过程中的时序差分（Temporal Difference, TD）误差累积，而且提升 Q 值估计的准确性。通过实验，本文使用离线策略评估（OPE）[39] 和在线 A/B 测试，将 SL-MGAC 与具有竞争力的基线方法进行比较，以证明其有效性和稳定性。

本文的主要贡献如下。

- 本文提出 SL-MGAC，这是一种新的强化学习模型，能够在满足 App 使用时长和用户留存等平台级约束的同时，优于现有方法并最大化直播用户参与度。
- 本文提出新的方差缩减技术 [3,15,24,29,34]，包括多用户组状态分解、用于奖励学习的分布离散化、奖励归一化以及 Q 值归一化。
- 本文将多任务监督式奖励学习与传统 Critic 学习结合起来，以缓解 TD 误差累积并提高 Q 值估计准确性。
- 本文成功将 SL-MGAC 模型部署到快手的短视频与直播混合推荐场景中。快手是一款拥有超过一亿用户的短视频 App。

问题形式化

如图 1 所示，在短视频与直播混合推荐系统中，直播推荐系统被视为一个智能体。该智能体随时与不同用户交互，并接收用户反馈。然而，如果智能体只考虑单次请求的即时用户反馈，就可能在短视频信息流中过于贪婪地分配直播，并最终影响用户留存。因此，最优直播分配控制问题被建模为一个无限请求级 CMDP，目标是在满足平台级约束的同时最大化累计直播奖励。例如，直播分配不能降低整体 App 使用时长。

形式上，本文将直播分配 CMDP 定义为六元组 (S, A, P, R, γ, C) ：

- 状态空间 S ：状态空间是用户交互状态 s 的集合，其中包括用户静态特征（如用户 ID、位置、性别、国家）、用户历史特征（如直播观看历史、短视频观看历史）以及物品特征（如直播 ID、作者 ID、作者性别等）。本文按照时间戳顺序限制用户直播和短视频历史列表长度，只保留前 50 个物品。
- 动作空间 A ：动作 a 表示是否响应用户请求注入一个推荐直播。本文将动作 a 定义为二元变量，其中 $a=1$ 表示注入直播。
- 转移概率 P ：转移概率记为 $p(s_{t+1}|s_t, a_t)$ ，由环境决定。
- 奖励函数 R ：奖励函数 R 是时间戳 t 下状态 s_t 和动作 a_t 到奖励的映射，可表示为 $r(s_t, a_t): S \times A \rightarrow R$ 。
- 折扣因子 γ ：折扣因子 $\gamma [0,1]$ 用于计算累计奖励。通常，在模型训练过程中设置 $\gamma < 1$ 。
- 约束 C ：平台级约束是一种即时约束，即直播观看时长应尽可能长于每次请求中的平均视频观看时长。这样可以防止直播观看时长较短时对 App 使用时长产生负面影响。通过满足该约束，可以确保直播提升用户长期 App 参与度，而不是降低用户在 App 上花费的时间。

总体而言，具体奖励函数 $r(s_t, a_t)$ 和约束函数 $c(s_t, a_t)$ 如下：

$$\begin{aligned} r(s_t, a_t) &= y_l, \\ c(s_t, a_t) &= 1\{B\}y_v - y_l, \end{aligned}$$

其中 y_l 表示直播观看时长， y_v 表示总视频观看时长， B 表示一次请求中的视频数量。

上述最优直播分配控制问题的优化目标如下：

$$\begin{aligned} \max_{\pi} \{ & J_R(\pi) \\ \text{s.t. } & J_C(\pi) \leq \varepsilon, \end{aligned}$$

其中

$$\begin{aligned} J_R(\pi) &= E[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)], \\ J_C(\pi) &= c(s_t, a_t), t \in [0, \infty), \end{aligned}$$

$\pi(s_t, a_t)$ 是需要优化的直播分配策略。

求解上述 CMDP 的常见方法是引入拉格朗日乘子 λ ，将该问题转化为一个极小极大优化问题：

$$\begin{aligned} (\pi^*, \lambda^*) &= \\ \operatorname{argmin}_{\lambda \geq 0} \{ & \max_{\pi} \{ J_R(\pi) - \lambda (J_C(\pi) - \varepsilon) \}. \end{aligned}$$

受 RCPO [38] 算法启发，通过代入式 (1) 中的 $r(s_t, a_t)$ 和 $c(s_t, a_t)$ ，原始-对偶优化问题可以转化为具有惩罚奖励函数的等价无约束问题：

$$\begin{aligned} & r(\lambda, s_t, a_t) \\ & | = r(s_t, a_t) - \lambda c(s_t, a_t) \\ & | = y_l - \lambda (1\{B\}y_v - y_l) \end{aligned}$$

$$|=(1+\lambda)y_l-\lambda\{B\}y_v.$$

在实践中，本文使用如下简化奖励函数求解无约束 MDP 问题：

$$\max_{\pi}\{E[\sum_{t=0}^{\infty}\gamma^t(y_l-\lambda\{B\}y_v)],$$

其中 λ 是一个需要谨慎设置的超参数，用于控制最终直播分配比例。从约束强化学习的角度看， $\lambda\{B\}y_v$ 可以被视为一种隐式代价约束。关于上述奖励函数的进一步讨论，原文放在附录 C 中。

所提出的框架

为了解决强化学习固有的发散和不稳定问题，并成功将强化学习智能体部署到短视频与直播混合推荐系统中，本文提出一种新的监督学习增强多用户组 Actor-Critic 算法，即 SL-MGAC，如图 2 所示。SL-MGAC 包含一个监督学习增强的 Actor-Critic 模型，该模型具有共享的用户与直播特征提取模块，以及相互独立的多用户组状态分解（MG-SD）模块。为清晰起见，图 2 中只展示了一个 Critic 网络，其余三个具有相同结构的 Critic 网络被省略。

图 2 SL-MGAC 算法整体框架。SL MG-SD 模块和 RL MG-SD 模块分别表示用于监督式奖励学习和 Critic 学习的多用户组状态分解模块。

用户与直播特征提取模块

用户与直播特征提取模块的目标是为状态 s_t 生成非线性的嵌入表示。首先，本文使用统一的嵌入层，将用户静态特征、直播特征、历史直播列表特征和短视频列表特征映射为低维稠密表示。本文分别用 v_U 、 v_L 、 $\{e_1, \dots, e_{M_l}\}$ 、 $\{e'_1, \dots, e'_{M_v}\}$ 表示对应的嵌入向量或嵌入向量集合。随后，定义 $h_a=[v_U, v_L]$ 为 v_U 和 v_L 的拼接。

为了聚合历史直播（短视频）表示，本文引入目标注意力机制 [41,49]，其定义如下：

$$h_{\text{live}}=\sum_{i=0}^{M_l}f_l(h_a, e_i)e_i,$$

$$h_{\text{video}}=\sum_{j=0}^{M_v}f_v(h_a, e'_j)e'_j,$$

其中 f_l 和 f_v 是不同的目标注意力函数，例如输出归一化分数的前馈网络。

在通过两个独立注意力网络分别聚合历史直播特征和短视频特征之后，本文将上述全部嵌入向量拼接为 $h_s=[v_U, v_L, h_{\text{live}}, h_{\text{video}}]$ 。然后，本文为 Actor 和 Critic 网络使用一个共享多层感知机（MLP），以获得状态 s_t 的潜在表示，即 $h'_s=f_{\text{MLP}}(h_s)$ 。为保证训练稳定性，本文在 Actor 网络中截断通过 h'_s 的梯度流，只使用更复杂的 Critic 网络优化 h'_s 。这是因为本文发现，共享特征提取模块和 f_{MLP} 网络会导致策略梯度和 Critic 梯度之间发生干扰。

多用户组状态分解模块

由于直播内容对短视频 App 快手中的所有用户并非同等有吸引力，因此有选择地将直播注入短视频信息流非常关键。否则，过量直播曝光可能会干扰用户对短视频的兴趣，导致整体 App 使用时长下降。在实践中，与短视频相比，用户对直播的交互数据更加稀疏且噪声更大，这使得强化学习算法很难为每个用户学习最优直播分配策略。直接从稀疏且带噪声的用户反馈中学习策略通常不可行，因为这会无意中在短视频信息流中过量注入直播，并显著影响用户参与度。

本文发现，不同用户组的先验信息对于提升该场景中强化学习模型决策准确性至关重要，因为它为策略提供了额外的用户偏好信息。区分不同行为用户的一种自然方法，是基于用户历史活跃度将用户划分为不同组。具体而言，本文按照用户对直播的活跃程度，将用户划分为 K 个互不相交的组。该活跃程度由过去 3 周的累计直播观看时长确定。历史观看时长越高的用户，会被分配到活跃程度越高的用户组。

在后续实验中，本文经验性地展示了该模块在增强强化学习模型稳定性方面的有效性。本文发现，不包含 MG-SD 模块的 SL-MGAC 在训练过程中往往更不稳定，其 Q 值方差也更大。此外，MG-SD 模块具有灵活性和可迁移性，用户组划分策略可以很容易地适配到广告和电商等多种场景中。

监督学习增强的 Actor-Critic

为了缓解数据分布剧烈变化对强化学习模型带来的影响，避免其发散或不稳定，本文提出一个监督学习增强的 Actor-Critic 框架，以防止 Critic 网络由于 Critic 学习过程中的巨大累计误差而陷入模型崩塌。

层归一化

一项关于强化学习发散和不稳定的近期工作 [45] 表明，离线 Critic 学习存在自激励模式。具体来说， Q 值的迭代可能无意中导致目标 Q 值 $Q(s_{t+1}, a^*)$ 的增幅甚至大于 $Q(s_t, a_t)$ 的增幅，从而放大 TD 误差，并使 Critic 学习过程陷入正反馈循环，直到模型崩塌。因此，可以利用层归一化 (Layer Normalization) [4] 等归一化技术缓解发散和不稳定问题。

根据文献 [45] 附录 D 中的证明可知，对于任意输入 x 和任意方向 v ，如果网络对输入应用层归一化，则有 $k_{\{NTK\}}(x, x + \lambda v) \leq C$ ，其中 $\lambda > 0$ ， C 是常数， $k_{\{NTK\}}$ 是神经切线核 (Neural Tangent Kernel, NTK) [20]。这在理论上说明，具有层归一化的网络对输入变化不那么敏感，即使模型训练过程中存在扰动，也能够保持稳定梯度。因此，本文如图 2 所示，对 Actor 网络和 Critic 网络的输入都应用层归一化。

Critic 网络

设 $(s_t, a_t, r_t, s_{t+1}, a_{t+1}, r_{t+1})$ 是来自实时数据集 D 的一个训练样本。为了解决最大化偏差问题 [40]，本文在 Clipped Double Q-Learning [13] 中使用四个 Critic 网络：两个当前 Q 网络 $Q_{\{\phi_1\}}$ 、 $Q_{\{\phi_2\}}$ ，以及两个对应的目标 Q 网络 $Q'_{\{\phi_1\}}$ 、 $Q'_{\{\phi_2\}}$ 。Critic 学习目标如下：

$$\begin{aligned} L_{\{Critic\}} &= \sum_{i=1}^2 E_{\{s, a\}} \\ &[Q_{\{\phi_i\}}(s_t, a_t) - Q_{\{label\}}(s_{t+1})]^2, \\ &Q_{\{label\}}(s_{t+1}) \\ &= r(s_t, a_t) + \gamma \max_{a_{t+1}} Q'(s_{t+1}, a_{t+1}), \end{aligned}$$

其中 $Q'(s_{t+1}, a_{t+1}) = \min_{i=1,2} Q'_{\{\phi_i\}}(s_{t+1}, a_{t+1})$ 。本文使用 Huber 损失 [17] 优化上述目标。

在实践中，Critic 学习时 $Q_{\{label\}}(s_{t+1})$ 可能会被 $Q'(s_{t+1}, a_{t+1})$ 主导，从而影响 Critic 网络的性能。具体来说，由于不稳定和发散问题，目标网络常常预测出不准确的 $Q'(s_{t+1}, a_{t+1})$ 值，并且该值远大于 $r(s_t, a_t)$ 项。此时， $r(s_t, a_t)$ 项无法为 Critic 学习提供任何指导信息。因此，本文将监督学习（如多任务学习 [48]）无缝引入 Critic 学习过程。具体而言，本文将 Critic 网络 $Q_{\{\phi_i\}}$ （或 $Q'_{\{\phi_i\}}$ ）划分为两个组成部分：奖励预测网络 (Reward Prediction Network, RPN) 和 Q 残差网络 (Q Residual Network, QRN)：

$$\begin{aligned}
& Q_{\phi_i}(s_t, a_t) \\
& | = R_{\theta_i}(s_t, a_t) + \gamma T_{\xi_i}(s_t, a_t), i=1,2, \\
& Q'_{\phi_i}(s_{t+1}, a_{t+1}) \\
& | = R'_{\theta_i}(s_{t+1}, a_{t+1}) + \\
& \gamma T'_{\xi_i}(s_{t+1}, a_{t+1}), i=1,2.
\end{aligned}$$

其中, R_{θ_i} 和 T_{ξ_i} 分别是 RPN 和 QRN, R'_{θ_i} 和 T'_{ξ_i} 分别是目标 RPN 和目标 QRN。本文使用独立 MLP 对 RPN 和 QRN 进行建模。

由于直播（短视频）观看时长分布会随时间发生剧烈变化, 式 (5) 中的时长收益奖励 r 变得难以学习。在本文中, 作者提出一种分布离散化方法来改进奖励学习。

形式上, 本文将直播观看时长和短视频观看时长分布分别划分为 N_l 和 N_v 个不重叠的分箱, 每个分箱表示一个直播（短视频）观看时长区间。令 y 表示真实直播或短视频观看时长, 并假设其落入时间分箱 $[y_{st}, y_{end}]$ 。 y 在该分箱内的比例为

$$\delta = \frac{y - y_{st}}{y_{end} - y_{st}} [0, 1].$$

然后, 本文使用一个线性重构层从 δ 重构 y :

$$y = y_{st} + \delta (y_{end} - y_{st}),$$

该结构类似于线性奖励平移 [35]。

令 $o_l^{\wedge}(t)^{\wedge} \{N_l+1\}$ 、 $o_v^{\wedge}(t)^{\wedge} \{N_v+1\}$ 表示 one-hot 向量, 分别对应样本 (s_t, a_t, r_t) 的真实直播观看时长和短视频观看时长所在时间分箱。注意, 对于 $a_t=0$ 的情况, 本文设置了一个单独分箱。于是, RPN R_{θ_i} 可以由多任务神经网络建模:

$$\begin{aligned}
& R_{\theta_i}(s_t, a_t) \\
& | = \text{sigmoid}(F_{\Gamma_i}(s_t, a_t) - G_{\Theta_i}(s_t, a_t)), \\
& F_{\Gamma_i}(s_t, a_t) \\
& | = (o_l^{\wedge}(t))^{\wedge} T(y_{st}^{\wedge} + f_{\Gamma_i}(s_t, a_t)(y_{end}^{\wedge} - y_{st}^{\wedge})), \\
& G_{\Theta_i}(s_t, a_t) \\
& | = (o_v^{\wedge}(t))^{\wedge} T(y_{vst}^{\wedge} + g_{\Theta_i}(s_t, a_t)(y_{vend}^{\wedge} - y_{vst}^{\wedge})),
\end{aligned}$$

其中, $y_{st}^{\wedge}, y_{end}^{\wedge} \{N_l+1\}$ 是直播观看时长分箱的预定义左边界（右边界）向量, $y_{vst}^{\wedge}, y_{vend}^{\wedge} \{N_v+1\}$ 是短视频观看时长分箱的预定义左边界（右边界）向量。

需要注意的是, 在式 (10) 中引入后验 one-hot 向量 $o_l^{\wedge}(t)$ 和 $o_v^{\wedge}(t)$ 不会影响 $Q'_{\phi_i}(s_{t+1}, a_{t+1})$ 的计算, 因为数据集 D 中已经保留了 r_{t+1} 。因此, $o_l^{\wedge}(t+1)$ 和 $o_v^{\wedge}(t+1)$ 可以很容易地从 r_{t+1} 中获得, 并用于计算 $R'_{\theta_i}(s_{t+1}, a_{t+1})$ 。

如式 (10) 所示, 本文使用两个独立 MLP, 即 $f_{\Gamma_i}(s_t, a_t)$ 和 $g_{\Theta_i}(s_t, a_t)$, 分别预测时间分箱内比例。随后, 重构预测的直播观看时长和短视频观看时长, 即 $F_{\Gamma_i}(s_t, a_t)$ 和 $G_{\Theta_i}(s_t, a_t)$ 。最后, 获得归一化后的预测奖励 $R_{\theta_i}(s_t, a_t)$ 。为优化预测观看时长比例, 本文使用 Huber 损失:

$$\begin{aligned}
L_{SL} = & \sum_{i=1}^2 \text{Huber_Loss}(\delta_l, F'_{\Gamma_i}) \\
& + \text{Huber_Loss}(\delta_v, G'_{\Theta_i}),
\end{aligned}$$

其中 δ_l 、 δ_v 分别是真实直播观看时长和短视频观看时长的比例标签。

本文对时间比例 δ 而不是真实观看时长 y 使用 Huber 损失, 其原因在于时间比例位于 $[0, 1]$ 范围内, 因此神经网络中的梯度更小。此外, δ 的方差远小于原始观看时长 y 的方差。因此, 学习到的奖励网络 (f_{Γ_i} 和 g_{Θ_i}) 输出也会具有更小的方差。因此, 带有观看时长分布离散化的奖励学习可

以被视为一种新的方差缩减技术。

Actor 网络

本文也将多用户组状态分解模块引入 Actor 网络。Actor 网络的损失函数如下：

$$L_{\{Actor\}} = E_{\{(s,a)\}} [-Q(s_t, a_t) p(s_t, a_t)],$$

其中 $Q(s_t, a_t) = \min_{i=1,2} Q_{\{\phi_i\}}(s_t, a_t)$, $p(s_t, a_t)$ 是 Actor 网络输出的动作概率。

此外，本文观察到，较高的 $Q(s_t, a_t)$ 值会导致 Actor 训练不稳定，并最终导致策略退化，即对任意 t ，出现 $\pi(a_t=1|s_t) > \pi(a_t=0|s_t)$ 或 $\pi(a_t=1|s_t) < \pi(a_t=0|s_t)$ 的极端情况。为解决这一问题，本文对 $Q(s_t, a_t)$ 应用 softmax 归一化，得到 $Q_{\{norm\}} = \text{softmax}(Q(s_t, a_t))$ ，并提出修改后的 Actor 损失函数：

$$L_{\{Actor\}} = E_{\{(s,a)\}} [-Q_{\{norm\}}(s_t, a_t) p(s_t, a_t)].$$

在 AWAC [33] 中可以找到类似的损失函数，其理论结果表明，上述损失等价于一个隐式约束强化学习问题：

$$\begin{aligned} & \pi_{\{k+1\}} \\ & | = \arg\max_{\pi} E_{\{a \sim \pi(\cdot|s)\}} [Q^{\pi_k}(s_t, a_t)], \\ & \text{s.t.} \\ & | D_{\{KL\}}(\pi(\cdot|s) \parallel \pi_o(\cdot|s)) \leq \varepsilon, \end{aligned}$$

其中 $D_{\{KL\}}$ 是 Kullback-Leibler (KL) 散度， π_o 是由数据集 D 得到的行为策略。

本文指出，式 (13) 中的 Actor 损失是标准交叉熵损失函数。从知识蒸馏 [18] 的角度看，Actor 从更复杂的 Critic 网络中蒸馏策略知识。作为教师的 Critic 网络指导更轻量的学生 Actor 网络调整并收敛到最优策略。在实践中，在线直播推荐系统中只需要部署 Actor 网络，这显著降低了计算复杂度并提高了实时响应速度。

总体而言，本文提出的 SL-MGAC 算法的最终损失函数如下：

$$L = L_{\{Actor\}} + L_{\{Critic\}} + L_{\{SL\}}.$$

在线探索与部署

对于在线探索，本文采用常用的 ε -greedy [42] 策略：

```

 $\pi_{\{online\}}(s_t) =$ 
cases
从  $A(s_t)$  中随机选择动作, | 若  $\psi < \varepsilon$ ,
 $\arg\max_{a(s_t)} \pi(a_t|s_t)$ , | 否则,
cases
```

其中 ψ 是随机数， ε 是最大探索概率。

图 3 SL-MGAC 算法的系统架构。在线强化学习智能体收集实时用户交互日志；离线模型训练器基于流式训练数据以离策略方式优化

SL-MGAC 模型，并将最新 Actor 参数实时同步到线上服务。

本文在推荐系统中实现了 SL-MGAC 算法，其整体系统架构如图 3 所示。在线强化学习智能体收集实时用户交互日志，而离线模型训练器使用流式训练数据，以离策略方式优化 SL-MGAC 模型。此外，离线训练器会发送最新模型参数，从而实时更新在线部署的 Actor 网络。

最重要的是，为了成功部署，本文从两个关键方面降低计算成本。首先，对于实时训练，本文避免使用用户-物品交叉特征。此类特征常见于工业排序模型，但会增加稀疏嵌入参数。其次，SL-MGAC 中 Actor 部分的网络参数远小于 Critic，复杂 Critic 作为教师指导 Actor 学习，如第 3.3.3 节所述。因此，在本文推荐系统中，SL-MGAC 的总参数量低于一亿，显著小于典型排序模型通常超过十亿的参数规模。

对于快速在线推理，更小的 Actor 网络能够实现快速推理，即使在峰值时每秒超过 10,000 次请求的情况下，每次请求的处理时间也低于 20 ms。此外，由于复杂 Critic 不用于在线推理，计算成本进一步降低，从而有助于缩短在线环境中的响应时间。

实验

本文在从推荐系统中收集的真实世界数据集上进行离线评估，并使用 SL-MGAC 与基线方法进行在线 A/B 测试实验。

数据集

由于缺乏可公开获得的、涉及短视频信息流中直播分配决策的推荐数据集，本文从推荐系统中通过随机采样收集了 100,000 名用户一天的离线数据集，用于离线评估，并确保不同用户组比例与真实在线数据中的比例相近。总体而言，本文拥有超过 1,800,000 条样本，并按照 4:1 的比例划分为训练集和测试集。此外，用于 A/B 测试的在线环境包含超过一亿 App 用户。

比较方法

基线方法

本文将所提出方法与已有的非强化学习方法和强化学习方法进行比较。

- Learning to Rank (L2R) [6]：一种监督学习框架，用于预测每个动作的奖励。奖励最大的动作会被选为智能体动作。
- DQN [32]：一种用于 Q-learning 的深度神经网络算法，引入目标网络更新技术。
- BCQ [14]：一种广泛使用的离线强化学习算法，通过添加动作限制，鼓励智能体行为接近行为策略。
- SAC [7,16]：一种经典离策略强化学习方法，最大化累计奖励与策略熵之间的权衡。后续实验使用离散版 SAC。
- TD3 [13]：DDPG [27] 的改进版本，通过三种技术解决函数逼近误差，即 Clipped Double Q-Learning、延迟策略更新和目标策略平滑。
- TD3-BC [12]：TD3 算法的离线强化学习变体，使用行为克隆 (BC) 正则化约束策略学习。
- IQL [23]：一种离线强化学习算法，在 Q-learning 中利用 expectile regression。
- RLUR [5]：一种旨在优化长期用户留存的强化学习模型。

需要注意的是，在本文的最优直播分配控制问题中，动作是离散的。因此，本文在 TD3 和 TD3-BC 中引入 Straight-Through Gumbel Softmax [21] 技术。

本文模型的变体

本文还在消融实验中将 SL-MGAC 算法与若干变体进行比较，以说明多用户组状态分解、用于 Critic 学习的监督学习、分布离散化（Distribution Discretization, DD）以及其他技术的有效性。

- SL-MGAC (w/o MG)：不含多用户组状态分解模块的 SL-MGAC 变体。
- SL-MGAC (w/o MG \ | DD)：不含多用户组状态分解模块，也不含奖励学习中分布离散化技术的 SL-MGAC 变体。
- SL-MGAC (w/o MG \ | DD \ | SL)：不含多用户组状态分解模块、分布离散化技术以及监督学习过程的 SL-MGAC 变体。
- SL-MGAC (w/o LN)：不含层归一化技术的 SL-MGAC 变体。
- SL-MGAC (w/o SG)：Actor 网络隐藏状态表示中不使用 Stop Gradient 技术的 SL-MGAC 变体。
- SL-MGAC (w/o Q-norm)：Actor 损失中不使用 Q 值归一化的 SL-MGAC 变体。
- SL-MGAC-0：折扣因子 $\gamma = 0$ 的 SL-MGAC 变体。
- SL-MGAC-sep：独立优化 Actor 网络的 SL-MGAC 变体。因此，式 (13) 中的 Q_{norm} 会从计算图中分离。
- SL-MGAC-vanilla：在 Critic 损失中使用普通 Q 标签的 SL-MGAC 变体，如下式所示，其中 $p(s_{t+1}, \cdot)$ 是 Actor 网络对 s_{t+1} 输出动作的概率。

$$Q_{\text{label}}(s_{t+1}) = r(s_t, a_t) + \gamma \sum_{a_{t+1}} p(s_{t+1}, a_{t+1}) Q(s_{t+1}, a_{t+1}).$$

实现细节

为确保所有比较方法之间的公平性，本文使用相同的特征提取模块，其中嵌入层大小为 5000。除嵌入层外，特征提取模块还包括一个 2 层 MLP，其隐藏层大小为 [256, 128]。所有方法的 batch size 和训练 epoch 数分别为 2048 和 500。嵌入层学习率设为 1×10^{-5} ，其他隐藏参数学习率设为 1×10^{-3} 。所有方法的折扣因子 γ 均设为 0.9，式 (5) 中的 λ 设为 0.1。SL-MGAC 的详细网络结构和参数设置见附录 A 的表 4。SL-MGAC 方法的代码可在 GitHub 获取：<https://github.com/frankg1/SL-MGAC-torch>。

离线策略评估

本文遵循文献 [44] 的方法，采用一种常用离线策略评估方法，即归一化截断重要性采样（Normalized Capped Importance Sampling, NCIS）[37] 来评估性能。评估指标是测试用户所有轨迹上的累计奖励。

离线策略评估结果如表 1 所示。与监督学习方法 L2R 相比，除 DQN 外，大多数强化学习方法都取得了更高的累计奖励。SL-MGAC 显著优于所有其他方法，表明在数据分布剧烈变化的复杂直播与短视频混合推荐系统中，SL-MGAC 可以获得更高的长期奖励。此外，SL-MGAC 优于 SL-MGAC-vanilla，这说明在式 (17) 的 Q 标签计算中引入 Actor 网络，可能会在一定程度上干扰 Critic 学习，并略微影响 SL-MGAC-vanilla 的性能。

【表/图题】比较方法的整体离线性能。

方法 | 累计奖励

L2R [6] | 413.49

DQN [32]	413.18
BCQ [14]	416.69
SAC [7]	435.41
TD3 [13]	432.08
TD3-BC [12]	430.23
IQL [23]	432.03
RLUR [5]	443.01
SL-MGAC-sep	435.19
SL-MGAC-vanilla	450.21
SL-MGAC	458.49

消融研究

本文比较了不同 SL-MGAC 变体的离线性能。如表 2 所示，SL-MGAC 在离线数据集上优于所有其他变体，证明了所提出的多用户组状态分解模块、监督学习过程以及其他技术的有效性。此外，本文发现 SL-MGAC (w/o Q-norm) 获得了最低奖励，这表明 Actor 损失中的 Q 归一化技术增强了模型收敛性并提高了模型性能。

【表/图题】SL-MGAC 变体的离线性能。

方法	累计奖励
SL-MGAC (w/o MG)	454.62
SL-MGAC (w/o MG \ DD)	452.59
SL-MGAC (w/o MG \ DD \ SL)	449.13
SL-MGAC (w/o LN)	453.61
SL-MGAC (w/o SG)	457.26
SL-MGAC (w/o Q-norm)	392.12
SL-MGAC	458.49

接下来，本文比较了 SL-MGAC 与 SL-MGAC (w/o MG) 的训练过程，如图 4 所示。需要注意的是，黄色阴影区域对应 SL-MGAC 模型的 Q 值标准差范围，紫色阴影区域对应 SL-MGAC (w/o MG) 模型的 Q 值标准差范围。可以观察到，SL-MGAC 的 Q 值曲线比 SL-MGAC (w/o MG) 更稳定，并且 SL-MGAC 的 Q 值方差显著更小。这证明了 MG-SD 模块的有效性及其方差缩减效果。

图 4 SL-MGAC 与 SL-MGAC (w/o MG) 在 10 轮训练中的 Q 值曲线。曲线对应 Q 值均值，阴影区域对应标准差。

参数敏感性

本文分析了用户组数量 K 对 SL-MGAC 性能的影响。如图 5 所示，当 K=6 时，所提出的 SL-MGAC 算法获得最高累计奖励，这表明在一定范围内增加用户组数量能够提升模型性能。

图 5 不同用户组数量 K 下的性能。

在线 A/B 测试实验

在线 A/B 测试在 2024 年 9 月持续 5 天进行，本文随机选取快手 App 中 20% 的用户（超过 2000 万）作为实验组。随后，本文比较不同方法相对于基线在直播日活用户数（DAU）、直播观看时长、视频观看时长、App 使用时长和用户留存方面的提升。基线方法使用 SAC 框架进行直播分配。在线 A/B 测试结果如表 3 所示。

需要注意的是，Dummy 方法会对每次请求都注入一个直播。可以看到，与其他方法相比，SL-MGAC 在显著提升直播观看时长的同时，也提高了 App 使用时长和用户留存。这表明，SL-MGAC 在最大化长期直播奖励方面更加有效，并且能够避免对 App 使用时长和用户留存造成负面影响。虽然与 SL-MGAC 相比，SL-MGAC-0 在直播 DAU 上提升更大，但它更倾向于贪婪地注入直播，这可能会影响大多数用户的长期体验。此外，虽然 Dummy 方法可以大幅提升 DAU 和直播观看时长，但会显著影响 App 使用时长和用户留存。

【表/图题】比较方法的在线 A/B 测试性能。

方法	直播 DAU	直播观看时长	视频观看时长	App 使用时长	用户留存
L2R	+0.321%	-0.558%	-0.238%	-0.178%	-0.154%
Dummy	+51.3%	+34.6%	-2.216%	-1.062%	-0.439%
SL-MGAC-0	+3.928%	-2.934%	-0.153%	-0.117%	-0.102%
SL-MGAC	+2.616%	+7.431%	+0.197%	+0.121%	+0.086%

在线模型稳定性

本文评估了基于 SAC 的基线模型与 SL-MGAC 之间的在线模型稳定性。评价指标选择直播注入比例，其计算方式是在给定时间戳内，用直播注入请求数量除以总请求数量。如图 6 所示，两个模型的直播分配比例在一天内都会显著波动，从高流量时段（如 6:00--11:00）到低流量时段（14:00--18:00）均如此。这种变化是由这些时段整体用户规模变化造成的，而用户规模变化会进一步影响数据分布。

然而，与基线相比，SL-MGAC 表现出更强稳定性，波动幅度更小。需要注意的是，直播分配比例指动作 $a=1$ 的请求占比。

图 6 一整天内在线直播分配比例的趋势曲线。

本文计算了 20 分钟滑动时间窗口内直播分配比例的振幅。振幅密度如附录 B 的图 8 所示。结果表明，SL-MGAC 的平均振幅更小，离群点更少。相比之下，基线模型具有更大的振幅离群点，如红色虚线框所示，这展示了 SL-MGAC 更优的在线模型稳定性。

相关工作

推荐系统中的强化学习

强化学习旨在随时间优化累计长期奖励，近年来在推荐系统研究中受到广泛关注 [1]。SLATEQ [19]、GeMS [9] 和 HAC [28] 等方法使用强化学习推荐完整物品列表，其中候选物品数量可能很大。BatchRL-MTF [47]、RLUR [5] 和 UNEX-RL [46] 利用强化学习建模多路排序分数聚合过程，并优化分数聚合权重。文献 [30] 探索了在多会话个性化搜索排序中使用离策略强化学习。CrossDQN [26] 提出一种基于强化学习的信息流广告分配方法，目标是在提升用户体验的同时最大化收益。此外，DQN [31,32]、Double DQN [40]、SAC [16]、DDPG [27] 和 TD3 [13] 等传统强化学习方法，也被作为真实推荐系统强

化学习应用中的主干方法。

一种类似方法称为自监督 Actor-Critic [43]，它将监督学习与 Critic 学习结合起来。其监督学习任务侧重于预测下一物品推荐概率，而本文方法则引入监督学习以约束 Critic 学习。

然而，上述强化学习方法可能遇到不稳定问题，并且在面对高噪声或剧烈变化的数据分布时可能失败。本文提出的 SL-MGAC 方法更加鲁棒，并已经成功部署在真实工业推荐系统中一个“高风险”的最后阶段。本文认为，该工作不仅为工业推荐系统中强化学习应用的模型框架设计提供了有价值的见解，也为其他工业公司部署鲁棒且成功的强化学习系统提供了实践经验。

强化学习发散与不稳定

近年来，越来越多文献开始关注强化学习的发散和不稳定问题。文献 [40] 提出 Double DQN，以缓解 DQN 中的最大化偏差问题。文献 [13] 在 TD3 中提出 Clipped Double Q-Learning 技术，以降低 Q 值过估计。文献 [29] 为策略梯度算法 [36] 引入无偏且依赖输入的 baseline，以降低方差并提高训练稳定性。文献 [10] 在二状态 MDP 中研究策略崩塌，并发现 L2 正则化和非平稳 Adam 优化器 [22] 都能有效缓解强化学习不稳定。文献 [45] 从理论上分析强化学习发散的原因，并应用层归一化缓解强化学习发散和不稳定问题。

结论

在直播与短视频混合推荐系统这一具有挑战性的场景中，本文提出一种新的监督学习增强多用户组 Actor-Critic 算法（SL-MGAC），用于在 App 使用时长和用户留存的平台级约束下优化请求级直播分配策略。具体而言，本文引入多用户组状态分解模块以降低预测方差，并将多任务监督式奖励学习与传统 Critic 学习无缝结合，以约束 Q 值估计。

与现有推荐系统强化学习方法相比，本文方法不仅关注提升在线性能，还改善了强化学习模型的稳定性和鲁棒性。在实践中，本文最小化了策略退化或模型崩塌的风险，从而使所提出的 SL-MGAC 方法能够成功应用于大规模工业推荐系统。

目前，作者正在尝试将 SL-MGAC 方法应用到其他类似推荐场景中，包括电商和广告。作者还计划在后续研究中持续提升 SL-MGAC 的性能。从长序列用户行为 (s_t, a_t, r_t) 中学习直播策略，以及探索更加精细和复杂的用户状态表示，将成为未来工作方向。

致谢

作者感谢 Wei Bai、Xiaoshuang Chen 以及匿名审稿人提出的详细修改建议，这些建议帮助作者提升了本文稿件质量。

附录 A：表格

【表/图题】SL-MGAC 的超参数。

超参数 | 取值

Actor 中的 MGN | [128, 63, 31, 2]

RPN 中的 MGN | [128, 64, 32, 8]

QRN 中的 MGN | [128, 64, 32, 2]

直播时长 DDB | [0s, 6s, 15s, 30s, 60s, 100s, 600s, 1200s]

视频时长 DDB | [0s, 3s, 10s, 25s, 50s, 100s, 600s, 1200s]

优化器 | Adam

用户组数量 K | 6

在线探索 ϵ | 0.2

本文将 MGN 记为多用户组网络，将 RPN 记为奖励预测网络，将 QRN 记为 Q 残差网络，将 DDB 记为分布离散化分箱。直播观看时长和视频观看时长分布均包含 7 个时间分箱。本文为 $a=1$ 的情况额外保留一个时间分箱，因此 RPN 的输出层维度为 8。

附录 B：图

图 7 在线直播间数量（或观看人数）、直播观看时长以及短视频观看时长的数据分布。其中，子图 (a) 展示在线直播房间数和观看人数分布；子图 (b) 展示平均观看时长分布。

图 8 直播注入比例的振幅分布。该图用于比较 SL-MGAC 与基线模型在线分配比例波动幅度的密度分布。

附录 C：更多消融研究

本文进一步进行在线 A/B 实验，以展示式 (5) 中不同 λ 取值下 SL-MGAC 策略的性能，如表 5 所示。结果表明，当 $\lambda > 0$ 时，SL-MGAC 的直播分配策略会更加保守，以平衡直播观看时长和视频观看时长，并最终优化用户长期参与度和留存。然而，当 $\lambda < 0$ 时，SL-MGAC 会更加贪婪地向视频信息流分配直播。具体而言，本文发现，由于奖励中的位置偏差，SL-MGAC 会向会话中更早发生的请求分配更多直播，这会打断用户在整个会话中的兴趣，并因此影响用户留存。

【表/图题】不同 λ 取值下 SL-MGAC 的在线 A/B 测试性能。

λ | 直播 DAU | 直播观看时长 | 视频观看时长 | App 使用时长 | 用户留存

0.2 | -1.245% | -3.567% | +0.215% | +0.123% | +0.106%

0.1 | +2.616% | +7.431% | +0.197% | +0.121% | +0.086%

-0.1 | +4.123% | +6.564% | -0.248% | -0.362% | -0.112%

-0.2 | +5.876% | +7.215% | -0.296% | -0.445% | -0.159%

参考文献

{

- M Mehdi Afsar, Trafford Crump, and Behrouz Far. 2022. Reinforcement learning based recommender systems: A survey. *Computing Surveys* 55, 7 (2022), 1--38.
- Eitan Altman. 2021. *Constrained Markov decision processes*. Routledge.

- Oron Anschel, Nir Baram, and Nahum Shimkin. 2017. Averaged-dqn: Variance reduction and stabilization for deep reinforcement learning. In International Conference on Machine Learning. PMLR, 176--185.
- Jimmy Lei Ba. 2016. Layer normalization. arXiv preprint arXiv:1607.06450 (2016).
- Qingpeng Cai, Shuchang Liu, Xueliang Wang, Tianyou Zuo, Wentao Xie, Bin Yang, Dong Zheng, Peng Jiang, and Kun Gai. 2023. Reinforcing user retention in a billion scale short video recommender system. In Companion Proceedings of the ACM Web Conference 2023. 421--426.
- Ming Chen and Xiuze Zhou. 2020. DeepRank: Learning to rank with neural networks for recommendation. Knowledge-Based Systems 209 (2020), 106478.
- Petros Christodoulou. Soft actor-critic for discrete action settings. arXiv preprint arXiv:1910.07207.
- Vibhavari Dasagi, Jake Bruce, Thierry Peynot, and Jürgen Leitner. 2019. Ctrl-z: Recovering from instability in reinforcement learning. arXiv preprint arXiv:1910.03732.
- Romain Deffayet, Thibaut Thonet, Jean-Michel Renders, and Maarten De Rijke. 2023. Generative slate recommendation with reinforcement learning. In Proceedings of WSDM. 580--588.
- Shibhansh Dohare, Qingfeng Lan, and A Rupam Mahmood. 2023. Overcoming policy collapse in deep reinforcement learning. In European Workshop on Reinforcement Learning.
- Vincent François-Lavet, Raphael Fonteneau, and Damien Ernst. 2015. How to discount deep reinforcement learning: Towards new dynamic strategies. arXiv preprint arXiv:1512.02011.
- Scott Fujimoto and Shixiang Shane Gu. 2021. A minimalist approach to offline reinforcement learning. NeurIPS 34 (2021), 20132--20145.
- Scott Fujimoto, Herke Hoof, and David Meger. 2018. Addressing function approximation error in actor-critic methods. In ICML. PMLR, 1587--1596.
- Scott Fujimoto, David Meger, and Doina Precup. 2019. Off-policy deep reinforcement learning without exploration. In ICML. PMLR, 2052--2062.
- Evan Greensmith, Peter L Bartlett, and Jonathan Baxter. 2004. Variance Reduction Techniques for Gradient Estimates in Reinforcement Learning. JMLR 5, 9 (2004).
- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. 2018. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In ICML. PMLR, 1861--1870.
- Trevor Hastie, Robert Tibshirani, Jerome H Friedman, and Jerome H Friedman. 2009. The elements of statistical learning. Springer.
- Geoffrey Hinton. 2015. Distilling the Knowledge in a Neural Network. arXiv preprint arXiv:1503.02531.
- Eugene Ie et al. 2019. SlateQ: A tractable decomposition for reinforcement learning with recommendation sets.
- Arthur Jacot, Franck Gabriel, and Clément Hongler. 2018. Neural tangent kernel: Convergence and generalization in neural networks. NeurIPS 31.
- Eric Jang, Shixiang Gu, and Ben Poole. 2016. Categorical reparameterization with gumbel-softmax. arXiv preprint arXiv:1611.01144.
- Diederik P Kingma. 2014. Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980.
- Ilya Kostrikov, Ashvin Nair, and Sergey Levine. 2021. Offline reinforcement learning with implicit q-learning. arXiv preprint arXiv:2110.06169.
- Aviral Kumar et al. 2019. Stabilizing off-policy q-learning via bootstrapping error reduction. NeurIPS 32.

- Yuxi Li. 2017. Deep reinforcement learning: An overview. arXiv preprint arXiv:1701.07274.
- Guogang Liao et al. 2022. Cross dqn: Cross deep q network for ads allocation in feed. In WWW. 401--409.
- TP Lillicrap. 2015. Continuous control with deep reinforcement learning. arXiv preprint arXiv:1509.02971.
- Shuchang Liu et al. 2023. Exploration and regularization of the latent action space in recommendation. In WWW. 833--844.
- Hongzi Mao et al. 2018. Variance reduction for reinforcement learning in input-driven environments. arXiv preprint arXiv:1807.02264.
- Dadong Miao et al. 2021. Sequential Search with Off-Policy Reinforcement Learning. In CIKM. 4006--4015.
- Volodymyr Mnih. 2013. Playing atari with deep reinforcement learning. arXiv preprint arXiv:1312.5602.
- Volodymyr Mnih et al. 2015. Human-level control through deep reinforcement learning. Nature 518, 7540 (2015), 529--533.
- Ashvin Nair et al. 2020. AWAC: Accelerating online reinforcement learning with offline datasets. arXiv preprint arXiv:2006.09359.
- Joshua Romoff et al. 2018. Reward estimation for variance reduction in deep reinforcement learning. arXiv preprint arXiv:1805.03359.
- Hao Sun et al. 2022. Exploit reward shifting in value-based deep-RL. NeurIPS 35.
- Richard S Sutton et al. 1999. Policy gradient methods for reinforcement learning with function approximation. NeurIPS 12.
- Adith Swaminathan and Thorsten Joachims. 2015. The self-normalized estimator for counterfactual learning. NeurIPS 28.
- Chen Tessler, Daniel J Mankowitz, and Shie Mannor. 2018. Reward constrained policy optimization. arXiv preprint arXiv:1805.11074.
- Masatoshi Uehara, Chengchun Shi, and Nathan Kallus. 2022. A review of off-policy evaluation in reinforcement learning. arXiv preprint arXiv:2212.06355.
- Hado Van Hasselt, Arthur Guez, and David Silver. 2016. Deep reinforcement learning with double q-learning. In AAAI.
- A Vaswani. 2017. Attention is all you need. NeurIPS.
- Christopher John Cornish Hellaby Watkins. 1989. Learning from delayed rewards.
- Xin Xin et al. 2020. Self-supervised reinforcement learning for recommender systems. In SIGIR. 931--940.
- Wanqi Xue et al. 2023. PrefRec: recommender systems with human preferences for reinforcing long-term user engagement. In KDD. 2874--2884.
- Yang Yue et al. 2024. Understanding, predicting and better resolving Q-value divergence in offline-RL. NeurIPS 36.
- Gengrui Zhang et al. 2024. UNEX-RL: Reinforcing Long-Term Rewards in Multi-Stage Recommender Systems with UNidirectional EXecution. In AAAI. 9305--9313.
- Qihua Zhang et al. 2022. Multi-task fusion via reinforcement learning for long-term user satisfaction in recommender systems. In KDD. 4510--4520.
- Yu Zhang and Qiang Yang. 2021. A survey on multi-task learning. IEEE TKDE 34, 12 (2021), 5586--5609.

- Guorui Zhou et al. 2018. Deep interest network for click-through rate prediction. In KDD. 1059--1068.
- Lixin Zou et al. 2019. Reinforcement learning to optimize long-term user engagement in recommender systems. In KDD. 2810--2818.

}