

AURO：用于推荐系统中自适应用户留存优化的强化学习

逐段中文翻译版

原文作者：Zhenghai Xue, Qingpeng Cai, Bin Yang, Lantao Hu, Peng Jiang, Kun Gai, Bo An；原文发表于 WWW 2025。

说明：本文档根据用户上传论文《AURO: Reinforcement Learning for Adaptive User Retention Optimization in Recommender Systems》制作。正文按原文结构逐段翻译，保留主要公式、表格、算法和图题说明；参考文献题名保持原文形式，便于检索。

摘要

强化学习（Reinforcement Learning, RL）因能够优化推荐系统中的用户留存而受到越来越多关注。在这一优化过程中，一个主要障碍是环境非平稳性，这种非平稳性来自用户行为模式随时间持续且复杂的演化，例如交互率和留存倾向的变化。这些变化会给现有强化学习推荐算法带来显著挑战，导致环境动力学和奖励分布发生偏移。本文提出了一种新方法 AURO 来应对这一挑战。为了在非平稳环境中引导推荐策略，AURO 在策略网络中引入状态抽象模块。该模块通过一种新的基于价值的损失函数训练，使其输出与当前策略的估计性能对齐。由于强化学习中的策略性能对环境漂移十分敏感，该损失函数使状态抽象能够反映环境变化，并提醒推荐策略相应适应。此外，环境非平稳性还会引入隐式冷启动问题，即推荐策略会持续与表现出新行为模式的用户交互。AURO 通过基于性能的拒绝采样保护探索过程，从而在成本敏感的在线环境中维持稳定推荐质量。作者在用户留存模拟器、MovieLens 数据集以及真实短视频推荐平台上进行了大量实证分析，结果表明 AURO 相比所有评估基线均表现更优。

概念：信息系统 → 推荐系统；计算方法 → 强化学习。

关键词：强化学习；推荐系统；用户留存；非平稳环境。

引言

近年来，推荐系统研究表明，强化学习在提升用户留存方面取得了有希望的结果 $\llbracket 6,45,55 \rrbracket$ 。这主要得益于强化学习能够有效处理延迟奖励信号 $\llbracket 7,37 \rrbracket$ ，并促进高效探索策略 $\llbracket 5,11 \rrbracket$ 。与短期反馈相比，长期参与度受到关注，是因为它与日活跃用户数（DAU）和用户停留时长等关键业务指标直接相关。然而，大规模在线推荐平台具有动态且不断变化的特点，用户行为模式会持续偏移，这给基于强化学习的推荐算法带来了显著挑战。例如，在重大金融新闻期间，股票交易者可能会在新闻推荐应用中表现出更高活跃度；购物应用中的促销活动也可能提升用户与推荐商品的交互频率。从强化学习视角看，不同用户行为模式会导致环境动力学和奖励函数持续变化。由于标准强化学习方法的泛化能力较弱 $\llbracket 23,46 \rrbracket$ ，训练阶段表现良好的策略，在部署阶段可能会因推荐环境持续演化而难以保持效果。

为了提升强化学习在动态环境中的泛化能力，当前 Meta-RL 或零样本策略泛化算法 $\llbracket 30,46 \rrbracket$ 通常尝试显式识别一个唯一环境参数，并将其作为对应环境的潜在特征。然而，在推荐任务中，用户行为在不同时段会表现出明显不同的模式，其中既包括点击、点赞、评论、负反馈等即时反馈的正样本比例，也包括用户返回时间分布等长期反馈，本文第 3.1 节的动机示例对此进行了展示。这些因素共同构成了非平稳推荐环境，而该环境无法被简化为单一隐藏参数。非平稳环境还会带来隐式冷启动问题 $\llbracket 20 \rrbracket$ ，即推荐策略会持续与表现出新行为模式的用户交互。因此，策略需要能够主动适应新的环境设定。一些强化学习方法 $\llbracket 5,11 \rrbracket$ 的探索能力有助于满足这种快速适应需求，但它们可能过于乐观，

并在成本敏感的推荐环境中提出不可靠探索动作。总体而言，动态演化的推荐环境带来了两个关键挑战：准确识别复杂环境变化，以及对这些变化做出安全适应。

本文提出自适应用户留存优化（Adaptive User Retention Optimization, AURO），用于同时应对上述两个挑战。由于强化学习策略对分布偏移较为敏感 ([6,46])，策略性能可以成为检测推荐环境变化的可靠且通用信号。因此，为了主动且通用地识别非平稳性，本文在策略网络中引入额外的状态抽象模块，并将状态抽象输出与状态价值函数对齐。状态价值函数可作为当前策略性能的代理度量。随后，状态抽象模块会根据环境变化生成不同输出，并在当前策略不再适合新的用户行为模式时向策略发出提示。对于快速策略适应，不确定性下的乐观探索 ([10,11]) 是一种常见方法。为了保证探索安全，AURO 先生成一组候选探索动作，再根据估计状态-动作价值进行筛选。这种方法显著降低了选择可能产生负面影响的探索动作的概率，从而增强在线训练过程的稳定性和可靠性。

为了评估 AURO 在多种推荐任务中优化用户留存的有效性，作者在用户留存模拟器 ([49]) 和 MovieLens 数据集上进行了实验，并将 AURO 完整上线到一个流行的短视频推荐平台。实验结果表明，在复杂且非平稳的推荐环境中，AURO 在训练稳定性和适应能力方面均优于当前先进方法。

背景

原文图 1 展示了强化学习与实际推荐流程之间的联系。在该框架中，用户被视为环境，强化学习策略通过向环境输入动作来运行。由于候选物品数量可能非常庞大，离散动作选择会变得十分繁重，因此本文遵循已有文献 ([6,45]) 的做法，采用 k 维连续动作。

在步骤 t ，强化学习策略生成动作 a_t 。一个预训练深度打分模型为每个候选物品 i 预测一个 k 维分数

$$x_i = (x_{i1}, x_{i2}, \dots, x_{ik}),$$

其中每一维都从某一方面评价该物品。本文将该打分模型视为黑盒。随后，系统采用预定义排序函数 f 计算每个被选物品 i 的最终排序分数 $f(a_t, x_i)$ ，再根据排序分数向用户推荐前 n 个物品。

根据图 1 的形式化描述，用户行为模式的波动会使推荐环境变得非平稳。为了对此类环境中的推荐任务建模，本文采用隐藏参数马尔可夫决策过程 (HiP-MDP) ([13])：

$$S, A, \Theta, T, r, \gamma, \rho_0,$$

并将非平稳性归因于一个未知隐藏参数分布 Θ 。其中， S 为连续状态空间， A 为 k 维连续动作空间， Θ 为联合隐藏参数分布。当 episode 开始时，会采样 $\theta \sim \Theta$ ，用于反映当前非平稳环境状态； Θ 和 θ 对强化学习算法均不可见。 T 是转移函数。在步骤 t ， T 根据动作 a_t 和当前隐藏参数 θ 更新状态 s_t 中的用户画像与浏览历史，并生成下一状态分布

$$s_{t+1} \sim T_\theta(s_t, a_t, \theta).$$

r 是奖励函数。为了优化用户留存，用户返回推荐平台的时间间隔被用于计算留存奖励，并将该奖励分配到 episode 的最后一步：

$$r_\theta(s_0, a_0, s_1, a_1, \dots, s_t, a_t, \theta) = \lambda \times \text{user return time},$$

其中 λ 为预定义权重系数。其他步骤奖励为零。 γ 是折扣因子，用于决定策略在多大程度上考虑未来奖励。 ρ_0 是初始状态分布。当会话开始时， s_0 会根据 ρ_0 和当前隐藏参数 θ 随机采样：

$$s_0 \sim \rho_0(\theta).$$

本文目标是最大化策略 π 的期望累积回报：

$$\eta_T(\pi) = E_{\pi, T, \Theta} [\sum_{t=0}^{\infty} \gamma^t r_\theta(s_0, a_0, \dots, s_t, a_t, \theta)].$$

其中期望按 $a_t \sim \pi(s_t)$ 、 $s_{t+1} \sim T_\theta(s_t, a_t, \theta)$ 和 $\theta \sim \Theta$ 计算。状态-动作价值函数 $Q^\pi(s, a)$ 表示在状态 s 下采取动作 a 之后的期望回报：

$$Q^\pi(s, a) = E_{\pi, T, \Theta} [r_t + \gamma V^\pi(s_{t+1}, \theta) | s_t = s, a_t = a].$$

状态价值函数，也称为 V 函数，定义为

$$V^\pi(s) = E_{\pi} [Q^\pi(s, a)].$$

AURO：自适应用户留存优化

动机示例

本文主要关注由用户行为中多个波动因素引起的非平稳环境挑战。为了从经验上验证实际推荐系统中确实存在这一问题，作者在一个流行短视频推荐平台上进行了数据驱动研究，该平台也用于第 4.3 节的在线实验。为了避免不同推荐物品和交互历史的影响，作者选取每次推荐会话开始时发生的交互，也即轨迹中的 s_0 。本文主要关注用户返回时间分布，以及所有数据中即时反馈的正样本比例，包括点击、点赞、关注、评论和负反馈。

原文图 2 左侧可视化了不同日期和一天中不同时间段的归一化交互比例；图 2 右侧展示了连续三周内用户返回时间分布。表 1 还展示了若干即时交互比例的归一化标准差。结果显示，返回概率和交互比例会随时间产生较大变化。例如，用户第二天返回应用的平均概率在第 1 周可能低至约 70%，而在第 2 周可能高达约 81%。在即时信号中，“点击”和“点赞”相对更加稳定，而其他三个信号波动显著，其标准差约为“点赞”的 3 到 4 倍。例如，第 5 天的“关注”信号频率大约是第 9 天的两倍；上午 8 点的“评论”信号频率约为凌晨 3 点和 5 点的三倍。此外，作者几乎无法从一个月不同日期或一天内不同时间段的交互频率变化中识别出清晰规律。因此，手动用规则抽取环境信息并输入策略网络变得非常困难。总体而言，这些发现刻画了推荐环境复杂且非平稳的性质，即用户行为的多个方面都会随时间演化。

表/图说明：原文表 1：在线环境采样数据统计。即时反馈在计算标准差之前被归一化为单位均值。

→prule

维度 | 数量 | 正样本比例 | 比例的归一化标准差

用户 | 27,285 | -- | --

物品 | 7,551 | -- | --

样本 | 1,186,059 | -- | --

点击 | 208,934 | 17.61% | 0.049

点赞 | 5,691 | 0.480% | 0.116

关注 | 310 | 0.026% | 0.286

评论 | 411 | 0.035% | 0.418

负反馈 | 1,351 | 0.114% | 0.334

框架概览

为了解决上述挑战，本文提出一种新的范式，称为自适应用户留存优化（AURO）。其结构如原文图 3 所示，算法流程列在附录 C 中。如第 2 节所述，推荐策略以用户特征、物品特征和物品历史作为输入。这些输入先经过 embedding 网络和 Transformer 处理，然后被拼接到一起并生成向量化状态。在本节后续部分，作者讨论 AURO 的两个关键贡献，即状态抽象网络和受保护的在线探索过程。

原文图 3 的整体框架可概括为三部分：（a）用户状态编码模块，将用户特征、物品特征和物品历史嵌入为低维状态向量；（b）带状态抽象的 Actor-Critic 模块，状态抽象网络生成潜在特征向量 $\phi(s)$

，随后状态向量与 $\phi(s)$ 拼接后输入 Actor 和 Critic 网络；（c）探索模块，用于选择与推荐环境交互的探索动作。

基于价值状态抽象的通用非平稳性识别

本文引入一个额外状态抽象网络，并将其输出与当前策略的期望性能对齐。相比直接识别某个特定隐藏变量，这种方式更通用，能够反映环境非平稳性。当 HiP-MDP 中采样出新的隐藏参数 θ 时，由于环境动力学和奖励分布发生偏移，策略性能会下降，并随动态环境演化而变化。一个经过良好对齐的状态抽象网络输出便可作为识别当前环境状态的通用方法。为了实现抽象-性能对齐，本文要求状态抽象空间中的 $_2$ 距离接近一个与性能相关的距离度量 d 。因此，用于更新状态抽象网络 ϕ 的损失函数可表示为

$$J(\phi) = \sum_{i,j} (\phi(s_i) - \phi(s_j))_2^2 - d(s_i, s_j)^2.$$

在强化学习的 Actor-Critic 架构中，状态价值函数 V 可以作为 Critic，用于评价学习策略的性能。如果两个状态 s_i 和 s_j 都具有较高状态价值，则策略在这两个状态上都会表现良好，因此潜变量 $\phi(s_i)$ 应该接近 $\phi(s_j)$ 。如果两个状态具有不同状态价值，则对应潜变量应当彼此远离。因此，本文选择以下基于状态价值函数 V 的距离度量：

$$d(s_i, s_j) = \begin{cases} 0, & \text{若 } V(s_i, \phi(s_i)) \text{ 与 } V(s_j, \phi(s_j)) \text{ 接近,} \\ \infty, & \text{否则.} \end{cases}$$

通过将距离函数设置为在不同估计策略性能输入下取极端值，状态抽象器 $\phi(s)$ 会获得更加精确且简化的信号，从而区分不同环境。如原文图 3 所示，状态抽象 $\phi(s)$ 也作为状态价值函数 V 的额外输入，以获得更准确的价值估计。原文图 6(d) 比较了不同算法训练过程中的价值误差。AURO 的价值估计比不使用状态抽象的其他算法更加准确，说明使用状态价值函数作为策略性能代理是可行的。同时，更低价值误差对应非平稳环境下更好的训练稳定性，展示了额外状态抽象模块的有效性。

为了判断 $V(s_i, \phi(s_i))$ 和 $V(s_j, \phi(s_j))$ 是否接近，作者按状态价值对大小为 B 的输入状态批次 $s_1, s_2, \dots, s_B$ 排序，并将其划分为 n 个类别 $C_1, C_2, \dots, C_n$ ，其中 n 是超参数。被分配到同一类别的状态被认为具有相似价值。若 s_i 和 s_j 落入同一类别，则记为 $j \in N(i)$ 。将式 (2) 代入式 (1)，可得

$$J(\phi) = \sum_i \left[\sum_{j \in N(i)} (\phi(s_i) - \phi(s_j))_2^2 - \sum_{j \in N(i)} (\phi(s_i) - \phi(s_j))_2^2 \right],$$

其中第一项使同一类别中的状态抽象更接近，第二项则将不同类别中的状态抽象推远。

在实践中，状态价值函数 V 会随着策略训练同步更新，而状态批次又是从不断更新的 replay buffer 中随机采样的。因此， $\phi(s_i)$ 的输出可能不稳定；当 $\phi(s_i)$ 被用作策略输入的一部分时，这种不稳定性并不理想。为缓解该问题，本文在式 (3) 的两项中都引入每个状态类别的滑动平均：

$$\phi_k \leftarrow (1 - \eta) \phi_k + \eta |C_k|^{-1} \sum_{s_i \in C_k} \phi(s_i), k=1, 2, \dots, n.$$

作者将式 (3) 转化为与平均状态抽象

$$\phi_k = |C_k|^{-1} \sum_{s_i \in C_k} \phi(s_i)$$

相关的形式。对于第一项，有

$$J_{\text{same}}(\phi)$$

$$|_{k=1}^n \sum_{i,j} C_{k,i,j} (\phi(s_i) - \phi(s_j))^2$$

$$|_{k=1}^n \sum_{i,j} C_{k,i,j} (\phi(s_i) - \phi(s_j))^2.$$

为了最大化不同类别状态之间的项，有

$$J_{\text{diff}}(\phi)$$

$$|_{k=1}^n \sum_{m>k} C_{k,s_i} C_{k,s_j} C_{k,m}$$

$$\phi(s_i) - \phi(s_j))^2$$

$$|_{k=1}^n \sum_{m>k} C_{k,s_i} C_{k,s_j} C_{k,m} (\phi(s_i) - \phi(s_j))^2.$$

通过最小化式 (4) 中的最后一项，实际上是在最小化原始损失函数的一个上界。平均状态抽象 ϕ_k 可被滑动平均 $\bar{\phi}_k$ 替代，由此得到训练时使用的最终损失函数：

$$J(\phi) =$$

$$2 \sum_{k=1}^n \sum_i C_{k,i} (\phi(s_i) - \bar{\phi}_k)^2$$

-

$$B \sum_{k=1}^n \sum_{m>k} C_{k,s_i} C_{k,s_j} C_{k,m} (\bar{\phi}_k - \bar{\phi}_m)^2.$$

在实践中，除了基于价值的损失函数 $J(\phi)$ 之外，策略优化损失也会在训练过程中反向传播到状态抽象网络，以加速训练。

用于隐式冷启动的受保护在线探索

在第 3.1 节所示的非平稳推荐环境中，推荐策略会持续面对具有新行为模式的用户。从 HiP-MDP 角度看，不同 episode 中不同的 θ 会导致新的环境动力学 T 和奖励函数 r 。虽然状态抽象网络能够帮助策略识别环境新颖性，但策略本身也需要主动适应新的环境参数。这类似推荐系统中的冷启动问题 ([21,33])，但会在在线训练期间以隐式方式发生。

强化学习中处理该问题的一种理想方法是探索。本文考虑不确定性下的乐观探索 ([11])，并定义乐观状态-动作价值估计：

$$Q_{\text{UB}}(s,a) = \bar{Q}(s,a) + \beta \sigma_Q(s,a),$$

其中 $\bar{Q}$ 和 σ_Q 分别表示多个 Q 网络输出的均值和标准差， β 为超参数。探索动作 a_E 可通过将原始策略输出 a_T 沿 $Q_{\text{UB}}(s,a)$ 的梯度上升方向延伸来计算：

$$a_E = a_T + \delta$$

$$[\nabla_a Q_{\text{UB}}(s,a)]_{a=a_T}$$

$$[\nabla_a Q_{\text{UB}}(s,a)]_{a=a_T}.$$

其中 δ 是步长超参数。确定原始动作应延伸多远并不容易。较小步长可能导致探索效率低下，较大步长可能带来不准确的梯度近似。如原文图 4 左侧所示，状态-动作函数可能呈现多个峰值，不合适步长会使探索动作错过局部最优解。

在推荐任务中，选择合适步长 δ 的挑战更加明显，因为状态-动作价值景观可能高度复杂。另一个挑战在于推荐任务通常是风险敏感的：如果用户遇到无法吸引其兴趣的推荐物品，可能会退出应用并终止推荐过程。

为缓解上述问题，本文提出使用乐观探索生成一组动作，并通过拒绝采样过滤掉可能导致较差推荐质量的候选动作。动作 $a_k, k=1,2,\dots,N$ 位于原始策略输出 $\pi(s, \phi(s))$ 附近，并沿梯度 $\nabla_a Q_{\text{UB}}(s,a)$ 的方向分布。探索动作 a_E 根据平均 Q 值从动作集合中选择：

$$a_E = \arg \max_k Q(s,a_k),$$

$$a_k = a_T + k \delta [Q_{UB}(s, a) - a] = \pi(s).$$

其中 δ 是控制动作粒子间隔的超参数。它可以设置为较小值，并且不需要额外调参，原文表 2 的消融实验对此进行了说明。通过从多个候选动作中选择，探索模块可以更高效地找到具有更高状态-动作价值的动作，并降低采用低价值危险动作的风险。原文图 6 也可可视化展示了该探索技术的有效性。

实验

为了评估和分析 AURO 的实际性能，作者进行了大量实验来研究以下问题：RQ1：当应用于推荐数据集和模拟器时，AURO 能否比基线算法更好地优化用户留存？RQ2：AURO 的每个组件如何贡献整体性能？RQ3：AURO 能否在大规模真实推荐平台的在线 A/B 测试中表现良好？为回答这些问题，作者在修改后的 MovieLens-1M 数据集和 KuaiSim 留存模拟器中使用 AURO 的状态抽象模块生成推荐策略，并进行了消融实验和可视化分析。此外，AURO 也被部署到一个动态的大规模真实短视频推荐平台中进行在线 A/B 测试。

留存模拟器中的实验

实验设置。AURO 采用新的范式，关注优化用户留存，而不是即时用户反馈。然而，已有广泛使用的推荐模拟器 ([19,35,40]) 无法模拟用户留存行为。KuaiSim 留存模拟器 ([49]) 旨在模拟短视频推荐平台上的长期用户留存。它已经验证了若干同样研究用户留存的推荐算法 ([6,26,27])。KuaiSim 包含用户离开模块和用户返回模块：前者预测用户是否会离开会话并终止 episode；后者将用户每天返回平台的概率预测为一个多项分布。为了刻画用户行为的动态性质并构造非平稳评估环境，每个 episode 中用户离开和返回概率都会改变。更多设置见附录 D.1。

对于基线算法，作者纳入了非强化学习推荐方法（CEM、DIN）、基于价值的强化学习算法（DDPG、TD3、SAC）、促进高效探索的强化学习算法（OAC、RND）、基于上下文编码器的强化学习算法（ESCP），以及用于优化用户留存的强化学习推荐算法（RLUR、OSPia、RL-LTV）。在基于模拟器的实验中，作者选择三个指标评估算法：用户平均返回天数（越低越好）、用户次日返回概率（越高越好）以及第 2 节定义的留存奖励（越高越好）。所有对比算法均以五个不同随机种子运行 50,000 个训练步骤。

性能比较。AURO 以及部分基线算法的训练曲线如原文图 5 所示。在时间步 20K 处与所有基线算法的对比结果列于表 2 左侧。CEM 和 DIN 的表现弱于其他基于强化学习的算法，说明强化学习在优化用户留存方面有效。TD3 和 SAC 的性能在训练早期有所提升，但随着训练进行会逐渐恶化。由于没有显式建模环境分布偏移，它们获得的策略会松散地耦合到特定用户行为模式，从而导致次优性能。OAC 和 RND 相比 TD3 与 SAC 没有显著提升，主要源于不安全探索过程。RLUR 和 OSPia 考虑了长期推荐优化中的偏差问题，因此优于 TD3 和 SAC，但训练不稳定，且比 AURO 需要更多步骤收敛。ESCP 引入上下文编码器，能够在一定程度上捕捉环境非平稳性，但它显式依赖单一隐藏参数，无法通用建模环境波动，因此整体性能仍然次优。

与基线算法相比，AURO 展现出稳定训练曲线以及最佳整体性能。其稳定性来自状态抽象模块，该模块使算法能够拟合不同环境动力学和奖励函数。良好的渐近性能则可归因于安全且高效的探索模块，该模块能够在环境变化时快速导航至高奖励区域。

表/图说明：原文表 2 左：模拟器中 AURO 与基线算法的性能比较。

→prule

算法 | 平均返回天数 ↓ | 次日返回率 ↑ | 留存奖励 ↑

CEM | 1.8580.232 | 0.7150.065 | -0.0180.001

DIN | 1.7250.029 | 0.7550.005 | -0.0170.001

TD3	1.7720.146	0.7380.048	-0.0170.001
SAC	1.8100.166	0.7260.053	-0.0170.001
DDPG	2.0120.013	0.6620.003	-0.0190.000
OAC	1.7940.070	0.7310.026	-0.0180.000
RND	1.8280.034	0.7240.012	-0.0180.000
ESCP	1.7050.125	0.7640.039	-0.0170.001
RL-LTV	1.7190.281	0.7610.050	-0.0170.003
RLUR	1.7060.114	0.7650.038	-0.0170.001
OSPJA	1.7260.113	0.8030.020	-0.0170.001
AURO	1.5310.058	0.8240.018	-0.0150.000

消融与分析。作者在修改后的 KuaiSim 模拟器中进行了消融实验，以分析 AURO 各模块作用，并研究超参数 n 和 δ 的不同取值影响。如表 2 右侧所示，移除任意组件都会导致整体性能下降。其中，探索模块影响最显著。这一对比强调了在优化稀疏留存信号时进行探索的必要性。如果不使用状态抽象，或者在没有基于价值的辅助损失的情况下训练状态抽象网络，AURO 性能也会下降。这说明第 3.3 节提出的状态抽象模块和新的基于价值的损失函数是有效的。不同 n 或 δ 取值对性能影响较小，表明方法对超参数选择具有鲁棒性。

表/图说明：原文表 2 右：消融实验结果。

→prule

设置	平均返回天数 ↓	次日返回率 ↑	留存奖励 ↑
无探索	1.8680.061	0.7080.015	-0.0180.000
无状态抽象	1.8030.109	0.7320.034	-0.0180.001
无辅助损失	1.6720.208	0.7760.068	-0.0170.002
$n=3$	1.5980.171	0.8040.029	-0.0160.002
$n=5$	1.5340.062	0.8150.011	-0.0150.001
$n=6$	1.5500.064	0.8120.011	-0.0160.001
$\delta=0.3$	1.5470.068	0.8130.013	-0.0160.001
$\delta=3$	1.5650.125	0.8080.023	-0.0160.001
AURO ($n=4, \delta=1$)	1.5310.058	0.8240.018	-0.0150.000

作者在原文图 6 中可视化展示了 AURO 的两个关键组件。图 6(a) 展示状态抽象模块输出：具有相似价值的状态会形成紧密聚集的抽象表示，而不同价值类别的状态倾向于具有不同抽象。图 6(b,c) 展示动作在某一维度变化时的状态-动作价值景观。AURO 的探索策略可以找到比固定步长探索动作更好的动作。图 6(d) 比较价值损失，其中 AURO 在训练过程中具有最低价值误差，说明状态抽象模块能够有效增强价值估计。

MovieLens 数据集实验

为了验证 AURO 在不同推荐任务中的有效性，作者使用著名推荐数据集 MovieLens-1M 进行评估。该数据集包含 6,040 名 MovieLens 用户对约 3,900 部电影给出的 1,000,209 条匿名评分。作者采样 5,000 名用户的数据作为训练集，并将其余用户的数据作为测试集。

遵循用户留存优化领域已有研究 ([42,45])，作者假设 MovieLens-1M 中用户平均返回天数与电影评分成比例。对于评分 1，赋予留存奖励 -1；对于评分 3、4、5，分别赋予留存奖励 1、2、3。为了在离线训练期间保证保守策略更新，作者移除探索模块，并在使用在线强化学习算法训练策略时加入 BC 损失，类似 TD3+BC ([15])。作者使用归一化截断重要性采样 (NCIS) ([39]) 进行离线算法评估。对比结果如表 3 所示，其中 AURO 取得最高性能。这说明即使没有显式用户行为变化，状态抽象模块在状态表示方面仍然有效。

表/图说明：原文表 3：修改后的 MovieLens-1M 数据集中不同算法的性能比较。

→prule

指标 | BC | CEM | TD3+BC | ESCP+BC | RLUR+BC | AURO+BC

留存奖励 | 1.7020.018 | 1.7080.055 | 1.7140.054 | 1.7550.031 | 1.7840.060 | 1.7980.032

在线实验

实验设置。在线实验中的 MDP 设置与第 2 节类似。各算法被集成到一个流行短视频推荐平台的候选排序系统中。在线实验持续两周，平均每天涉及 2,500 万活跃用户和数十亿次交互。在如此长时间跨度和如此大用户规模下，推荐环境会出现较大偏移，这一点也由第 3.1 节基于该平台采集数据的分析所展示。为了比较分析，用户被随机划分到若干桶中。第一个桶运行基线 RLUR，其余桶运行 AURO、TD3 和 ESCP。作者没有像数据集或模拟器实验中那样考虑大量基线，因为在线实验具有成本敏感性，较差算法可能使平台用户感到无聊或被打扰。在线实验中，留存信号可能存在噪声，并且有时会受到线上平台其他模块影响。因此，作者使用的主要指标是在 7 天内平均的用户返回平台比例，而不是 1 日留存率。作者还关注应用停留时长，以及即时用户响应，包括视频点击率、点赞率、评论率和不喜欢率。这些指标是推荐算法的标准评价标准，并在经验上被证明与长期用户体验相关 ([42])。

性能分析。对比结果如表 4 所示。表中统计量为相对于 RLUR 的千分比或百分比提升。AURO 在所有评估指标上都优于 TD3、ESCP 和 RLUR 等基线。具体而言，AURO 是唯一在应用停留时长上取得性能提升的算法。AURO 还将用户评论率提升了 8.392 千分比，几乎是 TD3 提升幅度的 5 倍。这些实证结果表明，AURO 在真实推荐平台上具有有效性和可扩展性。

从实际角度看，在线环境中一些朴素算法修改往往难以同时提升表 4 中的所有性能指标。这一现象已在文献 ([7]) 中被报道，也在本文在线实验中被观察到。在表 4 中，ESCP 可以提升 CTR 和点赞率，但会导致停留时长和评论率下降。相比之下，AURO 能够提升所有性能指标，同时显著降低负反馈率。这可能是因为已有方法只会推荐一些能够带来较高 CTR 或点赞率的常见物品，例如非常有趣的短视频或非常便宜的商品；与此同时，它们在推荐真正面向用户、考虑每个用户动态行为的物品方面能力有限，这一点从较差的用户停留时长和评论率可以看出。得益于用于策略适应的状态抽象模块，AURO 能够推荐及时更新且面向用户的物品，从而捕捉动态用户兴趣。AURO 中用户负反馈率的大幅下降为这一推断提供了证据。

表/图说明：原文表 4：在线实验中不同算法相对 RLUR 基线的性能比较。

→prule

算法 | 7日留存率↑ | 停留时长↑ | 点击率↑ | 点赞率↑ | 评论率↑ | 不喜欢率↓

TD3 | 0.0410.148 | -0.6850.297 | 1.4120.619 | 1.7981.127 | 1.7151.782 | -0.5670.820

ESCP | 0.1230.073 | -0.1150.277 | 0.7030.313 | 0.3020.952 | -1.9751.204 | -0.1160.791

AURO | 0.1380.089 | 0.2630.181 | 3.2600.332 | 2.8210.925 | 8.3921.881 | -1.8740.781

相关工作

用于推荐的强化学习。在强化学习 ([38]) 中，学习智能体与环境交互 ([31])，或者利用离线数据集 ([16])，以优化整个轨迹中获得的累积奖励。强化学习已被证明对推荐任务具有前景 ([1,29,34,48])。传统方法提出学习额外预测模型 ([2,41])，或显式构建高保真模拟器 ([35])，以提升强化学习算法样本效率。它们也可以被划分为基于价值的方法 ([9,25]) 或基于策略的方法 ([8])。近年来，越来越多研究关注使用强化学习优化用户留存 ([55])。RLUR ([6]) 和 OSPIA ([43]) 处理了该领域中伴随出现的问题，包括延迟奖励、不确定性以及训练不稳定等，它们也作为本文实验中的基线。其他方法关注奖励工程，例如采用受约束 Actor-Critic 方法 ([7]) 或纳入人类偏好 ([44])。本文同样旨

在优化用户留存，但重点在于缓解非平稳环境挑战，而这一挑战在以往方法中很大程度上被忽视。

基于强化学习的自适应策略训练。已有少量强化学习算法用于在存在分布偏移的演化环境中训练自适应策略。Meta-RL 算法 ([3,32]) 可以通过对测试环境中的少量数据微调来适应新环境。ESCP ([30])、CaDM ([22]) 和 SRPO ([46]) 等零样本适应算法无需额外数据即可拟合新环境。使强化学习策略能够快速适应的关键组件之一是上下文编码器 ([30])，它以一组历史状态作为输入，并生成表示不同上下文的稠密向量。该编码器可以通过变分推断 ([14,54]) 或辅助损失 ([30]) 训练。其输出可以作为环境模型 ([22]) 或策略网络 ([46]) 的额外输入。其他方法则关注表示学习 ([47]) 或重要性采样 ([28])。然而，这些方法都没有专门考虑推荐系统复杂性，直接应用时可能不可靠或效率较低。关于用户兴趣演化的推荐相关研究，作者将其放在附录 B 中。

结论

本文研究了使用强化学习优化用户留存时面临的非平稳环境挑战。通过数据驱动分析，作者识别出用户行为中的多个波动因素，例如即时反馈正样本比例和用户返回时间分布，并将它们视为非平稳性的主要原因。为应对这一挑战，作者提出 AURO 算法，用于训练自适应推荐策略。AURO 使用一种新的基于价值的对比损失，在策略网络中训练额外状态抽象模块。状态抽象使强化学习策略能够通用地识别不同类型的用户行为模式波动。为了促进安全且高效的策略适应，本文将不确定性下的乐观思想与拒绝采样相结合，从而增强探索。实验结果表明，AURO 在优化长期且非平稳的用户留存方面优于先进方法。面对环境动力学和奖励函数的分布偏移时，它也能够保证稳定推荐质量。

伦理声明

虽然本文方法涉及真实用户日志，但所使用用户数据已经去除了所有敏感隐私信息。每个用户都由匿名用户 ID 表示，敏感特征以 one-hot 向量形式加密。

致谢

本研究由新加坡国家研究基金会和 DSO National Laboratories 在 AI Singapore Programme 下支持 (AISG Award No: AISG2-GC-2023-009)。作者感谢 Shuchang Liu 的有益讨论。

详细推导

损失 $J_{\text{same}}(\phi)$ 可推导如下：

$$\begin{aligned} J_{\text{same}}(\phi) &= \sum_{k=1}^n \sum_{i,j} C_k \phi(s_i) - \phi(s_j)_{-2}^2 \\ &= \sum_{k=1}^n [\sum_i C_k \phi(s_i)_{-2}^2 - 2 \sum_{i,j} C_k \phi(s_i) \phi(s_j)] \\ &= 2B \sum_{k=1}^n \sum_i C_k \phi(s_i)_{-2}^2. \end{aligned}$$

损失 $J_{\text{diff}}(\phi)$ 可推导如下：

$$\begin{aligned} J_{\text{diff}}(\phi) &= - \sum_{k=1}^n \sum_{m>k} C_k C_m \phi(s_i) - \phi(s_j)_{-2}^2 \\ &\leq -B \sum_{k=1}^n \sum_{m>k} C_k \phi(s_i)_{-2}^2 \\ &\leq -B^2 \sum_{k=1}^n \sum_{m>k} \phi_k - \phi_m_{-2}^2. \end{aligned}$$

补充相关工作：用户兴趣演化的推荐

已有 point-wise 或 list-wise 推荐模型已经纳入用户行为演化的概念，但它们主要关注用户兴趣分布变化 ([36])。然而，本文还考虑与长期用户体验相关的其他用户行为，例如即时响应比例和用户返回时间分布。为了建模演化的用户兴趣，文献 ([52,53]) 从历史行为中学习用户兴趣表示，并进行点击率预测。Brown 和 Agarwal ([4]) 提出，在面对自适应偏好时，应确保向用户推荐足够多样化内容。但该算法是在 bandit 设置下分析的，缺少经验验证。Zhao 等人 ([51]) 在训练过程中预测用户口味迁移，并将这些预测纳入后排序网络。另一类方法预测 top-k 目标客户分布，并据此训练推荐模型 ([50])。一些研究也指出，此类分布调整可能对整体推荐准确率产生负面影响 ([50])。与其预先预测用户行为并训练推荐模型，本文更关注新分布识别以及快速适应这些分布的能力。

算法

表/图说明：原文算法 1：AURO 的工作流程。

p0.08X

→prule

步骤 | 内容

- 1 | 输入状态抽象网络 ϕ_{π} 、确定性策略 π_{θ} 、状态-动作价值函数 Q_{π} 、replay buffer D 、训练步数 N 和训练 horizon H 。
- 2 | 初始化网络和 replay buffer。
- 3 | 对 $1, 2, 3, \dots, N$ 循环。
- 4 | 对 $t=1, 2, \dots, H$ 循环。
- 5 | 从 $\phi_{\pi}(s_t)$ 得到 z_t ，并从 $\pi_{\theta}(s_t, z_t)$ 采样 a_t 。
- 6 | 使用式 (7) 得到探索动作 a_E ，并设置 $a_t = a_E$ 。
- 7 | 与模拟器交互，得到转移数据 $(s_{t+1}, r_t, d_{t+1}, s_t, a_t, z_t)$ ，并加入 D 。
- 8 | 结束内层循环。
- 9 | 根据式 (5) 更新状态抽象网络 ϕ_{π} 。
- 10 | 使用 replay buffer D 和 TD3 算法更新策略与价值网络参数 θ 和 Q 。
- 11 | 结束外层循环。

AURO 与 TD3 的主要区别包括两点。第一，策略额外接收潜变量 z_t 作为输入；该潜变量是状态抽象模块 ϕ_{π} 的输出，并通过式 (5) 所指定损失训练。第二，探索动作 a_E 由式 (7) 生成，而不是通过在原始动作 a_t 上添加高斯噪声生成。

算法局限与失败案例。本文聚焦于优化用户留存，没有考虑留存信号与即时用户反馈的结合。如何平衡这两类奖励信号是值得研究的问题。该算法的潜在失败案例之一是，用户表现出算法从未见过的异常或对抗性模式。例如，用户可能突然厌倦应用，并不喜欢推荐给他的任何物品。状态抽象模块可能无法适应该行为模式，也无法推荐合适物品。另一个案例是用户非常固执，不会点击任何其不熟悉的新颖物品。在这类用户上，探索模块可能会比贪婪推荐方法导致更差留存性能。作者还指出，在其真实推荐平台中，基于强化学习的算法只是长推荐链路中的一步。AURO 选择的物品不会在进一步排序和过滤之前直接展示给用户。过滤机制保证不会向用户展示危险或非法物品。当类似算法应用于真实世界时，未来实践者必须重视物品过滤等后处理步骤，以实现安全且鲁棒推荐。

补充实验细节

实验设置

根据 KuaiSim \([49]\)), 留存模拟器网络结构与策略网络类似。作者假设即时用户响应服从伯努利分布, 用户返回时间 (以天为单位) 服从几何分布。模拟器以监督学习方式训练, 并通过最大化训练数据似然更新。AURO 训练时的超参数见表 5。

表/图说明: 原文表 5: AURO 算法的超参数。

→prule
超参数 取值
优化器 Adam
学习率 3×10^{-4}
Batch size B 256
Transformer 层数 2
前馈网络维度 64
注意力头数 4
折扣因子 γ 0.9
奖励权重参数 λ -0.1
Replay buffer 大小 5×10^4
目标平滑系数 0.005
目标更新间隔 1
动作空间维度 k 7
聚类数量 n 4
探索中的 β 30
探索中的 δ 1
候选动作数量 6

基线算法

在 KuaiSim 模拟器中的对比实验里, 作者考虑 CEM、DIN、DDPG、TD3、SAC、OAC、RND、ESCP、OSPia 和 RLUR。CEM 是交叉熵方法, 常被用作推荐任务中强化学习的替代方法。DIN 是深度兴趣网络, 从历史行为中学习用户兴趣表示并执行点击率预测; 作者保持 DIN 原始输入不变, 并使用与 AURO 结构相同的 Transformer 作为 backbone, 以便公平比较。DDPG 是基于价值的离策略强化学习算法, 使用确定性策略梯度更新确定性策略。TD3 在 DDPG 基础上引入一对 Q 网络, 以缓解过估计问题。SAC 使用随机策略和最大熵强化学习目标。OAC 融合不确定性下乐观探索思想, 并在训练阶段获得单独乐观动作。RND 将状态输入编码以拟合随机网络输出, 编码误差较大的状态会被赋予更高内在奖励。ESCP 是环境敏感上下文 Meta-RL 方法, 显式识别隐藏参数并将其作为额外策略输入; 在线实验中作者使用用户活跃度水平作为代理隐藏参数。OSPia 是一步策略改进算法, 使策略偏向于具有更高长期用户参与度指标的推荐。RLUR 是专门为优化长期用户参与度设计的强化学习推荐算法。

探索模块的计算成本

AURO 在动作选择中需要额外步骤, 包括计算 Q 函数梯度, 并在候选动作中采样。但除了动作选择之外, 强化学习训练还包括与环境交互以及通过梯度下降更新策略。这两部分通常比动作选择更耗时。作者在表 6 中展示一个训练步骤中动作选择的平均时间成本, 同时展示总时间成本。结果表明, 尽管探索模块使动作选择计算成本增加 129%, 但总时间只增加不到 10%。此外, 在部署期间探索模块不会被包含, 因此不会带来额外计算成本。

表/图说明: 原文表 6: 一个训练步骤中动作选择的平均时间成本。

→prule
方法 动作选择时间 (秒) 总时间 (秒)

AURO | 0.259 | 1.738

AURO（无探索） | 0.113 | 1.595

探索时间成本 | 129% | 8.966%

参考文献

参考文献列表较长，本文保留原文编号引用格式。完整条目见原论文 References 部分；其中包括 RL 推荐综述、RLUR、KuaiSim、TD3、SAC、OAC、ESCP、MovieLens 离线评估相关工作以及用户兴趣演化推荐等文献。