

xMTF：一种用于推荐系统中基于强化学习多任务融合的无预定义公式模型

逐段中文翻译

原文作者：Yang Cao, Changhao Zhang, Xiaoshuang Chen, Kaiqiao Zhan, Ben Wang

WWW 2025

说明

本文根据论文 *xMTF: A Formula-Free Model for Reinforcement-Learning-Based Multi-Task Fusion in Recommender Systems* 逐段翻译整理。为便于阅读，保留原文的章节结构、公式、表格、算法流程和图题说明；图像本体未重绘，改为中文说明。

摘要

推荐系统需要同时优化多种用户反馈，例如点击、点赞和分享。一个处理多种反馈类型的典型推荐系统通常包含两个组成部分：多任务学习（Multi-Task Learning, MTL）模块，用于预测点击率、点赞率等反馈；多任务融合（Multi-Task Fusion, MTF）模块，用于将这些预测整合为一个单一分数以进行物品排序。MTF 对保证用户满意度非常关键，因为它会直接影响推荐结果。近年来，强化学习（Reinforcement Learning, RL）被用于 MTF 任务，以提升用户长期满意度。然而，现有基于强化学习的 MTF 方法大多是基于公式的方法，只能在预定义公式中调整有限数量的系数。预定义公式限制了强化学习的搜索空间，并成为 MTF 的瓶颈。为解决这一问题，本文提出一种无预定义公式的 MTF 框架。根据 Sprecher 表示定理，本文说明任意合适的融合函数都可以表示为若干单变量单调函数的组合。基于此，本文提出一种新的可学习单调融合单元（Monotonic Fusion Cell, MFC）来替代预定义公式，并将该基于 MFC 的模型称为 eXtreme MTF（xMTF）。进一步地，本文采用两阶段混合（Two-Stage Hybrid, TSH）学习策略有效训练 xMTF。通过扩展 MTF 的搜索空间，xMTF 在大量离线和在线实验中均优于已有方法。

CCS 概念：信息系统 → 推荐系统。 **关键词：**多任务融合；强化学习；推荐系统。

1 引言

推荐系统在电商、视频、新闻等多类平台中发挥着越来越重要的作用。实际推荐系统通常需要优化多种类型的用户反馈。例如，在视频平台中，用户满意度会同时受到观看时长以及点赞、关注、分享等互动行为的影响。因此，推荐系统必须综合考虑多种反馈类型，才能给出最终推荐。一个处理多种反馈类型的典型推荐系统包含两个模块：MTL 模块负责预测点击率、点赞率等反馈；MTF 模块负责将这些预测整合为一个单一分数，用于物品排序。图 1 展示了 MTL 与 MTF 的关系。

图 1：推荐系统中的 MTL 与 MTF。候选召回模块得到候选物品后，MTL 输出 K 类预测 $o_{1i}, o_{2i}, \dots, o_{Ki}$ ，MTF 将这些预测融合为排序分数 z_i ，再按 z_i 返回 Top 物品。

MTF 对保证推荐系统的用户满意度至关重要，因为它会直接影响推荐结果。然而，与已经被广泛研究的 MTL 相比，MTF 更具挑战性。MTF 需要把多种用户反馈预测整合为一个单一分数，以反映用户整体满意度。但用户通常不会直接对每个物品给出整体满意度反馈。相反，整体满意度往往体现在会话长度、日观看时长、留存等长期反馈中，而这些反馈无法直接对应到某一个单独推荐物品上。

近年来，强化学习被越来越多地用于 MTF。基于强化学习的方法将用户视为环境，将推荐系统视为智能体，并把融合权重视为强化学习动作。通过建模长期用户满意度，这类方法已经被证明对 MTF 有效。

不过，现有基于强化学习的方法都是基于公式的 MTF 方法。它们会定义融合公式 $f(o_1, \dots, o_K; a_1, \dots, a_K)$ ，其中 $o_1, \dots, o_K$ 为 K 个预测结果， $\mathbf{a} = [a_1, \dots, a_K]$ 为系数，并将系数 $\mathbf{a}$ 作为强化学习动作。表 1 给出了已有研究中的典型融合公式。

表 1: 已有研究中的典型融合公式

序号	公式	文献
1	$z_i = \sum_{k=1}^K a_k o_{ki}$	[1,33]
2	$z_i = \sum_{k=1}^K a_k \log(o_{ki} + \beta_k)$ ，其中 β_k 为预定义参数	[34]
3	$z_i = \prod_{k=1}^K o_{ki}^{a_k}$	[3]

通过预定义融合公式，强化学习只需要优化少量系数，因此学习更容易。但预定义公式存在几个问题。第一，不同公式会导致不同推荐结果，因此很难确定最优公式，尤其是不同用户可能适合不同公式。第二，预定义公式会限制 MTF 的搜索空间，进而导致模型性能不足。

为解决该问题，本文提出无预定义公式的 MTF 框架 eXtreme MTF (xMTF)，整体结构如图 2 所示。本文首先说明，任意合适的融合函数都可以表示为针对每个预测值 o_{ki} 的单变量单调函数组合。基于此，xMTF 引入新的单调融合单元 MFC，用于学习输入预测值的单调变换。MFC 具有三个特点：其一，MFC 能捕获输出与输入变量之间的单调性，这是 MTF 的重要内在结构，因此具有可解释性；其二，MFC 是可学习的，可替代已有方法中的预定义融合公式，从而扩展搜索空间；其三，可学习 MFC 能为不同用户和不同预测结果提供个性化融合函数，而基于公式的方法通常只能个性化少数系数。

图 2：xMTF 的整体结构。图中依次展示普通融合函数、Sprecher 表示、基于可学习 MFC 的 xMTF 框架，以及 xMTF 的训练过程。

更大的搜索空间会使 xMTF 的训练更复杂，现有基于强化学习的方法无法直接适用。为此，本文提出两阶段混合 (TSH) 训练方法，包含一个基于强化学习的外层阶段和一个基于监督学习的内层阶段。外层阶段参数较少，并将这些参数作为强化学习动作来学习长期奖励；内层阶段参数更多，通过监督学习吸收外层阶段的知识。TSH 使 xMTF 能够被有效训练，并显著优于已有方法。

本文贡献如下：第一，提出无预定义公式的 MTF 框架 xMTF，用于扩展 MTF 搜索空间；第二，提出可学习 MFC 替代预定义公式，捕获 MTF 的内在单调性，并支持个性化融合函数；第三，提出 TSH 训练 xMTF，解决搜索空间增大带来的训练困难；第四，大量离线和在线实验验证 xMTF 的有效性，并且该模型已部署在线上系统，服务超过 1 亿用户。

2 相关工作

2.1 多任务学习

MTL 同时预测多种用户反馈，例如点击率和点赞率。MMoE 使用多个专家网络捕获任务特定模式并共享信息。PLE 动态分配共享层和任务特定层以提升准确性。也有研究关注嵌入学习中的负迁移以及梯度冲突问题。

MTL 能生成多种用户反馈的预测结果，但如何利用这些预测形成最终推荐仍然困难。为此，推荐系统通常在 MTL 后接入 MTF 模块，将多个预测整合为一个排序分数。

2.2 多任务融合

MTF 为每个物品生成单一分数，用于最终推荐并提升用户整体满意度。MTF 不同于 MTL，因为用户不会直接对每个物品给出整体满意度反馈；整体满意度通常由长期奖励体现。常见方法是预定义融合公式，并通过网格搜索、贝叶斯优化或交叉熵方法等黑盒优化方法寻找最优系数。这些方法得到的是非个性化系数，难以反映个人偏好。

近年来，基于强化学习的方法开始用于提供个性化系数并提升长期奖励。DRRS 通过确定 MTF 中的个性化系数最大化平台累计奖励；BatchRL-MTF 面向 MTF 推荐任务，解决实际推荐系统中传统离策略方法的 deadly triad 问题和外推误差问题；另有研究关注用户留存建模，以及多阶段推荐系统中的基于强化学习 MTF。

然而，已有非强化学习和强化学习 MTF 方法都依赖预定义融合公式，并只搜索有限数量的系数。预定义公式限制了 MTF 搜索空间，导致性能并非最优。本文通过无预定义公式的 MTF 框架解决这一限制。

3 问题形式化

本文首先介绍 MTF 的强化学习建模，然后讨论单调性性质以及现有基于公式方法的解决方案，最后分析挑战。

3.1 MTF 的强化学习建模

MTF 的目标是基于多种预测结果为每个物品计算一个融合值，以提升用户整体满意度。这种满意度通常反映在长期奖励中，例如总观看时长和留存。

强化学习将用户与推荐系统的交互建模为马尔可夫决策过程 $(S, \mathcal{A}, P, R, \rho_0, \gamma)$ 。其中 S 是状态空间， $\mathcal{A}$ 是动作空间， $P: S \times \mathcal{A} \rightarrow S$ 是转移函数， $R: S \times \mathcal{A} \rightarrow \mathbb{R}$ 是奖励函数， ρ_0 是初始状态， γ 是折扣因子。当用户打开应用时，一个会话开始，并由多个请求组成，直到用户离开。

在第 t 步，系统获得用户状态 $s_t \in S$ ，并由候选召回模块获得候选集合 Ω_t 。预测模型为每个物品 $i \in \Omega_t$ 提供 K 个预测 $o_{ki}, 1 \leq k \leq K$ ，通常包括点击率、点赞率、期望观看时长等。MTF 将 K 个预测融合为一个分数：

$$z_i = f(o_{1i}, o_{2i}, \dots, o_{ki}, \dots, o_{Ki}; a_t), \quad \forall i \in \Omega_t. \quad (1)$$

其中 $a_t \in \mathcal{A}$ 是函数 f 的参数，也是强化学习动作。

MTF 后，系统按照融合分数 z_i 返回 Top 物品。用户观看后给出反馈 $r_t = R(s_t, a_t)$ ，再转移

到下一状态 $s_{t+1} \sim P(s_t, a_t)$ ，并决定是否继续请求或离开。MTF 的目标是寻找最优动作 a_t ，最大化长期奖励：

$$\max_{a_t} R_t = \sum_{t'=t}^T \gamma^{t'-1} r_{t'}, \quad (2)$$

其中 T 是用户离开应用时的步数。动作可由策略函数建模：

$$a_t = \mu(s_t; \xi), \quad (3)$$

其中 ξ 是参数。DDPG、TD3、SAC 等强化学习模型均可用于学习策略函数和动作。

图 3： MTF 的 MDP 建模。每一步中，系统基于用户状态、候选集合、MTL 预测和 MTF 动作生成排序结果，并根据反馈进入下一状态。

看似只要给出式 (1) 中融合函数的参数化形式以及待优化参数 a_t ，典型强化学习方法就可以寻找最优 a_t 。但融合函数 f 的选择并不简单。

3.2 挑战

MTF 中，融合函数 f 应满足单调性性质： $f(o_{1i}, \dots, o_{Ki})$ 关于每个预测 o_{ki} 单调递增。即若 o_{ki} 被更大的 o'_{ki} 替代，其他输入不变，则

$$f(o_{1i}, \dots, o_{ki}, \dots, o_{Ki}; a_t) \leq f(o_{1i}, \dots, o'_{ki}, \dots, o_{Ki}; a_t).$$

单调性很重要，因为推荐系统中的反馈（如点击率）通常与用户满意度正相关。如果违反单调性，可能出现预测分数上升但融合分数下降的情况，这与实际不一致。

为保证单调性，现有方法都采用基于公式的方式，即预定义单调融合公式，并把系数 a_k 作为强化学习动作。在这种设置下，动作数量等于预测类型数量 K ，非常小，因此搜索空间有限、性能受限。此外，融合公式本身如何选择也没有被充分研究。

若使用更复杂、参数更多的函数 f 扩展搜索空间，会面临两个挑战：一是如何用具有足够表达能力的模型刻画单调性；二是复杂函数会使强化学习动作 a_t 变得高维，导致训练极其困难。因此，需要权衡搜索空间与训练难度。第 4 节提出 xMTF 捕获单调性，第 5 节讨论其有效训练。

4 xMTF 框架

本节介绍 xMTF。首先说明融合函数可表示为多个单变量单调函数的组合，然后引入可学习 MFC 描述这些单调函数，从而更一般地刻画融合函数。

4.1 融合函数的表示

核心问题是找到合适模型刻画融合函数单调性。本文给出如下命题。

命题 4.1 (融合函数表示)： 若融合函数 $f(o_{1i}, o_{2i}, \dots, o_{Ki})$ 关于每个 o_{ki} 单调递增，则存在一个单变量单调递增函数 $g(\cdot)$ 和 K 个单变量单调递增函数 $h_k(\cdot)$ ，使得

$$f(o_{1i}, o_{2i}, \dots, o_{Ki}) = g\left(\sum_{k=1}^K q_{ki}\right), \quad (4)$$

其中

$$q_{ki} = h_k(o_{ki}). \quad (5)$$

证明：该命题是 Sprecher 构造的推论，见附录 A。

命题 4.1 表明，任意融合函数都可以分解为单变量单调函数。这一表示统一并扩展了表 1 中已有融合公式。表 2 给出这些公式对应的 g 和 h_k 。

表 2: 表 1 中已有公式的表示形式

序号	g	h_k
1	$g(x) = x$	$h_k(o_k) = a_k o_k$
2	$g(x) = x$	$h_k(o_k) = a_k \log(o_k + \beta_k)$
3	$g(x) = \exp(x)$	$h_k(o_k) = a_k \log(o_k)$

命题 4.1 保证了任意合适融合函数存在单调表示。因此，只要使这些单调函数可学习，就可以显著扩展 MTF 搜索空间。

4.2 带有 MFC 的 xMTF

首先，式 (4) 中的递增函数 g 不需要建模，因为它不影响结果集合排序；推荐系统只需按融合分数取 Top 物品。因此，只需为每种预测类型建模单调函数 h_k 。

本文将第 k 个预测 o_{ki} 的 MFC 定义为一个可学习参数化函数，以用户状态 s_t 和预测 o_{ki} 为输入：

$$\tilde{q}_{ki} = \tilde{h}_k(o_{ki}, s_t; \theta_k), \quad (6)$$

其中 θ_k 为参数。为保证 MFC 单调性，训练时使用辅助 pairwise loss：

$$\mathcal{L}_k^{\text{mono}} = \sum_{i,j \in \Omega_t} \mathbf{1}_{o_{ki} < o_{kj}} \max\{0, \tilde{h}_k(o_{ki}, s_t; \theta_k) - \tilde{h}_k(o_{kj}, s_t; \theta_k)\}. \quad (7)$$

给定 $\tilde{q}_{ki}$ ，新的融合函数为

$$\tilde{z}_i = \tilde{f}(o_{1i}, o_{2i}, \dots, o_{Ki}) = \sum_{k=1}^K \tilde{h}_k(o_{ki}, s_t; \theta_k). \quad (8)$$

通过学习最优 θ_k ，式 (8) 无需预定义融合公式即可生成最终排序结果。MFC 还能提供个性化融合函数：相比式 (5)，式 (6) 额外引入用户状态 s_t ，使模型能为不同请求学习个性化单调变换。已有方法通常只在固定公式中个性化少量系数，而 MFC 将个性化权重扩展为个性化函数。

同时，MFC 可视为已有融合公式的扩展，能够捕获 MTF 的内在单调性结构。这种单调性还支持更有效的训练方法。

5 xMTF 的训练

本节介绍如何确定式 (6) 中的参数 θ_k 。本文提出两阶段混合 (TSH) 训练方法，包含一个动作数量较少的强化学习阶段和一个具有更多可学习参数的监督知识迁移阶段。

图 4： TSH 训练方法。外层阶段通过强化学习根据长期奖励调节融合结果，内层阶段通过监督学习吸收外层阶段知识，两者持续交互。

5.1 总体框架

目标是最大化式 (2) 中的长期用户体验 R_t 。为了降低强化学习训练难度，需要减少动作数量，因此不能把所有 θ_k 都作为动作，因为每个 θ_k 都包含大量参数。

TSH 的核心思想是将 MFC 分解为两个级联单调部分。定义 $\theta_k = (\theta_k^I, a_k)$ ，并将式 (6) 拆为

$$\tilde{q}_{ki}^I = \tilde{h}_k^I(o_{ki}, \mathbf{s}_t; \theta_k^I), \quad (9)$$

$$\tilde{q}_{ki} = \tilde{h}_k^O(\tilde{q}_{ki}^I; a_k). \quad (10)$$

其中 $\tilde{h}_k^I$ 为内层阶段， $\tilde{h}_k^O$ 为外层阶段。内层阶段参数多、表达能力强；外层阶段参数少，便于作为强化学习动作。选择简单外层函数不会降低 MFC 表达能力，因为给定任意原始函数 $\tilde{h}_k$ ，都可找到对应 $\tilde{h}_k^I$ 满足两阶段分解。

本文用不同方式训练两阶段：外层阶段参数少，用强化学习优化长期用户体验；内层阶段参数多，用监督学习保证收敛。但用户不会为每个物品提供综合反馈标签，因此内层监督学习仍有挑战。

为此，本文采用知识迁移：使用外层阶段输出作为内层阶段标签。外层阶段基于长期用户体验不断调整内层输出，内层阶段则吸收外层阶段的新知识。这样，内层阶段无需直接使用强化学习，也能学习长期满意度信息。

5.2 外层阶段

外层阶段是只含少量参数 a_k 的简单参数化函数，实践中使用二阶函数：

$$\tilde{h}_k^O(\tilde{q}_{ki}^I; a_k) = \tilde{q}_{ki}^I(1 + a_k \tilde{q}_{ki}^I). \quad (11)$$

此时每个 a_k 是标量。

将 a_k 作为强化学习动作。定义动作向量 $\mathbf{a} = \{a_1, \dots, a_K\}$ ，actor 网络生成动作：

$$\mathbf{a}_t = \mu(\mathbf{s}_t; \xi). \quad (12)$$

critic 函数 $Q(\mathbf{s}_t, \mathbf{a}_t; \phi)$ 估计长期奖励，critic 损失为

$$\mathcal{L}^{\text{critic}}(\phi) = [Q(\mathbf{s}_t, \mathbf{a}_t; \phi) - (r_t + \gamma Q(\mathbf{s}_{t+1}, \mu(\mathbf{s}_{t+1}; \xi^-); \phi^-))]^2. \quad (13)$$

其中 ξ^- 和 ϕ^- 分别为目标 actor 和目标 critic 参数。策略梯度为

$$\nabla_{\xi} J = \nabla_{\xi} \mu(\mathbf{s}_t; \xi) \nabla_{\mu} Q(\mathbf{s}_t, \mu(\mathbf{s}_t; \xi)). \quad (14)$$

5.3 内层阶段

内层阶段从外层阶段学习，以捕获长期用户体验。定义内层阶段之和：

$$\tilde{z}_i^I = \sum_{k=1}^K \tilde{q}_{ki}^I. \quad (15)$$

相较式 (8) 的实际输出 $\tilde{z}_i$ ， $\tilde{z}_i^I$ 不包含外层阶段。本文使用 $\tilde{z}_i$ 指导 $\tilde{z}_i^I$ 学习，从而将知识从外层迁移到内层。具体使用 BPR pairwise loss 保证二者排序一致：

$$\mathcal{L}^{\text{transfer}} = - \sum_{i,j \in \Omega_t} \mathbf{1}_{\tilde{z}_i < \tilde{z}_j} \log \sigma(\tilde{z}_j^I - \tilde{z}_i^I). \quad (16)$$

其中 $\tilde{z}_i$ 被视为标签。由于内层阶段表达能力强于外层阶段，内层可以吸收外层知识。

内层阶段的单调性损失为

$$\mathcal{L}_k^{\text{mono},I} = \sum_{i,j \in \Omega_t} \mathbf{1}_{o_{ki} < o_{kj}} \max\{0, \tilde{h}_k^I(o_{ki}, \mathbf{s}_t; \theta_k^I) - \tilde{h}_k^I(o_{kj}, \mathbf{s}_t; \theta_k^I)\}. \quad (17)$$

最终损失为

$$\mathcal{L}^I = \lambda \sum_{k=1}^K \mathcal{L}_k^{\text{mono},I} + (1 - \lambda) \mathcal{L}^{\text{transfer}}, \quad (18)$$

其中 λ 用于平衡两类损失。

算法 1: xMTF 的训练过程

输入：每个用户的训练数据 (replay buffer) $\{\mathbf{s}_{1:T}, \mathbf{a}_{1:T}, r_{1:T}, \mathbf{o}_{1:T}\}$ 。输出：MFC 内层阶段 $\tilde{h}_k^I(o_{ki}, \mathbf{s}_t; \theta_k^I)$ 、外层策略 $\mu(\mathbf{s}_t; \xi)$ 以及 critic 函数 $Q(\mathbf{s}_t, \mathbf{a}_t; \phi)$ 。

对 replay buffer 中每个包含 T 个请求的用户会话，依次遍历 $t = 1, \dots, T$ ：先收集奖励 r_t 、预测 $\mathbf{o}_t$ 和动作 $\mathbf{a}_t$ ；再进行外层 critic 学习 $\phi \leftarrow \phi - \alpha \nabla_{\phi} \mathcal{L}^{\text{critic}}(\phi)$ ；随后进行外层 actor 学习 $\xi \leftarrow \xi - \beta \nabla_{\xi} J$ ；最后进行内层学习 $\theta_k^I \leftarrow \theta_k^I - \eta \nabla_{\theta_k^I} \mathcal{L}^I(\theta_k^I)$ 。

6 实验

本文研究四个问题：RQ1, xMTF 与最先进 MTF 方法相比表现如何；RQ2, MFC 是否提升 xMTF 性能且是否可解释；RQ3, TSH 各组成部分如何影响性能；RQ4, xMTF 是否能在真实线上推荐系统中提升 MTF 性能。

6.1 离线实验设置

6.1.1 数据集与指标

本文选择 KuaiRand 作为离线数据集。该公开数据集来自快手，包含 27285 个用户和 32038725 个物品，提供用户与物品上下文特征以及多种用户反馈信号。本文考虑点击、长观看、点赞、关注、评论、分享六种反馈。MTL 模型性能不是本文重点，因此使用常用 MTL 模型 MMoE 生成每个物品上的反馈预测。得到预测后，MTF 将它们融合为最终分数并返回 Top 物品。

为模拟用户接收推荐后的行为，本文构建离线模拟器作为环境。当模拟器接收当前请求的推荐物品后，会生成用户反馈，并决定是否继续请求。退出规则为：若用户满意度被耗尽，则离开会话。过早退出会导致较差推荐性能。本文选择完整会话中所有物品的总观看时长（Total Watch Time）作为长期奖励和评价指标。

6.1.2 细节与基线

用户状态 s_t 包含用户画像、行为历史和请求上下文。xMTF 内层阶段使用 MLP 建模 $\tilde{h}_k^I$ ，外层阶段使用强化学习建模 $\tilde{h}_k^O$ 。为公平比较，所有方法的 actor 和 critic 均采用五层 MLP。每个实验进行 20 次试验并报告均值和标准差。

基线包括 CEM-1 和 CEM-2，它们分别采用表 1 的第一、第二个公式；还包括 TD3、BatchRL-MTF、TSCAC、MR-MPL 等基于公式的强化学习 MTF 方法，每类方法同样测试两种公式；xMTF 为本文提出的无预定义公式方法；此外还测试去掉外层或内层阶段的 xMTF 消融版本。

6.2 性能比较 (RQ1)

表 3 展示不同方法结果。CEM 为所有用户搜索全局系数，明显差于基于强化学习的方法，说明个性化系数和长期满意度建模很重要。TD3-2 优于 TD3-1，说明融合公式本身会影响 MTF 性能。xMTF 在所有方法中取得最好结果，因为它不依赖预定义公式，并提供更大的搜索空间。

表 3: 不同方法的离线性能

方法	总观看时长 (秒)
CEM-1	897.5(± 12.3)
CEM-2	931.2(± 13.5)
TD3-1	1088.7(± 13.7)
TD3-2	1129.1(± 14.8)
BatchRL-MTF-1	1137.3(± 13.1)
BatchRL-MTF-2	1185.4(± 12.6)
TSCAC-1	1153.3(± 12.8)
TSCAC-2	1194.7(± 12.4)
MR-MPL-1	1145.3(± 11.8)
MR-MPL-2	1189.6(± 12.3)
xMTF	1279.7(± 12.9)
xMTF w/o outer stage	1092.8(± 9.1)
xMTF w/o inner stage	1106.3(± 11.2)

6.3 MFC 的影响 (RQ2)

本文可视化 MFC。图 5 展示同一“长观看”预测在不同用户下 MFC 输入 o_{ki} 与输出 $\tilde{q}_{ki}$ 的关系；图 6 展示同一用户下不同预测对应的 MFC 输入输出关系。所有函数都表现出单调性，符合融合函数应关于输入变量单调这一事实，而这种单调性来自式 (17) 的单调性损失。

图 5：同一种“长观看”预测在不同用户下的 MFC 函数。不同用户曲线不同，但保持单调。

图 6：同一用户下不同预测类型对应的 MFC 函数。不同反馈预测的函数形态不同，并保持单调。

MFC 能为不同用户和不同预测捕获不同单调性质。图 5 说明不同用户的 MFC 不同，图 6 说明不同预测的 MFC 也不同。这些个性化融合函数来自可学习 MFC 扩大的搜索空间，是 xMTF 优于预定义公式方法的重要原因。

为考察单调性损失的影响，本文在不同 λ 下实验。 $\lambda = 0$ 表示不使用单调性损失， $\lambda = 1$ 表示只关注单调性损失。图 7 显示，当 $\lambda = 0$ 时输入输出几乎不具备单调关系；表 4 显示此时性能显著较差，说明单调性是必要的。 $\lambda = 0.4$ 取得最佳性能，因此为最终选取值。 $\lambda = 0.9$ 虽有更强单调性，但削弱了反映用户满意度的迁移损失，因此性能下降； $\lambda = 1$ 由于缺少迁移损失，性能也较差。

表 4: 不同超参数 λ 下的性能

超参数 λ	总观看时长 (秒)
$\lambda = 0$	732.8(± 18.2)
$\lambda = 0.1$	1073.2(± 14.6)
$\lambda = 0.4$	1279.7(± 12.9)
$\lambda = 0.9$	1254.4(± 12.5)
$\lambda = 1$	1103.1(± 16.3)

6.4 训练方法的影响 (RQ3)

首先，移除外层阶段、保留内层阶段，记为 xMTF w/o outer stage。这表示不使用强化学习建模长期满意度。其总观看时长为 1092.8 秒，明显差于 xMTF，说明长期满意度建模必要。

其次，移除内层阶段、保留外层阶段，记为 xMTF w/o inner stage。这会移除 xMTF 中表达能力最强的部分，此时模型退化为基于公式的 MTF: $z_i = \sum_{k=1}^K o_{ki}(1 + a_k o_{ki})$ 。其总观看时长为 1106.3 秒，差于 xMTF，说明本文模型优于基于公式 MTF。

6.5 在线实验 (RQ4)

本文在一个拥有超过 1 亿用户的热门短视频平台上评估 xMTF。平台对每个物品考虑有效观看、长观看、完整播放、期望观看时长、点赞、关注、评论、分享、主页访问等反馈。MTF 将这些反馈预测融合为最终分数，选择用户满意度最高的视频。本文使用日观看时长作为评价指标，因为它是长期奖励，能反映整体满意度；同时也考察播放次数和互动指标。

图 8: 在线系统实现。xMTF 按流式方式持续训练：用户退出会话后，会话数据立即进入 xMTF 模型训练，更新后的模型被部署到线上执行 MTF 任务。

在线实验中，用户被随机平均分为基线组和实验组。部署 xMTF 前的最新基线是 UNEX-RL，即一种考虑多阶段推荐系统的先进基于公式 MTF 模型。本文重点报告 xMTF 相对 UNEX-RL 的提升。

连续 7 天评估结果如表 5。xMTF 显著提升性能，其中日观看时长提升 0.833%，其他指标也有明显提升。一些互动指标如点赞、关注未超过置信区间，因此未列出。作者指出，在该平台上日观看时长提升 0.1% 已具有统计显著性，而 0.833% 是当年最大的提升之一。

表 5: xMTF 的在线性能

指标	xMTF 性能增益
日观看时长	+0.833% [-0.11%, 0.11%]
播放次数	+0.583% [-0.14%, 0.14%]
评论	+2.391% [-1.26%, 1.26%]
分享	+2.205% [-0.81%, 0.81%]

7 结论

本文提出一种无预定义公式的多任务融合框架 xMTF，用于最大化推荐系统中的用户长期满意度。xMTF 使用单调融合单元 MFC 捕获 MTF 的单调性质，从而无需预定义公式。为解决更大搜索空间带来的训练挑战，本文提出两阶段混合学习方法 TSH，有效训练 xMTF。大量离线和在线实验表明，xMTF 相比已有基于公式 MTF 方法具有明显优势。xMTF 已完整部署到线上系统，服务超过 1 亿用户。

A 命题 4.1 的证明

Sprecher 表示定理指出：对任意整数 $K \geq 2$ 和定义域 I ，存在实值严格单调函数 $h_k(x)$ ，使得 $y = h(x_1, x_2, \dots, x_K) = \sum_{k=1}^K h_k(x_k)$ 是 $y \in I$ 与 $(x_1, x_2, \dots, x_K) \in I^K$ 之间的双射，并且当 y 增大时，每个 x_k 都不会减小。任意定义在 $[0, 1]^K$ 上的连续函数都可表示为

$$f(x_1, x_2, \dots, x_n) = g(y) = g\left[\sum_{k=1}^K h_k(x_k)\right]. \quad (19)$$

命题 4.1 只需证明 g 的单调性。由于当 y 增大时每个 x_k 都不会减小，而 f 本身关于每个输入单调，因此 $g(y) = f(x_1, x_2, \dots, x_n)$ 是非递减的。证毕。

B 数据与超参数

表 6: KuaiRand 中用户反馈统计

反馈类型	稀疏比例
click	37.93%
long view	26.35%
like	1.51%
follow	0.12%
comment	0.25%
share	0.09%

表 7: xMTF 的超参数

超参数	取值
优化器	Adam
Actor 学习率	0.0001
Critic 学习率	0.0002
监督学习率	0.0002
Actor 动作维度	6
折扣因子	0.9
Replay Buffer 大小	1×10^6
训练 batch size	1024
Fine-Tuning	True
归一化观测	True
训练平台	Tensorflow

C 先前基线

CEM 是最早基线，随后作者依次在线上系统部署 TD3 和 UNEX-RL。TD3 相比 CEM 的日观看时长提升为 +0.414%（置信区间 [-0.12%, 0.12%]）；UNEX-RL 相比 TD3 的日观看时长提升为 +0.556%（置信区间 [-0.11%, 0.11%]）。

参考文献说明

参考文献部分在本文档中不逐条展开翻译，编号与原论文保持一致，便于回查原文。