

SLATEQ：一种面向推荐集合的可处理强化学习分解方法

原文：SLATEQ: A Tractable Decomposition for Reinforcement Learning with Recommendation Sets

逐段中文翻译

说明：本文依据用户上传论文内容进行逐段翻译整理，尽量保持原文结构、术语与公式编号一致。

摘要

面向推荐系统的强化学习 (RL) 方法旨在优化推荐结果，以提升用户的长期参与度。然而，在实际系统中，用户通常会同时看到由多个物品组成的推荐集合，而这些物品之间可能会共同影响用户的选择行为。因此，相关方法必须处理强化学习动作空间中的组合爆炸问题。本文提出了 **SLATEQ**，这是一种针对基于价值的时序差分学习与 Q 学习的分解方法，使得在存在推荐集合时，强化学习仍然具有可处理性。在对用户选择行为作出温和假设的条件下，我们证明：一个推荐集合的长期价值可以被分解为其组成物品逐项长期价值的一个可处理函数。我们在模拟环境中验证了该方法，并在 YouTube 平台上证明了分解式 TD 学习的可扩展性与有效性。

1 引言

在实际推荐系统中，大多数方法主要关注**短视预测**，即**估计用户对一次推荐的即时响应**，而**不考虑该推荐对后续用户行为的长期影响**。这种做法存在局限：如果能够建模推荐对未来行为的随机影响，那么系统便有机会在短期参与和长期收益之间进行权衡，例如主动探索用户兴趣，或者提升用户满意度。因此，推荐系统研究越来越关注用户行为的序列性，并使用时序模型进行建模，例如隐马尔可夫模型和循环神经网络，以及使用强化学习技术进行长期规划。然而，由于将此类模型大规模部署到真实系统中存在复杂性，强化学习在推荐领域的应用往往仍局限于受限场景。

许多推荐系统面临的一个挑战在于：系统往往会同时向用户**推荐多个物品**，这通常被称为一个**推荐集合** (recommendation slate)。这使得**强化学习问题具有一个巨大的组合动作空间**。近期关于组合动作强化学习的方法在这一问题上取得了一定进展，但由于其通用

性较强，仍无法扩展到大型真实推荐系统所面临的问题规模。本文提出一种新的推荐集合分解技术，称为 **SLATEQ**。该方法通过直接利用集合中各个单物品的长期价值估计，来估计整个推荐集合的长期价值。这种分解利用了用户选择行为的特殊性，但对用户选择仅作了最小化假设。

具体而言，首先，我们说明如何将 SLATEQ 分解嵌入到时序差分 (TD) 学习算法中，例如 SARSA 和 Q 学习，从而尽管系统始终以集合形式向用户展示物品，仍然能够在**单个物品层面**学习其长期价值。这一点对于泛化能力和探索效率都至关重要。接着，我们讨论优化问题，即如何构造使长期价值最大的推荐集合。这是训练阶段进行策略改进（例如在 Q 学习中）以及在线服务时选择最优推荐集合所必需的步骤。尽管底层优化问题具有组合性且呈分式形式，我们证明它可以通过**两步转化为线性规划**，并在多项式时间内求解。我们还表明，尽管**简单的 top-k 方法和贪心近似方法**没有理论保证，但在实践中表现良好。

最后，我们在离线模拟实验和 YouTube 视频推荐系统的在线实验中验证了该方法。结果表明，我们的方法具有良好的可扩展性，并且相较于短视推荐能够显著提升用户参与度。在线实验还展示了：基于现有短视系统的学习基础设施，部署 TD 与 RL 方法其实可以相对直接地实现。更多细节可参见扩展版本论文 [1]。

2 相关工作

推荐系统传统上主要依赖协同过滤技术。这类方法利用用户对部分物品的反馈——无论是显式反馈（如评分）还是隐式反馈（如消费行为）——直接估计用户对未见物品的偏好。随着研究的发展，推荐系统逐渐不再局限于显式偏好预测，而是进一步去刻画用户行为中更细致的方面，例如用户对特定推荐的响应方式，包括预测点击率、参与程度（如停留时长、观看时长、收听时长）、评分以及社交行为（如评论、分享）等。

较早将推荐建模为强化学习问题的的工作包括：**面向购物推荐的 MDP 模型**，以及用于**网页导航的 Q 学习**方法，但这些方法只能**处理非常小规模场景**，**例如数百个物品和数千名用户**。更近期的研究包括：将双聚类与强化学习算法结合的方法，以及若干商业应用。后者提出了一种可扩展的离策略策略梯度方法，但并不显式计算长期价值，也不建模推荐集合效应。Zhao 等人的工作考虑了基于 actor-critic 的推荐集合强化学习，并在电子商务数据集上进行仿真测试；虽然其动机与本文相似，但并未显式解决动作空间的组合复杂性。

在推荐系统中考虑推荐集合是十分常见的，这会由于集合本身的组合性而引入有趣的建模问题和计算问题。Swaminathan 等人利用逆倾向评分研究了推荐集合交互下的离策略评估与优化；Jiang 等人则使用变分自编码器来建模物品分布并生成推荐集合。

最优推荐集合通常依赖于用户选择行为。选择建模在计量经济学、心理学、统计学、运筹学与市场营销中均有广泛研究。最常见的用户选择模型大概是多项 Logit (MNL) 模型及其扩展，例如条件 Logit (CL) 模型。MNL 与 CL 都可看作一种更一般的**条件选择形式**的实例：对于用户 i ，其从候选集合 A 中选择物品 $j \in A$ 的非归一化概率为 $v(x_{ij})$ ，其中 v 是

关于用户-物品特征向量 x_{ij} 的某个函数：

$$P(j | A) = \frac{v(x_{ij})}{\sum_{\ell \in A} v(x_{i\ell})}. \quad (1)$$

在 CL 模型中, $v(x_{ij}) = e^{\tau u(x_{ij})}$, 其中 u 为效用函数。此类模型被广泛用于描述消费者选择或其他类型的用户行为。级联模型也被广泛用于解释用户对有序推荐列表、搜索结果等的浏览行为, 尤其适合捕捉位置偏置。

针对组合动作设计可处理的强化学习方法本身就十分困难。Sequential DQN 将一个 k 维动作分解为一个原子动作序列, 但它用状态空间指数级增大来换取动作空间的可分解性。Slate MDPs 则将推荐集合视为由原始动作组成的集合, 并用 DQN 学习整个物品集合的价值, 再通过贪心方法构造集合。然而, 这些方法要么要求单个原始动作可以脱离集合单独执行——这在推荐集合系统中并不可行——要么需要显式维护一个针对整个集合的 Q 函数, 因此并未真正解决表示、探索与泛化方面的组合复杂性问题。

3 推荐集合的 MDP 模型

本节构建一个面向内容推荐集合的马尔可夫决策过程 (MDP) 模型。我们考虑这样一个推荐系统：它向用户展示一个推荐集合, 用户从中选择零个或多个物品进行消费, 例如收听某些音乐曲目。在若干物品被消费后, 用户可能返回系统获取新的推荐集合, 也可能终止当前会话。用户对物品的响应可能包含多个维度, 例如参与程度 (如消费时长)、参与质量、超出推荐器直接控制范围的后续参与、评分反馈、分享行为等。本文在不失一般性的前提下, 将参与程度视为奖励。

会话优化可以建模为一个具有状态集合 S 、动作集合 A 、奖励函数 R 和转移核 P 的 MDP, 并带有折扣因子 γ 。其关键组成如下：

(1) 状态 S 表示用户状态, 既包括相对静态的用户特征 (如人口属性、兴趣), 也包括相关的用户历史或过去行为 (如历史推荐、已消费物品、参与程度等)。

(2) 动作 A 表示可能的推荐集合。设物品全集为 I , 则动作是满足 $A \subseteq I$ 且 $|A| = k$ 的子集, 其中 k 为推荐集合大小。

(3) 状态转移概率 $P(s' | s, A)$ 表示在状态 s 下采取动作 A 后, 系统转移到状态 s' 的概率。

(4) 奖励 $R(s, A)$ 是推荐集合的期望奖励, 用于刻画用户对集合 A 中物品的期望参与程度。

一个 (平稳、确定性) 策略 $\pi : S \rightarrow A$ 规定了在任一状态下应采取的动作。其价值函

数 V^π 与动作价值函数 Q^π 定义为:

$$V^\pi(s) = R(s, \pi(s)) + \gamma \sum_{s' \in S} P(s' | s, \pi(s)) V^\pi(s'), \quad (2)$$

$$Q^\pi(s, A) = R(s, A) + \gamma \sum_{s' \in S} P(s' | s, A) V^\pi(s'). \quad (3)$$

最优策略 π^* 在所有状态上统一最大化期望价值 $V(s)$, 其价值函数 V^* 由 Bellman 方程的不动点给出:

$$V^*(s) = \max_{A \in \mathcal{A}} \left[R(s, A) + \gamma \sum_{s' \in S} P(s' | s, A) V^*(s') \right], \quad (4)$$

$$Q^*(s, A) = R(s, A) + \gamma \sum_{s' \in S} P(s' | s, A) V^*(s'). \quad (5)$$

最优策略满足 $\pi^*(s) = \arg \max_{A \in \mathcal{A}} Q^*(s, A)$ 。

当已知状态转移模型和奖励模型时, 可以使用多种方法计算最优策略与价值函数; 但在大规模状态与动作问题中, 这些方法一般都需要近似。若只有采样数据, 则可以使用 SARSA 与 Q-learning 等强化学习方法。给定训练数据中的观测转移与奖励样本 (s, A, r, s', A') , Q 函数可以按下述方式更新 (其中 $\alpha^{(t)}$ 为学习率):

$$Q^{(t)}(s, A) \leftarrow \alpha^{(t)} [r + \gamma Q^{(t-1)}(s', A')] + (1 - \alpha^{(t)}) Q^{(t-1)}(s, A), \quad (6)$$

$$Q^{(t)}(s, A) \leftarrow \alpha^{(t)} \left[r + \max_{A'} \gamma Q^{(t-1)}(s', A') \right] + (1 - \alpha^{(t)}) Q^{(t-1)}(s, A). \quad (7)$$

其中, 式 (6) 对应 SARSA, 它是离线控制语境下的同策略方法, 用于估计数据生成策略 π 的价值, 即状态-动作对上的 TD 预测问题。不过, 只要策略包含足够探索或其他随机性——这在大型推荐系统中非常常见——那么对 Q^π 采取贪心动作, 并使用由此产生的数据训练新 Q 函数, 就实现了策略改进; 重复这一过程即可收敛到最优 Q 函数。式 (7) 对应 Q-learning, 它是离策略方法, 直接估计最优 Q 函数。与 SARSA 不同, Q-learning 在训练时不仅需要在服务阶段构造最优推荐集合, 还需要在**训练阶段**就能计算最优后继集合 A' 。

4 SLATEQ: 面向强化学习的推荐集合分解

上述建模中的一个关键难点在于动作空间具有组合性质: 所有有序的 k 元集合数量为 $\binom{|I|}{k} \cdot k!$ 。这给强化学习带来两方面困难。首先, 动作空间规模过大, 使得充分探索变得不现实; 如果不使用压缩表示, 推荐集合之间的 Q 值泛化也十分困难。其次, 还存在寻找最大 Q 值推荐集合的组合优化问题。若不引入结构性假设或近似, 这一优化问题无法满足生产级推荐系统对在线时延的要求 (通常仅有几十毫秒)。

为了解决这一问题, 本文对系统动态与用户选择行为之间的关系作出两个假设, 并据此提出 SLATEQ, 使得一个推荐集合的 Q 值可以被分解为其组成物品逐项 Q 值的组合。下

面先给出这种分解，然后说明它如何使推荐集合优化变得可处理。

4.1 推荐集合 Q 值的分解

我们将用户从推荐集合中**不选择任何物品**视为选择了一个**空物品** $\perp$ ，它隐式地存在于每一个推荐集合中。为了得到 SLATEQ 分解，我们先对用户从推荐集合中选择物品的行为作出两个假设：

- **单一选择 (SC)**: 用户从每个推荐集合中只消费一个物品（也可能是空物品 $\perp$ ）。
- **奖励/转移仅依赖于被选物品 (RTDS)**: 实际获得的奖励（即用户参与） $R(s, A)$ 仅依赖于用户所消费的物品 $i \in A$ ；同样，状态转移 $P(s' | s, A)$ 也仅依赖于被消费的物品 $i \in A$ 。

SC 假设意味着用户只会从集合 A 中选择一个单元子集 $B \subseteq A$ 且 $|B| = 1$ 。这一假设在第二节介绍的条件选择模型（包括 CL）与级联模型中都成立。尽管在某些设置下该假设具有一定限制，但在本文所关注的应用中，用户一次只消费一个内容项；如果用户回到原集合再消费第二个物品，那将被视为新的状态与新的事件。

RTDS 假设在许多推荐系统中是合理的，尤其是对于即时奖励而言更是如此。关于状态转移的部分，它适用于这样一类推荐系统：真正驱动用户效用、整体满意度与新兴趣形成的是用户**与物品的直接交互**。当然，在另一些系统中，哪怕用户没有消费某个物品，仅仅看到这个曝光本身也可能引发后续好奇心，此时 RTDS 可以被视为一种简化假设。基于 RTDS，可将奖励与状态转移写为：

$$R(s, A) = \sum_{i \in A} P(i | s, A) R(s, i), \quad (8)$$

$$P(s' | s, A) = \sum_{i \in A} P(i | s, A) P(s' | s, i). \quad (9)$$

对于一个固定的数据生成策略 π ，本文对同策略 Q 函数的分解依赖于一个逐项辅助函数 $Q^\pi(s, i)$ ，它表示用户消费物品 i 时的长期价值，即在**已知该物品被点击/被选中**条件下，该物品的长期价值。在 RTDS 下，这个函数与物品 i 是从哪个推荐集合 A 中被选出的无关。其定义为：

$$Q^\pi(s, i) = R(s, i) + \gamma \sum_{s' \in S} P(s' | s, i) V^\pi(s'). \quad (10)$$

由此，在 SC 假设下可立即得到如下命题。

命题 1. 对任意推荐集合 A ，有

$$Q^\pi(s, A) = \sum_{i \in A} P(i | s, A) Q^\pi(s, i).$$

其证明思路很直接：从 $Q^\pi(s, A)$ 的定义出发，利用式 (8) 与式 (9) 将奖励项和状态转移项分别按所选物品展开，然后将同一物品对应的即时奖励与未来价值合并，即可得到上述结果。原文对应推导为：

$$Q^\pi(s, A) = R(s, A) + \gamma \sum_{s' \in S} P(s' | s, A) V^\pi(s') \quad (11)$$

$$= \sum_{i \in A} P(i | s, A) R(s, i) + \gamma \sum_{i \in A} P(i | s, A) \sum_{s' \in S} P(s' | s, i) V^\pi(s') \quad (12)$$

$$= \sum_{i \in A} P(i | s, A) \left[R(s, i) + \gamma \sum_{s' \in S} P(s' | s, i) V^\pi(s') \right] \quad (1)$$

$$= \sum_{i \in A} P(i | s, A) Q^\pi(s, i). \quad (13)$$

其中，式 (12) 直接来自 SC 与 RTDS 假设，式 (13) 则来自 $Q^\pi(s, i)$ 的定义。

这个简单结果表明：推荐集合的 Q 值可以被完全分解为单个物品的 Q 值。因此，只要我们能够通过 TD 方法学习 $Q^\pi(s, i)$ ，原先的组合困难就会消失。幸运的是，一个简单的 Q 更新式即可做到这一点。

给定在状态 s 下被消费的物品 i ，其观测奖励为 r ，系统转移到状态 s' ，且下一时刻推荐集合为 $\pi(s') = A'$ ，则可按如下方式更新 Q^π ：

$$Q^\pi(s, i) \leftarrow \alpha \left(r + \gamma \sum_{j \in A'} P(j | s', A') Q^\pi(s', j) \right) + (1 - \alpha) Q^\pi(s, i). \quad (14)$$

需要注意的是，这个更新式假定已知用户选择模型 $P(i | s, A)$ 。类似 MNL、CL 与级联模型都可以独立于长期价值，从用户响应数据中学习得到。事实上，大多数推荐系统原本就使用预测物品点击率的模型，只是忽略了集合内部的相互作用。我们可以将现有 pCTR 模型 v 的分数或 logit 作为物品在状态 s 下对用户相对吸引力的代理量，并将其用于本文的各种选择模型之中。

这种分解式 SLATEQ 更新使得 Q 值模型能够更加紧凑：模型的动作输入由整个推荐集合缩减为单个物品。这将带来更强的泛化能力与更高的数据利用效率。更重要的是，虽然 SLATEQ 学习的是**物品级** Q 值，但在标准条件下，它依然可以收敛到正确的**集合级** Q 值。

命题 2. 在学习率调度与探索起点满足标准条件，并且用户选择概率、状态转移与奖励满足前述假设时，SLATEQ 使用更新式 (14) 以及集合价值定义式 (13) 将收敛到真实的集合 Q 函数 $Q^\pi(s, A)$ ，并能够支持对策略 π 的贪心改进。

原文给出的证明思路是：TD(0) 的标准收敛证明可直接适用于 Q^π ，唯一新增之处在于对用户选择引入了显式期望，即在后继集合上取 $\sum_{j \in A'} P(j | s', A')$ ，而不是使用采样值。但这种显式期望不会破坏收敛性，类似 expected SARSA 的分析即可说明这一点。至于探索，如果选择模型允许某个物品 j 在某一状态下对任何被策略选中的集合都满足 $P(j | s, A) = 0$ ，

那么在策略 π 下, 状态 s 中的物品 j 将永远不会被采样, 这会导致 Q^π 难以学习。因此探索机制必须与选择模型相协调, 例如采样所有集合, 或构造确保每个物品都能被选中的探索集合。对大多数选择模型而言, 每个物品的选择概率都非零, 因此标准动作级探索条件依然适用。

若要将式 (10) 修改为最优的离策略物品级 Q 函数 $Q(s, i)$, 只需要将其中的 $V^\pi(s')$ 替换为 $V^*(s')$ 。同理, 将分解式更新从式 (14) 扩展到完整的 Q -learning, 只需加入通常的最大化操作:

$$Q(s, i) \leftarrow \alpha \left(r + \gamma \max_{A' \in \mathcal{A}} \sum_{j \in A'} P(j | s', A') Q(s', j) \right) + (1 - \alpha) Q(s, i). \quad (15)$$

命题 1 与命题 2 的对应结论也可以自然扩展到这一情形。

4.2 推荐集合 Q 值的优化

接下来讨论组合性的长期价值推荐集合优化问题, 即: 在所有可能集合中, 给定选择模型的前提下, 寻找期望 Q 值最大的推荐集合。这一问题不仅在使用 Q -learning 训练时是必需的, 在部署阶段执行任意 Q 函数诱导的贪心策略时也同样需要。本文重点考虑一般条件选择模型, 即式 (1) 所示模型, 其中 CL 与 MNL 都是其特例。在这类模型中, 集合中物品的排列顺序不会影响选择概率, 因此动作空间是所有大小为 k 的**无序**集合, 总数为 $\binom{|I|}{k}$ 。

精确优化 长期价值的推荐集合优化问题可表述为:

$$\max_{A \subseteq I, |A|=k} \sum_{i \in A} P(i | s, A) Q(s, i). \quad (16)$$

在一般条件选择模型式 (1) 下, 包括 MNL 与 CL, 这个问题可以写成一个分式混合整数规划。对每个物品 $i \in I$ 引入二元变量 $x_i \in \{0, 1\}$, 表示该物品是否进入推荐集合, 则有:

$$\max \frac{\sum_{i \in I} x_i v(s, i) Q(s, i)}{v(s, \perp) + \sum_j x_j v(s, j)} \quad (17)$$

$$\text{s.t.} \quad \sum_{i \in I} x_i = k, \quad x_i \in \{0, 1\}, \quad \forall i \in I. \quad (18)$$

这是经典产品线优化问题的一种简化变体。可以证明, 这里的二元指示变量可被松弛, 从而得到如下分式线性规划:

$$\max \frac{\sum_{i \in I} x_i v(s, i) Q(s, i)}{v(s, \perp) + \sum_j x_j v(s, j)} \quad (19)$$

$$\text{s.t.} \quad \sum_{i \in I} x_i = k, \quad 0 \leq x_i \leq 1, \quad \forall i \in I. \quad (20)$$

该松弛问题的约束矩阵是全酉模的, 因此其最优解天然就是整数解, 从而可以使用标准非线性优化方法来求解。但由于它本身是一个分式线性规划, 还可以进一步用 Charnes-Cooper 变换将其直接改写为普通线性规划。

为此, 引入变量 t , 其隐式表示所选物品总选择权重的倒数:

$$t = \left(v(s, \perp) + \sum_j x_j v(s, j) \right)^{-1},$$

同时引入辅助变量 y_i 表示 $x_i \left(v(s, \perp) + \sum_j x_j v(s, j) \right)^{-1}$, 则可得到线性规划:

$$\max \quad \sum_i y_i v(s, i) Q(s, i) \quad (21)$$

$$\text{s.t.} \quad t v(s, \perp) + \sum_i y_i v(s, i) = 1, \quad (22)$$

$$t \geq 0, \quad \sum_i y_i \leq kt. \quad (23)$$

该线性规划的最优解 $(\mathbf{y}^*, t^*)$ 可以恢复出原分式线性规划中的最优 x_i :

$$x_i = \frac{y_i^*}{t^*}.$$

进一步, 原始问题中的最优推荐集合可由 $y_i^* > 0$ 的物品组成。

观察 3. 在一般条件选择模型和固定集合大小 k 的条件下, 长期价值推荐集合优化问题, 即式 (16), 可以在物品数 $|I|$ 的多项式时间内求解。

因此, 尽管问题本质上具有组合性, 基于 SLATEQ 分解的全 Q-learning 相比普通物品级 Q-learning 至多只增加了一个小的多项式开销。此外, 在真实生产系统中, 通常会先由独立的召回策略筛出较小的候选集, 再在其上排序, 所以线性规划中考虑的物品集合一般远小于完整物品库 I 。

Top-k 与贪心优化 虽然在条件选择模型下, 可以借助物品级 Q 值和吸引力函数 v 通过线性规划精确求解最优推荐集合, 但我们可能希望在服务时避免直接求解线性规划。最自然的启发式方法是简单地选择得分最高的 k 个物品, 也就是按“未归一化期望长期价值” $v(s, i)Q(s, i)$ 从高到低依次加入推荐集合, 作者称其为 **top-k 优化**。与物品级 Q-learning 在线最大化所需的 $O(|I|)$ 时间相比, 该方法只需额外的 $O(\log |I|)$ 开销。

然而, top-k 的局限在于: 当要为第 L 个位置 ($1 < L \leq k$) 选取物品时, 它并不会根据已经放入集合中的前 $L - 1$ 个物品重新更新剩余物品的分数。贪心优化则不同, 它会相对于当前的部分集合动态更新分数。具体而言, 若当前部分集合为 $A_0 = \{i^{(1)}, \dots, i^{(L-1)}\}$, 则

第 L 个被加入的物品应满足：

$$\arg \max_{i \notin A_0} \frac{v(s, i)Q(s, i) + \sum_{\ell < L} v(s, i^{(\ell)})Q(s, i^{(\ell)})}{v(s, i) + v(s, \perp) + \sum_{\ell < L} v(s, i^{(\ell)})}.$$

作者在后续模拟实验中将 top-k、贪心与线性规划最优解进行了比较。

在一般条件选择模型下，无论是 top-k 还是贪心都不能保证找到最优推荐集合。文中给出如下反例：

物品	得分 $v(s, i)$	Q 值
空物品	1	0
a	2	0.8
b_1, b_2	1	1

空物品始终出现在推荐集合中。物品 b_1, b_2 在行为上完全相同。对于单物品集合，有 $V(\{a\}) = 1.6/3$ ，大于 $V(\{b_i\}) = 1/2$ ，因此无论是 top-k 还是贪心都会先把 a 放入集合中。然而对于大小为 2 的推荐集合，有 $V(\{a, b_i\}) = 2.6/4$ ，而最优集合 $\{b_1, b_2\}$ 的价值是 $2/3$ 。因此，对于 $k = 2$ 的情形，top-k 和贪心都无法找到最优解。

作者进一步指出：若将推荐集合的期望价值视为一个集合函数，则它既不是子模的，也不是单调的，因此无法直接套用经典贪心算法的近似分析。并且，top-k 在一般情况下甚至可能表现得任意糟糕。

观察 4. top-k 算法在推荐集合构造上的近似比是无界的。

文中给出的例子如下：

物品	得分 $v(s, i)$	Q 值
$\perp$	ε	0
a	ε	1
b	1	ε

设 $k = 1$ 。由于 top-k 会认为 b 的得分高于 a ，因此会选择 $\{b\}$ ，其价值为 $V(\{b\}) = \varepsilon/(1 + \varepsilon)$ ；而最优集合应为 $\{a\}$ ，其价值为 $V(\{a\}) = 1/2$ 。

算法变体 由于存在多种推荐集合优化方法，基于 SLATEQ 的强化学习算法也可以有多种变体，其差异在于训练阶段和服务阶段各使用何种集合优化方法。给定一个训练好的 SLATEQ 模型，在服务时可以采用 top-k、贪心或基于线性规划的最优方法来生成推荐集合，作者分别记为 TS、GS 和 OS。这些标记既可以作用于离策略的 Q-learning 模型，也可以作用于同策略的 SARSA 模型，甚至适用于非强化学习的短视模型。

在 Q-learning 中，由于训练时也需要计算后继状态的最大 Q 值，因此训练阶段同样需要进行推荐集合优化。训练时对应的三种方式分别记为 TT、GT 与 OT。对于短视模型与

SARSA，由于它们不需要训练时最大化后继集合，因此这些训练阶段记号并不适用。例如，QL-OT-OS 表示训练时使用最优优化、服务时也使用最优优化的 Q-learning；QL-OT-TS 则表示训练时使用最优优化、服务时使用 top-k。MYOP-GS 表示短视推荐模型在服务阶段使用贪心构造集合。作者在实验中还考虑了两个基线：其一是 **Random**，即从可行集合中随机推荐；其二是 **full-slate Q-learning** (FSQ)，即一种不做分解的标准 Q-learning，它将整个推荐集合视为一个原子动作来整体学习。后者是一个重要基线，用于检验 SLATEQ 分解是否确实在泛化与探索方面带来了收益。

其他选择模型 SLATEQ 并不仅限于本文重点讨论的选择模型（例如 CL）；不过，对于不同选择模型，其对应的优化问题形式会发生变化。扩展论文中还讨论了其他模型，例如级联模型。

5 实证评估：模拟实验

在第六节中，作者将在大规模线上流量实验中评估 SLATEQ 的效果；本节则使用模拟环境评估若干基于 SLATEQ 的算法。之所以构造模拟环境，是因为大多数公开数据集都是点式、静态的，并不适合评估多步的用户-推荐系统交互。即使在能够开展线上实验的情况下，模拟评估对于强化学习研究仍很有价值，因为真实线上实验成本高昂，且容易受到难以控制的混杂因素影响。

模拟环境的大致机制如下。设文档集合 D 表示可被推荐的内容物品，每个文档反映一个主题集合 T 的混合。任意 $d \in D$ 都是一个位于 $[0, 1]^{|T|}$ 中的主题向量；在实验中，每个文档只对应单一主题 $T(d)$ 。文档从分布 P_D 中抽样得到。每个文档还具有一个不可观测的固有质量 L_d ，它服从正态分布 $\mathcal{N}(\mu_{T(d)}, \sigma^2)$ ，其中 μ_t 是主题 t 对应的平均质量，因此不同主题在平均质量上有所差异。用户 $u \in U$ 则通过对各主题的兴趣来刻画，其兴趣范围从 -1 （完全不感兴趣）到 1 （完全感兴趣），因此用户可表示为 $u \in [-1, 1]^{|T|}$ ，从先验分布 P_U 中抽样得到。用户对文档 d 的兴趣定义为内积 $I(u, d) = u \cdot d$ 。

在每次交互中，系统先从 P_D 中抽取 m 个候选文档，再从中选出大小为 k 的推荐集合。用户依据式 (1) 所示的简单条件选择模型，从集合中选取一个物品 d_i ，其选择概率与 $I(u, d_i)$ 成比例，即

$$P(d_i \text{ 被选}) \propto \frac{I(u, d_i)}{\sum_{j \leq k} I(u, d_j)}.$$

用户对被选择并消费的文档 d 的满意度 $S(u, d)$ 由其兴趣与文档质量共同决定。文中采用简单凸组合：

$$S(u, d) = \alpha I(u, d) + (1 - \alpha)L_d.$$

每个用户在一次会话开始时具有一个不可观测的时间预算 B_u ，表示其愿意持续参与内容消费的总时长。每次选择一个文档都会减少用户预算，当预算下降到 0 时，会话结束。预算减少量为一个固定常数 c 减去一个随满意度增加而上升的奖励项；也就是说，越让用户满意的内容，对话话剩余时长的消耗越慢。当用户消费某个文档 d 后，其对主题 $T(d)$ 的兴

趣会受到一个随机扰动，这种扰动整体偏向提升兴趣，但也有一定概率降低兴趣。因此，该推荐系统面临一个典型的短期-长期权衡：它可以在短期内快速消耗用户预算，也可以适度“引导”用户向平均质量更高的主题靠近，从而在长期获得更大收益。每种策略都在 5000 个模拟用户上评估，文中所有结果均位于 95% 置信区间内。

5.1 短视推荐与非短视推荐的比较

作者首先检验使用 SLATEQ 学得的非短视长期价值策略 ($\gamma = 1$) 对用户参与度优化的效果，考虑了若干 SLATEQ 算法变体，例如 SARSA 与 Q-learning，以及不同的训练/服务集合优化方法。作为对比，作者还考虑了短视评分模型 (MYOP, $\gamma = 0$)，即仅优化即时奖励的模型，以及随机策略 Random。实验结果如下：

策略	平均回报 (%)	平均质量 (%)
Random	159.2	-0.5929
MYOP-TS	166.3 (4.46%)	-0.5428 (8.45%)
MYOP-GS	166.3 (4.46%)	-0.5475 (7.66%)
SARSA-TS	168.4 (5.78%)	-0.4908 (17.22%)
SARSA-GS	172.1 (8.10%)	-0.3876 (34.63%)
QL-TT-TS	168.4 (5.78%)	-0.4931 (16.83%)
QL-GT-GS	172.9 (8.61%)	-0.3772 (36.38%)
QL-OT-TS	169.0 (6.16%)	-0.4905 (17.27%)
QL-OT-GS	173.8 (9.17%)	-0.3408 (42.52%)
QL-OT-OS	174.6 (9.67%)	-0.3056 (48.46%)

结果表明，利用 SLATEQ 的长期价值方法——无论是 SARSA 还是 Q-learning——都能在整体上提升每个用户会话的平均回报。与随机基线相比，QL-OT-GS 相对 MYOP-GS 提供了更大的提升幅度。所有长期价值方法都学会了推荐平均质量更高的文档，而这会正向影响整体会话长度，因此解释了平均回报的提升。

此外，当在 Q-learning 中比较相同服务方式下的不同训练方式时，可以看到训练阶段采用线性规划最优集合优化 (OT) 优于 top-k 或贪心优化 (TT、GT)；例如，QL-OT-GS 优于 QL-GT-GS，QL-OT-TS 优于 QL-TT-TS。在相同训练机制下，服务阶段采用最优优化 (OS) 又稳定优于 top-k 与贪心，而贪心服务 (GS) 也显著优于 top-k 服务 (TS)。作者指出，一个很实用的配置是“训练时最优，服务时 top-k 或贪心”，因为训练阶段通常可以离线完成，而服务阶段受到较强的时延约束。

最后，使用 Q-learning 进行优化的结果在可比设置下优于同策略的 SARSA；但即便是 SARSA，其回报也明显高于短视模型 MYOP。这说明：即使只是同策略强化学习，也能给推荐系统带来显著收益。更进一步，如果系统在部署中持续采用“服务-采样-训练”的循环，并配合适当探索，那么 SARSA 实际上就能实现一种自然、持续的策略改进过程。整体来看，这些结果在该合成推荐环境中清楚表明：使用强化学习来规划长期交互，能够显著提升整体用户参与。

5.2 SLATEQ 与整体式优化的比较

作者进一步将基于 SLATEQ 分解学习得到的策略与 FSQ 进行比较。FSQ 是不做分解的 Q-learning 方法，它把整个推荐集合视为一个原子动作来学习。实验设定为 $|T| = 20$ 、 $m = 10$ 、 $k = 3$ ，这样就可以对 FSQ 所需的全部 $\binom{10}{3}$ 个推荐集合进行枚举最大化。需要注意的是，FSQ 的 Q 函数需要把所有 $\binom{20}{3} = 1140$ 个集合都作为动作表示，这会严重妨碍探索与泛化。对 SLATEQ，作者仅测试了 SARSA-GS。结果如下：

策略	平均回报 (%)	平均质量 (%)
Random	160.6	-0.6097
FSQ	164.2 (2.24%)	-0.5072 (16.81%)
SARSA-GS	170.7 (6.29%)	-0.5340 (12.41%)

虽然从理论上说，只要探索足够充分，FSQ 这种离策略 Q-learning 一定可以收敛到最优推荐集合策略，但实验显示：即便 SLATEQ 在这里采用的是同策略的 SARSA，它仍然表现得显著更好。相对于 Random，SARSA-GS 带来的改进幅度是 FSQ 的约 1.8 倍。原因在于 FSQ 必须为 1140 个不同集合分别学习 Q 值，这使得探索和泛化都极其困难。这些结果表明，SLATEQ 分解本身具有显著价值。

作者同时指出，虽然通过更强的表示方法或许可以帮助 FSQ 改善泛化，但该方法本质上仍然缺乏可扩展性，而 SLATEQ 不存在这种根本限制。有趣的是，FSQ 虽然很快收敛到一个平均推荐质量高于 SLATEQ 的策略，但它未能在文档质量与用户兴趣之间作出足够合适的权衡。

5.3 对用户选择模型偏差的鲁棒性

作者还测试了 SLATEQ 在用户真实选择模型与训练假设不一致时的鲁棒性。具体而言，真实用户不再按照前述条件选择模型从推荐集合中选取物品，而是采用一个简单级联模型：用户从上到下依次检查集合中的物品，每个位置以某个与位置相关的概率被查看；若被查看，则以与 $I(u, d)$ 成比例的概率消费该物品；若不消费，则继续检查下一个物品。尽管真实用户行为如此，SLATEQ 在训练和服务时仍然假设原来的条件选择模型。实验结果如下：

策略	平均回报 (%)	平均质量 (%)
Random	159.9	-0.5976
MYOP-TS	163.6 (2.31%)	-0.5100 (14.66%)
SARSA-TS	166.8 (4.32%)	-0.4171 (30.20%)
QL-TT-TS	166.5 (4.13%)	-0.4227 (29.27%)
QL-OT-TS	167.5 (4.75%)	-0.3985 (33.32%)
QL-OT-OS	167.6 (4.82%)	-0.3903 (34.69%)

可以看到，即便所采用的选择模型并不准确反映真实环境，SLATEQ 仍然持续优于短视模型 MYOP，这说明其具有一定鲁棒性。尽管 SLATEQ 本身也可以推广到其他选择模型，但由于任何选择模型都只能是对真实用户行为的近似，因此这种鲁棒性在实际应用中非常重要。

还应注意，在这一实验中，QL-TT 与 SARSA 的相对性能顺序与前一组实验发生了对调。原因在于，Q-learning 会在训练阶段利用这个**错误的**选择模型进行最大化，而 SARSA 作为同策略方法，主要在服务阶段才使用该选择模型计算期望。因此，这个结果暗示：在某些情形下，同策略控制的 SARSA 可能比 Q-learning 更具鲁棒性。

6 实证评估：线上实验

作者在 YouTube 上对 SLATEQ 进行了测试，这一系统具有数量级为 $O(10^9)$ 的用户和 $O(10^8)$ 的物品库。该系统具有典型工业推荐器的两级结构：首先由候选生成器从大规模语料库中召回与当前用户上下文最匹配的一小部分候选物品（通常为数百个），随后由排序模型利用用户上下文与物品特征，对候选进行打分与排序。现有推荐器的策略是短视的，它用物品的**即时预测参与度**来对推荐集合中的物品进行打分。

本文方法将排序模型中的短视参与度替换为**长期价值估计**。其余预测目标则保持不变，并与短视模型相同地融入最终打分函数。非短视推荐器所优化的是累积期望参与度，并将时间跨度截断到 N 天。由于用户访问首页的时间间隔可能很不规则，作者采用基于时间的折扣来处理大时间间隔下的信用分配问题。

作者将原短视排序模型扩展为一个多任务前馈深度网络，同时学习 $Q(s, i)$ ——即在状态 s 下、物品 i 在被点击条件下的长期参与度预测——以及 $v(s, i)$ ，用于点击率建模。为了保证比较公平，该模型使用与短视模型完全相同的状态特征与物品特征。模型在 TensorFlow 上使用分布式训练与随机梯度下降完成训练。训练采用连续两次首页访问所构成的同策略样本对，长期价值标签由式 (14) 计算得到；训练与服务阶段都采用 top-k 优化，即作者在线上实际测试的是 **SARSA-TS**。现有短视基线模型也采用类似方式构造推荐集合，即 MYOP-TS。

作者进行了为期三周的线上流量实验，将一小部分但具有统计显著性的用户流量分配给基于长期价值的 SARSA-TS 模型。实验中的对照组是一个经过高度优化的生产级机器学习模型，它优化的是即时参与度，即 MYOP-TS。原文图 1 展示了在实验期内，与对照组相比，长期价值模型在聚合用户参与度上带来的百分比提升；结果表明，该模型在所关注的关键指标上持续且显著地优于基线。原文图 2 则展示了来自推荐集合不同位置的累计参与度分布变化。结果表明，在实验组中，位于集合前部位置的物品带来了更高的长期参与，这说明在这一应用场景中，贪心式推荐集合优化具有相当不错的实际效果。

7 结论

本文提出了 SLATEQ，这是一种面向推荐集合强化学习的新型分解方法。它能够利用单个物品的长期价值估计，有效地开展 TD 学习和 Q-learning。该方法对用户选择行为所作的假设较为温和，并且适用于许多推荐系统场景，因此能够支持可处理的推荐集合优化。实验结果表明：(1) SLATEQ 具有良好的鲁棒性与可扩展性，能够应用于如 YouTube 这样的大规模推荐系统；(2) 长期价值估计能够显著提升用户参与度。

虽然 SLATEQ 的假设已经较为宽松，但其方法论仍有进一步扩展空间，例如继续放宽这些假设。作者正在进行的其他研究方向包括：将 SLATEQ 应用于其他选择模型、进一步提升可扩展性，以及向研究社区开放其模拟环境。

致谢

感谢 Larry Lansing 对系统优化所做的贡献，也感谢审稿人提出的宝贵反馈。

参考文献

下列参考文献保留原文条目形式：

1. Abadi et al., 2015. TensorFlow: Large-scale machine learning on heterogeneous systems.
2. Breese et al., 1998. Empirical analysis of predictive algorithms for collaborative filtering.
3. Charnes and Cooper, 1962. Programming with linear fractional functionals.
4. Chen and Hausman, 2000. Mathematical properties of the optimal product line selection problem using choice-based conjoint analysis.
5. Chen et al., 2019. Top-k off-policy correction for a REINFORCE recommender system.
6. Cheng et al., 2016. Wide & deep learning for recommender systems.
7. Choi et al., 2018. Reinforcement learning-based recommender system using biclustering technique.
8. Covington et al., 2016. Deep neural networks for YouTube recommendations.
9. Deshpande and Karypis, 2004. Item-based top-n recommendation algorithms.
10. Gauci et al., 2018. Horizon: Facebook's open source applied reinforcement learning platform.
11. Ie et al., 2019. Reinforcement learning for slate-based recommender systems: A tractable decomposition and practical methodology.

12. Jiang et al., 2019. Beyond greedy ranking: Slate optimization via list-CVAE.
13. Joachims, 2002. Optimizing search engines using clickthrough data.
14. Konstan et al., 1997. GroupLens: Applying collaborative filtering to Usenet news.
15. Le and Lauw, 2017. Indexable Bayesian personalized ranking for efficient top-k recommendation.
16. Louviere et al., 2000. Stated Choice Methods: Analysis and Application.
17. Metz et al., 2017. Discrete sequential prediction of continuous actions for deep RL.
18. Nemhauser et al., 1978. An analysis of approximations for maximizing submodular set functions.
19. Puterman, 1994. Markov Decision Processes: Discrete Stochastic Dynamic Programming.
20. Rendle et al., 2010. Factorizing personalized Markov chains for next-basket recommendation.
21. Salakhutdinov and Mnih, 2007. Probabilistic matrix factorization.
22. Schon, 2010. On the optimal product line selection problem with price discrimination.
23. Shani et al., 2005. An MDP-based recommender system.
24. Sunehag et al., 2015. Deep reinforcement learning with attention for slate Markov decision processes with high-dimensional states and actions.
25. Sutton and Barto, 1998. Reinforcement Learning: An Introduction.
26. Swaminathan et al., 2017. Off-policy evaluation for slate recommendation.
27. Taghipour et al., 2007. Usage-based web recommendations: A reinforcement learning approach.
28. van den Oord et al., 2013. Deep content-based music recommendation.
29. Van Seijen et al., 2009. A theoretical and empirical analysis of expected SARSA.
30. Viappiani and Boutilier, 2010. Optimal Bayesian recommendation sets and myopically optimal choice query sets.
31. Wu et al., 2017. Recurrent recommender networks.
32. Zhao et al., 2018. Deep reinforcement learning for page-wise recommendations.

参考文献

- [1] Eugene Ie, Vihan Jain, Jing Wang, Sanmit Narvekar, Ritesh Agarwal, Rui Wu, Heng-Tze Cheng, Martin Lustman, Vinnie Gatto, Paul Covington, Jay McFadden, Tushar Chandra, and Craig Boutilier. Reinforcement learning for slate-based recommender systems: A tractable decomposition and practical methodology. [arXiv:1905.12767](#), 2019.