

冷启动推荐中基于强化学习的生命周期价值优化

逐段中文翻译

原文作者：Luo Ji, Qi Qin, Bingqing Han, Hongxia Yang 译文整理：ChatGPT

原文发表于 CIKM 2021

说明

本文为论文 Reinforcement Learning to Optimize Lifetime Value in Cold-Start Recommendation 的中文逐段翻译稿。公式、表格与主要符号尽量保留原文结构；图像部分以中文图注和文字说明呈现，便于阅读与复制。

摘要

推荐系统在现代电子商务平台中发挥着至关重要的作用。由于用户与物品之间缺少历史交互，冷启动推荐是一个具有挑战性的问题。为了缓解冷启动问题，大多数现有方法都会引入内容信息和上下文信息作为辅助信息。然而，这些方法通常假设被推荐物品在时间维度上的表现是稳定的；而在典型电子商务场景中，物品在其整个生命周期内通常会呈现出非常不同的表现。在这种情况下，从物品视角考虑长期回报是有益的，但这一点通常被传统方法忽略。

强化学习天然适合处理这类长期优化问题。在这种设定下，推荐系统可以识别具有高潜力的物品，主动为其分配更多用户曝光，以促进其成长，从而提升多周期累计收益。受此思想启发，本文将该过程建模为一种部分可观测且部分可控的马尔可夫决策过程（Partially Observable and Controllable Markov Decision Process, POC-MDP），并提出一种 actor-critic 强化学习框架 RL-LTV，将物品生命周期价值（Lifetime Value, LTV）引入推荐中。

在 RL-LTV 中，critic 学习物品的历史轨迹，并预测新鲜物品未来的 LTV；actor 则给出一种基于分数的策略，以最大化未来 LTV 的期望。actor 给出的分数随后会在双重排序框架中与经典排序分数结合，从而使推荐结果兼顾 LTV 因素。本文方法在一个大型电子商务平台上，相比强线上基线，在冷启动物品的 IPV 和 GMV 上分别取得了 8.67% 和 18.03% 的相对提升。

CCS 概念：计算方法学 \rightarrow 强化学习；信息系统 \rightarrow 推荐系统；应用计算 \rightarrow 在线购物。

关键词：冷启动推荐；强化学习；Actor-Critic 模型；POC-MDP；生命周期价值。

引言

推荐系统（Recommender Systems, RS）已经变得越来越普遍，并被用于多种领域，例如商品、音乐、电影等。推荐系统通过向目标用户推荐最符合其偏好的物品列表，帮助用户完成信息寻找任务。对于实际系统来说，一个常见流程是：首先从海量候选中召回一系列物品，然后通过排序策略

对这些物品排序，以优化某个期望指标，例如 CTR（Click-Through Rate，点击率）。

然而，由于缺少用户-物品交互，冷启动推荐问题是一个常见挑战。冷启动问题的解决方案往往取决于平台特征。传统解决冷启动问题的方法，是将辅助信息引入推荐系统，例如基于内容的信息、异构信息和跨域信息。虽然这些方法已经取得了较好的效果，但它们主要关注即时奖励，而忽略长期奖励。相应地，近期也有越来越多工作开始关注长期或延迟指标，并提出了优化长期用户参与度的方法。然而，从物品侧出发的长期视角仍然是缺失的。

在电子商务场景中，被推荐物品通常是商品，因此很有必要考虑它们的长期行为，而这些行为会在商品生命周期内不断变化。根据产品生命周期理论，商品生命周期动态通常具有相似的发展模式。相关工作进一步提出了引入期、成长期、成熟期和衰退期四个不同阶段，并使用数学工具对产品生命周期阶段建模、预测不同阶段之间的转移概率。本文同样考虑商品生命周期动态，但采用连续的数值方式建模。在冷启动推荐的范围内，本文更关注早期阶段的物品，也就是引入期和成长期的物品。

对于一个最近刚被引入平台的物品来说，只关注即时指标的推荐算法可能会产生曝光偏差。通常情况下，由于缺少历史行为，这类新鲜物品不太容易被即时指标偏好，因此会得到较低的排序优先级。结果是，在传统算法存在的情况下，系统中可能出现严重的“马太效应”：成熟物品持续获得更多曝光，而新鲜物品则难以成长。然而，对于某些新鲜物品来说，只要投入一定用户曝光，它们可能会变得越来越受欢迎，并在未来产生更多收益。从这一角度看，一个智能的冷启动推荐系统应该能够提前识别高潜力物品，并为其分配更高排序优先级；相反，对低潜力商品则可以降低优先级。因此，这里需要一个多周期最大化任务。

强化学习（Reinforcement Learning, RL）提供了一个天然且统一的框架，能够同时最大化即时奖励和长期奖励。不过，考虑到真实在线环境的复杂性，构建一个在用户与物品之间交互的推荐智能体，并同时考虑长期奖励，是一项具有挑战性的任务。强化学习的试错行为可能损害系统表现，或者影响用户满意度；计算复杂度也可能高到难以承受。基于这些考虑，同时考虑到商品的时间演化天然发生在比在线推荐慢得多的时间尺度上（日级别对比毫秒级别），本文改为在物品层面、按天粒度定义一种离策略学习方法，从而使该方案具有实际可行性。

本文提出一种新的方法，称为基于生命周期价值的强化学习（Reinforcement Learning with Lifetime Value, RL-LTV），用于在冷启动推荐问题中考虑被推荐物品的长期奖励。本文将这类长期奖励称为物品生命周期价值（Item Lifetime Value, LTV）。该方法采用一种带有循环组件的离策略 actor-critic 强化学习框架，学习物品层面的动态，并进行面向长期目标的主动决策。前述产品生命周期阶段的信息由循环隐藏记忆状态进行编码，这些状态由 LSTM 组件学习，并由 actor 与 critic 共享。为了将历史物品中的信息迁移到冷启动物品，本文将物品固有特征、趋势偏置项以及记忆状态作为额外输入，引入 actor 和 critic。actor 输出的一个最重要动作是物品 LTV 偏好分数，该分数随后与传统排序分数结合，构成双重排序框架。二者的组合权重由 critic 给出的动作价值决定。图 1 展示了本文所提算法的整体框架。

本文的主要贡献如下：

- 本文定义了部分可观测且部分可控马尔可夫决策过程（POC-MDP）的概念，用于刻画商品生命周期动态。不可观测状态描述商品的内在生命周期阶段；不可控状态能够影响商品增长速度，但独立于动作。

- 本文通过 RL-LTV 将物品 LTV 纳入在线排序。通过在排序阶段优先考虑高潜力冷启动物品，可以克服冷启动物品的曝光偏差。据我们所知，这是首次将这类技术用于解决冷启动推荐问题。
- 成熟物品的知识可以被泛化并迁移到冷启动物品，甚至是首次引入平台的物品。为实现这一点，本文在物品层面构建 MDP，采用连续的观测空间和动作空间，并使用参数共享的策略网络与 critic 网络。
- 本文设计了一个名为 IE-RDPG 的学习框架，用于以逐物品、逐 episode 的方式解决大规模强化学习问题。该算法已经部署到生产环境中，并在冷启动物品的 IPV 和 GMV 上分别观察到 8.67% 和 18.03% 的提升。

本文其余部分组织如下：第 2 节讨论与已有工作的联系；第 3 节介绍预备知识；第 4 节给出 POC-MDP 的建模方式及其学习算法；第 5 节总结实验结果；第 6 节对全文进行总结。

相关工作

本节简要回顾冷启动推荐和强化学习方面的代表性工作。

冷启动推荐。虽然协同过滤和基于深度学习的模型已经在推荐系统中取得了相当大的成功，但它们通常难以处理新用户或新物品，因为这些对象只有很少的用户-物品交互，这就是所谓的冷启动推荐问题。传统的冷启动推荐解决方案，是向推荐系统中引入辅助信息，例如基于内容的信息、异构信息和跨域信息。具体而言，基于内容的方法依赖于通过合并用户侧或物品侧信息进行数据增强。例如，有研究提出了名为 visual-CLiMF 的方法，为冷启动视频学习具有代表性的隐因子，其中物品的情绪方面被纳入视频内容的隐因子表示。另有研究提出一种混合模型，通过堆叠降噪自编码器从物品描述中学习物品特征，并进一步将这些特征结合到协同过滤模型中，用于解决物品冷启动问题。

除了基于内容的特征和用户-物品交互外，更丰富的异构数据也可以通过异构信息网络的形式加以利用，从而捕获物品与其他对象之间的交互。对于基于异构信息的方法而言，其主要任务之一是在推荐设定中借助高阶图结构探索异构语义，例如元路径（Metapath）或元图（Metagraph）。最后，跨域方法通常基于迁移学习，将源域特征迁移到目标域。此类方法的前提是源域可用，并且两个域中的用户或物品能够对齐。例如，有研究基于偏最小二乘回归分析提出一种跨域推荐模型，可用于更好地预测冷启动用户评分。另有研究提出跨域隐特征映射模型，其中基于邻域的跨域隐特征映射方法被用于为每个冷启动用户学习特征映射函数。

虽然上述方法已经取得了较好的性能，但其中大多数只是从单周期视角缓解冷启动问题，而忽略长期奖励。最近已有一些研究尝试从用户侧研究长期影响，但并未从物品侧展开。本文尝试解决物品冷启动问题，不仅使用物品内容信息，还根据物品的长期回报来决定其排序偏好。

强化学习。本文方法与强化学习在推荐问题中的广泛应用密切相关。这些应用包含不同策略：基于价值的方法、基于策略的方法以及基于模型的方法。当环境被识别为部分可观测 MDP（POMDP）时，循环神经网络是处理隐藏状态的自然方案。强化学习还可以帮助生成端到端的列表级解决方案，甚至可以联合决定页面展示布局。

也有一些基于强化学习的冷启动推荐研究。有研究提出了一种离线元层级、基于模型的方法；有研究结合策略梯度方法和最大似然方法，并将这种冷启动强化学习方法应用于结构化输出预测问题中的序列生成模型训练；还有研究使用强化学习解决用户参与度上的多周期奖励问题。另有研究基于物品生命周期阶段的考虑，提出了一种用于曝光分配的强化学习框架。在该工作中，物品阶段

通过数学模型显式识别和预测，而强化学习被用于曝光分配问题内部。

与上述基于显式阶段识别的方法不同，本文以端到端方式通过强化学习隐式学习物品阶段信息。具体而言，本文使用循环神经网络基于物品历史，将隐藏状态编码为生命周期阶段的连续稠密表示。本文框架联合学习该循环隐藏状态、作为物品长期奖励预测的动作价值，以及排序策略。

预备知识

本节首先介绍电子商务中商品代谢和物品生命周期价值的背景，这也是本文工作的基本动机。在理解该场景的基础上，本文定义一种特殊类型的马尔可夫决策过程，用于建模物品代谢过程。最后，本节给出基础 DDPG 算法，作为本文方法的底层学习方法。

物品代谢与生命周期价值

电子商务平台上典型的商品代谢模式如图 2 所示。假设一个平衡电动车刚被引入平台，它通常只会获得很少的用户兴趣，相关统计指标也处于低水平。虽然可以让该物品自然成长，但仍有多个渠道可以改变其状态。首先，该物品的用户曝光，或者更具体地说页面浏览量（PV），会受到搜索和推荐算法的显著影响。其次，搜索与推荐的合理性会直接影响点击率，也就是有多少物品页面浏览（IPV）能够从 PV 中转化出来。进一步地，作为第三个渠道，定价系统的定价策略会显著影响有多少销售量（SLS）能够由 IPV 转化而来。

在这一过程中，PV、IPV 和 SLS 不断累积，物品声誉逐渐建立，感兴趣的用户群体也会持续扩大。随着更多用户被该物品吸引，他们的行为会帮助该特定物品在搜索和推荐算法中获得更高重要性，从而形成一种正反馈闭环机制。随着时间推移，新鲜物品可能会在 PV、IPV 和 SLS 等关键指标上形成增长型生命周期动态轨迹。

然而，并非所有物品都能实现这种正反馈闭环机制。物品增长率取决于其固有特征（即该物品是什么）、品牌、市场、外部趋势或噪声以及算法。实际上，大多数物品最终都会落入所谓“长尾商品”群体，只有很少的用户浏览、点击或购买。因此，如果能够在物品早期阶段就识别其是否能够在未来带来显著 PV、IPV 和 GMV，就有助于区分明星商品与长尾商品。本文将这种长期奖励称为物品生命周期价值（LTV）。通过为高潜力商品分配更多资源，平台将在未来获得更多 LTV 回报，从而推动整个生态系统增长和繁荣。如图 2

所示，搜索、推荐和定价都是分配资源并调节物品动态的重要工具。

MDP 及其扩展

马尔可夫决策过程（MDP）通常用于建模序列决策问题。标准 MDP 通常由四元组 $(\mathcal{S}, \mathcal{A}, \mathcal{R}, \mathcal{P})$ 组成，其中 $\mathcal{S}$ 、 $\mathcal{A}$ 、 $\mathcal{R}$ 、 $\mathcal{P}$ 分别表示状态空间、动作空间、奖励集合和状态转移概率函数。在时间步 t ，状态 $s_t \in \mathcal{S}$ 表示当前系统阶段，该状态受到智能体动作 $a_t \in \mathcal{A}$ 的影响，并通过奖励函数生成奖励 r_t ，同时转移到下一状态 $s_{t+1} \in \mathcal{S}(s_t, a_t)$ 。对于这种标准 MDP，它假设 s 中的所有元素既能被智能体观测，又能被智能体动作改变。

然而，在真实环境中，这一假设很少成立。例如，在 Atari 的 Pong 游戏中，状态既包括当前图像，也包括球的速度，但只有当前图像被提供给智能体。部分可观测马尔可夫决策过程（PO-MDP）捕获了系统复杂性中的部分可观测性。它通常被描述为五元组 $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \mathcal{O})$ ，其中 $\mathcal{O}$

表示可观测状态集合，即 $\mathcal{O}$ 是 $\mathcal{S}$ 的子集。

另一种系统复杂性形式研究相对较少，即具有不可控状态的 MDP。在这类场景中， s_t 的某些元素永远不会受到智能体动作影响，但它们能够决定 s_{t+1} ，从而也会影响未来奖励。本文特别关注这种不可控性形式，下一节将对此作更详细讨论。

在本文主题中，作者认为不可观测状态和不可控状态同时存在。为处理上述问题，本文定义一种部分可观测且部分可控马尔可夫决策过程（POC-MDP）。虽然“状态”一词可以指所有状态，无论其是否可观测、是否可控，但为了清晰起见，本文使用符号 s 仅表示标准状态，即既可观测又可控的状态。不可观测但可控的状态记为 $h \in \mathcal{H}$ ；不可控但可观测的状态记为 $x \in \mathcal{X}$ 。因此，本文的 POC-MDP 可以写为六元组 $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \mathcal{O}, \mathcal{H})$ 。此时观测是标准状态与不可控状态的拼接，即 $o := [s, x]$ 。

DDPG 方法

本节简要介绍一种无模型、离策略、actor-critic 强化学习算法，即深度确定性策略梯度（DDPG）方法。该方法与本文提出的方法密切相关。

在 DDPG 中，actor 网络 π 由网络参数 θ 近似并生成策略，critic 网络 Q 由网络参数 w 近似并生成动作价值函数。确定性策略的梯度为 $\nabla_{\theta} J = \mathbb{E}_s \sum_{a \sim \pi(s)} d^{\pi(s)} \left[\nabla_{\theta} \pi_{\theta}(s) \nabla_a Q_w(s, a) \right]$ 。其中 $d^{\pi(s)}$ 表示策略 π 下状态 s 的折扣分布。随后， θ 可以按如下方式更新： $\theta \leftarrow \theta + \eta \mathbb{E}_s \sum_{a \sim \pi(s)} d^{\pi(s)} \left[\nabla_{\theta} \pi_{\theta}(s) \nabla_a Q_w(s, a) \right]$ ，其中 η 为学习率。对于 critic，动作价值函数可以迭代地获得： $Q_w(s_t, a_t) = \mathbb{E} \left[r_t + \gamma \mathbb{E}_{a \sim \pi_{\theta}} \left[Q_w(s_{t+1}, a_{t+1}) \right] \right]$ 。 w 通过最小化如下目标函数进行更新： $L = \mathbb{E}_s \sum_{a \sim \pi} \left[\left(R(s_t, a_t) + \gamma \mathbb{E}_{a' \sim \pi_{\theta'}} \left[Q_{w'}(s_{t+1}, a_{t+1}) \right] - Q_w(s_t, \pi_{\theta}(s_t)) \right)^2 \right]$ 。其中 $\pi_{\theta'}$ 和 $Q_{w'}$ 分别是 actor 和 critic 的目标网络。目标网络参数可以通过软更新方式更新： $\theta \leftarrow \tau \theta' + (1 - \tau) \theta$, $w \leftarrow \tau w' + (1 - \tau) w$ 。

方法

本节说明本文方法的关键概念，包括如何实现 RL-LTV，以及其动作如何应用于在线系统。首先列出 POC-MDP 中各术语的定义，然后介绍 actor 和 critic 网络架构，随后给出学习算法。actor 输出一个偏好分数，该分数在线性方式下与传统 CTR 模型给出的排序分数结合，形成双重排序框架。新的排序分数随后被用于对每次请求响应中的物品进行排序。表 1 总结了本节及相关章节中经常使用的重要符号。

符号说明

符号	含义
符号	含义
x_i	物品固有的、时间不变的特征
x_t	随时间变化的趋势偏置因素
$\mathcal{X}, x$	不可控状态空间, $x := [x_i, x_t] \in \mathcal{X}$
$\mathcal{S}, s$	状态空间, $s \in \mathcal{S}$

符号	含义
$\mathcal{O}, o$	观测空间, $o := [s, x] \in \mathcal{O}$
$\mathcal{H}, h$	不可观测的隐藏状态空间, $h \in \mathcal{H}$
$\mathcal{A}, a$	动作空间, $a \in \mathcal{A}$
$\mathcal{R}, r$	奖励空间, $r \in \mathcal{R}$
γ	用于平衡即时奖励与未来奖励的折扣因子
J	折扣累计回报
$\mathcal{T}$	转移四元组 (o_t, a_t, r_t, o_{t+1})
$\pi_{\theta}(a o)$	策略函数, 其中 θ 为 actor 参数
$Q_w(o, a)$	状态-动作价值函数, 其中 w 为 critic 参数
PV	所有渠道的页面浏览量, 搜索加推荐
$PV_{\{rec\}}$	仅来自推荐的页面浏览量
IPV	从所有渠道跳转得到的物品页面浏览量
SLS	销售数量
p	平均支付价格的折扣程度
GMV	物品收益, 基本等于价格乘以 SLS
$y_{\{ctr\}}$	CTR 模型给出的点式用户-物品亲和分数
$y_{\{rl\}}$	RL-LTV 给出的物品亲和分数
y	最终应用的加权点式推荐分数
α	$y_{\{ctr\}}$ 与 $y_{\{rl\}}$ 之间的线性权重

定义

本文考虑一个两级智能体, 其中推荐系统 (RS) 影响点击率, 定价系统 (PS) 影响转化率。环境是电子商务生态系统。图 3 给出了本文 POC-MDP 的一个快照。

状态。 状态空间定义在物品层面, 表示当前物品生命周期阶段中的可观测部分, 包括物品上架时间、PV (当前值与累计值)、IPV (当前值与累计值)、SLS (当前值与累计值), 以及当前对该物品感兴趣的用户群体属性, 例如人数、平均活跃频率、平均购买力等。

动作。 动作记为 $a_t = [y_{\{rl, t\}}, p_t] \in \mathcal{A}$ 。对于推荐系统部分, $y_{\{rl\}} \in (0, 1)$ 表示推荐系统对某一特定物品的偏好排序分数。位于推荐系统下游的定价系统的动作为 p , 本文将其建模为价格折扣程度, 即平均支付价格除以原价。 $y_{\{rl\}}$ 与 p 都可以很容易从真实数据中获得。

不可控状态。 本文对这类状态的建模灵感来自如下事实: 物品下一状态不仅是当前状态的结果, 还由其固有特征和外部趋势偏置因素决定。固有特征, 例如标题、封面图像、类目、品牌和店铺名称, 通常可以被假设为相对于物品不变。因此, 本文将其记为 x_i , 其中下标 i 同时表示 inherent (固有) 和 item-invariant (物品不变)。值得注意的是, 在 x_i 中, 本文使用一个预训练的 128 维物品标题与图像多模态 embedding 作为核心信息, 用于连接不同物品之间的信息。 x_i 的其他部分包括类目、品牌和店铺, 它们以 ID 类型特征输入。外部偏置因素可以来自不同趋势来源, 包括整体市场、平台活动、物品卖家、品牌或类目。由于这些因素显然随时间变化, 本文将其记为 x_t 。对于每一种趋势来源, 本文纳入其 PV、IPV 和 SLS 的移动平均增长百分比。

奖励。如前所述，为了在物品之间共享信息，MDP 被定义在物品层面。然而，在线推荐包含列表级排序，这意味着不同物品之间会竞争曝光分配。考虑到这种维度不匹配，不能简单地将奖励定义为绝对值，例如 PV、IPV、SLS 的 LTV，或它们的线性组合；因为在这种情况下，强化学习会倾向于为每个物品生成尽可能大的 y_{rl} 。因此，本文选择一种类似 ROI（投资回报率）的奖励形式，将其定义为下一步 IPV 回报与当前推荐 PV 投入之比： $r_t = \frac{IPV_{t+1}}{PV_{rec,t}}$ 。

长期收益与折扣因子。多周期累计收益定义为 $J_t = \sum_{i=0}^T \gamma^i r_{t+i}$ ，它可以被视为本文 ROI 版本的 LTV。T 是窗口长度， γ 是重要的折扣因子，二者共同控制模型在优化 J 时向前看的时间跨度。在本文研究中， γ 被设置为较小值，即 0.5，表示本文的强化学习在两方面进行平衡：其一是长期总奖励，其二是尽可能加快冷启动物品的成长。

Actor

actor 的设计目标是在给定当前观测 $o_t = [s_t, x_t, x_i]$ 时生成动作 $a_t = [y_{rl}, p]$ 。该策略函数由 actor 网络 $\pi_{\theta}(a_t|o_t)$ 近似，其中 θ 表示网络参数。如第 4.1 节所述，物品固有特征 x_i 包含两部分：第一部分是预训练 embedding 向量；第二部分由不同 ID 组成，所有 ID 都被输入编码器网络 $f_e(x_i, w_e)$ 。该编码器生成的 embedding 会与预训练向量拼接，形成 $x_{\{e,i\}}$ ，即 x_i 的嵌入版本。于是，嵌入后的新观测为 $o_{\{e,t\}} = [s_t, x_t, x_{\{e,i\}}]$ 。

为了使智能体能够捕获物品内在生命周期阶段，本文引入一个 LSTM 单元，将历史观测的序列信息编码为连续隐藏状态：
$$\begin{aligned} Z_{\{f,t\}} &= \sigma(W_f \cdot [h_{t-1}, o_{\{e,t\}}]), \quad Z_{\{u,t\}} = \sigma(W_u \cdot [h_{t-1}, o_{\{e,t\}}]), \\ Z_{\{o,t\}} &= \sigma(W_o \cdot [h_{t-1}, o_{\{e,t\}}]), \quad \tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, o_{\{e,t\}}]), \\ c_t &= Z_{\{f,t\}} \cdot c_{t-1} + Z_{\{u,t\}} \cdot \tilde{c}_t, \quad h_t = Z_{\{o,t\}} \cdot \tanh(c_t). \end{aligned}$$
 其中， $Z_{\{f,t\}}$ 、 $Z_{\{u,t\}}$ 、 $Z_{\{o,t\}}$ 分别为遗忘门、更新门和输出门； W_f 、 W_u 、 W_o 、 W_c 是 LSTM 参数； c_t 和 h_t 分别是 cell state 和 hidden state。总体而言，actor 的输入为 $[o_{\{e,t\}}, h_t]$ 。

为了增强 actor 记忆 $o_{\{e,t\}}$ 和泛化 h_t 的能力，本文采用了 Wide & Deep 结构：
$$\begin{aligned} o_{\{wide\}} &= f_{\{wide\}}(W_w, o_{\{e,t\}}), \quad o_{\{deep\}} = f_{\{deep\}}(W_d, [o_{\{e,t\}}, h_t]), \end{aligned}$$
 其中 $f_{\{wide\}}$ 和 $f_{\{deep\}}$ 分别是一层和三层全连接层。为了得到第一个动作，即 $y_{rl} \in (0,1)$ ，本文使用如下函数：
$$S = \text{softmax}(W_s^T \cdot [o_{\{deep\}}, o_{\{wide\}}]), \quad y_{rl} = \sigma(x_{\{e,i\}} \cdot S),$$
 其中 W_s^T 和 σ 分别表示线性层权重和 sigmoid 函数。第二个动作，即定价折扣 p ，通过与 y_{rl} 相似的逻辑结构输出；为了简洁，该部分逻辑未在图中展示。

Critic

critic 与 actor 共享相同的 ID 编码器和 LSTM 组件。本文采用 dueling 结构来刻画动作价值函数，将其分解为状态价值 $V(o)$ 和动作优势价值 $A(o,a)$ 。 $V(o)$ 由一个稠密网络在给定 o_t 和 h_t 的条件下生成。对于 $A(o,a)$ ，本文进一步将其分解为 $A(o_t, a_t) = A(s_t, a_t) + \text{Bias}(s_t, x_t, a_t)$ 。其中， $A(s_t, a_t)$ 的含义与普通 dueling 结构中的定义一致，由另一个稠密网络计算；第二项 $\text{Bias}(s_t, x_t, a_t)$ 表示由趋势偏置因素 x_t 造成的偏置考虑，由单个线性层计算。最终 Q 值通过简单相加得到：
$$Q = V(o_t) + A(s_t, a_t) + \text{Bias}(s_t, x_t, a_t)$$

$$Q(o_t, a_t, h_t) = V(o_t, h_t) + A(o_t, a_t) \quad \& = V(o_{\{e,t\}}, h_t) + A(s_t, a_t) + \text{Bias}(s_t, x_t, a_t). \quad \text{\end{aligned}}$$

学习过程

强化学习的目标是求解 MDP，并提供一个策略 $\pi_{\theta}(a|s)$ ，使其最大化式 (2) 中的期望折扣回报。由于本文强化学习框架和在线推荐运行在不同的时间频率上，离策略方法更适合本文场景，例如第 3.3 节介绍的 DDPG。与原始 DDPG 版本相同，本文也使用双 Q 网络设置和 replay memory buffer。然而，考虑到循环组件的存在，同时为了降低工业级数据上的计算负担，本文采用了一种不同的数据采样和网络更新方式。

在普通 DDPG 方法中，通常采样一批转移，即四元组 (o_t, a_t, r_t, o_{t+1}) ，梯度更新则是每个转移反馈的 batch 平均。本文方法改为从 buffer 中随机采样一批物品，或者说这些物品对应的 episode；更新从 episode 开始处执行，然后沿时间方向向前推进，直到 episode 结束。通过这种方式，LSTM 中的隐藏状态始终由其前一个值向前传递，这有助于改善其收敛速度。相关工作中也存在类似更新方法，称为 Bootstrapped Sequential Updates。在本文系统中，一个 episode 是某个物品的转移序列，按天队列收集并排序。因此，本文将训练算法命名为逐物品 episodic 循环确定性策略梯度 (IE-RDPG)。

IE-RDPG 的一次训练 session 包含两个阶段。第一阶段中，智能体根据当前策略与平台交互，并持续收集数据，直到 T 天。对于每个物品，转移按时间顺序存储，形成 episode。之后进入参数更新阶段，每次从 buffer 中随机采样一批 N 个 episode。参数更新首先在起始时间步并行执行，随后继续沿时间方向推进，直到所有 episode 结束。参数更新阶段可以包含多个 epoch。这个两阶段 session 会在真实世界时间线上不断重复。IE-RDPG 提供了一种异步且分布式的架构，能够解决大型电子商务平台中海量物品带来的问题。

双重排序模块

点式学习排序 (Pointwise Learning to Rank, LTR) 在工业推荐排序中被广泛使用。对于每个用户请求，物品特征会与用户特征对齐，并由一个监督模型，例如点击率模型，计算用户亲和分数。该 CTR 分数 y_{ctr} 被用作排序指标，从而生成排序后的物品列表。在本文研究中，RL-LTV 提供另一个物品亲和分数 y_{rl} ，表示其基于物品 LTV 的偏好。通过构建双重排序模块并同时考虑这两个分数，在线排序不仅能够考虑即时点击奖励，也能够考虑长期奖励。因此，一些没有足够历史交互但具有高 LTV 潜力的新鲜物品，可能拥有较小的 y_{ctr} 但较大的 y_{rl} ，并有望获得更高排序优先级。

本文通过如下方程获得新的排序分数： $y = (1 - \alpha) \cdot y_{\text{ctr}} + \alpha \cdot y_{\text{rl}}$ ，其中 $\alpha \in (0, 1)$ 是混合参数。由于 critic 输出的 Q 预测未来 LTV，因此它可以用于确定 α 的大小，从而决定 CTR 奖励与 LTV 奖励之间如何权衡。在实验中， α 计算如下： $\alpha = e^{\frac{Q - Q_{\min}}{Q_{\max} - Q_{\min}}} / (\ln(1 + \alpha_{\max} - \alpha_{\min}) - 1 + \alpha_{\min})$ ，其中 $\alpha_{\min}$ 和 $\alpha_{\max}$ 是超参数，分别强调 α 的下界和上界；Q 更高的物品总是会拥有更高的 α 。

实验

为了评估所提出模型，本文将方法应用于淘宝这一全球领先的电子商务平台。本文设计了一系列实验，用于回答以下问题：（1）所提出方法是否优于基线，或者优于某些非强化学习竞争方法；（2）验证引入 x 或 LSTM

组件是否有助于提升性能；（3）是否能够找到一些代表性案例，从业务角度展示该框架如何提升 LTV。需要强调的是，推荐领域中的大多数公开数据集并不具备第 3.1 节所描述的物品动态特征，因此无法简单地将本文方法与大多数最先进基线直接比较。另一方面，真实线上环境包含数十亿用户和物品，因此在真实系统中任意上线一个基线也并非易事。作为补救，本文将 RL-LTV 的性能与线上排序算法进行比较，后者是这种复杂工业系统中的合理基线。本文还围绕 LTV 识别进行了离线分析，并比较了若干基线。消融实验和敏感性分析也被用于进一步说明本文框架的合理性。

实验设置

训练过程。 在线排序系统是实时运行的，而本文方法按日更新。在实际应用中，用户日志会持续被收集，随后按物品、按天聚合，并记录 MDP 转移。根据算法 1，对于每个物品，系统会等待 T 个新转移出现；随后形成一个新的 episode，并放入 buffer。类似地，每次 buffer 采样会抽取 episode，并据此执行梯度更新。

参数设置。 在 RL-LTV 的训练中，本文使用 Adam 优化器训练 actor 和 critic，学习率为 0.0001。超参数 γ 、 τ 、 $\alpha_{\min}$ 和 $\alpha_{\max}$ 分别为 0.5、0.001、0 和 0.2。LSTM 组件中的隐藏状态维度为 4。物品编码器输出的物品固有特征维度为 8。从可应用性角度出发，时间步被选择为一天。本文使用相对较小的 buffer（200）和 batch size（50），因为 replay memory buffer 是以 episode 为单位运行，而不是以 transition 为单位运行。

LTV 识别

由于推荐与客户体验和平台收入直接相关，当前阶段的在线实验规模和深度受到限制。尽管如此，仍然可以从 LTV 识别角度进行一些离线分析。

指标。 离线评估可从两个方面进行：（1）由于 critic 提供的是实际累计收益 J 的预测版本 Q ，因此可以计算并评估 Q 与实际 J ，即 J_{actual} ，之间的回归准确性；（2）actor 生成 y_{rl} ，表示其相对于 LTV 的排序偏好，因此可以通过按 y_{rl} 降序排序，并与真实排序（按 J_{actual} 排序的物品）比较序列相似性，来评估排序指标。

为了计算 J_{actual} ，本文收集连续 5 天的数据；由于当 $\gamma=0.5$ 时，较长时间范围内的数据权重会快速衰减，因此可以忽略更长 horizon 的数据。对于第一个方面，本文使用均方根误差（RMSE）和平均绝对误差（MAE）来研究该 J_{actual} 的预测误差。

本文采用归一化折扣累计增益（NDCG）作为第二个方面中序列相似性的度量。为了模拟线上环境并降低计算成本，本文在该离线评估中同样使用在线召回方法，它会针对每个用户查询生成一系列物品。随后从召回列表中选取 top- K 物品计算 NDCG@ K ，其中 $K=10, 20, 50$ ，并使用 J_{actual} 作为相关性分数。

基线。 本文采用以下实验版本与 RL-LTV 进行比较：

- Vanilla-CTR：线上点式、单周期的普通 CTR 模型，是淘宝每天运行的自然基线；截至目前它具有最先进的 CTR 性能，但没有任何 LTV 考虑。
- Empirical：为模拟人工决策过程，基于业务经验手动分配分数。例如，分别根据类目、卖家和品牌收集 J_{actual} 的分位数，计算它们的加权平均，然后缩放到 (0,1)。
- LSTM：使用监督式 LSTM 模型回归并预测 J_{actual} ，随后基于预测结果分配分数。它与 RL-LTV 中的 LSTM 组件共享相同结构。

需要注意的是，本文只比较 LSTM 与 RL-LTV 的回归准确性，因为 Vanilla-CTR 和 Empirical 并没有显式的 LTV 预测。另一方面，本文可以为所有基线评估 LTV 排序的 NDCG。对于 Vanilla-CTR，使用 CTR 分数来排序其对 LTV 排名的偏好，而这实际上正是线上平台当前的情况。

结果。表 2 总结了相关结果。由于具有交互式学习行为和长时间 horizon 优化，RL-LTV 预期应具有更好的 LTV 回归准确性，实验结果验证了这一点。与 LSTM 相比，RL-LTV 在 MAE 和 RMSE 上都降低了 LTV 预测误差。对于 NDCG@K，可以发现 Empirical、LSTM 和 RL-LTV 的 NDCG 均优于 Vanilla-CTR，后者只关注即时 CTR 指标。尽管如此，RL-LTV 仍然是这些实验中表现最好的方法。

物品 LTV 的离线指标。Baseline 和 Empirical 没有 RMSE 或 MAE 结果，因为它们没有 Q 估计。

模型	RMSE	MAE	NDCG@10	NDCG@20	NDCG@50
Vanilla-CTR	–	–	0.746	0.662	0.582
Empirical	–	–	0.765	0.678	0.581
LSTM	7.900	4.761	0.772	0.684	0.600
RL-LTV	7.873	4.067	0.782	0.705	0.625

线上实验

线上实验在淘宝上进行。A/B 测试从 2021 年 1 月 26 日开始，持续一周。RL-LTV 策略首先使用第 5.2 节中的训练版本进行预热，然后按日在线更新。由于真实世界限制，动作中只有 y_{rl} 实际生效； p 则由其他团队决定和控制，因此对本文方法而言成为一个只读参数。

冷启动表现。本文首先考察冷启动物品的表现。为定义冷启动物品，在实验开始时，本文将上架时间少于一个月的新鲜商品标记出来，然后将其随机划分为不同组。每组冷启动物品只允许被一个实验推荐，因此不同实验的物品级指标（IPV 和 GMV）可以被合理计算并公平比较。在线测试结束后，本文收集 PV、IPV 和 GMV 形式的 LTV。对于 RL-LTV，本文计算其相对于 Vanilla-CTR 的 LTV 差异，结果见表 3。可以看到，在几乎相同的 PV 投入下，RL-LTV 显著提升了 IPV 和 GMV 形式的 LTV。

冷启动物品相对于 Vanilla-CTR 的 LTV 百分比差异。

模型	PV	IPV	GMV
RL-LTV (w/o R)	1.01%	6.25%	12.31%
RL-LTV	-1.19%	8.67%	18.03%

全局表现。冷启动推荐的最终目标是提升整个推荐系统的性能。因此，本文需要检查所有物品的指标，而不仅仅是冷启动物品的指标。虽然由于对冷启动物品的投资，推荐系统的短期表现可能受到损害，但预期其长期表现能够随着 LTV 的增长而得到补偿。到实验结束时，本文观察到了这种补偿效应。更具体地说，与 Vanilla-CTR 相比，RL-LTV 的 PV 为 -0.55%，IPV 为 -0.60%，这表明全局表现并没有出现严重下降。

典型案例。为了更深入理解强化学习如何帮助识别某个具体高潜力物品并提升其 LTV，本文还考察了一些具体案例。图 5 展示了这样一个案例：一个挂钩把手物品于 1 月 26 日首次被引入平台。其冷启动时，只有很少人浏览、点击和购买。然而，RL-LTV 将其识别为具有高 LTV 潜力的物品，因此在早期阶段进行了大量 PV 投入。该投入是成功的，因为它激发了更多人的兴趣和行为，主要来自其他渠道，同时 PV、IPV 和 GMV 均快速增长。当该物品转变为明星商品后，RL-LTV 转向投资其他冷启动物品。因此，在第 3 天之后 $PV_{\{rec\}}$ 下降，而其他指标已经进入健康的闭环反馈。

消融实验

为说明 RL-LTV 中若干重要组件的有效性，本文对以下尝试进行消融分析：

- RL-LTV (w/o x_s)：本文方法，但不包含物品固有特征 x_s 。原文此处符号写作 x_s ，结合上下文应指物品固有特征。
- RL-LTV (w/o x_t)：本文方法，但不包含趋势偏置因素 x_t 。
- RL-LTV (w/o R)：本文方法，但不包含循环 LSTM 组件。

与第 5.2 节类似，本文对这些实验执行离线分析，并将其结果与 RL-LTV 一同列在表 4 中。不出所料，RL-LTV 仍然具有最佳性能，这表明 x_s 、 x_t 和循环单元都非常关键。由于线上资源有限，只有 RL-LTV (w/o R) 进行了线上实验，结果同样显示在表 3 中。可以看到，与 Vanilla-CTR 相比，RL-LTV (w/o R) 也具有正向线上影响，但效果不如 RL-LTV。

组件消融分析的离线性能比较。

模型	RMSE	MAE	NDCG@10	NDCG@20	NDCG@50
RL-LTV (w/o x_s)	7.947	4.135	0.771	0.686	0.613
RL-LTV (w/o x_t)	8.146	4.351	0.763	0.680	0.611
RL-LTV (w/o R)	7.931	4.133	0.754	0.672	0.592
RL-LTV	7.873	4.067	0.782	0.705	0.625

所有这些结果都强调了本文最初定义 POC-MDP 的有效性。与 RL-LTV 相比，Vanilla-CTR 在第 5.2 节和第 5.3 节中的退化表现验证了整个 MDP 和强化学习框架；RL-LTV (w/o x_s) 和 RL-LTV (w/o x_t) 的退化表现表明不可控状态，也就是 x_s 和 x_t ，是必要的；RL-LTV (w/o R) 的退化表现说明不可观测状态也有助于建模。

超参数敏感性分析

本文还对式 (7) 中的重要参数，即融合权重 α ，进行敏感性分析。不同的 α 选择会生成不同的最终分数 y ，类似地，也可以使用第 5.2 节介绍的 NDCG 进行评估。此外，作为 CTR 预测相对于真实 CTR 标签的指标， y 的 AUC 也可以在不同 α 下进行评估。随着 α 从 0

稳定变化到 1, y 会从 CTR 排序指标转变为物品 LTV 排序指标。通过检查 AUC (CTR 的 AUC) 和 NDCG (LTV 的 NDCG) 随 α 变化的曲线, 可以获得即时奖励与长期奖励之间权衡关系的快照。需要注意的是, 根据式 (8), α 应该随不同物品而变化; 不过, 在这里本文只是通过为所有物品固定相同的 α 来执行一个简化的离线分析。

实验结果显示, 随着 α 增大, AUC 下降而 NDCG 上升。这符合预期。根据曲线形状, 本文期望 α 的均值约为 0.1, 因为此时 AUC 曲线开始更快下降。相应地, 式 (8) 中的 $\alpha_{\min}$ 和 $\alpha_{\max}$ 分别设置为 0 和 0.2。

结论

本文提出一种新的 RL-LTV 框架, 通过考虑物品的长期奖励, 即 LTV, 来解决冷启动推荐问题。本文采用一种特殊形式的 MDP, 即 POC-MDP, 来建模物品生命周期动态。泛化的物品级观测空间和动作空间, 以及参数共享网络, 有助于将成熟历史物品中的知识迁移到新鲜冷启动物品。本文采用一个带有 LSTM 组件的离策略 actor-critic 强化学习智能体, 通过优化即时奖励和长期 LTV 的策略, 交互式地学习并改变在线系统。这是首次将这类策略纳入在线推荐系统, 用于解决物品冷启动问题。本文开发了一个名为 IE-RDPG 的训练框架, 用于完成大规模、逐物品、episodic 训练任务。通过严格实验, 结果表明, 与淘宝线上最先进基线相比, 本文算法在冷启动物品的长期奖励上表现显著更好。在实验期间, 整体线上性能没有出现明显退化。未来工作中, 一个有趣方向是使用强化学习研究商品的完整生命周期, 从而产生不仅用于冷启动、也用于终身推荐的策略。另一个可能改进方向是增强模型可解释性, 以显式展示商品生命周期阶段之间的转移。

参考文献说明

正文引用编号与原论文一致。参考文献条目请见原论文 References 部分; 本翻译稿主要面向正文逐段理解, 因此未逐条翻译参考文献题名。