

1 PPO（近端策略优化）算法流程与伪代码

算法流程

1. 初始化策略网络参数 θ 、价值网络参数 ϕ ，以及旧策略参数 $\theta_{\text{old}} \leftarrow \theta$ 。

2. 对于每次迭代：

(a) 使用旧策略 $\pi_{\theta_{\text{old}}}$ 与环境交互，收集轨迹数据

$$\mathcal{D} = \{(s_t, a_t, r_t, s_{t+1})\}.$$

(b) 根据奖励序列计算折扣回报 R_t 和优势估计 $\hat{A}_t$ 。

(c) 对采集到的数据重复更新 K 轮：

i. 将数据划分为小批量。

ii. 对每个小批量，计算新旧策略概率比：

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}.$$

iii. 计算裁剪策略目标：

$$L^{\text{CLIP}}(\theta) = \min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right).$$

iv. 更新策略网络，使 L^{CLIP} 最大化。

v. 计算价值函数损失：

$$L^{\text{VF}}(\phi) = (V_{\phi}(s_t) - R_t)^2.$$

vi. 更新价值网络，使 L^{VF} 最小化。

(d) 更新旧策略参数：

$$\theta_{\text{old}} \leftarrow \theta.$$

伪代码

Algorithm 1 PPO-Clip 算法（Actor-Critic 版本）

```

1: 初始化策略网络参数  $\theta$ 、价值网络参数  $\phi$ 
2: 初始化旧策略参数  $\theta_{\text{old}} \leftarrow \theta$ 
3: for 每次迭代 do
4:   使用  $\pi_{\theta_{\text{old}}}$  采集轨迹数据  $\mathcal{D}$ 
5:   计算折扣回报  $R_t$  和优势估计  $\hat{A}_t$ 
6:   for  $epoch = 1$  到  $K$  do
7:     for 每个小批量  $(s, a, \hat{A}, R)$  do
8:       计算概率比:

$$r(\theta) \leftarrow \frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)}$$

9:       计算裁剪目标:

$$L^{\text{CLIP}} \leftarrow \min \left( r(\theta)\hat{A}, \text{clip}(r(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A} \right)$$

10:      计算熵正则:

$$S \leftarrow \mathcal{H}(\pi_{\theta}(\cdot|s))$$

11:      策略目标:

$$L^{\text{Policy}} \leftarrow L^{\text{CLIP}} + c_2 S$$

12:      更新策略网络:

$$\theta \leftarrow \theta + \alpha_{\pi} \nabla_{\theta} L^{\text{Policy}}$$

13:      计算价值损失:

$$L^{\text{VF}} \leftarrow (V_{\phi}(s) - R)^2$$

14:      更新价值网络:

$$\phi \leftarrow \phi - \alpha_V \nabla_{\phi} L^{\text{VF}}$$

15:     end for
16:   end for
17:   更新旧策略:

$$\theta_{\text{old}} \leftarrow \theta$$

18: end for

```

2 MADDPG (多智能体深度确定性策略梯度) 算法流程与伪代码

算法流程

1. 对每个智能体 i 初始化 Actor 网络 $\mu_i(o_i; \theta_i)$ 、Critic 网络 $Q_i(x, a_1, \dots, a_N; \phi_i)$ ，以及对应的目标网络 $\theta'_i \leftarrow \theta_i$, $\phi'_i \leftarrow \phi_i$ 。
2. 初始化经验回放池 $\mathcal{D}$ 。
3. 对于每个 episode:

(a) 初始化环境，获得所有智能体的初始观测 $o_1, \dots, o_N$ 。

(b) 每个智能体根据自身观测选择动作:

$$a_i = \mu_i(o_i; \theta_i) + \mathcal{N}_t.$$

(c) 所有智能体同时执行动作 $(a_1, \dots, a_N)$ ，获得奖励 $(r_1, \dots, r_N)$ 和下一观测 $(o'_1, \dots, o'_N)$ 。

(d) 将经验

$$(x, a_1, \dots, a_N, r_1, \dots, r_N, x')$$

存入经验回放池，其中 $x = (o_1, \dots, o_N)$ 。

(e) 从经验回放池中采样小批量数据，对每个智能体 i :

i. 使用目标 Actor 计算下一时刻动作:

$$a'_j = \mu'_j(o'_j; \theta'_j), \quad j = 1, \dots, N.$$

ii. 构造 TD 目标:

$$y_i = r_i + \gamma Q'_i(x', a'_1, \dots, a'_N; \phi'_i).$$

iii. 更新 Critic:

$$L_i(\phi_i) = \frac{1}{B} \sum (Q_i(x, a_1, \dots, a_N; \phi_i) - y_i)^2.$$

iv. 更新 Actor:

$$\nabla_{\theta_i} J \approx \frac{1}{B} \sum \nabla_{\theta_i} \mu_i(o_i) \nabla_{a_i} Q_i(x, a_1, \dots, a_N) \Big|_{a_i = \mu_i(o_i)}.$$

v. 软更新目标网络:

$$\theta'_i \leftarrow \tau \theta_i + (1 - \tau) \theta'_i, \quad \phi'_i \leftarrow \tau \phi_i + (1 - \tau) \phi'_i.$$

伪代码

Algorithm 2 MADDPG 算法

```

1: 初始化  $N$  个智能体的 Actor、Critic 及其目标网络
2: 初始化经验回放池  $\mathcal{D}$ 
3: for 每个 episode do
4:   初始化环境, 获得  $o_1, \dots, o_N$ 
5:   for 每个时间步 do
6:     for 每个智能体  $i = 1, \dots, N$  do
7:        $a_i \leftarrow \mu_i(o_i; \theta_i) + \mathcal{N}_t$ 
8:     end for
9:     执行动作  $(a_1, \dots, a_N)$ 
10:    获得奖励  $(r_1, \dots, r_N)$  和下一观测  $(o'_1, \dots, o'_N)$ 
11:     $x \leftarrow (o_1, \dots, o_N)$ ,  $x' \leftarrow (o'_1, \dots, o'_N)$ 
12:    存储  $(x, a_1, \dots, a_N, r_1, \dots, r_N, x')$  到  $\mathcal{D}$ 
13:    从  $\mathcal{D}$  中采样小批量数据
14:    for 每个智能体  $i = 1, \dots, N$  do
15:       $a'_j \leftarrow \mu'_j(o'_j; \theta'_j)$ ,  $j = 1, \dots, N$ 
16:       $y_i \leftarrow r_i + \gamma Q'_i(x', a'_1, \dots, a'_N; \phi'_i)$ 
17:       $L_i \leftarrow \frac{1}{B} \sum (Q_i(x, a_1, \dots, a_N; \phi_i) - y_i)^2$ 
18:       $\phi_i \leftarrow \phi_i - \alpha_Q \nabla_{\phi_i} L_i$ 
19:       $\theta_i \leftarrow \theta_i + \alpha_\mu \nabla_{\theta_i} J$ 
20:       $\theta'_i \leftarrow \tau \theta_i + (1 - \tau) \theta'_i$ 
21:       $\phi'_i \leftarrow \tau \phi_i + (1 - \tau) \phi'_i$ 
22:    end for
23:     $o_i \leftarrow o'_i$ ,  $i = 1, \dots, N$ 
24:  end for
25: end for

```
