

DAPO: 一个开源的大规模大语言模型强化学习系统

论文逐段中文翻译

根据用户上传论文整理翻译

原文题目: DAPO: An Open-Source LLM Reinforcement Learning System at Scale

日期: 2025 年 3 月 17 日 (arXiv v2: 2025 年 5 月 20 日)

说明: 本文档为对原论文内容的中文翻译整理稿, 便于阅读与做笔记; 公式、章节结构与主要表述尽量忠实于原文。参考文献条目保留原始英文信息, 以便检索。

摘要

推理时扩展 (inference scaling) 赋予了大语言模型前所未有的推理能力, 而强化学习则是激发复杂推理行为的核心技术。然而, 当前最先进推理型大模型的关键技术细节仍然被隐藏起来 (例如 OpenAI o1 博客和 DeepSeek R1 技术报告), 因此整个社区仍然难以复现它们的强化学习训练结果。本文提出了解耦裁剪与动态采样策略优化算法 (Decoupled Clip and Dynamic sAmpling Policy Optimization, DAPO), 并将一个达到当前先进水平的大规模强化学习系统完整开源。该系统基于 Qwen2.5-32B 基座模型, 在 AIME 2024 上取得了 50 分。不同于此前对训练细节有所保留的工作, 我们介绍了使大规模大模型强化学习取得成功的四项关键技术。此外, 我们还开源了基于 verl 框架构建的训练代码, 以及一份经过精心筛选和处理的数据集。这些开源组件提升了结果的可复现性, 也为未来的大规模大模型强化学习研究提供了支持。

1 引言

像 OpenAI 的 o1 和 DeepSeek 的 R1 这样的“测试时扩展”方法, 给大语言模型带来了深刻的范式转变。测试时扩展使模型能够进行更长的思维链 (Chain-of-Thought) 推理, 并诱发更复杂的推理行为, 这使得模型在 AIME、Codeforces 等数学和编程竞赛任务上表现得更加出色。

推动这一变革的核心技术是大规模强化学习。强化学习能够激发诸如自我验证、迭代修正等复杂推理行为。然而, 可扩展强化学习训练的真实算法与关键 recipe 依然近似于“黑箱”, 在现有推理模型的技术报告中并没有被充分披露。本文揭示了大规模强化学习训练中的重要障碍, 并开源了一个可扩展的强化学习系统: 它不仅公开了完整算法, 还公开了训练代码与数据集, 从而为社区提供了具有工业级结果的、民主化的大规模强化学习解决方案。

我们使用 Qwen2.5-32B 作为强化学习的预训练模型。在最初的 GRPO 实验中, 我们在 AIME 上仅取得了 30 分, 这一结果显著低于 DeepSeek 的强化学习结果 (47 分)。经过深入分析, 我们发现朴素 GRPO 基线存在若干关键问题, 例如熵塌缩 (entropy collapse)、奖励噪声以及训练不稳定。更广泛的社区在复现 DeepSeek 结果时也遇到了类似困难, 这表明 R1 论文中可能省略了若干对于构建工业级、大规模且可复现强化学习系统而言至关重要的训练细节。

为了弥补这一差距, 我们开源了一个面向大规模大模型强化学习的先进系统。该系统基于 Qwen2.5-32B, 在 AIME 2024 上取得了 50 分, 超过了此前 DeepSeek-R1-Zero-Qwen-32B 达到的 47 分, 而

且所用训练步数仅为后者的 50%。我们提出了 DAPO 算法，并给出了四项关键技术，使强化学习在长思维链（long-CoT）场景中真正发挥出效果。具体包括：

1. **Clip-Higher**: 促进系统的多样性，避免熵塌缩；
2. **Dynamic Sampling**: 提升训练效率与稳定性；
3. **Token-Level Policy Gradient Loss**: 在长思维链强化学习场景中至关重要；
4. **Overlong Reward Shaping**: 降低奖励噪声并稳定训练。

我们的实现基于 verl。通过完整公开这一当前先进水平的强化学习系统，包括训练代码与数据，我们希望为大规模大模型强化学习提供有价值的洞见，并使更广泛的社区受益。

2 预备知识

2.1 近端策略优化 (PPO)

PPO 引入了一个带裁剪的代理目标（clipped surrogate objective）来进行策略优化。通过利用裁剪操作将策略更新约束在旧策略附近的一个近端区域内，PPO 能够稳定训练并提升样本效率。具体而言，PPO 通过最大化如下目标来更新策略：

$$J_{\text{PPO}}(\theta) = \mathbb{E}_{(q,a) \sim D, o_{\leq t} \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\min \left(\frac{\pi_{\theta}(o_t | q, o_{< t})}{\pi_{\theta_{\text{old}}}(o_t | q, o_{< t})} \hat{A}_t, \text{clip} \left(\frac{\pi_{\theta}(o_t | q, o_{< t})}{\pi_{\theta_{\text{old}}}(o_t | q, o_{< t})}, 1 - \varepsilon, 1 + \varepsilon \right) \hat{A}_t \right) \right], \quad (1)$$

其中， (q, a) 是来自数据分布 D 的问答对， ε 为重要性采样比值的裁剪范围， $\hat{A}_t$ 是时刻 t 的优势函数估计。给定价值函数 V 与奖励函数 R ， $\hat{A}_t$ 可由广义优势估计（GAE）计算为：

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}, \quad (2)$$

其中

$$\delta_l = R_l + \gamma V(s_{l+1}) - V(s_l), \quad 0 \leq \gamma, \lambda \leq 1. \quad (3)$$

2.2 组相对策略优化 (GRPO)

与 PPO 相比，GRPO 去除了价值函数，并采用组相对（group-relative）的方式来估计优势。对于一个特定的问答对 (q, a) ，行为策略 $\pi_{\theta_{\text{old}}}$ 会采样出一个包含 G 个响应的组 $\{o_i\}_{i=1}^G$ 。随后，第 i 个响应的优势通过对组级奖励 $\{R_i\}_{i=1}^G$ 进行归一化而得到：

$$\hat{A}_{i,t} = \frac{r_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (4)$$

与 PPO 类似，GRPO 也采用带裁剪的目标函数，并直接加入 KL 惩罚项：

$$J_{\text{GRPO}}(\theta) = \mathbb{E}_{(q,a) \sim D, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_{i,t} \right) - \beta D_{\text{KL}}(\pi_{\theta} \| \pi_{\theta_{\text{old}}}) \right] \quad (5)$$

其中

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}. \quad (6)$$

还需要注意的是，GRPO 在**样本级**上计算目标函数。更准确地说，GRPO 首先对每个生成序列内部按 token 取平均 loss，然后再对不同样本的 loss 进行平均。正如第 3.3 节将讨论的那样，这种差异会对算法性能产生影响。

2.3 移除 KL 散度

KL 惩罚项原本用于约束在线策略与冻结参考策略之间的偏离程度。在 RLHF 场景中，强化学习的目标是让模型行为与人类偏好对齐，同时又不能与初始模型偏离过远。然而，在训练长思维链推理模型时，模型分布可能会显著偏离初始模型，因此这种限制并非必要。基于此，我们在提出的算法中移除了 KL 项。

2.4 基于规则的奖励建模

使用奖励模型通常会遭遇“奖励黑客”（reward hacking）问题。因此，我们直接使用**可验证任务的最终正确性**作为结果奖励，并采用如下规则：

$$R(\hat{y}, y) = \begin{cases} 1, & \text{is_equivalent}(\hat{y}, y), \\ -1, & \text{否则。} \end{cases} \quad (7)$$

其中， y 为真实答案， $\hat{y}$ 为模型预测答案。已有研究表明，这种方式在激发基座模型的推理能力方面是有效的，并且已经在自动定理证明、程序生成、数学竞赛等多个领域得到验证。

3 DAPO

我们提出了解耦裁剪与动态采样策略优化算法（DAPO）。对于每个问题 q 及其对应答案 a ，DAPO 会采样一个输出组 $\{o_i\}_{i=1}^G$ ，并通过以下目标优化策略：

$$J_{\text{DAPO}}(\theta) = \mathbb{E}_{(q,a) \sim D, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot \mid q)} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) \hat{A}_{i,t} \right) \right], \quad (8)$$

满足约束

$$0 < |\{o_i \mid \text{is_equivalent}(a, o_i)\}| < G, \quad (9)$$

其中

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}, \quad \hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (10)$$

完整算法见后文算法描述。本节将介绍与 DAPO 相关的关键技术。

3.1 提高上限：Clip-Higher

在最初使用朴素 PPO 或 GRPO 的实验中，我们观察到了熵塌缩现象：随着训练推进，策略熵迅速下降。某些组中采样得到的响应几乎完全相同。这意味着探索受限，策略过早变得确定性，从而阻碍了后续扩展。

为了解决这一问题，我们提出了 **Clip-Higher** 策略。PPO-Clip 中对重要性采样比值进行裁剪，本意是限制 trust region、增强强化学习的稳定性。我们发现：**上侧裁剪会抑制策略探索**。原因在于，使“利用型 (exploitation) token”变得更可能相对容易，而对于原本概率很低的“探索型 (exploration) token”，其概率提升却被上裁剪门限严格约束。

具体来说，当 $\varepsilon = 0.2$ （多数算法的默认值）且 $\hat{A}_{i,t} > 0$ 时，系统试图提高某个动作的概率。若两个动作的旧策略概率分别为 $\pi_{\theta_{\text{old}}}(o_i|q) = 0.01$ 和 0.9 ，则更新后概率的上界分别为 0.012 和 1.08 ，即 $\pi_{\theta_{\text{old}}} \cdot (1 + \varepsilon)$ 。这意味着：对于原本高概率的“利用型” token（例如 0.9 ），即便进一步升到 0.999 也几乎不受限制；而对于低概率的“探索型” token，要想获得一个非平凡的概率提升却困难得多。经验上我们也观察到，被上裁剪命中的 token，其平均概率很低，即 $\pi_{\theta}(o_i|q) < 0.2$ 。这一发现支持了我们的直觉：上裁剪阈值确实在限制低概率探索 token 的概率上升，因此可能束缚系统的探索能力。

因此，我们采用 Clip-Higher 策略，将上下裁剪范围解耦为 ε_{low} 与 $\varepsilon_{\text{high}}$ ：

$$J_{\text{DAPO}}(\theta) = \mathbb{E}_{(q,a) \sim D, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) \hat{A}_{i,t} \right) \right], \quad (11)$$

并保持约束

$$0 < |\{o_i \mid \text{is_equivalent}(a, o_i)\}| < G. \quad (12)$$

我们增大 $\varepsilon_{\text{high}}$ ，为低概率 token 的概率提升留出更多空间。实验结果表明，这一调整有效提升了策略熵，并促进模型生成更多样化的样本。至于 ε_{low} ，我们保持不变，因为若也将其增大，则会更强地压制这类 token 的概率，甚至导致采样空间塌缩。

3.2 越多越好：Dynamic Sampling

现有强化学习算法在某些 prompt 的准确率达到 1 时，会出现梯度减弱问题。以 GRPO 为例，如果某个 prompt 对应的所有输出 $\{o_i\}_{i=1}^G$ 都正确并获得了相同奖励，那么该组对应的优势就是 0。优势为 0 将导致策略梯度为 0，这会缩小 batch 梯度的有效幅度、增加其对噪声的敏感性，进而降低样本效率。经验上，准确率等于 1 的样本数量会持续增加。这意味着每个 batch 中真正有效的 prompt 数量在不断减少，从而导致梯度方差增大，并削弱模型训练所需的梯度信号。

为此，我们提出：在采样时**过采样**，并过滤掉准确率恰为 1 或 0 的 prompt，只保留那些梯度有效的样本，从而使 batch 中的有效 prompt 数量保持稳定。此时，每个 batch 的采样成本是动态变化的；在训练前，我们会持续采样，直到 batch 被那些准确率既不为 0 也不为 1 的样本填满。其目标形式仍然写作：

$$J_{\text{DAPO}}(\theta) = \mathbb{E}_{(q,a) \sim D, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) \hat{A}_{i,t} \right) \right], \quad (13)$$

且仍满足

$$0 < |\{o_i \mid \text{is_equivalent}(a, o_i)\}| < G. \quad (14)$$

需要注意的是，这一策略并不一定会降低训练效率，因为如果强化学习系统是同步的、且生成阶段没有流水化，那么生成时间通常由长尾样本主导。此外，我们发现，使用 dynamic sampling 后，实验能够更快达到相同性能。

3.3 重新平衡：Token-Level Policy Gradient Loss

原始 GRPO 算法采用**样本级** loss 计算方式：先在每个样本内部对 token 的 loss 取平均，再在样本之间进行平均。也就是说，每个样本在最终 loss 中具有相同权重。然而我们发现，在长思维链强化学习场景下，这种聚合方式会带来若干问题。

由于所有样本在 loss 计算中权重相同，因此较长响应中的单个 token 对总体 loss 的贡献会被不成比例地降低，从而引发两个负面后果。第一，对于高质量的长样本，这会削弱模型从其中学习推理相关模式的能力。第二，我们观察到，过长样本中往往包含低质量模式，例如乱码 (gibberish) 和重复词。样本级 loss 由于无法有效惩罚长样本中的这些不良模式，会导致熵与响应长度出现不健康增长。

为解决上述问题，我们在长思维链强化学习场景中引入了 **token-level policy gradient loss**：

$$J_{\text{DAPO}}(\theta) = \mathbb{E}_{(q,a) \sim D, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) \hat{A}_{i,t} \right) \right], \quad (15)$$

并保持同样的有效样本约束。

在这一设定下，较长序列相对于较短序列能够在总体梯度更新中产生更大的影响。此外，从单个 token 的视角来看，只要某种生成模式会导致奖励上升或下降，那么无论它出现在长响应还是短响应中，都将被等价地鼓励或抑制。

3.4 捉迷藏：Overlong Reward Shaping

在强化学习训练中，我们通常会为生成设置一个最大长度，超过该长度的样本会被截断。我们发现：如果对这些被截断样本的奖励塑形不当，会引入奖励噪声，并显著破坏训练过程。

默认情况下，我们会给被截断样本一个惩罚性奖励。但这种方式可能向训练中引入噪声，因为某条推理链本身可能是合理的，只是由于长度过长才受到惩罚。这种惩罚会让模型对自身推理过程的有效性产生混淆。

为了研究这种奖励噪声的影响，我们首先使用 **Overlong Filtering** 策略，即对被截断样本的 loss 做 masking。我们发现，这种做法能够显著稳定训练并提升性能。

DAPO 的算法流程可概括如下：

1. 输入初始策略模型 π_{θ} 、奖励模型 R 、任务提示集合 D 以及超参数 $\varepsilon_{\text{low}}, \varepsilon_{\text{high}}$ ；
2. 对于每一步训练，从 D 中采样一个 batch D_b ；
3. 更新旧策略模型： $\pi_{\theta_{\text{old}}} \leftarrow \pi_{\theta}$ ；
4. 对 batch 中每个问题 q ，从旧策略采样 G 个输出；
5. 用奖励函数 R 计算每个输出的奖励；
6. 按 dynamic sampling 规则过滤样本，并加入动态采样缓冲区；
7. 如果缓冲区大小尚未达到要求，则继续采样；
8. 对缓冲区中的每个样本，计算其各 token 的优势 $\hat{A}_{i,t}$ ；
9. 执行若干次优化迭代，通过最大化 DAPO 目标更新策略模型 π_{θ} 。

进一步地，我们提出了 **Soft Overlong Punishment**：这是一种与长度相关的惩罚机制，用于对被截断样本进行奖励塑形。具体而言，当响应长度超过预设最大值附近时，我们定义一个惩罚区间；在这个区间内，响应越长，惩罚越大。该惩罚将与基于规则的正确性奖励相加，从而向模型传递“避免生成过长响应”的信号：

$$R_{\text{length}}(y) = \begin{cases} 0, & |y| \leq L_{\text{max}} - L_{\text{cache}}, \\ \frac{(L_{\text{max}} - L_{\text{cache}}) - |y|}{L_{\text{cache}}}, & L_{\text{max}} - L_{\text{cache}} < |y| \leq L_{\text{max}}, \\ -1, & L_{\text{max}} < |y|. \end{cases} \quad (16)$$

3.5 数据集变换

我们的数据集来自网络与官方竞赛主页，通过网页抓取和人工标注相结合的方式获得。数学数据集集中的答案往往具有多种形式，例如表达式、公式、数字等，这使得设计一套完备的解析规则变得困难。为了借助规则提供准确奖励、同时减少公式解析器带来的误差，我们受到 AIME 的启发，对答案进行筛选与变换，将其统一转成**整数答案**，因为整数最容易解析。

例如，如果原始答案写成 $\frac{a + \sqrt{b}}{c}$ 的形式，那么我们会指示大模型改写题目，使期望答案变成 $a + b + c$ 。经过筛选与变换之后，我们得到 DAPO-Math-17K 数据集，其中包含 17K 个 prompt，每个 prompt 都对应一个整数答案。

4 实验

4.1 训练细节

本文聚焦于数学任务来评估所提出的算法，而这些方法也可以较为直接地迁移到其他任务中。训练框架采用 verl。我们将朴素 GRPO 作为基线算法，并通过组内奖励归一化来估计优势。

在超参数方面，我们使用 AdamW 优化器，采用恒定学习率 1×10^{-6} ，并在前 20 个 rollout step 中使用线性 warm-up。对于 rollout，prompt 的 batch size 设为 512，并且对每个 prompt 采样 16 个响应。训练时，mini-batch size 也设为 512，即每个 rollout step 对应 16 次梯度更新。对于 overlong reward shaping，我们将期望最大长度设置为 16,384 个 token，并额外分配 4,096 个 token 作为 soft punish cache，因此生成最大 token 数设为 20,480。对于 Clip-Higher 机制，裁剪参数设置为 $\epsilon_{\text{low}} = 0.2$ 、 $\epsilon_{\text{high}} = 0.28$ ，从而在探索与利用之间取得较好的平衡。评估 AIME 时，我们将评测集重复 32 次，并报告 avg@32，以提升结果稳定性。评估阶段的推理超参数为 temperature 1.0、top-p 0.7。

4.2 主要结果

在 AIME 2024 上的实验表明，DAPO 成功将 Qwen-32B Base 训练成了一个强大的推理模型，其性能优于 DeepSeek 在 Qwen2.5-32B 上采用 R1 方法得到的结果。从图 1 可以看到，AIME 2024 的准确率从接近 0% 提升到了 50%。值得注意的是，这一提升仅使用了 DeepSeek-R1-Zero-Qwen-32B 一半的训练步数。

我们进一步分析了各项训练技术在整体方法中的贡献，如表 1 所示。结果表明，这些技术在强化学习训练中都是有效的，每一项都能为 AIME 2024 带来若干个点的精度提升。尤其值得强调的是，在原始 GRPO 设置下，基于 Qwen2.5-32B base model 训练最多只能达到 30% 的准确率。

对于 token-level loss, 虽然它带来的直接性能提升较小, 但我们发现它能够提升训练稳定性, 并让响应长度的增长变得更加健康。对于 dynamic sampling, 尽管由于过滤掉零梯度数据而需要采更多数据, 但整体训练时间并未明显增加。相反, 由于所需训练步数更少, 模型的收敛时间甚至进一步缩短。

表 1: 逐步加入 DAPO 各项技术后的主要结果

模型	AIME24 avg@32
DeepSeek-R1-Zero-Qwen-32B	47
Naive GRPO	30
+ Overlong Filtering	36
+ Clip-Higher	38
+ Soft Overlong Punishment	41
+ Token-level Loss	42
+ Dynamic Sampling (DAPO)	50

4.3 训练动态

大语言模型上的强化学习不仅是一个前沿研究方向, 同时也是一个本质上高度复杂的系统工程问题, 其中各个子系统之间相互依赖。对任意一个子系统的修改, 都可能沿着系统传播, 并由于这些组件之间复杂的耦合关系而引发意想不到的后果。即便只是初始条件中的微小变化, 例如数据和超参数的变化, 也可能在迭代式强化学习过程中不断放大, 最终导致显著不同的结果。

这种复杂性常常使研究者陷入两难: 即使经过严谨分析、并有充分理由相信某项改动会改善训练过程的某一方面, 实际结果也经常偏离预期轨迹。因此, 在实验过程中监控关键的中间指标, 对于快速定位偏差来源、进而不断完善系统而言至关重要。

原文重点监控了以下几类指标:

1. **生成响应长度**: 它与训练稳定性和性能高度相关。长度增加为模型提供了更大的探索空间, 使更复杂的推理行为得以被采样并通过训练逐步强化。不过, 长度并不会始终单调上升, 在某些阶段也可能停滞甚至下降, 这一点与 DeepSeek 的观察一致。通常作者会将长度与验证集准确率结合起来, 用于判断实验是否正在恶化。
2. **训练过程中的奖励动态**: 这是强化学习里一直非常关键的监控指标。在大多数实验中, 奖励的上升趋势比较稳定, 不会因为实验设置调整而剧烈波动或下降。这说明只要奖励信号可靠, 语言模型就能够稳健地拟合训练集分布。然而作者也发现, 训练集上的最终 reward 与验证集准确率往往相关性很弱, 这说明训练中存在对训练集过拟合的问题。
3. **Actor 模型的熵与生成概率**: 它们与模型的探索能力密切相关, 也是实验中重点监控的指标。直观地说, 模型熵需要维持在一个合适区间: 过低说明分布过于尖锐、探索能力丧失; 过高则通常意味着过度探索, 例如生成乱码和重复内容。与此相对, 平均生成概率的含义刚好相反。原文指出, 通过 Clip-Higher 策略, 他们有效缓解了熵塌缩问题; 后续实验还发现, 让熵保持缓慢上升趋势, 有利于模型性能提高。

4.4 案例研究

在强化学习训练过程中, 作者观察到了一个有趣现象: actor 模型的推理模式会随着时间动态演化。具体而言, 算法不仅会强化那些有助于正确解题的既有推理模式, 还会逐步催生出训练初期并

不存在的全新推理方式。这一发现揭示了强化学习算法的适应性和探索能力，也为理解模型的学习机制提供了新的视角。

例如，在模型训练早期，几乎看不到对先前推理步骤进行检查与反思的行为；但随着训练推进，模型逐渐表现出明显的反思 (reflection) 和回溯 (backtracking) 行为。作者认为，这为今后解释“推理能力在强化学习过程中是如何涌现出来的”这一问题提供了新的研究方向。

原文还给出了一个具体数学题案例，展示模型在解题过程中出现“等一下，让我们重新思考一下”等反思式语言，从而体现出这种 reflective behavior 的涌现。

5 结论

本文开源了一个完整的大规模大语言模型强化学习系统，包括算法、代码基础设施和数据集。该系统在大规模大模型强化学习上达到了当前先进性能：基于 Qwen-32B 预训练模型，在 AIME 上取得 50 分。作者提出了 DAPO 算法，并总结出四项关键技术，使强化学习在长思维链场景下既高效又有效。此外，通过开源训练代码与数据集，本文为更广泛的研究社区和社会提供了一个可实践、可扩展的强化学习解决方案，使更多人能够从这些进展中受益。

贡献说明

项目负责人：Qiyong Yu。

算法：Qiyong Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue。

基础设施：Weinan Dai, Tiantian Fan, Gaohong Liu, Juncai Liu, Lingjun Liu, Xin Liu, Haibin Lin, Zhiqi Lin, Bole Ma, Guangming Sheng, Yuxuan Tong, Qiyong Yu, Chi Zhang, Mofan Zhang, Ru Zhang, Wang Zhang, Hang Zhu, Jinhua Zhu。

数据集：Jiaze Chen, Jiangjie Chen, Chengyi Wang, Hongli Yu, Yuxuan Song, Xiangpeng Wei, Qiyong Yu。

指导：Hao Zhou, Jingjing Liu, Wei-Ying Ma, Ya-Qin Zhang, Lin Yan, Mu Qiao, Yonghui Wu, Mingxuan Wang。

单位：ByteDance Seed；清华大学智能产业研究院 (AIR)；香港大学；清华 AIR 与字节 Seed 联合实验室 (SIA-Lab)。

致谢

作者感谢 Zhengyin Du、Shengding Hu、Kai Shen、Tianyang Zhan、Zhen Xiao、Renjie Zheng、Li Han、Kaihua Jiang 以及字节跳动的其他同事对 DAPO 项目的支持。

A 附录 A：数据集变换示例

下面给出一个数据变换示例，展示原始题目、变换后的题目，以及模型在变换过程中给出的输出（原文中原始内容以 markdown 文本形式给出，为方便阅读已渲染）。

为了保证模型能够高精度完成这一任务，作者的目标是让模型进行充分推理，同时避免幻觉。为此，他们提供了清晰的思考框架，鼓励模型进行完整推理。具体而言，采用了思维链推理，并明确划分为四个步骤：提取答案格式、改写题目陈述、求解改写后的题目，并给出整数形式的最终答案。对于每一步，作者都提供了 few-shot 示例或详细指导，以引导模型推理。

通过这种方式, 作者观察到, 在多数情况下, 大模型都能生成在格式与质量上令人满意的改写版本。

原始题目: 设 x 和 y 为实数, 满足

$$x^2 + y^2 - 22x - 16y + 113 = 0.$$

求 x 的最小可能值。答案为: $11 - 2\sqrt{6}$ 。

变换后的题目: 设 x 和 y 为实数, 满足

$$x^2 + y^2 - 22x - 16y + 113 = 0.$$

求 x 的最小可能值。原答案可写为 $k - m\sqrt{n}$ 的形式, 其中 k, m, n 为整数。请给出 $k + m + n$ 的值。答案: 19。

模型输出的大意: 原始答案是代数表达式 $11 - 2\sqrt{6}$, 需要把它变为整数形式。首先识别出该答案由整数部分和根式部分构成; 按照规则, 将其写成 $k - m\sqrt{n}$ 的形式, 并要求学生求出 $k + m + n$ 。于是可以对应得到 $k = 11, m = 2, n = 6$, 最终结果为 19。

B 附录 B: 补充案例

原文还给出了另一个案例, 问题大意如下: 在 Aimeville 的 900 名居民中, 有 195 人拥有钻戒, 367 人拥有高尔夫球杆, 562 人拥有园艺铁锹; 此外, 所有 900 人都拥有一袋糖果心。已知 437 人恰好拥有其中两样, 234 人恰好拥有其中三样, 求同时拥有这四样东西的人数。

作者展示的模型响应中, 模型最初沿着一条计数思路推导, 但得到非整数结果后, 又明确指出“当前方法需要重新考虑”, 随后切换到另一种组合计数思路。这一案例进一步体现了训练过程中涌现出的反思式行为。

参考文献

1. OpenAI. Learning to reason with llms, 2024.
2. Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. arXiv preprint arXiv:2501.12948, 2025.
3. OpenAI. GPT4 technical report. arXiv preprint arXiv:2303.08774, 2023.
4. Anthropic. Claude 3.5 sonnet, 2024.
5. Tom Brown et al. Language models are few-shot learners. NeurIPS, 2020.
6. Aakanksha Chowdhery et al. Palm: Scaling language modeling with pathways. JMLR, 2023.
7. Aixin Liu et al. Deepseek-v3 technical report. arXiv preprint arXiv:2412.19437, 2024.
8. XAI. Grok 3 beta —the age of reasoning agents, 2024.
9. Google DeepMind. Gemini 2.0 flash thinking, 2024.
10. Qwen. Qwq-32b: Embracing the power of reinforcement learning, 2024.

11. Kimi Team et al. Kimi k1.5: Scaling reinforcement learning with llms. arXiv preprint arXiv:2501.12599, 2025.
12. An Yang et al. Qwen2.5 technical report. arXiv preprint arXiv:2412.15115, 2024.
13. Zhipeng Chen et al. An empirical study on eliciting and improving rl-like reasoning models. arXiv preprint arXiv:2503.04548, 2025.
14. Jingcheng Hu et al. Open-Reasoner-Zero: An open source approach to scaling reinforcement learning on the base model, 2025.
15. Jian Hu. Reinforce++: A simple and efficient approach for aligning large language models. arXiv preprint arXiv:2501.03262, 2025.
16. Ganqu Cui et al. Process reinforcement through implicit rewards. arXiv preprint arXiv:2502.01456, 2025.
17. Jung Hyun Lee et al. Token-supervised value models for enhancing mathematical reasoning capabilities of large language models. arXiv preprint arXiv:2407.12863, 2024.
18. Amirhossein Kazemnejad et al. VinePPO: Unlocking RL potential for LLM reasoning through refined credit assignment. arXiv preprint arXiv:2410.01679, 2024.
19. Yufeng Yuan et al. What’s behind PPO’s collapse in long-CoT? Value optimization holds the secret. arXiv preprint arXiv:2503.01491, 2025.
20. Guangming Sheng et al. HybridFlow: A flexible and efficient RLHF framework. arXiv preprint arXiv:2409.19256, 2024.
21. John Schulman et al. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347, 2017.
22. John Schulman et al. High-dimensional continuous control using generalized advantage estimation, 2018.
23. Long Ouyang et al. Training language models to follow instructions with human feedback. NeurIPS, 2022.
24. Dario Amodei et al. Concrete problems in AI safety, 2016.
25. Tom Everitt et al. Reinforcement learning with a corrupted reward channel, 2017.
26. Victoria Krakovna et al. Specification gaming: the flip side of ai ingenuity, 2020.
27. Tom Everitt et al. Reward tampering problems and solutions in reinforcement learning, 2021.
28. Leo Gao, John Schulman, and Jacob Hilton. Scaling laws for reward model overoptimization, 2022.
29. Lilian Weng. Reward hacking in reinforcement learning, 2024.
30. Stanislas Polu and Ilya Sutskever. Generative language modeling for automated theorem proving, 2020.

31. Trieu H Trinh et al. Solving olympiad geometry without human demonstrations. *Nature*, 2024.
32. Trieu Trinh and Thang Luong. Alphageometry: An olympiad-level ai system for geometry, 2024.
33. AlphaProof and AlphaGeometry Teams. AI achieves silver-medal standard solving international mathematical olympiad problems, 2024.
34. Hung Le et al. CodeRL: Mastering code generation through pretrained models and deep reinforcement learning. *NeurIPS*, 2022.
35. Noah Shinn et al. Reflexion: Language agents with verbal reinforcement learning, 2023.
36. Xinyun Chen et al. Teaching large language models to self-debug, 2023.
37. Jonas Gehring et al. RLEF: Grounding code LLMs in execution feedback with reinforcement learning, 2025.
38. Zhihong Shao et al. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
39. Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *ICLR*, 2019.