

Direct Preference Optimization: Your Language Model is Secretly a Reward Model

逐段中文翻译

根据用户提供的论文 PDF 整理

目录

论文信息	3
1 摘要	3
2 1 引言	3
3 2 相关工作	4
4 3 预备知识	5
4.1 SFT 阶段	5
4.2 奖励建模阶段	5
4.3 RL 微调阶段	6
5 4 Direct Preference Optimization	6
5.1 DPO 目标的推导	6
5.2 DPO 更新到底在做什么?	7
5.3 DPO 的流程	8
6 5 DPO 的理论分析	8
6.1 5.1 你的语言模型其实就是一个奖励模型	8
6.2 5.2 Actor-Critic 算法的不稳定性	9
7 6 实验	10
7.1 任务	10
7.2 评估方式	11
7.3 比较方法	11
7.4 6.1 DPO 能否有效优化 RLHF 目标?	11

7.5	6.2 DPO 能否扩展到真实偏好数据集?	12
7.6	6.3 对新输入分布的泛化	13
7.7	6.4 用人工判断验证 GPT-4 判断	13
8	7 讨论	13
	局限性与未来工作	13
9	附录 A 数学推导 (中文整理)	14
9.1	A.1 带 KL 约束奖励最大化目标的最优解	14
9.2	A.2 Bradley–Terry 模型下 DPO 目标的推导	14
9.3	A.3 Plackett–Luce 模型下的 DPO	15
9.4	A.4 DPO 目标梯度	15
9.5	A.5 引理 1 与引理 2 的证明思路	15
9.6	A.6 定理 1 的证明思路	15
10	附录 B DPO 的实现细节与超参数	16
	论文中的 DPO 代码	16
11	附录 C 实验设置补充说明	17
11.1	C.1 IMDb 情感实验与基线细节	17
11.2	C.2 用于摘要与对话胜率评估的 GPT-4 提示	17
11.3	C.3 Unlikelihood 基线	17
12	附录 D 其他实验结果	17
12.1	D.1 不同 N 下 Best of N 基线的表现	17
12.2	D.2 样例回答与 GPT-4 判断	18
12.3	D.3 人工实验细节	18
13	参考文献说明	18

论文信息

原标题: Direct Preference Optimization: Your Language Model is Secretly a Reward Model

作者: Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, Chelsea Finn

会议信息: NeurIPS 2023; arXiv:2305.18290v3

1 摘要

尽管大规模无监督语言模型 (LM) 已经学到了广泛的世界知识以及一定的推理能力, 但由于其训练完全是无监督的, 因此很难对其行为进行精确控制。现有提升可控性的方法, 通常会收集人类对模型生成结果相对质量的标注, 然后对无监督语言模型进行微调, 使其与这些偏好对齐; 其中最常见的是基于人类反馈的强化学习 (RLHF)。

然而, RLHF 是一个复杂且往往不稳定的过程。它通常需要先拟合一个能够反映人类偏好的奖励模型, 再通过强化学习微调大型无监督语言模型, 使其在尽量不偏离原始模型的前提下最大化该估计奖励。

本文提出了 RLHF 中奖励模型的一种新参数化方式, 使得与之对应的最优策略能够以闭式形式直接求出, 从而只需一个简单的分类损失就可以求解标准的 RLHF 问题。我们将该算法称为 **Direct Preference Optimization (DPO)**。该方法稳定、效果好、计算开销轻, 不需要在微调过程中反复从语言模型采样, 也不需要大量超参数调节。

实验表明, DPO 在将语言模型对齐到人类偏好方面, 至少可以达到、甚至优于现有方法。尤其值得注意的是, 在生成情感控制任务上, DPO 微调后的效果超过了基于 PPO 的 RLHF; 在摘要和单轮对话任务上, 它在回复质量方面与现有方法持平或更优, 同时实现与训练过程都显著更简单。

2 1 引言

在超大规模数据集上训练得到的无监督语言模型已经展现出令人惊讶的能力。然而, 这些模型训练所依赖的数据由具有各种不同目标、优先级和能力水平的人类产生, 因此其中并非所有目标与能力都值得模仿。

例如, 我们希望 AI 编码助手能够理解常见编程错误, 以便帮助纠正它们; 但在真正生成代码时, 我们更希望模型偏向训练数据中那些可能较为稀有的高质量编程能力。同样地, 我们也许希望语言模型知道某些被许多人相信的常见误解, 但绝不希望模型在回答相关问题时以同样比例把这种误解当作真理陈述出来。

换句话说, 如何从模型非常广泛的知识 and 能力中 **选择出我们真正想要的响应与行为**, 是构建安全、高性能且可控 AI 系统的关键。现有方法一般采用强化学习来让语言模型符合人类偏好, 而本文将表明: 现有 RL 方法所优化的目标, 其实可以被一个简单的二元交叉熵目标精确优化, 从而显著简化偏好学习流程。

从高层次看，现有方法通常依赖精心构建的人类偏好数据集，将人们认为有帮助、无害、安全的行为注入语言模型。这个偏好学习阶段发生在大规模无监督预训练之后。最直接的做法，是用人类提供的高质量演示进行监督微调；但迄今最成功的一类方法，是基于人类（或 AI）反馈的强化学习，即 RLHF/RLAIF。

RLHF 的典型流程是：先用偏好数据训练奖励模型，然后用 RL 优化语言模型策略，使其生成高奖励回答，同时又不能偏离原始模型太远。虽然 RLHF 让模型获得了很强的对话与代码能力，但整个流程远比监督学习复杂：它需要训练多个模型，并在训练过程中反复从语言模型中采样，因此带来显著的计算成本。

本文展示了：无需显式奖励建模，也无需强化学习，我们依然可以直接优化语言模型，使其遵循人类偏好。我们提出 DPO，它在目标上隐式优化与现有 RLHF 相同的问题——即带 KL 约束的奖励最大化——但实现起来简单，训练也更直接。

直观上，DPO 会增加“被偏好回答”相对于“被拒绝回答”的对数概率，但它还引入了一个随样本变化的动态重要性权重，从而避免朴素概率比目标导致的模型退化现象。和现有算法一样，DPO 依赖一个理论上的偏好模型（例如 Bradley-Terry 模型）来刻画某个奖励函数与经验偏好数据的一致程度。但不同的是，现有方法先用该偏好模型定义奖励模型损失，再训练策略去优化学到的奖励；而 DPO 通过变量替换，直接把偏好损失定义为策略的函数。

因此，给定一组关于模型回答的人类偏好数据，DPO 可以只用一个简单的二元交叉熵目标来优化策略，并得到与某个隐式奖励函数对应的最优策略。

本文的主要贡献，就是提出了这种**无需 RL 的偏好优化算法 DPO**。实验结果表明，在情感控制、摘要和对话等任务中，DPO 学习人类偏好的效果至少与现有方法相当，包括基于 PPO 的 RLHF；在许多场景下甚至更优，而实现与训练却显著更简单。

3 2 相关工作

随着规模不断增大，自监督语言模型已经能够进行零样本或少样本任务完成。然而，仅靠预训练得到的模型，在下游任务表现以及与用户意图的对齐方面，通常还能通过指令数据和人类撰写的高质量响应进行微调而显著提升。所谓“指令微调”能够让大语言模型泛化到训练集之外的指令，并整体提升可用性。

尽管指令微调非常成功，但与其收集专家演示，不如收集“哪一个回答更好”的相对人类判断往往更容易。因此，后续研究开始利用人类偏好数据来微调大语言模型，并在翻译、摘要、故事生成和指令跟随等任务中取得了改进。这些方法一般先在 Bradley-Terry 等偏好模型下训练一个神经奖励函数，再通过 REINFORCE、PPO 或其变体来优化语言模型，使其最大化该奖励。

一条紧密相关的研究路线是：利用已经通过人类反馈微调过、具备指令跟随能力的大语言模型，进一步生成额外的合成偏好数据，以对安全性、无害性等目标属性进行针对性优化，只需人类提供较弱形式的监督，例如文本规则说明。这些方法汇聚了两个方向：一是用强化学习训练语言模型以实现不同目标，二是更一般意义上的“从人类偏好中学习”。

尽管相对人类偏好的使用非常有吸引力，但用强化学习对大语言模型进行偏好微调，实践上仍然十分困难。本文提供了一种理论上有所依据的方法，使得我们**无需强化学习**也能优

化相对偏好。

在语言模型之外，从偏好中学习策略的问题也在 bandit 与强化学习场景中得到研究，并提出了多类方法。利用对动作的偏好或排序而非绝对奖励的上下文 bandit 学习，被称为 contextual dueling bandit (CDB)。由于没有绝对奖励，CDB 的理论分析通常用 von Neumann winner 来替代最优策略概念，即一种对任意其他策略的期望胜率都至少为 50% 的策略。

不过，CDB 的偏好标签通常是在线获得的；而在从人类偏好学习的场景中，我们更常处理的是一个固定的、离线标注好的偏好数据批次。类似地，基于偏好的强化学习 (PbRL) 假设偏好来自未知的“评分函数”而不是显式奖励。虽然 PbRL 已经有不少可复用离线偏好数据的方法，但多数仍然需要先显式估计这个潜在评分函数（也就是奖励模型），再去优化它。本文则提出了一种单阶段的策略学习方法，直接优化策略本身来满足偏好。

4.3 预备知识

我们回顾 Ziegler 等人及其后续工作中典型的 RLHF 流程。该流程通常分为三个阶段：(1) 监督微调 (SFT)；(2) 偏好采样与奖励学习；(3) 强化学习优化。

4.1 SFT 阶段

RLHF 通常首先在下游任务（如对话、摘要等）的高质量数据上，对预训练语言模型进行监督微调，从而得到模型 π_{SFT} 。

4.2 奖励建模阶段

第二阶段中，使用 SFT 模型在给定提示 x 的条件下生成回答对 $(y_1, y_2) \sim \pi_{\text{SFT}}(y|x)$ 。然后把这些回答对交给人工标注者，由其指出更偏好的一个回答，记为 $y_w \succ y_l \mid x$ ，其中 y_w 和 y_l 分别表示优选与劣选回答。

这些偏好被假设由某个潜在奖励模型 $r^*(y, x)$ 生成，而我们无法直接访问它。建模偏好的方法有很多，其中 Bradley–Terry (BT) 模型是常见选择。如果有多于两个回答的排序信息，也可以使用更一般的 Plackett–Luce 排序模型。

BT 模型假定，人类偏好分布 p^* 可以写为：

$$p^*(y_1 \succ y_2 \mid x) = \frac{\exp(r^*(x, y_1))}{\exp(r^*(x, y_1)) + \exp(r^*(x, y_2))}.$$

假设我们能获得一个静态比较数据集

$$D = \{x^{(i)}, y_w^{(i)}, y_l^{(i)}\}_{i=1}^N,$$

这些样本来自 p^* 。于是可以参数化一个奖励模型 $r_\phi(x, y)$ ，并通过极大似然估计其参数。将该问题视作二元分类，可得到负对数似然损失：

$$L_R(r_\phi, D) = -\mathbb{E}_{(x, y_w, y_l) \sim D} \log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l)),$$

其中 σ 是 logistic 函数。

在语言模型场景下，网络 $r_\phi(x, y)$ 往往由 SFT 模型 $\pi_{\text{SFT}}(y|x)$ 初始化，并在最后一层 Transformer 顶部添加一个线性层来输出单个标量奖励值。为了降低奖励函数的方差，以往工作通常还会对奖励做归一化处理，例如令对每个 x 都有 $\mathbb{E}_{x, y \sim D}[r_\phi(x, y)] = 0$ 。

4.3 RL 微调阶段

在 RL 阶段，学习到的奖励函数会被用于向语言模型提供反馈。遵循已有工作，优化目标一般写为

$$\max_{\pi_\theta} \mathbb{E}_{x \sim D, y \sim \pi_\theta(y|x)} [r_\phi(x, y) - \beta D_{\text{KL}}(\pi_\theta(y|x) \parallel \pi_{\text{ref}}(y|x))],$$

其中 β 控制策略相对基准参考策略 π_{ref} 的偏离程度；通常 π_{ref} 就取初始 SFT 模型 π_{SFT} 。实践中，语言模型策略 π_θ 也常由 π_{SFT} 初始化。

这个约束非常重要：它既防止模型偏离奖励模型有效的数据分布太远，又能维持生成多样性，避免塌缩到单一高奖励答案。由于语言生成是离散过程，这个目标不可直接求导，因此通常需要借助强化学习。标准做法是构造如下奖励：

$$r(x, y) = r_\phi(x, y) - \beta (\log \pi_\theta(y|x) - \log \pi_{\text{ref}}(y|x)),$$

再使用 PPO 进行优化。

5 4 Direct Preference Optimization

由于在大规模问题（如语言模型微调）上应用强化学习算法非常困难，本文的目标是推导出一种**直接利用偏好做策略优化**的简单方法。不同于“先学奖励、再用 RL 优化”的传统 RLHF，本文的方法采用一种特殊的奖励模型参数化，使得其对应的最优策略可以直接以闭式形式求出，从而避免 RL 训练循环。

其关键洞见是：存在从奖励函数到最优策略的解析映射，因此我们可以把一个原本定义在奖励函数上的损失，转化为一个直接定义在策略上的损失。这样的变量替换方法不再需要单独拟合一个显式的奖励模型，同时仍然保留对 Bradley–Terry 这类人类偏好模型的优化。换句话说，在 DPO 中，**策略网络既表示语言模型，也隐式表示奖励模型**。

5.1 DPO 目标的推导

我们从与现有工作相同的 RL 目标出发，即在一般奖励函数 r 下考虑带 KL 约束的奖励最大化。已有研究表明，该问题的最优解具有如下形式：

$$\pi_r(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right),$$

其中

$$Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right)$$

是配分函数。

即便我们用最大似然学到了真实奖励函数 r^* 的估计 r_ϕ ，配分函数 $Z(x)$ 的估计仍然开销很大，因此这个形式在实践中不好直接利用。但我们可以把上式重新整理，用其对应的最优策略 π_r 、参考策略 π_{ref} 和未知配分函数 $Z(\cdot)$ 来表示奖励函数：

$$r(x, y) = \beta \log \frac{\pi_r(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x).$$

将这个重参数化应用到真实奖励 r^* 及其对应最优模型 π^* 上。幸运的是，Bradley–Terry 模型只依赖于两个回答奖励的差值，因此在偏好概率中代入上式时，配分函数项会相互抵消。于是，人类偏好概率可以只用最优策略 π^* 和参考策略 π_{ref} 来表达：

$$p^*(y_1 \succ y_2|x) = \frac{1}{1 + \exp\left(\beta \log \frac{\pi^*(y_2|x)}{\pi_{\text{ref}}(y_2|x)} - \beta \log \frac{\pi^*(y_1|x)}{\pi_{\text{ref}}(y_1|x)}\right)}.$$

既然我们已经把人类偏好数据的概率用**最优策略**而不是奖励模型表示出来，那么就可以直接对参数化策略 π_θ 写出最大似然目标。与奖励建模的二元分类损失类似，DPO 的策略目标为：

$$L_{\text{DPO}}(\pi_\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l) \sim D} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right].$$

这样一来，我们通过另一种参数化方式拟合了一个隐式奖励，而其对应的最优策略恰好就是 π_θ 本身。由于该过程等价于拟合一个重参数化后的 Bradley–Terry 模型，因此也继承了一些理论性质，例如在合适假设下的一致性。

5.2 DPO 更新到底在做什么？

为了从机制上理解 DPO，分析损失 L_{DPO} 的梯度很有帮助。对参数 θ 的梯度可写为：

$$\nabla_\theta L_{\text{DPO}}(\pi_\theta; \pi_{\text{ref}}) = -\beta \mathbb{E}_{(x, y_w, y_l) \sim D} \left[\sigma(\hat{r}_\theta(x, y_l) - \hat{r}_\theta(x, y_w)) \left(\nabla_\theta \log \pi(y_w|x) - \nabla_\theta \log \pi(y_l|x) \right) \right],$$

其中

$$\hat{r}_\theta(x, y) = \beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)}$$

是由当前语言模型 π_θ 与参考模型 π_{ref} 共同定义的隐式奖励。

直观而言，DPO 的梯度会提高优选回答 y_w 的似然，同时降低劣选回答 y_l 的似然。更重要的是，每个样本都会被一个权重项调节：当隐式奖励模型错误地把劣选回答的评分设得更高时，这个样本的权重就会更大；而这个权重还受到 β 的缩放，也即受 KL 约束强度影响。

实验表明，这个加权项非常关键。如果去掉它，只用朴素版本的概率比目标，语言模型往往会出现退化现象。

5.3 DPO 的流程

DPO 的一般流程如下：

第一，对每个提示 x ，从参考策略 $\pi_{\text{ref}}(\cdot|x)$ 采样两个回答 y_1, y_2 ，然后通过人工偏好标注构造离线偏好数据集

$$D = \{x^{(i)}, y_w^{(i)}, y_l^{(i)}\}_{i=1}^N.$$

第二，在给定 π_{ref} 、偏好数据集 D 和所选 β 的情况下，优化语言模型 π_θ 以最小化 L_{DPO} 。

在实践中，人们更希望直接复用公开可得的偏好数据集，而不想重新采样和标注。由于这些偏好数据通常是由 π_{SFT} 采样得到的，因此只要可用，本文就将 π_{ref} 初始化为 π_{SFT} 。如果拿不到 π_{SFT} ，则可以通过最大化优选回答 (x, y_w) 的似然来初始化 π_{ref} 。这样做有助于缓解真实参考分布不可得所带来的分布偏移。

6 5 DPO 的理论分析

本节进一步解释 DPO 的理论含义，为其提供理论支撑，并将 DPO 的优势与 RLHF 中常用的 actor-critic 算法（如 PPO）存在的问题联系起来。

6.1 5.1 你的语言模型其实就是一个奖励模型

DPO 能够绕开显式奖励拟合和 RL 策略学习，只用单一的最大似然目标完成训练。注意，前述优化目标实际上等价于一个 Bradley–Terry 模型，只不过其奖励参数化形式为

$$r^*(x, y) = \beta \log \frac{\pi_\theta^*(y|x)}{\pi_{\text{ref}}(y|x)}.$$

也就是说，我们优化的是参数化模型 π_θ ，这与在变量替换后的坐标系下做奖励模型优化是等价的。本节将建立这种重参数化的理论基础，说明它并不会缩小可学习奖励模型的表达能力，而且还允许精确恢复最优策略。

首先，作者定义了奖励函数之间的一个等价关系。

定义 1. 若存在某个仅依赖于提示 x 的函数 $f(x)$ ，使得

$$r(x, y) - r'(x, y) = f(x),$$

则称两个奖励函数 $r(x, y)$ 与 $r'(x, y)$ 等价。

显然，这确实是一个等价关系，它把所有奖励函数划分为若干等价类。然后作者给出两个引理：

引理 1. 在 Plackett–Luce，尤其是 Bradley–Terry 偏好框架下，同一等价类中的两个奖励函数会诱导出相同的偏好分布。

引理 2. 在带约束的 RL 问题中，同一等价类中的两个奖励函数会诱导出相同的最优策略。

第一个引理反映了 Plackett–Luce 这类模型的一个经典“欠定”问题：奖励函数本身并不唯一，只能确定到一个与 x 有关的平移项。第二个引理则说明：对于最终的优化目标，我们其实只需要恢复出**某个与最优类等价的奖励函数**即可，因为同类中的所有奖励都会给出相同最优策略。

作者进一步证明了如下定理：

定理 1. 在较弱假设下，所有与 Plackett–Luce（尤其是 Bradley–Terry）模型一致的奖励等价类，都可以表示为

$$r(x, y) = \beta \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)}$$

的形式，其中 $\pi(y|x)$ 是某个模型，而 $\pi_{\text{ref}}(y|x)$ 是给定参考模型。

其证明思路是：对于任意奖励函数 $r(x, y)$ ，根据带 KL 约束的最优策略表达式，它总会对应某个最优模型 $\pi_r(y|x)$ 。然后定义一个投影算子，把奖励函数减去其配分函数的对数项。这个减法只依赖于 x ，因此得到的新奖励函数仍然与原奖励属于同一等价类；同时，该新奖励函数恰好就可以写成

$$\beta \log \frac{\pi_r(y|x)}{\pi_{\text{ref}}(y|x)}$$

的形式。

因此，DPO 所采用的这种奖励重参数化**没有损失一般性**。换个角度说，DPO 实际上是在每个奖励等价类中选取了一个特殊代表元：它满足

$$\sum_y \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right) = 1.$$

而这个条件恰好对应于由该奖励诱导出的最优策略是一个合法概率分布。

DPO 的关键就在于：它通过对欠约束的 Plackett–Luce / Bradley–Terry 偏好模型施加适当约束，使得既保留了可表示奖励模型的完整类别，又让最优策略对每个提示 x 都可以解析求出。

6.2 5.2 Actor–Critic 算法的不稳定性

作者还利用这一框架分析了 RLHF 中标准 actor–critic 算法（如 PPO）存在的不稳定性。我们沿用 RLHF 流程，重点关注第 3 节中的 RL 微调步骤。

可以把该带约束 RL 问题与“将控制视为推断”的框架联系起来。设参数化策略模型为 $\pi_\theta(y|x)$ ，并最小化其与最优策略 $\pi^*(y|x)$ 之间的 KL 散度，其中 π^* 由奖励函数 $r_\phi(y, x)$ 按前述公式诱导出来。经过代数变换，可以得到如下优化目标：

$$\max_{\pi_\theta} \mathbb{E}_{\pi_\theta(y|x)} \left[r_\phi(x, y) - \beta \log \sum_y \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r_\phi(x, y)\right) - \beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)} \right].$$

这其实正是已有 RLHF 工作在使用与 DPO 等价的奖励类时所优化的目标。在这个表

达式中，中间那一项归一化项可以被理解为参考策略 π_{ref} 的 soft value function。

虽然该项**不改变最优解**，但如果把它去掉，目标的策略梯度会有很高方差，导致学习不稳定。理论上可以学习一个值函数来吸收这个归一化项，但值函数本身也很难训练。另一种做法是利用人工完成作为基线，本质上是在用单样本 Monte Carlo 去估计这个归一化项。相比之下，DPO 的重参数化直接得到一个**不需要任何基线项**的奖励形式，因此更稳定也更简单。

7 6 实验

本节从经验上评估 DPO 直接从偏好中训练策略的能力。首先，在一个受控的文本生成设置中，作者考察：与 PPO 等常见偏好学习算法相比，DPO 在**最大化奖励与最小化相对参考策略的 KL 散度**之间，能否实现更高效的权衡。

随后，作者又在更大模型和更复杂的 RLHF 任务上评估 DPO，包括摘要和单轮对话。结果发现，即使几乎不调超参数，DPO 往往也能达到甚至超过 PPO 式 RLHF 以及“从奖励函数中采样 N 条轨迹再选最优”这类强基线的效果。在展示结果之前，作者先介绍实验设置。

7.1 任务

实验覆盖三个开放式文本生成任务，所有任务中算法都从偏好数据集

$$D = \{x^{(i)}, y_w^{(i)}, y_l^{(i)}\}_{i=1}^N$$

学习策略。

在**受控情感生成**中， x 是 IMDB 影评数据集中的一个小前缀，策略需要生成一个带有正面情感的后续文本 y 。为了进行受控评估，这一实验中的偏好对并不是由人工给出，而是由一个预训练情感分类器自动生成：当 $p(\text{positive} | x, y_w) > p(\text{positive} | x, y_l)$ 时，就认为 y_w 优于 y_l 。SFT 阶段，作者在 IMDB 训练集评论上将 GPT-2-large 微调至收敛。

在**摘要任务**中， x 是 Reddit 论坛帖子，策略需要生成能够概括帖子主要内容的摘要 y 。作者沿用已有工作所使用的 Reddit TL;DR 摘要数据集，以及 Stiennon 等人收集的人类偏好数据。SFT 模型是在人工撰写的论坛帖子摘要上微调得到的，并借助 TRLX 框架用于 RLHF。偏好数据则来自于另一个训练方式类似但不完全相同的 SFT 模型所生成样本的人类标注。

在**单轮对话任务**中， x 是来自用户的单次查询，可能是天体物理学问题，也可能是情感建议请求。策略需要给出一个有帮助、能让人投入的响应 y 。作者使用 Anthropic Helpful and Harmless 对话数据集，其中包含 17 万段人机对话。每段记录最后都给出两个由某个大型语言模型生成的回答，以及人类标注的偏好标签。在这个任务中，没有现成的预训练 SFT 模型，因此作者先用数据集中优选完成对一个现成语言模型做监督微调，以此构造参考模型。

7.2 评估方式

实验采用两种评估方法。

第一种用于分析不同算法优化“带 KL 约束的奖励最大化目标”的有效性。在受控情感生成任务中，由于我们拥有真实奖励函数（即情感分类器），因此可以直接计算每个算法所达到的**奖励-KL 前沿**。

第二种更接近真实场景，因为现实中通常并不知道真实奖励函数。于是，在摘要和单轮对话任务中，作者使用 **GPT-4 作为人类评估的代理**，通过与基线策略的胜率来评价算法。摘要任务中，测试集中的参考摘要被当作基线；对话任务中，则使用测试集中被偏好的回复作为基线。

作者指出，已有研究表明，大语言模型有时比传统自动指标更适合做评估器。为了验证用 GPT-4 评估的合理性，作者还在第 6.4 节进行了一项人工实验。结果显示，GPT-4 的判断与人类判断高度相关，而且人类与 GPT-4 的一致性往往与人类标注者之间的一致性相当甚至更高。

7.3 比较方法

除了 DPO，作者还比较了多种已有方法。

最简单的是零样本或少样本提示：在摘要任务上使用 GPT-J 的 zero-shot prompting，在对话任务上使用 Pythia-2.8B 的 2-shot prompting。

此外，还评估了 SFT 模型本身，以及 **Preferred-FT**：该方法只在优选回答 y_w 上做监督学习微调。在受控情感和摘要任务中，Preferred-FT 从 SFT 模型继续训练；而在单轮对话任务中，则从通用语言模型开始训练。

另一种伪监督方法是 **Unlikelihood**，即同时最大化优选回答的概率、最小化劣选回答的概率；其中“unlikelihood”项的系数 α 可选。

作者还评估了 **PPO**，其奖励函数由偏好数据学习得到；以及 **PPO-GT**，它在受控情感实验中可以直接访问真实奖励函数，因此相当于“oracle”。

在情感实验中，作者使用了两个 PPO-GT 实现：一个是现成库版本，另一个是自行修改后的版本，后者额外加入奖励归一化并调节了更多超参数以提升效果；普通 PPO 也使用了这些修改。

最后，作者还考虑了 **Best of N** 基线：从 SFT 模型（或对话任务中的 Preferred-FT）中采样 N 个回答，然后利用从偏好数据中学到的奖励函数，对这 N 个回答打分并选出最优者。该方法能把奖励模型质量与 PPO 优化能力分离开来，但在测试时需要为每个查询采样 N 次，因此计算上很不现实。

7.4 6.1 DPO 能否有效优化 RLHF 目标？

典型 RLHF 算法中的带 KL 约束奖励最大化目标，需要在**利用奖励与限制偏离参考策略**之间取得平衡。因此比较不同算法时，不能只看奖励，还必须同时考虑 KL 偏差。即使某个方法拿到了略高的奖励，但如果 KL 大得多，也未必是理想选择。

论文图 2 展示了情感任务中多种算法的奖励-KL 前沿。作者对每种算法做了多次训

练，分别改变控制策略保守程度的超参数：PPO 使用不同目标 KL，DPO 使用不同 β ，Unlikelihood 使用不同 α ，Preferred-FT 则使用不同随机种子。总共包含 22 次运行。

训练过程中，每经过 100 个 step，作者就在测试提示上评估一次策略，计算其在真实奖励函数下的平均奖励，以及相对于参考策略的平均序列级 KL。结果表明，**DPO 给出了明显最优的前沿**：在保持较低 KL 的同时，它取得了最高的奖励。

这一结果之所以值得注意，有两个原因。第一，DPO 和 PPO 在理论上优化的是同一个目标，但 DPO 的优化效率更高。第二，即使让 PPO 直接访问真实奖励函数（即 PPO-GT），DPO 的奖励/KL 权衡依然严格优于 PPO。

7.5 6.2 DPO 能否扩展到真实偏好数据集？

随后，作者在摘要和单轮对话任务上评估 DPO 的微调效果。

对于摘要任务，ROUGE 等传统自动指标通常与人类偏好相关性不高；已有工作发现，利用 PPO 在人类偏好上微调语言模型，能够得到更有效的摘要。作者在 TL;DR 测试集上对不同方法进行采样生成，并计算其相对于测试集参考摘要的平均胜率。所有方法都在不同采样温度下生成，图 2 右侧展示了对应结果。

DPO、PPO 和 Preferred-FT 都从同一个 GPT-J SFT 模型出发。结果显示，当采样温度为 0.0 时，DPO 的胜率约为 61%，超过 PPO 在其最佳温度 0.0 下约 57% 的表现。DPO 的最高胜率也优于 Best of N 基线。作者还指出，他们并没有认真调节 DPO 的 β ，因此当前结果甚至可能低估了 DPO 的潜力。

此外，DPO 对采样温度的变化显著更鲁棒，而 PPO 在较高温度下性能可能退化到接近基础 GPT-J 模型。Preferred-FT 相比 SFT 的提升则不明显。作者还进行了 DPO 与 PPO 的人工 head-to-head 对比：在温度 0.25 下采样的 DPO 结果，有 58% 的情况被人类偏好于温度 0.0 下采样的 PPO 结果。

对于单轮对话任务，作者在 Anthropic HH 数据集的一步人机交互测试子集上进行评估。GPT-4 以测试集中的优选回答为参考，计算不同方法的胜率。

由于这个任务没有现成的标准 SFT 模型，作者从预训练的 Pythia-2.8B 出发，先用 Preferred-FT 在优选完成上训练一个参考模型，使模型生成保持在数据分布内，然后再用 DPO 训练。作者还比较了 Best of 128 Preferred-FT，以及一个 2-shot 提示版本的 Pythia-2.8B，发现 DPO 在各自最优采样温度下表现相当甚至更好。

作者也尝试评估一个公开来源的、在 Anthropic HH 上用 PPO 训练过的 RLHF 模型，但无论如何调 prompt 或采样温度，都无法超过基础 Pythia-2.8B。基于 TL;DR 上的结果，以及 DPO 与 PPO 优化同一奖励函数这一事实，作者将 Best of 128 看作 PPO 水平的一个粗略代理。

总体来看，DPO 是**唯一一种计算上高效，同时还能超过 Anthropic HH 数据集中优选回答本身的算法**，其表现与甚至优于计算代价很高的 Best of 128 基线。图 3 还表明，DPO 能 relatively quickly 收敛到最佳性能。

7.6 6.3 对新输入分布的泛化

为了进一步比较 PPO 和 DPO 在分布偏移下的表现，作者将 Reddit TL;DR 摘要实验中训练得到的 PPO 与 DPO 策略，拿到另一个分布——CNN/DailyMail 新闻文章测试集——上进行评估，并使用在 TL;DR 上最优的采样温度（0 与 0.25）。

结果见表 1。作者仍然使用与 Reddit TL;DR 相同的 GPT-4(C) 评估提示，只是把其中的“forum post”替换成“news article”。结果表明，在这个新的输入分布上，DPO 依然显著优于 PPO。这个实验初步说明：尽管 DPO 并没有像 PPO 那样额外利用无标签的 Reddit TL;DR 提示，它学到的策略在分布外泛化能力上仍然与 PPO 相当甚至更好。

7.7 6.4 用人工判断验证 GPT-4 判断

作者开展了一项人工实验，用来验证 GPT-4 评估结果的可靠性。实验基于 TL;DR 摘要任务，并使用两种不同的 GPT-4 提示。

GPT-4(S) 提示只问“哪个摘要更好地概括了帖子的重要信息”。GPT-4(C) 提示除了概括效果外，还强调“不要包含不重要或无关细节”，也即好的摘要应当既准确又简洁。作者之所以引入第二种提示，是因为他们发现 GPT-4(S) 往往会偏好更长、重复性更强的摘要，而这与人类偏好并不一致。

实验比较了三种情形：表现最好的一种方法（DPO, temp 0.25）、表现最差的一种方法（PPO, temp 1.0），以及一个居中的方法（SFT, temp 0.25），三者都与贪心采样的 PPO（也就是其最佳温度）做对比。

结果表明，无论使用哪一种 GPT-4 提示，GPT-4 与人类的判断一致程度都大致相当于人类之间彼此的一致程度，这说明 GPT-4 作为人类评估的代理是合理的。整体而言，GPT-4(C) 给出的胜率更接近人类，因此作者在主实验结果中采用这一提示。

8 7 讨论

从偏好中学习是一种强大且可扩展的框架，可用于训练能力强、与人类意图对齐的语言模型。本文提出了 DPO——一种无需强化学习、可直接从偏好中训练语言模型的简单方法。它并没有为了套用现成 RL 算法而强行把偏好学习问题变成标准 RL 问题，而是识别出了语言模型策略与奖励函数之间的映射关系，使我们可以直接用一个简单的交叉熵损失来训练语言模型满足人类偏好，而不会损失一般性。

实验表明，即便几乎不需要超参数调节，DPO 也能达到甚至超过包括 PPO 在内的现有 RLHF 算法的效果。因此，DPO 显著降低了利用人类偏好训练语言模型的门槛。

局限性与未来工作

本文结果也提出了若干值得进一步研究的问题。首先，与显式奖励函数学习相比，DPO 学到的策略在分布外究竟如何泛化？现有初步结果表明其与 PPO 型模型相当，但仍需更系统研究。例如，是否也能像显式奖励学习那样，通过自标注有效利用无标签提示？

其次，奖励过优化在 DPO 这种直接偏好优化框架中会如何表现？图 3 右侧中的轻微性能下降，是否就是这类现象的一个例子？另外，尽管本文评估了最高 6B 参数规模的模型，但如何把 DPO 进一步扩展到数量级更大的最先进模型，也是一条很有吸引力的研究方向。

在评估方面，作者发现 GPT-4 给出的胜率会受到提示词设计影响，因此未来工作可以研究如何更稳定地从自动系统中 elicitation 出高质量判断。最后，DPO 的潜在应用并不局限于从人类偏好训练语言模型，它同样可能适用于其他模态的生成模型训练。

9 附录 A 数学推导（中文整理）

9.1 A.1 带 KL 约束奖励最大化目标的最优解

作者考虑如下优化目标：

$$\max_{\pi} \mathbb{E}_{x \sim D, y \sim \pi} [r(x, y) - \beta D_{\text{KL}}(\pi(y|x) \parallel \pi_{\text{ref}}(y|x))].$$

经过变换，可以把它改写为最小化

$$\mathbb{E}_{x \sim D} [D_{\text{KL}}(\pi(y|x) \parallel \pi^*(y|x)) - \log Z(x)],$$

其中

$$\pi^*(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right), \quad Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right).$$

由于 $Z(x)$ 与待优化策略 π 无关，最优解只需要令 KL 项达到最小。根据 Gibbs 不等式，当且仅当两个分布相等时，KL 为 0，因此最优策略就是

$$\pi(y|x) = \pi^*(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right).$$

9.2 A.2 Bradley–Terry 模型下 DPO 目标的推导

Bradley–Terry 模型写作

$$p^*(y_1 \succ y_2|x) = \frac{\exp(r^*(x, y_1))}{\exp(r^*(x, y_1)) + \exp(r^*(x, y_2))}.$$

而在第 4 节中，真实奖励可写成

$$r^*(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x).$$

将其代入 BT 模型后， $Z(x)$ 在分子分母中相消，于是得到

$$p^*(y_1 \succ y_2|x) = \sigma\left(\beta \log \frac{\pi^*(y_1|x)}{\pi_{\text{ref}}(y_1|x)} - \beta \log \frac{\pi^*(y_2|x)}{\pi_{\text{ref}}(y_2|x)}\right),$$

这就对应正文中的 DPO 单样本损失形式。

9.3 A.3 Plackett–Luce 模型下的 DPO

Plackett–Luce 模型是 Bradley–Terry 在多项排序场景下的推广。对给定提示 x 和 K 个候选回答 $y_1, \dots, y_K$ ，用户给出一个排列 τ 表示其排序，则有

$$p^*(\tau \mid y_1, \dots, y_K, x) = \prod_{k=1}^K \frac{\exp(r^*(x, y_{\tau(k)}))}{\sum_{j=k}^K \exp(r^*(x, y_{\tau(j)}))}.$$

若将奖励函数替换成通过最优策略参数化后的形式，同样可以让归一化常数 $Z(x)$ 相消，并最终得到以 π_θ 和 π_{ref} 直接表示的最大似然目标。也就是说，DPO 并不只适用于二元偏好对，也可自然拓展到更一般的排序偏好数据。

9.4 A.4 DPO 目标梯度

DPO 损失的梯度推导表明，其最终形式为：

$$\nabla_\theta L_{\text{DPO}}(\pi_\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l) \sim D} \left[\beta \sigma \left(\beta \log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) (\nabla_\theta \log \pi(y_w|x) - \nabla_\theta \log \pi(y_l|x)) \right]$$

用隐式奖励

$$\hat{r}_\theta(x, y) = \beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)}$$

代换后，就得到正文中对 DPO 更新方向的解释。

9.5 A.5 引理 1 与引理 2 的证明思路

引理 1 的证明关键在于：若两个奖励函数只相差一个仅依赖于 x 的项 $f(x)$ ，那么在 Plackett–Luce 概率表达式中，这个额外项在分子与分母中会完全抵消，因此偏好分布保持不变。

引理 2 的证明则利用带 KL 约束最优策略的闭式解。若 $r'(x, y) = r(x, y) + f(x)$ ，则它们对应的最优策略在分子分母中都会多出同一个 $\exp(f(x)/\beta)$ 因子，该因子同样会被约掉，因此两者的最优策略一致。

9.6 A.6 定理 1 的证明思路

定理 1 的证明表明：对任意奖励函数 $r(x, y)$ ，都可以构造一个与其同一等价类中的奖励函数 $r'(x, y)$ ，使其恰好满足

$$r'(x, y) = \beta \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)}$$

的形式。

为此，作者定义了一个映射

$$f(r, \pi_{\text{ref}}, \beta)(x, y) = r(x, y) - \beta \log Z(x),$$

其中

$$Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right).$$

由于减掉的项只依赖于 x ，因此 $f(r, \pi_{\text{ref}}, \beta)$ 与 r 属于同一等价类；而根据最优策略公式，它又恰好等于

$$\beta \log \frac{\pi_r(y|x)}{\pi_{\text{ref}}(y|x)}.$$

附录中还进一步证明：对每一个奖励等价类而言，这种满足 DPO 重参数化形式的代表元其实是**唯一的**。

10 附录 B DPO 的实现细节与超参数

论文给出了一段非常简洁的 PyTorch 代码来实现 DPO 损失。其核心思想是：分别取出优选回答与劣选回答在当前策略和参考策略下的对数概率，然后计算它们的 log-ratio 差值，并通过 $\log \sigma(\cdot)$ 构造损失。

默认设置下，作者使用 $\beta = 0.1$ 、batch size 为 64，并采用 RMSprop 优化器，学习率为 10^{-6} 。学习率会在前 150 个 step 线性 warmup 到该值。对于 TL;DR 摘要任务，作者使用 $\beta = 0.5$ ，其他参数保持不变。

论文中的 DPO 代码

```
import torch.nn.functional as F

def dpo_loss(pi_logps, ref_logps, yw_idx, yl_idx, beta):
    """
    pi_logps: 当前策略对数概率, shape (B,)
    ref_logps: 参考模型对数概率, shape (B,)
    yw_idx: 偏好回答索引
    yl_idx: 非偏好回答索引
    beta: 控制 KL 惩罚强度的温度参数
    """
    pi_yw_logps, pi_yl_logps = pi_logps[yw_idx], pi_logps[yl_idx]
    ref_yw_logps, ref_yl_logps = ref_logps[yw_idx], ref_logps[yl_idx]
    pi_logratios = pi_yw_logps - pi_yl_logps
    ref_logratios = ref_yw_logps - ref_yl_logps
    losses = -F.logsigmoid(beta * (pi_logratios - ref_logratios))
    rewards = beta * (pi_logps - ref_logps).detach()
    return losses, rewards
```


11 附录 C 实验设置补充说明

11.1 C.1 IMDb 情感实验与基线细节

提示由 IMDb 数据集中长度为 2–8 个 token 的评论前缀构成。作者采用预训练情感分类器 `siebert/sentiment-roberta-large-english` 作为真实奖励模型，采用 `gpt2-large` 作为基础模型。选择较大模型的原因在于，小模型生成文本质量偏低，且奖励估计也不够准确。

作者先在 IMDb 数据子集上进行 1 个 epoch 的监督微调。随后，用该模型对 25000 个前缀各采样 4 个完成，并用真实奖励模型为每个前缀构造 6 对偏好样本。RLHF 中的奖励模型由 `gpt2-large` 初始化，并在偏好数据上训练 3 个 epoch，选择验证集准确率最高的 checkpoint。论文中“TRL”版本采用 TRL 库默认超参数；作者自己的 PPO 实现则在每一步使用更大的 batch 样本（1024）进行训练。

11.2 C.2 用于摘要与对话胜率评估的 GPT-4 提示

摘要任务中，作者设计了两种 GPT-4 评估提示：

第一种（S）只问：下面两个摘要中，哪个更好地概括了论坛帖子的最重要信息？

第二种（C）在此基础上进一步强调：好的摘要既要准确，也要简洁，不能包含不重要或无关细节。

对话任务中的 GPT-4 提示则是：对于给定的聊天机器人查询，哪一个回答更有帮助？同时要求 GPT-4 先用一句话解释理由，再输出 A 或 B。

所有实验都使用 `gpt-4-0314`，并在评估时随机交换两个候选答案的顺序，以减少位置偏置。

11.3 C.3 Unlikelihood 基线

虽然作者在情感实验中包含了 Unlikelihood 基线，但在摘要和对话实验中没有纳入它。原因是，该方法在更复杂问题上通常会生成没有意义的输出。论文附录给出的样例显示，Unlikelihood 容易生成大量重复词语和明显崩坏的文本，这说明单纯做“优选概率最大化、劣选概率最小化”的无约束似然优化，会导致模型严重退化。

12 附录 D 其他实验结果

12.1 D.1 不同 N 下 Best of N 基线的表现

作者进一步分析了 Best of N 基线在不同 N 取值下的性能。对于 Anthropic-HH 对话与 TL;DR 摘要任务，结果表明：随着采样数增加，性能会逐步提升，但大约在 64–128 个样本后趋于饱和。这说明 Best of N 确实是一个很强的基线，但其性能增长依赖于大量测试时采样，因此计算成本很高。

12.2 D.2 样例回答与 GPT-4 判断

附录展示了若干 DPO 与基线的具体输出样例。

在 TL;DR 摘要任务中，GPT-4 往往更偏好 DPO 生成的摘要，因为它们更聚焦主要信息、更简洁，也更少出现重复、冗余或无根据的扩展。

在 Anthropic-HH 对话任务中，部分样例表明 DPO 会比数据集中原始“优选回答”更安全、更符合帮助性要求。例如，当用户试图索取某位现实人物的住址时，DPO 会明确拒绝协助，强调隐私和合法性；而数据集中给出的“优选回答”却提供了一些背景信息，虽然没给出住址，但边界感较弱。

当然，附录也展示了 DPO 的失败案例。例如在回答“美国为何卷入二战”时，DPO 生成了冗长但部分事实错误的回答，而数据集中的原始优选回答更简洁直接、更准确。另一个例子是“7 加 2 等于多少”，DPO 虽然最终说出了 9，但回答极度冗长，甚至引入了错误的“算术前缀法”解释，GPT-4 因而更偏好数据集中的直接答案“11”（论文也指出 GPT-4 在该例中实际上误判了 ground truth）。

12.3 D.3 人工实验细节

为了验证使用 GPT-4 计算胜率合理性，作者在人类评估中选取了 TL;DR 摘要任务的三组对比：DPO（温度 0.25）对 PPO（温度 0）、SFT（温度 0.25）对 PPO（温度 0），以及 PPO（温度 1.0）对 PPO（温度 0）。

其中，DPO vs PPO-0 随机抽取了 150 组比较，每组由两名人工评审标注；PPO-1 vs PPO-0 抽取 100 组，也由两人评审；SFT 对比则抽取 125 组，每组由一人评审。若人类标为平局，则该样本被忽略；这类情况约占 1%。

作者统计了两类一致率：一是人类 A 与人类 B 的一致率，二是 GPT-4 与每位人类的逐条一致率。结果显示，GPT-4 与人类的一致程度大体相当于人类彼此之间的一致程度，这为将 GPT-4 用作自动评估代理提供了支持。

参与者共有 25 名，主要是斯坦福大学的本科生、研究生、访问者或毕业生，且大多具有 STEM（尤其是计算机科学）背景。论文还给出了 SurveyMonkey 调查界面示意图以及参与者名单。

13 参考文献说明

本文参考文献数量较多，且原论文中的条目本身已是标准英文文献格式。为避免因逐条意译造成书目信息失真，本翻译稿保留参考文献原始英文形式；如需，我后续也可以继续为你整理成中文“文献题目对照表”版本。

说明：本稿根据用户提供的论文 PDF 内容整理翻译，公式尽量保持与原文一致，表述以忠实原意为主，并对少量附录内容做了适度压缩性翻译整理。