

DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models

DeepSeekMath: 推动开源语言模型数学推理能力的极限

逐段中文翻译稿（根据用户上传 PDF 整理，不含参考文献逐条翻译）

摘要

由于数学推理具有复杂且高度结构化的特征，因此它一直是语言模型面临的重要挑战。本文提出 DeepSeekMath 7B。该模型以 DeepSeek-Coder-Base-v1.5 7B 为基础，继续在来自 Common Crawl 的 120B 数学相关 token 上进行预训练，同时混合自然语言与代码数据。无需依赖外部工具包和投票技术，DeepSeekMath 7B 在竞赛级 MATH 基准上取得了 51.7% 的优异成绩，已经接近 Gemini-Ultra 与 GPT-4 的性能水平。对 DeepSeekMath 7B 进行 64 次采样并采用 self-consistency 后，其在 MATH 上的成绩可达到 60.9%。

DeepSeekMath 的数学推理能力主要来源于两个关键因素。第一，作者通过一个经过精心设计的数据筛选流水线，充分挖掘了公开网页数据在数学领域中的巨大潜力。第二，作者提出了 Group Relative Policy Optimization (GRPO)，这是 Proximal Policy Optimization (PPO) 的一种变体。它在增强数学推理能力的同时，还优化了 PPO 的内存使用。

图 1 说明 图 1 展示了在不使用外部工具和投票技巧的条件下，开源模型在竞赛级 MATH 基准上的 Top-1 准确率。

1. 引言

大语言模型 (LLM) 已经彻底改变了人工智能中处理数学推理问题的方式，并显著推动了数量推理基准与几何推理基准上的进展。此外，这些模型也已经被证明能够帮助人类解决复杂数学问题。然而，GPT-4 与 Gemini-Ultra 等前沿模型并未公开开放，而当前可获得的开源模型在性能上仍明显落后。

本文提出了 DeepSeekMath，这是一个面向数学领域的专用语言模型，它在数学能力上显著超过现有开源模型，并在学术基准上逼近 GPT-4 的水平。为实现这一目标，作者构建了 DeepSeekMath Corpus，这是一个包含 120B 数学 token 的大规模高质量预训练语料库。该数据集借助基于 fastText 的分类器从 Common Crawl 中抽取而来。在初始迭代中，分类器以 OpenWebMath 中的样本作为正例，并结合多样化的其他网页作为负例进行训练。随后，作者利用该分类器从 Common Crawl 中继续挖掘新的正样本，并通过人工标注进一步精炼，再用增强后的数据集更新分类器，从而持续提升其性能。实验表明，这一大规模语料质量很高：其基础模型 DeepSeekMath-Base 7B 在 GSM8K 上达到 64.2%，在竞赛级 MATH

上达到 36.2%，超过了 Minerva 540B。除此之外，DeepSeekMath Corpus 还具有多语言特性，因此作者观察到它在中文数学基准上也带来了提升。他们认为，他们在数学数据处理上的经验可以作为后续研究的起点，而未来仍有很大的改进空间。

DeepSeekMath-Base 以 DeepSeek-Coder-Base-v1.5 7B 为初始化模型。作者观察到，相比从一个通用 LLM 出发，从代码训练模型出发是更好的选择。进一步地，他们还发现数学训练会提升模型在 MMLU 和 BBH 等基准上的表现，说明数学训练不仅增强了模型的数学能力，也放大了其一般推理能力。

在预训练之后，作者进一步对 DeepSeekMath-Base 进行数学指令微调，所用数据包括 chain-of-thought、program-of-thought 和工具集成推理数据。所得模型 DeepSeekMath-Instruct 7B 在所有 7B 级别模型中表现最佳，并且可以与 70B 级别的开源指令微调模型相媲美。

在此基础上，作者还提出了 Group Relative Policy Optimization (GRPO)，这是一种 PPO 风格的强化学习算法变体。GRPO 不再使用 critic 模型，而是从组内分数中直接估计 baseline，因此显著降低了训练资源消耗。仅使用一部分英文指令微调数据，GRPO 就在强大的 DeepSeekMath-Instruct 基础上继续取得明显提升，这一提升既体现在域内任务上，例如 GSM8K 从 82.9% 提升到 88.2%，MATH 从 46.8% 提升到 51.7%；也体现在域外数学任务上，例如 CMATH 从 84.6% 提升到 88.8%。

作者还提出了一个统一范式，用于理解拒绝采样微调 (RFT)、直接偏好优化 (DPO)、PPO 和 GRPO 等不同方法。在这一统一视角下，他们认为这些方法本质上都可以被理解为直接的或简化的强化学习技术。围绕这一范式，作者进一步开展了大量实验，例如在线训练与离线训练、结果监督与过程监督、单轮强化学习与迭代强化学习等，以更深入地分析该范式的关键要素。最后，作者解释了为什么强化学习能够提升指令微调模型的性能，并总结了在该统一范式下实现更有效强化学习的潜在方向。

1.1. 主要贡献

本文的贡献主要包括可扩展的数学预训练，以及围绕强化学习展开的探索与分析。

大规模数学预训练

- 本文提供了有力证据，说明公开可获取的 Common Crawl 数据中确实蕴含大量对数学任务有价值的信息。通过精心设计的数据筛选流水线，作者成功构建了 DeepSeekMath Corpus。该数据集包含 120B 来自网页的数学内容 token，其规模约为 Minerva 所使用数学网页数据的 7 倍，也是 OpenWebMath 的 9 倍左右。
- 预训练后的 DeepSeekMath-Base 7B 可以取得与 Minerva 540B 相当的性能，这说明模型参数量并不是决定数学推理能力的唯一关键因素；在高质量数据上预训练的小模型，同样能够得到很强的效果。
- 作者还总结了数学训练实验中的一个重要发现：先进行代码训练，再进行数学训练，可以同时提升模型在“无工具”和“有工具”两种设置下解决数学问题的能力。这为“代

码训练是否能提升推理能力”这一长期问题提供了部分答案。至少在数学推理领域，作者认为答案是肯定的。

- 尽管在许多数学相关论文中，使用 arXiv 论文作为训练数据很常见，但在本文采用的所有数学基准上，训练 arXiv 数据并没有带来显著提升。

强化学习的探索与分析

- 作者提出了高效且有效的强化学习算法 GRPO。它省去了 critic/value 模型，转而利用组内分数估计 baseline，因此与 PPO 相比显著降低了训练资源需求。
- 作者证明，仅使用指令微调数据，GRPO 就能显著提升 DeepSeekMath-Instruct 的性能，并且在强化学习过程中还观察到了域外性能的同步提升。
- 作者提出了统一范式，用于理解 RFT、DPO、PPO 与 GRPO 等多种方法，并通过在线/离线训练、结果/过程监督、单轮/迭代强化学习等大量实验，对这一范式的本质要素进行了系统研究。
- 基于这一统一范式，作者进一步分析了强化学习之所以有效的原因，并总结了若干实现更有效 LLM 强化学习的潜在方向。

1.2. 评测与指标概述

作者从三个方面评估模型。

第一，英文与中文数学推理。作者在多个英文与中文基准上开展了全面评测，题目覆盖从小学到大学的不同数学难度层次。英文基准包括 GSM8K、MATH、SAT、OCW Courses 与 MMLU-STEM；中文基准包括 MGSM-zh、CMATH、Gaokao-MathCloze 与 Gaokao-MathQA。评测既考察模型在不借助工具的情况下生成完整文字解答的能力，也考察模型借助 Python 解决问题的能力。

在英文基准上，DeepSeekMath-Base 与闭源的 Minerva 540B 具有竞争力，并超过了所有开源 base 模型，例如 Mistral 7B 与 Llemma-34B，不论这些模型是否进行过数学预训练，差距往往都较大。值得注意的是，DeepSeekMath-Base 在中文基准上的表现尤其出色，这很可能是因为作者没有像以往工作那样只收集英文数学预训练数据，而是同时纳入了高质量的非英文数据。进一步结合数学指令微调和强化学习后，DeepSeekMath-Instruct 与 DeepSeekMath-RL 成为开源社区中首批在竞赛级 MATH 数据集上把准确率提升到 50% 以上的模型。

第二，形式化数学。作者在 miniF2F 数据集上，采用来自已有工作的 informal-to-formal theorem proving 任务，并使用 Isabelle 作为证明助手来评估 DeepSeekMath-Base。结果表明，DeepSeekMath-Base 具备较强的 few-shot 自动形式化能力。

第三，自然语言理解、推理与代码能力。为了更全面地描绘模型的通用能力，作者在 MMLU、BBH、HumanEval 和 MBPP 上对 DeepSeekMath-Base 进行了评估。实验显示，数学预训练不仅有利于数学任务，也有利于语言理解和一般推理能力。

2. 数学预训练

2.1. 数据收集与去污染

本节介绍作者如何从 Common Crawl 构建 DeepSeekMath Corpus。如图 2 所示，作者提出了一个迭代式流水线，用于从 Common Crawl 中系统性地收集大规模数学语料，并以一个种子语料作为起点，例如一个规模较小但质量较高的数学数据集合。作者指出，这种方法并不限于数学领域，也可以推广到代码等其他领域。

首先，作者将 OpenWebMath 作为初始种子语料。借助这一语料，他们训练了一个 fast-Text 模型，以便从网页中召回更多与 OpenWebMath 风格相似的数学网页。具体来说，他们从种子语料中随机抽取 50 万条样本作为正例，再从 Common Crawl 中随机抽取 50 万个网页作为负例，并使用开源 fastText 库进行训练。训练时设置向量维度为 256，学习率为 0.1，词 n-gram 最大长度为 3，词最小出现次数为 3，训练轮数为 3。为缩小原始 Common Crawl 的规模，作者还采用了基于 URL 的去重和近似去重技术，最终得到 400 亿个 HTML 网页。在此基础上，再利用 fastText 模型从去重后的 Common Crawl 中召回数学网页。

为了进一步过滤低质量数学内容，作者按照 fastText 模型预测分数对收集到的网页排序，只保留分数最高的一部分。最终保留多少数据，是通过在前 40B、80B、120B 与 160B token 上开展预训练实验来决定的。在第一次迭代中，作者选择保留前 40B token。

第一次迭代完成后，仍有大量数学网页没有被收集到，主要原因在于正样本集合的多样性还不够，导致 fastText 模型召回能力受限。因此，作者继续识别新的数学网页来源以扩充种子语料，从而进一步优化 fastText 模型。具体而言，他们首先将整个 Common Crawl 按 domain 划分为彼此不相交的集合，这里的 domain 指共享相同 base URL 的网页集合。对于每个 domain，他们统计其中在第一次迭代中被收集到的网页比例；若某个 domain 中超过 10% 的网页被收集到，则将其视作“数学相关域名”，例如 `mathoverflow.net`。接着，作者人工标注这些域名中与数学内容相关的 URL 路径，例如 `mathoverflow.net/questions`。凡是链接到这些 URL 且此前尚未收集到的网页，都会被加入种子语料。借助这一策略，作者得以收集更多正样本，进而训练出更强的 fastText 模型，在下一轮迭代中召回更多数学数据。经过四轮迭代，最终收集到 3550 万个数学网页，总计 120B token。作者注意到，在第四轮迭代中，有将近 98% 的数据其实已经在第三轮中被收集到，因此他们停止继续扩充数据。

为了避免基准污染，作者遵循已有工作的方法，过滤掉包含英语数学基准（如 GSM8K、MATH）和中文数学基准（如 CMATH、AGIEval）中问题或答案的网页。其过滤规则为：若文本片段中包含与评测基准任一子串完全匹配的 10-gram，则从数学训练语料中移除；对于长度不足 10-gram 但至少含有 3-gram 的评测文本，则采用精确匹配来去除污染网页。

2.2. DeepSeekMath Corpus 的质量验证

作者通过预训练实验，将 DeepSeekMath Corpus 与几种近期发布的数学训练语料进行比较，包括 MathPile、OpenWebMath 和 Proof-Pile-2。

在训练设置上，作者选用一个 1.3B 参数的通用预训练语言模型 DeepSeek-LLM 1.3B，并分别在每个数学语料上训练 150B token。所有实验均在 HAI-LLM 框架下完成。优化器

使用 AdamW, 其中 $\beta_1 = 0.9$ 、 $\beta_2 = 0.95$ 、 $\text{weight_decay} = 0.1$; 学习率调度采用多阶段策略, 在 2000 个 warmup step 后达到峰值, 在训练进度 80% 时衰减为峰值的 31.6%, 在 90% 时进一步衰减到峰值的 10%。最大学习率设置为 5.3×10^{-4} , batch size 为 4M token, 上下文长度为 4K。

作者给出的比较结果显示, DeepSeekMath Corpus 质量高、具有多语言覆盖能力, 并且规模最大。在 8 个数学基准上的 few-shot CoT 评测中, 使用 DeepSeekMath Corpus 训练得到的模型表现明显领先。作者还指出, 图 3 表明, 在训练到 50B token 时, 基于 DeepSeekMath Corpus 的模型表现已经优于基于 Proof-Pile-2 的模型, 这说明 DeepSeekMath Corpus 的平均质量更高。

在多语言方面, DeepSeekMath Corpus 覆盖了多种语言, 其中英语与中文占比最高。实验结果表明, 在该语料上训练能够同时提升英文与中文数学推理能力; 相比之下, 现有主要以英文为中心的数学语料对中文数学推理的帮助有限, 甚至可能带来负面影响。

在规模方面, DeepSeekMath Corpus 的规模远大于现有数学语料。从学习曲线看, 在该语料上训练的 DeepSeek-LLM 1.3B 不仅上升更快, 而且改进持续更久。与之相对, 其他基线语料规模更小, 在训练过程中很快就被重复使用多轮, 模型性能也较快进入平台期。

2.3. DeepSeekMath-Base 7B 的训练与评估

本节介绍 DeepSeekMath-Base 7B。该模型以 DeepSeek-Coder-Base-v1.5 7B 为初始化, 并总共训练 500B token。训练数据的分布为: 56% 来自 DeepSeekMath Corpus, 4% 来自 AlgebraicStack, 10% 来自 arXiv, 20% 来自 GitHub 代码, 剩余 10% 为 Common Crawl 中的中英文自然语言数据。其余训练设置大致沿用前节设置, 但把最大学习率调整为 4.2×10^{-4} , batch size 调整为 10M token。

作者从多个角度对 DeepSeekMath-Base 7B 进行了全面评估: 一是考察它在不依赖外部工具时生成自洽数学解答的能力; 二是考察它借助工具求解数学问题的能力; 三是考察它进行形式化定理证明的能力。此外, 作者还评估了它在自然语言理解、一般推理和编程方面的表现。

在“逐步推理解题”任务中, 作者采用 few-shot CoT 提示, 在 8 个中英文基准上评估 DeepSeekMath-Base。结果表明, DeepSeekMath-Base 7B 在全部 8 个基准上都领先于开源 base 模型, 包括 Mistral 7B 和经过数学训练的 Llemma 34B。尤其是在竞赛级 MATH 上, 它相对现有开源 base 模型有超过 10 个百分点的绝对优势, 甚至超过了参数规模大 77 倍的闭源 Minerva 540B。

在“借助工具解题”任务中, 作者使用 few-shot program-of-thought 提示, 在 GSM8K 与 MATH 上进行程序辅助推理评估。模型需要为每道题写出 Python 程序, 可以调用 math 与 sympy 等库, 再以程序运行结果作为答案。实验结果表明, DeepSeekMath-Base 7B 超过了此前的 SOTA 模型 Llemma 34B。

在形式化数学方面, 作者让模型完成 informal-to-formal proving 任务: 给定非形式化陈述、其形式化对应表述以及非形式化证明, 要求模型生成 Isabelle 中的形式化证明。评测使用 miniF2F 数据集, 并结合 Sledgehammer 自动证明器补全细节。结果显示, DeepSeekMath-Base 7B 在证明自动形式化方面具有较强性能。

在通用能力方面，作者在 MMLU、BBH、HumanEval 与 MBPP 上进行评测。结果显示，与其前身 DeepSeek-Coder-Base-v1.5 相比，DeepSeekMath-Base 7B 在 MMLU 与 BBH 上提升明显，这说明数学训练对语言理解与一般推理有正向作用。同时，由于继续训练时也混入了代码 token，DeepSeekMath-Base 7B 在 HumanEval 与 MBPP 上基本维持了原有代码能力。总体而言，它在推理与编程相关基准上显著优于通用模型 Mistral 7B。

3. 监督微调

3.1. SFT 数据构建

作者构建了一个数学指令微调数据集，覆盖英文和中文、不同数学分支以及不同难度层级的问题。每个问题都配有相应解答，并采用 chain-of-thought、program-of-thought 或工具集成推理的格式进行组织。整个训练集共有 776K 条样本。

对于英文数学数据，作者为 GSM8K 与 MATH 问题补充了工具集成式解答，同时采用了 MathInstruct 的一部分数据以及 Lila-OOD 的训练集，其中问题通过 CoT 或 PoT 方式求解，内容覆盖代数、概率、数论、微积分、几何等多个领域。

对于中文数学数据，作者收集了 K-12 阶段的中文数学问题，涵盖线性方程等 76 个子主题，并为其标注了 CoT 与工具集成两种格式的解答。

3.2. DeepSeekMath-Instruct 7B 的训练与评估

DeepSeekMath-Instruct 7B 以 DeepSeekMath-Base 为基础进行数学指令微调。训练时，将样本随机拼接，直达到 4K token 的上下文长度上限。模型共训练 500 个 step，batch size 为 256，学习率恒定为 5×10^{-5} 。

作者在 4 个中英文数量推理基准上，同时评估模型在“不可用工具”和“可用工具”两种设置下的数学性能，并将其与当时主流的闭源与开源模型进行比较。闭源模型包括 GPT 系列、Gemini Ultra/Pro、Inflection-2、Grok-1 以及国内公司发布的 Baichuan-3 和 GLM-4；开源模型既包括通用对话模型如 DeepSeek-LLM-Chat 67B、Qwen 72B、SeaLLM-v2 7B、ChatGLM3 6B，也包括一批经过数学增强的模型，如 InternLM2-Math、Math-Shepherd-Mistral、WizardMath、MetaMath、ToRA 与 MAMmoTH。

结果显示，在不允许使用工具的设定下，DeepSeekMath-Instruct 7B 已经展现出很强的逐步推理能力。特别是在竞赛级 MATH 数据集上，它超过了所有开源模型，也超过了多数闭源专有模型，例如 Inflection-2 与 Gemini Pro，绝对优势至少达到 9 个百分点。即便与规模更大的模型（如 Qwen 72B）相比，或与经过专门数学强化学习增强的模型（如 WizardMath-v1.1 7B）相比，DeepSeekMath-Instruct 7B 依然更强。虽然它在 MATH 上已可与 GLM-4 和 Baichuan-3 这类中文闭源模型相抗衡，但相较 GPT-4 与 Gemini Ultra 仍有差距。

在允许结合自然语言推理与程序工具进行解题的设定下，DeepSeekMath-Instruct 7B 在 MATH 上的准确率接近 60%，超过了全部现有开源模型；在其他基准上，它也能与此前 SOTA 的 DeepSeek-LLM-Chat 67B 相竞争，而后者的参数规模大约是它的 10 倍。

4. 强化学习

4.1. Group Relative Policy Optimization

已有研究表明，在监督微调阶段之后，强化学习能够进一步提升 LLM 的数学推理能力。基于此，作者提出了高效而有效的强化学习算法 GRPO。

4.1.1. 从 PPO 到 GRPO

PPO 是一种广泛用于 LLM 强化学习微调阶段的 actor-critic 算法，其核心是最大化如下替代目标：

$$J_{\text{PPO}}(\theta) = \mathbb{E} \left[\frac{1}{|o|} \sum_{t=1}^{|o|} \min(r_t(\theta)A_t, \text{clip}(r_t(\theta), 1 - \varepsilon, 1 + \varepsilon)A_t) \right]. \quad (1)$$

其中， π_θ 与 $\pi_{\theta_{\text{old}}}$ 分别表示当前策略与旧策略， A_t 为 advantage，通常通过 GAE 基于奖励和价值函数 V_ψ 计算得到。为了抑制对奖励模型的过优化，PPO 常在每个 token 的奖励中加入相对参考模型的 KL 惩罚：

$$r_t = r_\phi(q, o_{\leq t}) - \beta \log \frac{\pi_\theta(o_t|q, o_{<t})}{\pi_{\text{ref}}(o_t|q, o_{<t})}. \quad (2)$$

然而，PPO 中的 value function 通常也是一个与策略模型规模相近的网络，这会带来显著的显存与计算负担。此外，在 LLM 场景中，奖励模型往往只在最后一个 token 上给出奖励，这使得“为每个 token 都学习一个准确 value”本身变得困难。

为了解决这一问题，作者提出 GRPO。它不再像 PPO 那样额外学习 value function，而是针对同一个问题从旧策略中采样一组输出，并直接使用这组输出的平均奖励作为 baseline。对于每个问题 q ，GRPO 从旧策略 $\pi_{\theta_{\text{old}}}$ 中采样一组输出 $\{o_1, o_2, \dots, o_G\}$ ，然后最大化如下目标：

$$J_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min(r_{i,t}(\theta)\hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon, 1 + \varepsilon)\hat{A}_{i,t}) - \beta D_{\text{KL}} \right) \right]. \quad (3)$$

其中， $\hat{A}_{i,t}$ 是只基于同组输出之间相对奖励计算得到的 advantage。作者认为，这种“组内相对比较”的方式与奖励模型本身的比较式训练特点十分契合，因为奖励模型通常正是基于同一问题下不同回答之间的比较数据训练得到的。此外，GRPO 不是把 KL 惩罚加到 reward 中，而是直接把策略与参考模型之间的 KL 散度加入 loss 中，从而避免干扰 $\hat{A}_{i,t}$ 的计算。

作者还给出了一个无偏的 KL 散度估计器：

$$D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) = \frac{\pi_{\text{ref}}}{\pi_\theta} - \log \frac{\pi_{\text{ref}}}{\pi_\theta} - 1, \quad (4)$$

该形式始终为正。

4.1.2. 基于结果监督的 GRPO

对于每个问题，先从旧策略中采样一组输出，再用奖励模型为每个输出打分，得到 G 个 reward。随后，对这组 reward 做标准化：先减去组均值，再除以组标准差。结果监督只在每个输出的结尾处给出归一化奖励，并把该归一化奖励赋给该输出中所有 token 的 advantage，也就是说，同一条回答中的所有 token 共享同一个最终奖励信号。

4.1.3. 基于过程监督的 GRPO

作者指出，结果监督只在输出末尾提供奖励，对于复杂数学任务来说可能不够充分。因此，他们进一步探索过程监督，即在每个推理步骤结束时提供 reward。具体而言，过程奖励模型会为每一步的结束位置打分，再对所有步骤奖励做标准化。随后，每个 token 的 advantage 被定义为其之后所有步骤归一化奖励之和。这样，模型就能获得更细粒度、更贴合推理过程本身的训练信号。

4.1.4. 迭代式 GRPO

随着强化学习训练不断推进，旧的奖励模型可能逐渐无法充分监督当前策略模型。因此，作者又研究了迭代式 GRPO。其核心做法是：根据当前策略模型的采样结果构造新的奖励模型训练集，并通过带 replay 机制的持续训练更新旧奖励模型，其中包含约 10% 的历史数据；之后再把当前策略模型设为新的参考模型，继续在更新后的奖励模型指导下训练策略模型。

算法 1 说明 迭代式 GRPO 的流程可以概括为：初始化策略模型；对每一轮迭代，先固定当前策略为参考模型；在每一步中采样一个 batch 问题，复制当前策略为旧策略，针对每个问题采样多条回答，用奖励模型打分，计算组相对 advantage，再进行若干轮 GRPO 更新，并持续更新奖励模型。

4.2. DeepSeekMath-RL 的训练与评估

作者在 DeepSeekMath-Instruct 7B 的基础上进行强化学习。RL 阶段的数据来自 SFT 数据中与 GSM8K 和 MATH 相关、且采用 chain-of-thought 格式的问题，总量约为 144K。作者有意排除了其他 SFT 问题，以便观察在 RL 阶段没有直接训练数据的基准上，强化学习是否仍能带来提升。

奖励模型训练集的构造遵循已有工作。初始奖励模型建立在 DeepSeekMath-Base 7B 之上，学习率为 2×10^{-5} 。对于 GRPO，策略模型学习率设置为 1×10^{-6} ，KL 系数设为 0.04。每个问题采样 64 条输出，最大长度为 1024，训练 batch size 为 1024。每轮探索之后，策略模型只进行一次更新。评测时沿用 DeepSeekMath-Instruct 7B 的同一套基准，其中 GSM8K 与 MATH 的 CoT 评测视为域内任务，其余基准视为域外任务。

实验结果表明，DeepSeekMath-RL 7B 在 CoT 设定下于 GSM8K 和 MATH 上分别达到 88.2% 与 51.7%，超过了 7B 到 70B 范围内的全部开源模型，也超过了大多数闭源模型。更重要的是，DeepSeekMath-RL 7B 仅用 GSM8K 和 MATH 的 CoT 指令数据进行强化学

习，却在所有评测指标上都超过了 DeepSeekMath-Instruct 7B，这充分体现了强化学习的有效性。

5. 讨论

本节总结作者在预训练与强化学习实验中的主要发现。

5.1. 预训练经验

除非特别说明，本节实验均沿用 2.2.1 节中的训练设置。这里提到的 DeepSeekMath Corpus 特指第二轮数据收集后得到的一个 89B token 数据集。

5.1.1. 代码训练有助于数学推理

“代码训练能够提升推理能力”是一个流行但尚未被充分验证的假设。作者尝试在数学领域对这一问题给出部分回答：代码训练的确能够提升模型在“无工具”和“有工具”两种设置下的数学推理能力。

为研究代码训练如何影响数学推理，作者设计了两类训练方案。第一类是两阶段训练：一是先用 400B 代码 token 训练，再用 150B 数学 token 训练；二是作为对照，先用 400B 通用 token 训练，再用 150B 数学 token 训练，从而分析代码 token 相比通用 token 的优势。第二类是一阶段训练：一是仅使用 150B 数学 token 训练；二是将 400B 代码 token 与 150B 数学 token 混合起来一次性训练，以研究在缓解灾难性遗忘的同时，代码 token 是否仍能提升数学能力。

实验结果表明，代码训练在两阶段和一阶段设置下都能促进程序辅助数学推理。在两阶段设置中，仅代码训练本身就已经显著提升了使用 Python 解 GSM8K 和 MATH 的能力，而第二阶段的数学训练则会带来进一步增强。更有意思的是，在一阶段混合训练设置下，把代码 token 与数学 token 混合起来，能够有效缓解两阶段训练导致的灾难性遗忘问题，同时还能够兼顾编程能力与程序辅助数学推理能力。

代码训练对“无工具”的数学推理同样有帮助。在两阶段设置中，第一阶段的代码训练已经带来中等幅度的提升，并且还能提高后续数学训练的效率，最终取得最佳结果。不过，把代码 token 和数学 token 直接混在一起做一阶段训练，反而会损害无工具数学推理性能。作者推测，这可能是由于 1.3B 模型规模有限，还不足以同时充分吸收代码与数学两类数据。

5.1.2. arXiv 论文对数学推理提升似乎有限

在许多数学预训练工作中，arXiv 论文是常见的数据组成部分。但作者指出，关于它到底如何影响数学推理，过去并没有被系统分析。根据本文实验，一个略显反直觉的结论是：arXiv 论文对数学推理的提升似乎并不明显。

作者在不同规模模型上开展实验，包括 DeepSeek-LLM 1.3B 与 DeepSeek-Coder-Base-v1.5 7B，并使用两种不同处理流程得到的 arXiv 语料：一种是以清洗与过滤规则构造的

MathPile, 其中超过 85% 为 arXiv 科学论文; 另一种是 ArXiv-RedPajama, 它保留了全部 arXiv LaTeX 文件内容, 但移除了引言区、注释、宏定义与参考文献, 总计 28B token。

实验中, 作者分别让 DeepSeek-LLM 1.3B 在每个 arXiv 语料上训练 150B token, 让 DeepSeek-Coder-Base-v1.5 7B 在每个 arXiv 语料上训练 40B token。结果显示, 当模型仅在 arXiv 语料上训练时, 无论是在 GSM8K、MATH 这类数量推理数据集上, 还是在 MMLU-STEM 这类选择题挑战上, 乃至 miniF2F 这类形式化数学任务上, 都几乎没有显著提升, 甚至会出现性能下降。

不过, 作者也强调这一结论并非定论, 还需要谨慎看待, 因为他们尚未研究以下几个问题: 第一, arXiv token 对某些本文未涉及的数学相关任务是否有效, 例如把形式化定理或证明转回自然语言表述的 informalization 任务; 第二, 当 arXiv 数据与其他类型数据混合时, 其效果会如何变化; 第三, 在更大规模模型上, arXiv 论文的好处是否才会真正显现。这些问题都留待后续工作继续探索。

5.2. 强化学习的洞见

5.2.1. 走向统一范式

作者提出了一个统一范式, 用来分析 SFT、RFT、DPO、PPO 与 GRPO 等训练方法。一般而言, 某个训练方法关于参数 θ 的梯度都可以写成如下形式:

$$\nabla_{\theta} J_A(\theta) = \mathbb{E}_{(q,o) \sim D} \left[\frac{1}{|o|} \sum_{t=1}^{|o|} GC_A(q, o, t, \pi_{rf}) \nabla_{\theta} \log \pi_{\theta}(o_t | q, o_{<t}) \right]. \quad (5)$$

这个统一表达式包含三个关键组成部分: 其一是数据来源 D , 决定训练用什么数据; 其二是奖励函数 π_{rf} , 决定训练信号从何而来; 其三是算法 A , 它把训练数据与奖励信号进一步转化为梯度系数 GC , 从而决定对样本施加多大的正向强化或负向惩罚。

在这一统一视角下, SFT 使用人工选择好的 SFT 数据, 梯度系数恒为 1; RFT 基于 SFT 模型对问题采样若干输出, 再筛选出正确答案对应的输出进行继续微调; DPO 则在 SFT 模型采样结果上使用成对偏好损失进行优化; Online RFT 与 RFT 的唯一区别在于, 它不是从静态的 SFT 模型采样, 而是从实时更新的策略模型中采样; 而 PPO 与 GRPO 都是以 SFT 模型为初始策略, 再用实时策略采样的输出进行强化更新。作者用表 10 对这些方法的数据来源、奖励函数与梯度系数进行了并列总结。

作者首先比较了数据来源的影响。他们将数据来源分为在线采样与离线采样两类。在线采样指训练数据来自当前实时策略模型的探索结果; 离线采样则指训练数据来自初始 SFT 模型的采样结果。RFT 和 DPO 属于离线风格, 而 Online RFT 与 GRPO 属于在线风格。实验表明, Online RFT 在两个基准上都明显优于 RFT。更具体地说, 在训练初期, Online RFT 与 RFT 表现接近, 因为这时 actor 与 SFT 模型仍然相似, 采样数据差异不大; 而随着训练推进, 实时策略模型采样出的数据与初始 SFT 输出之间差别逐渐拉大, 这时在线采样的优势便会更加明显。

随后, 作者分析了梯度系数的影响。在他们的实验中, 奖励函数可以分为“规则型”和“模型型”两类: 规则型指直接根据最终答案是否正确来判定回答质量; 模型型则是训练一

个奖励模型，为每条回答打分。奖励模型本身的训练数据，依然基于规则型判断得到。作者指出，GRPO 与 Online RFT 的一个关键差异在于，GRPO 会根据奖励模型给出的数值大小动态调整梯度系数，因此能够对不同质量的回答施加不同程度的强化与惩罚；相比之下，Online RFT 不会惩罚错误回答，并且会以同等强度强化所有正确回答。实验结果显示，GRPO 明显优于 Online RFT，这说明引入正负不同力度的梯度调节是有效的。进一步地，GRPO+PS 又优于 GRPO+OS，说明使用更细粒度、与步骤相关的梯度信号是有益的。除此之外，作者还研究了迭代强化学习，并进行了两轮迭代；结果表明，尤其在第一轮迭代中，性能提升十分显著。

5.2.2. 为什么强化学习有效

作者进一步讨论了为什么基于一小部分指令微调数据进行强化学习，仍然能够显著提升模型性能。为此，他们比较了 Instruct 模型与 RL 模型在两个基准上的 Pass@K 与 Maj@K。实验发现，强化学习显著提升了 Maj@K，但并未提升 Pass@K。这意味着，强化学习主要不是让模型“本质上更会做题”了，而是使输出分布变得更稳健、更偏向正确答案。换句话说，改进更像是把 Top-K 候选中的正确回答“推”到了更靠前的位置，而不是显著提升了模型生成正确解法的根本能力。作者还指出，这与已有工作关于 SFT 模型在推理任务上存在对齐失配问题的结论是一致的。

5.2.3. 如何实现更有效的强化学习

在统一范式下，作者认为未来可以从数据来源、算法和奖励函数三个方面继续改进强化学习。

在数据来源方面，强化学习中的原材料可以理解为“未标注问题 + 由策略模型采样得到的输出”。本文只使用了指令微调阶段的问题，并采用较朴素的 nucleus sampling 进行采样。作者认为，这可能正是他们的 RL 流水线只能提升 Maj@K、而难以提升 Pass@K 的原因之一。未来，他们计划在分布外问题提示上探索 RL，并结合更先进的采样/解码策略，例如树搜索方法。同时，高效推理技术也会极大影响策略模型的探索效率，因此同样非常关键。

在算法方面，当前方法在很大程度上都“完全信任”奖励函数给出的信号，即根据奖励增减某个 token 的条件概率。然而，在极其复杂的任务中，奖励信号不可能始终可靠。作者举例指出，即便是经过认真标注的 PRM800K 数据集，仍大约包含 20% 的错误标注。因此，未来值得探索对噪声奖励更鲁棒的强化学习算法。作者认为，这类从弱监督走向强能力的对齐方法，有可能带来学习算法层面的根本变化。

在奖励函数方面，奖励模型是 RL 训练信号的源头。作者认为未来至少有三个重要方向：第一，如何提升奖励模型的泛化能力，使其能够处理分布外问题和更复杂的解码输出，否则 RL 可能只是让模型的输出分布更稳定，而无法真正提高模型本质能力；第二，如何刻画奖励模型的不确定性，因为这种不确定性有潜力成为连接“弱奖励模型”与“弱到强学习算法”的桥梁；第三，如何高效构建高质量的过程奖励模型，为推理过程提供更细粒度的训练信号。

6. 结论、局限与未来工作

本文提出了 DeepSeekMath。它在竞赛级 MATH 基准上超过了所有开源模型，并逼近闭源模型的性能。DeepSeekMath 以 DeepSeek-Coder-v1.5 7B 为初始化模型，继续训练 500B token，其中相当大一部分来自 Common Crawl 中抽取的 120B 数学 token。大量消融实验表明，网页数据在构建高质量数学数据方面具有很大潜力，而 arXiv 的收益则没有预期中那么明显。作者提出的 GRPO 作为 PPO 的一个变体，在显著降低内存消耗的同时，能够明显提升数学推理能力。实验还表明，即使 DeepSeekMath-Instruct 7B 已经在各项基准上取得较高分数，GRPO 依然是有效的。除此之外，作者还给出了一个统一范式，用于理解一系列训练方法，并总结了未来实现更有效强化学习的若干方向。

不过，作者也坦率指出，尽管 DeepSeekMath 在数量推理基准上表现出色，但其在几何问题与定理证明上的能力仍弱于闭源模型。例如，在作者的内部测试中，模型还不能很好处理与三角形和椭圆有关的问题，这可能反映出预训练与微调阶段存在数据选择偏差。此外，受限于模型规模，DeepSeekMath 的 few-shot 能力仍落后于 GPT-4：GPT-4 能从 few-shot 示例中进一步获益，而 DeepSeekMath 在 zero-shot 与 few-shot 评测之间差别不大。未来，作者将继续改进其数据筛选流水线，以构建更高质量的预训练语料；同时，也将围绕第 5.2.3 节提出的方向，进一步探索更有效的 LLM 强化学习方法。

附录：强化学习分析（节选翻译）

附录 A.1 对 SFT、RFT、Online RFT、DPO、PPO 与 GRPO 的数据来源和梯度系数进行了更详细的推导。下面给出核心结论的中文整理。

SFT 监督微调的目标是最大化训练集中标准答案序列的对数似然：

$$J_{\text{SFT}}(\theta) = \mathbb{E}_{q, o \sim P_{\text{sft}}(Q, O)} \left[\frac{1}{|o|} \sum_{t=1}^{|o|} \log \pi_{\theta}(o_t | q, o_{<t}) \right]. \quad (6)$$

在这一方法中，数据来源就是 SFT 数据集本身，奖励函数可以被视作“人工选择”，梯度系数恒为 1。

RFT 拒绝采样微调会先从监督微调模型中为每个问题采样多条回答，然后只保留答案正确的回答继续训练。它的目标可写为：

$$J_{\text{RFT}}(\theta) = \mathbb{E}_{q \sim P_{\text{sft}}(Q), o \sim \pi_{\text{sft}}(O|q)} \left[\frac{1}{|o|} \sum_{t=1}^{|o|} I(o) \log \pi_{\theta}(o_t | q, o_{<t}) \right], \quad (7)$$

其中 $I(o)$ 表示回答是否正确。若正确则梯度系数为 1，否则为 0。

Online RFT 与 RFT 唯一不同的是，回答不再来自静态的 SFT 模型，而是来自实时更新的当前策略模型，因此本质上是把“拒绝采样微调”变成了一个在线过程。

DPO DPO 的训练数据由同一问题下的优回答与差回答构成。它通过偏好损失，直接把模型向更偏好优回答、远离差回答的方向推。附录中还将其梯度写成统一范式下的形式，以突出它与其他 RL 风格方法在数学上的共通结构。

PPO 在简化分析下，若每次探索后只做一次参数更新，则 PPO 的梯度可写为

$$\nabla_{\theta} J_{\text{PPO}}(\theta) = \mathbb{E} \left[\frac{1}{|o|} \sum_{t=1}^{|o|} A_t \nabla_{\theta} \log \pi_{\theta}(o_t | q, o_{<t}) \right]. \quad (8)$$

因此，在统一范式里，PPO 的梯度系数就是 advantage A_t ，它由奖励和价值函数共同决定。

GRPO 类似地，在简化分析下，GRPO 的梯度可以写成：

$$\nabla_{\theta} J_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\hat{A}_{i,t} + \beta \left(\frac{\pi_{\text{ref}}}{\pi_{\theta}} - 1 \right) \right) \nabla_{\theta} \log \pi_{\theta}(o_{i,t} | q, o_{i,<t}) \right]. \quad (9)$$

也就是说，在统一范式中，GRPO 的梯度系数由两部分组成：一部分是根据组内相对奖励计算得到的 $\hat{A}_{i,t}$ ，另一部分是参考模型与当前模型之间的 KL 正则项。这一形式正是 GRPO 相比 PPO 更节省资源、同时又保留有效策略优化能力的关键。