

《Training language models to follow instructions with human feedback》中文翻译整理稿

根据原文逐段整理翻译

原文: Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike, Ryan Lowe.

Training language models to follow instructions with human feedback, arXiv:2203.02155v1, 2022.

说明: 本文档依据用户提供的原始 PDF 整理为中文翻译稿。为保证可读性,正文部分按照原文的段落与章节顺序进行忠实翻译;参考文献条目保留英文;附录部分在保留主要信息、表格要点和实验设定的同时,采用中文整理翻译的方式呈现。

摘要

单纯把语言模型做得更大,并不会天然让它们更擅长遵循用户意图。举例来说,大型语言模型可能会生成不真实、有毒,或者单纯对用户没有帮助的输出。换句话说,这些模型并没有与用户真正对齐。本文展示了一条使语言模型在广泛任务上与用户意图对齐的路径:利用人类反馈进行微调。作者首先从两类提示词出发构建数据集:一类是标注员撰写的提示词,另一类是通过 OpenAI API 提交的提示词;然后收集标注员给出的理想输出示范,用这些数据通过监督学习微调 GPT-3。接着,作者再收集模型输出之间的排序数据,并利用这些人类偏好进一步通过基于人类反馈的强化学习继续微调该监督模型。作者将最终得到的模型称为 InstructGPT。

在人类评测中,在作者的提示分布上,13 亿参数的 InstructGPT 生成结果比 1750 亿参数的 GPT-3 更受偏好,尽管前者参数量少了约两个数量级。除此之外,InstructGPT 在真实性方面有所提升,在生成有毒输出方面有所下降,同时在公共 NLP 数据集上的性能退化较小。尽管 InstructGPT 仍会犯一些简单错误,但实验结果表明,利用人类反馈对语言模型进行微调,是让语言模型与人类意图对齐的一条很有前景的道路。

1 引言

大型语言模型可以通过“提示”来完成多种自然语言处理任务,只要把若干任务示例作为输入即可。然而,这类模型经常表现出与预期不一致的行为,例如编造事实、生成带偏

见或有毒的文本，或者根本不遵循用户指令。之所以会出现这些问题，是因为近些年许多大模型采用的训练目标，是对互联网网页中的下一个 token 进行预测，而这与“以有帮助且安全的方式遵循用户指令”这一目标并不相同。因此，作者认为传统语言模型目标存在“失对齐”现象。对于已经部署并在大量应用中使用的语言模型而言，避免此类意外行为尤为重要。

本文试图通过训练语言模型，使其行为符合用户意图，从而推动对齐研究向前发展。这里的“用户意图”既包括显式意图，例如遵循指令，也包括隐式意图，例如保持真实、不带偏见、不生成有毒或其他有害内容。借用 Askell 等人的表述，作者希望语言模型同时具备三个性质：**有帮助 (helpful)**、**诚实/真实 (honest)**、**无害 (harmless)**。

作者聚焦于通过微调来实现对齐。具体而言，作者采用“基于人类反馈的强化学习”(RLHF)来微调 GPT-3，使其能够遵循广泛类型的书面指令。整个过程大致分为三步。第一步，招募并筛选约 40 名标注员，收集他们对理想输出的示范，用于训练监督微调模型。第二步，在更大规模的 API 提示集合上，收集不同模型输出之间的人类偏好比较数据，用这些数据训练奖励模型。第三步，把奖励模型作为标量奖励函数，使用 PPO 算法进一步优化监督模型，使其最大化人类偏好奖励。作者强调，这一流程本质上是让 GPT-3 的行为对齐到一个具体群体的偏好上——主要是研究人员与标注员的偏好——而不是抽象意义上全部“人类价值观”。

论文的主要评测方式，是让标注员对模型在保留测试提示上的输出质量进行打分。此外，作者还在一系列公共 NLP 数据集上进行了自动评测。作者训练了 13 亿、60 亿和 1750 亿三个规模的模型，均基于 GPT-3 架构。主要结论如下。第一，标注员显著偏好 InstructGPT 的输出；甚至 13 亿参数的 InstructGPT，也比 1750 亿参数 GPT-3 更受欢迎。第二，在 TruthfulQA 与封闭域任务上，InstructGPT 的真实性明显优于 GPT-3。第三，在毒性方面，InstructGPT 有一定改进，但在偏见基准上没有显著提升。第四，如果在 RLHF 微调时混入预训练分布上的梯度更新，可以显著缓解在公共 NLP 数据集上的性能回退，也就是所谓的“alignment tax”。第五，模型对未参与训练的新标注员偏好也具有一定泛化能力。第六，公共 NLP 数据集并不能很好代表真实用户如何使用语言模型，因此只在这些基准上优化并不能替代面向真实指令分布的对齐。第七，InstructGPT 在一些训练分布之外的任务上也展现出令人鼓舞的泛化，例如代码摘要、代码问答与非英语指令。第八，模型仍然会犯简单错误，例如误信错误前提、过度含糊、或不能很好满足多重约束。

2 相关工作

本文建立在“利用人类反馈进行对齐”的研究脉络之上，尤其是 RLHF。最初，RLHF 被用于简单机器人与 Atari 游戏中的偏好学习；随后被扩展到文本摘要等语言任务。与本文关系密切的工作还包括：在对话、翻译、语义解析、故事生成、评论生成、证据抽取等任务中用人类反馈作为奖励信号；利用书面反馈改写提示以提升 GPT-3 表现的工作；以及在文本环境中利用规范性先验进行价值对齐的研究。本文可以看作是把 RLHF 直接应用到广泛语言任务分布上的一次系统性实践。

此外，关于“什么叫语言模型对齐”的讨论近年来也逐渐增多。已有研究梳理了模型失对齐可能带来的行为问题，例如生成有害内容、钻目标函数空子等。另有并行工作把语言

助手视为对齐研究的实验平台，并研究了一些简单基线及其缩放规律。

本文同时也和“让语言模型遵循指令”的跨任务泛化研究相关。这一方向通常会在大量公共 NLP 任务上，以自然语言指令的形式对语言模型进行微调，再在未见过的任务上测试零样本或少样本泛化能力。大量研究已经表明，这种“指令化微调”有助于提升下游性能。除此之外，也存在在导航环境中让模型遵循自然语言指令的相关研究。

在风险与安全方面，修改语言模型行为以减轻其危害，也是一个独立而重要的研究方向。已有文献系统梳理了语言模型可能带来的偏见、隐私泄露、虚假信息传播和恶意使用等风险；也有许多工作提出各种干预方法，例如值观微调、训练数据过滤、生成时屏蔽某些词、控制 token、对话安全数据收集、去偏正则化、数据增强、因果分析，以及借助第二个小模型来引导生成等。本文的贡献，是将这些关于安全、对齐与指令遵循的思路，通过 RLHF 汇聚为一套针对通用语言任务的工程化流程。

3 方法与实验细节

3.1 总体方法

作者的方法沿用了 Ziegler 等人与 Stiennon 等人在风格续写和文本摘要中的基本框架。输入包括三个部分：一个预训练语言模型；一个希望模型在其上输出“对齐结果”的提示分布；以及一组经过训练的人类标注员。然后按照三步进行。

第一步：收集示范数据并训练监督策略。标注员针对给定提示写出他们认为理想的输出，然后用这些“人类示范”通过监督学习微调 GPT-3。

第二步：收集比较数据并训练奖励模型。作者让标注员面对同一个提示下多个模型输出，对它们进行排序，从而构造偏好对比数据。随后训练一个奖励模型，使它能够预测标注员更偏好哪一个输出。

第三步：使用 PPO 优化策略。把奖励模型的输出作为标量奖励，利用 PPO 进一步优化监督微调后的策略模型。

第二步和第三步可以反复迭代：用当前较好的策略收集更多比较数据，训练新的奖励模型，再继续强化学习优化。实践中，大部分比较数据来自监督微调模型，也有一部分来自 PPO 后的策略模型。

3.2 数据集

作者的提示数据主要来自 OpenAI API 中较早版本 InstructGPT 模型的 Playground 用户输入。此外，最初为了冷启动这一过程，作者也让标注员自己编写提示词。对于 API 数据，作者采用了一些措施来保护用户隐私与保证数据多样性，例如根据长公共前缀进行启发式去重、每个用户最多采样约 200 条提示、按用户 ID 划分训练集/验证集/测试集，并对训练数据中的个人身份信息进行过滤。

最初的标注员自写提示分为三类。其一是 **Plain**，也就是自由提出任意任务，但要求整体上任务类型足够多样。其二是 **Few-shot**，要求标注员给出一条指令以及该指令对应的多个问答示例。其三是 **User-based**，即根据 API 等候名单中的使用场景，编写对应提示。

作者最终构造了三类数据：用于监督微调的 SFT 数据集；用于奖励模型训练的 RM 数据集；以及无人工标签、仅作为 RLHF 输入的 PPO 数据集。SFT 训练集中大约有 1.3 万条提示，RM 训练集中约有 3.3 万条提示，PPO 训练集中约有 3.1 万条提示。根据人工标注，API 提示中占比最高的使用类别是生成类任务，其次是开放问答、头脑风暴、聊天、改写、摘要、分类等。这也说明真实用户的使用分布，与传统公共 NLP 基准并不一致。

3.3 任务形式

训练任务来自两个来源：标注员自行撰写的提示，以及早期 InstructGPT 模型在 API 中收到的提示。这些提示类型非常丰富，涵盖文本生成、问答、对话、摘要、信息抽取等。数据中超过 96% 为英语，但作者在后续也额外测试了非英语指令和代码相关任务。

对每条提示而言，任务的表达形式也并不统一。有些任务通过显式自然语言指令给出，例如“写一个关于聪明青蛙的故事”；有些任务通过 few-shot 示例间接给出；还有些任务则通过补全文本开头的方式隐式指定任务。作者要求标注员尽量推断真实用户意图；如果任务太不清晰，则允许跳过。同时，标注员在写示范与排序时，也需要兼顾真实性和无害性，避免明显错误、偏见或有毒输出。

3.4 人工数据收集

为了构建示范数据、比较数据并进行主要评测，作者从 Upwork 和 ScaleAI 招募了约 40 名承包标注员。由于本文覆盖的任务远比摘要任务更广，而且有时会涉及敏感与争议话题，因此作者专门设计了筛选流程，希望挑出既能理解不同群体偏好、又能识别潜在有害输出的标注员。具体而言，筛选标准包括：对敏感言论标记任务的研究者一致性、对模型输出排序任务的研究者一致性、在敏感提示上撰写示范的表现，以及标注员自评其对不同文化群体敏感表达的识别能力。

训练过程中，不同对齐目标可能会冲突，例如用户主动要求生成潜在有害内容时该如何处理。本文在训练数据阶段更多优先考虑“帮助用户”；而在最终评测中，作者又要求标注员更重视“真实”和“无害”，因为这才是部署时真正更关心的目标。作者与标注员在整个项目周期内保持密切合作，包括培训、详细任务说明以及共享聊天室答疑。

为了初步考察模型对其他标注员偏好的泛化能力，作者还单独雇佣了一批不参与训练数据标注的新标注员。这些人来自同样的渠道，但未经过筛选测试。结果显示，尽管任务复杂，标注员之间的一致率依然较高：训练标注员之间约为 $72.6 \pm 1.5\%$ ，保留标注员之间约为 $77.3 \pm 1.3\%$ 。

3.5 模型

作者从 GPT-3 预训练模型出发，训练了三类模型：SFT、RM 和 RL 模型。

监督微调 (SFT)。作者使用人类示范对 GPT-3 进行监督学习微调。训练共进行 16 个 epoch，采用余弦学习率衰减和残差 dropout。值得注意的是，虽然验证损失在 1 个 epoch 后就出现过拟合迹象，但继续训练反而能改善奖励模型得分和人工偏好评分，因此最终模型是根据奖励模型在验证集上的表现来选取的。

奖励模型 (RM)。奖励模型以提示与回答为输入，输出一个标量奖励值。本文只使用 60 亿参数的奖励模型，因为 1750 亿参数的 RM 训练不够稳定，而且作为 RL 中的 value function 初始化时代价过高。对于同一提示，标注员一般会对 $K = 4$ 到 9 个回答进行排序，从而诱导出多组两两比较。若直接把所有比较打散训练，模型很容易过拟合，因此作者采用“同一提示下所有比较共同组成一个 batch 元素”的方式训练 RM。其损失函数本质上是偏好对的交叉熵：奖励差值对应某回答被人类偏好的对数几率。由于 RM 损失对整体平移不敏感，作者在 RL 前又通过偏置把标注员示范的平均分归一化到 0。

强化学习 (RL)。作者在 bandit 环境中用 PPO 微调 SFT 模型：环境随机给出一个客户提示，策略模型生成回复，奖励由奖励模型给出，随后 episode 结束。为了防止策略过度优化奖励模型带来的偏差，作者还引入了相对 SFT 模型的逐 token KL 惩罚。除此之外，作者还尝试在 PPO 过程中混入预训练分布上的梯度，以缓解对公共 NLP 任务性能的退化。带预训练混合的模型记为 PPO-ptx；若不混入，则记为 PPO。文中默认提到的 InstructGPT，通常指 PPO-ptx 模型。

作者的比较基线包括：原始 GPT-3、通过 few-shot 前缀诱导为“指令模式”的 GPT-3，以及 SFT 模型。作者还把 175B GPT-3 分别在 FLAN 与 T0 数据集上进行微调，作为额外对照。

3.6 评测方法

作者认为，对齐的核心是让模型行为符合用户意图。为了更可操作地度量这一点，本文采用类似 Askell 等人的框架，将“对齐”拆解为三个方面：有帮助、真实、无害。

有帮助。模型应当能够遵循指令，并在 few-shot 或其他可解释模式中推断任务意图。由于单独看提示时，用户真实意图并不总是明确，因此作者主要依赖标注员偏好评分来衡量“有帮助”。但作者也承认：标注员毕竟不是原始用户，他们对提示意图的理解可能与真实用户存在偏差。

真实性。在纯生成模型中，很难直接度量“诚实”，因为那需要比较模型输出与模型“内心真实相信什么”之间的差异，而这对黑箱模型并不可见。因此作者退而求其次，衡量“真实性”，也就是模型关于世界的陈述是否为真。具体使用两个指标：一是在封闭域任务上看模型是否会“幻觉式编造”输入中不存在的信息；二是在 TruthfulQA 数据集上测试其回答的真实与信息性。

无害性。对语言模型的危害进行量化同样非常困难，因为危害常常依赖部署场景。作者因此采用若干具体代理指标来近似，例如：输出是否适合作为客户助手、是否贬低受保护群体、是否包含色情或暴力内容、是否给出有害建议等；同时也在 RealToxicityPrompts、CrowS-Pairs、Winogender 等公开基准上进行评估。

评测总体分为两部分。第一部分是 API 分布上的人工评测，作者只使用训练中未出现过客户的提示，并以 175B SFT 作为主要基线，比较不同模型输出被偏好的频率，同时收集 1-7 的 Likert 评分与多种元数据标签。第二部分是公共 NLP 数据集评测，既包含真实性、毒性和偏见相关基准，也包含问答、阅读理解、翻译、摘要等传统能力基准。

4 实验结果

4.1 API 提示分布上的结果

作者首先发现，标注员在所有模型规模上都显著偏好 InstructGPT 的输出。GPT-3 原始输出表现最差；使用精心设计的 few-shot 前缀后，可以带来明显改善；再经过人类示范监督微调，表现继续提升；最后再结合偏好比较数据与 PPO 优化，则达到最好效果。以 175B 模型为例，InstructGPT 的输出有 $85 \pm 3\%$ 的概率优于原始 GPT-3，有 $71 \pm 4\%$ 的概率优于 few-shot GPT-3。甚至 1.3B 的 InstructGPT，也比 175B GPT-3 更受偏好。

进一步看元数据结果，InstructGPT 相比 GPT-3 更适合作为客户助手的输出风格，更能遵循显式约束，更少完全偏离用户任务，也更少在封闭域任务中凭空编造信息。这说明 InstructGPT 不仅整体偏好更高，而且在可控性、可靠性方面也更好。

作者还发现，这一结论对“保留标注员”同样成立，即使这些新标注员没有参与任何训练数据生产，他们依然明显偏好 InstructGPT，说明模型并不是单纯过拟合于训练标注员的主观偏好。与此一致的是，奖励模型对不同标注员群体的偏好预测，也展现了较强的泛化能力。

此外，作者把 InstructGPT 与在 FLAN、T0 上微调得到的模型进行了比较。结果表明，FLAN 和 T0 的确优于默认 GPT-3，大致与经过精心 few-shot 提示的 GPT-3 相当，但仍明显落后于作者的 SFT 和 InstructGPT。作者认为原因主要有两个：第一，公共 NLP 数据集更偏向于分类、问答、翻译等容易自动评测的任务，而真实 API 使用分布中，大量是开放式生成和头脑风暴任务；第二，公共数据集难以覆盖真实用户关心的多样化输入场景。因此，只用公共 NLP 数据集进行“指令微调”并不足以得到真正贴近真实使用分布的助手模型。

4.2 公共 NLP 数据集上的结果

在 TruthfulQA 上，PPO 模型相较 GPT-3 在真实且信息充分的回答比例上有显著提升。这种提升不是依赖额外“请说真话”的提示，而是作为默认行为出现的。即便只在那些并非专门针对 GPT-3 设计的题目子集上评测，PPO 模型依然更真实。与此同时，在 API 分布中的封闭域任务上，InstructGPT 的“幻觉率”也大约减半，这与真实性提升的结论一致。

在毒性方面，作者用 RealToxicityPrompts 数据集进行了自动评测和人工评测。结果显示：当明确要求模型“以礼貌、尊重的方式继续文本”时，InstructGPT 的输出比 GPT-3 更少有毒；但如果不加这类安全提示，两者差距不大。更有意思的是，当明确要求模型“以最大偏见和攻击性语言继续文本”时，InstructGPT 反而能更可靠地产生高毒性输出。也就是说，本文的方法主要提升了对指令的遵循能力，而不是自动拒绝危险请求的能力。

在偏见评测上，作者使用了 Winogender 和 CrowS-Pairs 的变体。以熵作为无偏性的代理指标，结果显示 InstructGPT 并未显著优于 GPT-3；某些情况下，在“请尊重地回答”的提示下，模型甚至会表现出更低熵，也就是更强的确定性，但这并不意味着更少偏见。

最后，作者关注了 RLHF 带来的“alignment tax”：如果仅使用 PPO 在 API 分布上优化，模型在多个公共 NLP 数据集上的零样本和少样本性能都会回退，例如 DROP、SQuADv2、

翻译等任务。作者发现，通过在 PPO 训练时混入预训练分布上的梯度更新，可以大幅缓解这类退化，而且这种方法比单纯增大 KL 惩罚更有效。也就是说，保留预训练分布知识对于减轻能力损失非常关键。

4.3 定性结果

作者展示了一些 RLHF 训练分布之外的定性案例。结果表明，InstructGPT 能在一定程度上遵循非英语指令，也能更可靠地对代码进行总结和回答有关代码的问题。虽然这些任务在微调数据中占比极低，但模型依然学到了一种更一般化的“遵循指令”能力。相较之下，GPT-3 也并非完全不能完成这些任务，但通常需要更精细的提示设计，而且在这些场景中较少自然表现出指令遵循行为。

不过，InstructGPT 仍会犯一些简单错误。第一，当提示中包含错误前提时，模型有时会顺着错误前提继续回答，而不是先指出前提不成立。第二，模型可能过度“谦虚”或过度含糊，在本来有清晰答案的问题上，给出一大段带保留的模糊回应。第三，当指令包含多个显式约束时，或者约束形式对语言模型较难时，模型表现会下降，例如要求列出满足多个筛选条件的电影，或要求精确用若干句完成摘要等。作者认为，这些问题有一部分与训练中偏好奖励“认识论谦逊”有关，也有一部分源自训练数据中缺少针对错误前提的对抗样本。

5 讨论

5.1 对对齐研究的启示

作者将本文视为更广义“让 AI 系统与人类意图对齐”研究计划的一部分。尽管本文研究对象仍是当前的大语言模型，而非未来更强的超人系统，但作者认为，在真实系统上进行迭代式对齐研究有明显优势：它提供了清晰的经验反馈回路，让研究者知道什么方法有效、什么方法无效，并迫使研究与机器学习能力进展同步推进。

作者从本文中总结出几点启示。第一，相对于预训练大模型本身的成本，对齐成本其实相当有限。175B SFT 模型和 175B PPO-ptx 模型的训练算力，只占 GPT-3 预训练成本的很小一部分；但这些额外成本带来的帮助性提升，却超过了简单扩大模型规模所带来的收益。第二，InstructGPT 在代码与非英语任务上的表现表明，对齐方法可能学到某种一般化的“遵循指令”能力，这一点十分重要，因为人类不可能对模型的每一项任务都进行逐一监督。第三，通过预训练混合，作者在一定程度上缓解了 alignment tax，这对未来方法能否被真正采用非常重要。第四，本文把过去较抽象的对齐研究，推进到了真实生产环境中使用的模型上，从而让对齐研究获得了现实世界中的验证与反馈。

5.2 我们究竟在与谁对齐

作者强调，语言模型最终表现出来的行为，是由底层预训练模型、微调数据以及对齐方法共同决定的。其中，微调数据又受到多重因素影响。文献中经常使用“人类偏好”“人类价值观”这类表述，但本文事实上对齐到的是一组具体标注员的偏好，而这些偏好又受到标注说明、工作场景和任务发布者等多重因素影响。

首先，模型直接对齐到训练标注员写下的示范和排序偏好；这些标注员主要是英语使用者，居住在美国或东南亚地区，他们之间的一致率约为 73%，并不能代表所有受语言模型影响的人群。其次，模型也在某种意义上对齐到了研究人员的偏好，因为研究人员撰写了标注说明，界定了边界案例，并通过沟通渠道不断塑造标注员的判断方式。第三，训练数据还隐含地对齐到了 OpenAI API 用户所认为有价值的提示类型，而这些 API 用户本身也并不等同于最终使用者，更不代表被语言模型影响的全部群体。

因此，作者明确表示：本文的目标并不是宣称研究人员、被招募的标注员或当前 API 用户，就是“正确的价值来源”；本文只是证明，这种技术路线确实能够让模型对齐到一个明确的人类参考群体。更广泛地说，如何设计一个更加公平、透明、可问责，并能体现不同受影响群体意见的对齐流程，仍然是一个开放问题。

5.3 局限性

在方法层面，InstructGPT 的行为在很大程度上取决于承包标注员提供的人类反馈。许多标注任务涉及价值判断，这难免会受到标注员身份、信念、文化背景与个人经历的影响。作者刻意把标注团队保持在较小规模，以便进行高带宽沟通和持续培训，但这也进一步削弱了其代表性。最直观的例子是：标注员主要讲英语，而数据几乎也全部是英语。

在模型层面，作者坦言 InstructGPT 既没有完全对齐，也远未完全安全。它仍然会生成有毒或带偏见的内容，仍会编造事实，也可能在没有显式要求时生成色情或暴力文本。更重要的是，在大多数情况下，模型仍会优先遵循用户指令，即便这样做可能会在现实世界中造成伤害。比如当用户明确要求模型输出最大偏见内容时，InstructGPT 甚至会比同规模 GPT-3 生成更有毒的文本。换言之，本文主要实现的是“更强的指令遵循”，而不是“更强的有害请求拒绝能力”。

5.4 开放问题

作者认为，本文只是让语言模型在广泛指令上实现对齐的第一步。未来仍有许多问题值得研究。首先，可以尝试更多方法进一步降低模型输出有毒、偏见或其他有害内容的倾向，例如让标注员主动寻找模型的最坏行为，构建对抗式数据收集流程；或者把本文方法与预训练数据过滤、WebGPT 一类的真实性增强方法结合起来。

其次，在本文中，如果用户主动要求一个可能有害或不诚实的回答，模型通常仍会照做。如何在保留帮助性的同时，让模型在适当情况下拒绝用户请求，是非常重要但也非常困难的课题，因为“是否有害”本身强烈依赖具体应用场景。作者计划在后续研究中探索拒绝式训练。

再次，除了 RLHF，还可以尝试许多其他利用示范和比较数据训练策略的方法，例如 expert iteration、行为克隆的变体、约束优化等。比较信号也不一定是最高效的人类反馈形式；人类也可以直接编辑模型输出、写出自然语言批评，或通过更丰富的界面提供反馈。最后，关于 alignment tax，本文提出的预训练混合法虽然有效，但尚不能完全消除性能回退，而且也可能把预训练数据中的不良行为重新带回模型，因此仍需进一步研究。

5.5 更广泛影响

本文工作的动机，是希望通过让语言模型更好地执行一组人类真正想让它做的事情，来扩大大型语言模型的正面影响。作者的结果表明，人类反馈微调有望使语言模型更加有帮助、更真实、更无害。从长远看，如果模型规模继续扩大，那么确保其与人类意图保持对齐将变得更加重要。

但另一方面，让语言模型更擅长遵循用户意图，也可能让它更容易被滥用，例如更容易生成有说服力的虚假信息、仇恨内容或辱骂内容。因此，对齐技术并不是解决语言模型安全问题的万能答案，而应只是更大安全生态中的一个组成部分。对于医疗诊断、基于受保护特征对人进行分类、信用/就业/住房资格判定、政治广告生成、执法等高风险领域，语言模型的部署仍需要极高谨慎，甚至不应使用。

作者最后指出，“模型究竟在与谁对齐”这一问题将极大影响这项技术的净社会影响究竟是正是负，这一点必须被严肃对待。

6 附录内容整理翻译

6.1 附录 A：提示数据的更多细节

附录 A 主要介绍提示词的来源与组成。对于标注员撰写的提示，作者补充说明了如何从 Plain、Few-shot 和 User-based 三类提示中构造训练样本。对于 API 用户提示，作者强调只使用 Playground 中经用户知情同意后可用于训练的数据，而不使用生产环境 API 的数据。为保证多样性，作者还按组织或用户进行去重与上限控制，并按组织 ID 划分训练、验证和测试集。

附录中还给出了大量来自 InstructGPT 分布与 GPT-3 分布的“示意性提示”，覆盖 brainstorming、classification、extract、generation、rewrite、chat、closed QA、open QA、summarization 等类别。整体上，InstructGPT 分布的提示更像“自然语言指令”，而 GPT-3 分布的提示则更像传统 prompt engineering 风格。

在数据规模上，SFT、RM 与 PPO 三类数据集分别报告了来自标注员和客户的样本数。作者指出，SFT 中标注员写的提示远多于客户提示，这是因为冷启动阶段大量 few-shot 指令由标注员提供。数据语言方面，使用轻量语言分类器统计后，约 96% 为英语，但作者估计真实比例可能更高。

6.2 附录 B：人工数据收集细节

附录 B 详细说明了标注员筛选流程、标注说明、人口统计与满意度调查。筛选主要依据对敏感言论标记的一致性、对模型输出排序的一致性、敏感示范撰写能力以及自评擅长识别哪些群体相关的敏感表达。标注说明在项目过程中多次迭代：训练阶段更偏向“帮助性优先”，最终评测阶段则更强调“真实性与无害性优先”。

人口统计数据显示，标注员整体较年轻，性别大体平衡，主要来自美国或东南亚。满意度调查显示，大多数标注员认为任务说明清晰、报酬公平、沟通顺畅，而且总体愿意参与该任务，尽管有一部分人认为任务具有一定重复性。附录还展示了用于打分、标注元数据

和排序的网页标注界面截图。

6.3 附录 C：模型训练细节

附录 C 给出了模型的更多训练超参数。所有模型都采用 GPT-3 架构，使用相同的 BPE 编码，context length 为 2k token，提示超过 1k token 的样本会被过滤，最大输出长度限制为 1k token。优化器均为 Adam。

SFT 模型训练 16 个 epoch，使用余弦学习率调度。RM 模型使用单个 6B 模型，训练 1 个 epoch，初始化自一个在多种公共 NLP 数据集上微调过的 6B GPT-3。RLHF 部分中，PPO 初始化模型先在示范数据上训练 2 个 epoch，并混入 10% 的预训练数据；PPO 训练共进行 256k 个 episode，batch size 为 512，minibatch size 为 64，PPO clip ratio 为 0.2，rollout 采样温度为 1。预训练混合时，作者每个 minibatch 额外引入来自预训练分布的梯度，并用系数 $\gamma = 27.8$ 控制其强度。

对于 FLAN 和 T0 基线，作者也给出了训练规模与学习率搜索方式。最终 checkpoint 的选择标准不是验证损失，而是奖励模型在验证集上的得分。

6.4 附录 D：自动评测细节

附录 D 详细列出了自动评测使用的公开数据集及其提示格式，包括 Winogender、CrowS-Pairs、RealToxicityPrompts、TruthfulQA、DROP、QuAC、SQuADv2、HellaSwag、RTE、SST、WSC、WMT 15 法译英、CNN/DM 摘要以及 Reddit TL;DR 摘要等。

作者还说明了三种提示模式：无额外提示 (basic/no prompt)、“请以礼貌且无偏见方式继续”的 respectful prompt，以及“请使用最大偏见和攻击性语言继续”的 biased prompt。对于偏见任务，作者用多项选择分布的熵来度量模型偏向程度；对于毒性任务，则使用 Perspective API 分数和人工打分结合评测。

6.5 附录 E：额外结果

附录 E 展示了更多图表，包括不同模型在多个公共 NLP 数据集上的零样本与少样本表现、奖励模型对保留标注员偏好的泛化情况、元数据评分随模型规模变化的曲线、Likert 评分曲线、Winogender 与 CrowS-Pairs 上的偏见结果，以及预训练混合系数、KL 惩罚系数对公共数据集性能和验证奖励的影响。

这些图进一步支持正文中的结论：纯 PPO 容易带来公共基准上的性能回退；混入预训练梯度是缓解这一回退的关键；而单纯增大 KL 惩罚并不能真正解决问题。附录还表明，PPO 初始化模型中混入适量预训练数据、选择合适的 batch size 和 learning rate，都对最终人工评分有影响。

6.6 附录 F：模型样例

附录 F 给出了更多 GPT-3 与 InstructGPT 的对照样例，包括法语和瑞典语指令、危险请求、代码解释、新闻问题回答、购物清单生成、儿童解释等。整体趋势与正文一致：InstructGPT 在遵循指令方面更强，尤其在代码问答、非英语任务和结构化任务上明显优

于 GPT-3；但它同样会顺着有害指令执行，也会在某些知识性或常识性问题上给出过度含糊或不够准确的答案。

参考文献说明

原论文参考文献共计数十条，本文档未逐条翻译其英文 bibliographic 信息，建议直接结合原论文参考文献页查阅。

原文文件

用户上传原始论文：InstructGPT.pdf