

《Learning to summarize from human feedback》中文翻译版

从人类反馈中学习摘要

原文作者：Nisan Stiennon, Long Ouyang, Jeff Wu, Daniel M. Ziegler, Ryan Lowe, CL

中文整理：OpenAI ChatGP7

原文：NeurIPS 2020, arXiv:2009.01325v3 (2022-02-15)

说明：本文件依据用户提供的论文 PDF 制作中文翻译稿。当前版本包含**正文完整翻译**，以及**附录中的主要说明、关键表格与核心结果摘译**；参考文献列表保留原始文献信息的结构，不逐条翻译题名。由于原附录后半部分包含大量大规模数值矩阵与示例样本页面，为保证可读性，本文对其进行了结构化摘译与必要保留。

摘要

随着语言模型能力不断增强，针对具体任务所使用的数据与评价指标，越来越成为训练与评估过程中的瓶颈。以摘要任务为例，现有摘要模型通常通过预测人工参考摘要来训练，并用 ROUGE 进行评估；但这两者都只是我们真正关心对象——**摘要质量**——的粗略代理指标。本文表明，通过训练模型去直接优化**人类偏好**，可以显著提升摘要质量。作者收集了一个大规模、高质量的人类摘要两两比较数据集，训练出一个能够预测“人类更喜欢哪一个摘要”的奖励模型，并将该模型作为奖励函数，用强化学习微调摘要策略。作者将该方法应用到 Reddit 帖子构成的 TL;DR 数据集一个版本上，发现所得模型显著优于人工参考摘要，也优于仅用监督学习微调、且规模更大的模型。这些模型还能迁移到 CNN/DM 新闻摘要任务中，即使没有任何新闻领域特定微调，也能生成接近人工参考质量的摘要。作者还对人类反馈数据集和微调后模型进行了大量分析，证明奖励模型可以泛化到新数据集，并且从人类视角看，优化该奖励模型得到的摘要优于直接优化 ROUGE。作者希望本文的证据能够促使机器学习研究者更加关注：训练损失究竟如何影响模型最终表现出的人类所期望行为。

1 引言

大规模语言模型预训练已经成为在多种自然语言处理任务上取得高性能的主流方法。将这些模型应用到特定任务时，通常还会进一步进行监督微调，一般做法是最大化一组人

工示范文本的对数概率。

尽管这种策略显著提高了性能，但其优化目标——最大化人类撰写文本的似然——与我们真正关心的目标——生成由人类判断为高质量的输出——之间依然存在错位。这种错位来自多个方面：最大似然目标不会区分重要错误（例如编造事实）与不重要错误（例如在同义词中选用哪个具体词语）；模型会被鼓励在所有人工示范上分配概率质量，包括低质量示范；而且采样时的分布偏移也会降低性能。借助 beam search 之类的非均匀采样策略，质量常常可以得到明显改善，但这又会带来重复等不希望出现的伪影。因此，直接围绕“质量”进行优化，也许是一种更原则化的解决路径。

本文的目标，是推动一种更能刻画我们真正想要行为的语言模型训练方法。为了在短期内取得进展，作者聚焦于英语生成式摘要任务。一方面，摘要任务在 NLP 社区有长期研究历史；另一方面，它本身又具有主观性，作者认为如果没有人类判断，摘要质量很难被准确量化。事实上，ROUGE 等现有自动摘要评价指标，长期以来就因与人类判断相关性不足而受到批评。

本文沿用了此前从人类反馈出发微调语言模型的研究思路。首先，收集成对摘要之间的人类偏好数据；然后，通过监督学习训练奖励模型（reward model, RM），使其预测给定两份候选摘要中哪一份更受人类青睐；最后，再用强化学习训练摘要策略，使其最大化奖励模型给出的分数。策略在每一个“时间步”输出一个 token，而针对整段摘要的奖励则由 PPO 算法进行更新。之后，还可以用当前策略生成的新样本继续收集人类数据，并重复上述流程。作者使用了大规模预训练 GPT-3 风格模型，参数规模最大可达 67 亿。

本文的主要贡献有四点。

第一，作者证明：基于人类反馈的训练在英语摘要任务上显著优于极强的基线方法。具体而言，在 Reddit TL;DR 数据集上，经由人类反馈训练得到的策略，其摘要质量优于仅通过监督学习训练、但参数规模更大的模型；甚至在人类标注者看来，其摘要也优于原始数据集中的人工参考摘要。

第二，作者证明：人类反馈模型相较于监督模型，更能泛化到新领域。用 Reddit 数据训练的人类反馈模型，在完全不做新闻领域微调的条件下，也能在 CNN/DailyMail 数据集上生成高质量新闻摘要，几乎达到该数据集人工参考摘要的水平。作者还进行了多项检查，以确认这种偏好差异反映的确实是质量差异，而不是模型仅仅在优化长度、拷贝比例等简单表面指标。

第三，作者对策略模型与奖励模型进行了系统的实证分析。他们研究了模型规模和数据规模的影响，考察了持续优化奖励模型时性能如何变化，并通过合成扰动和人工编辑的摘要来分析奖励模型的行为。结果表明，奖励模型在预测人类偏好方面优于 ROUGE 等自动指标，而且从人类角度看，直接优化奖励模型也优于直接优化 ROUGE。

第四，作者公开发布了人类反馈数据集，以支持后续研究。该数据集包含 TL;DR 上 64,832 组摘要比较，以及 TL;DR 和 CNN/DM 上的评测数据（比较结果和 Likert 评分）。

作者指出，本文方法的更长期动机，还来自 AI 系统与人类真实意图错位的问题。对摘要模型来说，编造事实这样的错误往往风险较低、也容易识别；但随着 AI 系统能力增强并承担更重要的任务，其错误会变得更隐蔽、也更具安全风险。因此，该方向值得继续深入研究。

2 相关工作

与本文最直接相关的，是此前利用人类反馈和强化学习训练摘要模型的研究。Böhm 等人基于 2500 条 CNN/DM 摘要的人类评分学习奖励函数，并训练出一个相较于优化 ROUGE 的策略更受人类偏好的模型。本文与 Ziegler 等人的工作最为相似：他们同样使用 Transformer 模型，在包括 Reddit TL;DR 和 CNN/DM 摘要在内的一系列任务上，利用人类反馈优化模型。与本文不同的是，他们采用在线式训练，并观察到模型带有很强的抽取性；他们还提到，标注者偏好抽取式摘要，且与研究者之间一致率较低。相比之下，本文使用了更大的模型，转向批量式人类反馈采集流程，强调高标注者—研究者一致率，并在算法上做了若干修改，例如将策略网络与价值网络分离。

人类反馈也已被用作其他领域的奖励信号，例如对话、机器翻译、语义解析、故事生成、评论生成和证据抽取。本文所使用的奖励建模方法，源于 learning to rank 研究，后者已被广泛用于搜索排序，并可依赖显式反馈或点击数据等隐式反馈。与之相关的另一条研究线，是在人类反馈指导下训练模拟环境中的智能体。此外，NLP 社区还有大量工作尝试用强化学习去优化自动评价指标，例如在摘要任务上优化 ROUGE，在翻译任务上优化 BLEU，以及其他生成任务上优化类似指标。除此之外，也有大量工作通过修改模型架构或预训练方式来提升摘要性能。

3 方法与实验细节

3.1 高层方法流程

本文的方法与既有工作类似，但调整为了离线批处理设定。起点是一个在目标数据集上用监督学习微调得到的初始策略模型（本文即 Reddit TL;DR 摘要模型）。整个过程可迭代重复，主要包含三个步骤。

步骤 1：从现有策略中采样，并将摘要比较任务交给人类。对于每一条 Reddit 帖子，作者会从多个来源采样摘要，包括当前策略、初始策略、原始参考摘要以及若干基线模型。然后，把若干成对摘要发送给人工评估者，让他们判断哪一个更好。

步骤 2：根据人类比较结果学习奖励模型。给定帖子和候选摘要，训练一个奖励模型来预测该摘要“比另一个摘要更好”的对数优势，判断依据来自标注者选择。

步骤 3：在奖励模型之上优化策略。作者将奖励模型输出的 logit 当作奖励信号，使用强化学习中的 PPO 算法对策略进行优化。

作者说明，实际项目中，这三个步骤并不是机械地严格轮转执行，而是在整个项目过程中，随着标签不断积累，数据采集与训练流程也在持续更新。

3.2 数据集与任务定义

数据集。作者使用 TL;DR 摘要数据集。该数据集包含大约 300 万条 Reddit 帖子，以及原始发帖人撰写的 TL;DR 摘要。作者对该数据集进一步过滤，以提高质量，例如只保留普通大众容易理解的话题子版块，并且只保留人工摘要长度在 24 到 48 个 token 之间的样

本，以尽量减弱摘要长度对质量判断的影响。最终过滤后的数据集包含 123,169 条帖子，其中约 5% 被划为验证集。后文中若无特别说明，“TL;DR 数据集”均指这一过滤后的版本。

作者选择 TL;DR 而不是更常见的 CNN/DM 数据集，主要原因是：在 CNN/DM 上，简单的抽取式基线就可以取得很强表现。作者在后文发现，标注者甚至更喜欢 lead-3（取新闻前 3 句）而不是 CNN/DM 的参考摘要；同时，在 CNN/DM 上，用低温采样的监督 T5 模型已经能超过参考摘要质量，但它往往会大量拷贝原文。相比之下，在 TL;DR 上，这类简单抽取基线在人类评估中表现较差。因此，作者并未在 CNN/DM 上训练人类反馈模型，而是考察：一个在 Reddit 上训练的模型，迁移到新闻摘要时会表现如何。

任务定义。作者将“真实目标任务”定义为：训练一个模型，使其生成长度少于 48 个 token、并且尽可能高质量的摘要；这里的“高质量”由研究者的判断来定义。判断标准是：对一个只能读摘要、不能读原文的读者而言，这个摘要在多大程度上忠实传达了原帖内容。由于研究者自身无法承担大规模比较任务，所以雇佣了标注者来进行判断，并通过详细的质量控制流程确保标注者与研究者在任务理解上保持高一致性。

3.3 收集人类反馈

此前工作曾报告，模型最终学到的“质量概念”与研究者的真正想让模型学到的质量概念之间存在偏差：模型生成的摘要在标注者看来质量较高，但在研究者看来质量并不高。

为提升人类数据质量，本文相较于前人做了两项重要改动。第一，完全转向离线设定：作者不是边采样边在线更新，而是交替进行“大批量比较数据发送给标注者”和“在累计数据上重新训练模型”这两个阶段。第二，作者与标注者建立了更紧密的协作关系：用详细说明文档对标注者进行培训，在共享聊天室中回答问题，并持续反馈其表现。所有标注者都接受训练，以确保他们与研究者的判断高度一致；作者还在整个项目期间持续监控标注者与研究者的一致率。

这套流程产生了较高的一致率：在一部分比较任务上，标注者与研究者的一致率达到 $77\% \pm 2\%$ ，而研究者之间的一致率为 $73\% \pm 4\%$ 。作者在附录中还对人类数据质量做了更详细的分析。

3.4 模型

本文使用的所有模型，都是 GPT-3 风格的 Transformer 解码器。人类反馈实验主要在 13 亿参数和 67 亿参数两个规模上开展。

预训练模型。和既有工作类似，这些模型首先在大规模文本语料上进行自回归预训练，以预测下一个 token。作者还将它们作为零样本基线：在上下文中填入若干高质量摘要示例后，让模型直接生成。

监督基线。接着，作者将预训练模型在过滤后的 TL;DR 数据集上进行监督微调，以预测参考摘要。这些监督模型一方面用于生成初始比较样本，另一方面也用于初始化后续的策略模型和奖励模型，并作为最终评估中的基线。最终人类评估阶段，所有模型都使用 $T = 0$ 进行采样，因为作者发现这种设定优于更高温度或 nucleus sampling。

为验证监督基线确实足够强，作者还在 CNN/DM 上用 67 亿参数模型运行同样的监督

微调流程，结果显示其 ROUGE 已略优于 2019 年中期的一些 SOTA 模型。

奖励模型。训练奖励模型时，作者从监督基线出发，在其顶部加入一个随机初始化的线性头，输出一个标量值。给定帖子 x 和摘要 $y \in \{y_0, y_1\}$ ，奖励模型被训练为预测哪个摘要更好。如果人类偏好的是 y_i ，则奖励模型损失写为：

$$\text{loss}(r_\theta) = -\mathbb{E}_{(x, y_0, y_1, i) \sim D} [\log \sigma(r_\theta(x, y_i) - r_\theta(x, y_{1-i}))].$$

其中 $r_\theta(x, y)$ 是奖励模型对帖子 x 与摘要 y 的标量输出， D 是人类判断数据集。训练结束后，作者再对奖励模型输出做归一化，使数据集中人工参考摘要的平均分为 0。

人类反馈策略。为利用上述奖励模型训练能生成更高质量摘要的策略，作者主要采用强化学习：把奖励模型输出看作整段摘要的奖励，并用 PPO 算法进行优化，其中每个时间步对应一个 BPE token。策略初始化为在 Reddit TL;DR 上监督微调过的模型。重要的是，奖励中还加入了一个 KL 散度惩罚项，用于约束强化学习策略 π_ϕ^{RL} 与原始监督模型 π^{SFT} 之间的偏移：

$$R(x, y) = r_\theta(x, y) - \beta \log \frac{\pi_\phi^{RL}(y | x)}{\pi^{SFT}(y | x)}.$$

这个 KL 项有两个作用。其一，它相当于一种熵奖励，鼓励策略探索，避免塌缩到单一模式。其二，它防止策略产生与奖励模型训练时所见分布差异过大的输出。

对于 PPO 的价值函数，作者使用了与策略完全参数分离的另一套 Transformer，而不是与策略共享参数。这样做可以避免价值函数更新在训练初期破坏已预训练好的策略表示。价值函数初始化为奖励模型参数。在实验中，奖励模型、策略模型和价值函数规模相同。

4 结果

4.1 基于人类反馈的 Reddit 摘要

人类反馈训练的策略优于更大规模的监督策略。主要结果如原文图 1 所示。作者以“人类更偏好该模型摘要而非数据集参考摘要的比例”来衡量策略质量。结果表明，人类反馈策略显著优于监督基线：13 亿参数的人类反馈模型，甚至可以超过一个参数规模大约大 10 倍的监督模型。以对参考摘要的原始偏好率为例，前者达到 61%，而后者仅为 43%。67 亿参数的人类反馈模型又显著优于 13 亿参数版本，说明人类反馈训练本身同样受益于模型扩展。此外，这两个模型都被人类判断为优于数据集中原本的人类示范摘要。

控制摘要长度后仍有优势。在判断摘要质量时，长度本身是一个混杂因素。因为摘要任务隐含着“简洁性与覆盖度如何权衡”的问题，所以更长或更短的摘要未必谁天然更好。由于作者的模型倾向于生成更长摘要，长度可能解释一部分质量提升。作者发现，在对长度做控制之后，人类反馈模型相对于参考摘要的偏好率约下降 5 个百分点；但即便如此，67 亿参数模型的摘要仍有大约 65% 的时间被偏好于参考摘要。

模型到底提升了什么？为更细致地理解模型相对于监督基线和参考摘要的改进，作者让标注者从四个维度用 7 分 Likert 量表对摘要打分：覆盖度、准确性、连贯性和总体质量。结果显示，人类反馈模型在所有维度上都优于监督基线，尤其是在覆盖度上优势最明显。虽

然标注者对“完美总体分”打分相当谨慎，但 67 亿参数 PPO 模型仍有 45% 的样本拿到 7/7 的总体分，而 67 亿监督基线与参考摘要分别只有 20% 与 23%。

4.2 迁移到新闻摘要

作者发现，人类反馈模型在**没有任何额外训练**的情况下，也能对 CNN/DM 新闻文章生成出色摘要。其表现显著优于在 TL;DR 上训练的监督模型，以及仅使用预训练语料的模型。事实上，67 亿参数的人类反馈模型几乎可以匹敌一个在 CNN/DM 参考摘要上进行过监督微调的 67 亿模型，尽管前者生成的摘要更短。

由于从 TL;DR 迁移过来的人类反馈模型，与 CNN/DM 上训练的模型在摘要长度分布上重叠很少，直接比较并不完全公平，因此作者同样采用四个质量维度上的 7 分 Likert 评估。原文图 4b 给出了不同摘要长度下的平均总体分，结果暗示：如果人类反馈模型生成更长的摘要，它还可能表现得更好。从定性上看，这些迁移摘要通常流畅、合理，也能把握新闻内容主旨。

4.3 理解奖励模型

当我们不断优化奖励模型时，会发生什么？从理论上说，针对奖励模型进行优化，应该让策略更符合人类偏好。但奖励模型并不是标注者偏好的完美表示：它容量有限，只看到了相对少量、而且分布较窄的摘要比较数据。我们可以希望它对未见摘要具有一定泛化能力，但并不清楚：到底能针对奖励模型优化到什么程度，而不至于让它失去意义。

为回答这个问题，作者拿一个较早版本的奖励模型，训练出一系列优化强度不同的策略，然后让标注者把这些策略样本与参考摘要进行比较。结果表明：在优化强度较轻时，模型摘要会改善；但随着优化继续增强，真实人类偏好相较于奖励模型预测开始下滑，最终奖励模型甚至会与人类偏好呈反相关。虽然这显然是不理想的，但作者指出：类似的“过度优化”现象在 ROUGE 上同样存在，在机器人领域的学习型奖励函数中也有相似观察。

奖励建模如何随模型规模与数据规模扩展？作者做了一个消融实验，用 8k 到 64k 组人类比较数据，训练了从 1.6 亿到 130 亿参数的 7 个奖励模型。结果发现：训练数据量翻倍，大致可使奖励模型验证准确率提升约 1.1%；而模型规模翻倍，则大致可提升约 1.8%。也就是说，在这一任务上，扩大模型规模带来的收益甚至略高于扩大数据规模。67 亿奖励模型在使用全部数据时，已经开始接近“单个标注者”的准确水平。

奖励模型到底学到了什么？作者在多个验证集上探查奖励模型的行为。结果显示，奖励模型可以泛化到 CNN/DM 摘要评估：13 亿和 67 亿版本分别有 62.4% 和 66.5% 的时间与标注者偏好一致，其中 67 亿版本几乎达到标注者之间的相互一致率 66.9%。

奖励模型也对一些语义上重要、但形式上很小的变化敏感。作者构造了一个额外验证集，让标注者对已有摘要做最小化编辑，使其变得更好。此时，奖励模型偏好编辑后摘要的概率，对 13 亿模型是 79.4%，对 67 亿模型是 82.8%，与另一组人类评估者的 84.1% 已十分接近。此外，当把参考摘要与“对参与者角色进行对调”的扰动摘要比较时，模型也能高概率选对原始摘要：13 亿模型为 92.9%，67 亿模型为 97.2%。不过，奖励模型对更长摘要存在偏置：以 67 亿奖励模型为例，当“改进性编辑”让摘要更短时，它只在 62.6% 的情

况下偏好编辑后版本，而人类为 76.4%。

4.4 分析摘要任务中的自动评价指标

作者考察了多种自动指标在多大程度上能够预测人类偏好，并将其与奖励模型进行比较。具体来说，作者比较了 ROUGE、摘要长度、从原文中拷贝的比例，以及在监督基线模型下的对数概率等指标。

结果显示，学习得到的奖励模型始终优于其他指标，即便是在它从未训练过的 CNN/DM 数据集上也是如此。同时，作者还发现：随着模型质量提高，ROUGE 越来越无法跟踪真实人类偏好。对监督基线样本来说，ROUGE 与标注者一致率大约是 57%；但在比较人类反馈模型的样本时，它会下降到约 50%。同样地，监督模型下的 log probability 在人类反馈模型样本上的一致率也降到 50% 甚至更低，而奖励模型仍然能保持在随机水平之上（约 62%）。单纯扩大监督模型规模，并不能稳定提升 log probability 与人类判断的一致性。

作者还通过一种简单的“best-of- N 拒绝采样”优化方案，比较了优化不同指标时的效果。结果表明，优化 ROUGE 不会稳定带来质量提升，而且峰值出现更早、峰值也显著低于优化奖励模型时的水平。

5 讨论

局限性

本文方法的一个重要局限，在于时间与成本都很高。尤其是，对 67 亿参数模型进行强化学习微调，大约需要 320 个 GPU-day。数据收集流程也显著昂贵于此前工作：训练集的构建耗费了数千小时的标注者时间，也需要研究者投入大量精力进行质量控制。因此，作者无法再额外收集一个同等规模、同等质量的人类示范数据集，用来构造“公平的监督学习对比基线”。作者将这一消融留待未来工作。不过，他们也认为，奖励建模更有可能扩展到那些“很难提供高质量示范、但人类可以比较输出优劣”的任务上。

未来方向

本文方法原则上可以应用到任何一个“人类能比较样本优劣”的任务中，例如对话、机器翻译、问答、语音合成和音乐生成。作者尤其预计，该方法在长文本生成任务中会很重要，因为最大似然生成在这类任务中常常遭遇分布偏移与退化问题。未来也许可以通过多任务联合预测反馈的方式提升样本效率。

作者还特别关心一个更困难的场景：当人类本身不容易直接评估模型输出质量时，如何扩展人类反馈方法。在这种设定下，判断一个机器学习系统是否与设计者意图一致，会变得尤为困难。一种思路是训练机器学习系统本身来协助人类更快、更准确地完成评估任务。

此外，人类反馈方法并不局限于二元比较。还可以探索让标注者提供高质量示范、直接编辑模型输出来改进它，或解释为何偏好某一输出而非另一输出。这些反馈都可能被用来训练更强大的奖励模型和策略模型。

更广泛影响

作者强调，本文探索的是一种通用技术：只要人类能够评估模型输出质量，它就可被用于广泛的机器学习应用。因此，其潜在影响范围很广。

从积极方面看，本文研究的主要动机，是希望让机器学习算法更加符合设计者偏好。许多现实系统只在优化粗糙代理目标，例如 YouTube 推荐可能促进标题党内容。更直接地学习并优化人类偏好，短期内有望让此类系统更符合人类福祉。

从长期看，随着机器学习系统能力提升，确保它们安全地运行会越来越困难：它们的错误可能更不易察觉，后果也更严重。例如，写错新闻摘要很容易被发现，影响也相对较小；而在自动驾驶等更高风险任务中，仅仅模仿人类行为，可能远不如“朝着人类偏好进行优化”来得安全。作者认为，本文所探索的技术，是缓解高能力系统风险、让其更符合人类真正关切的一个有希望的方向。

但与此同时，这类技术也可能被恶意使用。例如，人们可以利用人类反馈微调语言模型，使其更具说服力，从而操纵人类信念；或增强人类对技术的依赖；或批量生成有毒、伤害性内容来攻击特定个体。如何避免这些结果，是一个十分艰难、目前也缺少显然解法的问题。

此外，大规模人类反馈训练的模型可能影响许多群体，因此在定义“什么是好的模型行为”时必须格外谨慎。对“好摘要”的定义相对直观，但对更复杂任务则未必如此，因为不同人群可能对理想行为存在分歧。在这类情境中，以研究者自身标签作为“金标准”往往并不合适；相反，受到该技术影响的群体成员应当被纳入“良好行为”定义过程，并参与标注。

作者选择 Reddit TL;DR 数据集，是因为该摘要任务比 CNN/DM 更具挑战性。但由于数据来自用户自发发布、审核较少的帖子，其中常常包含冒犯性内容或反映有害社会偏见。因此，这些模型也可能生成带有偏见或冒犯性的摘要。在将模型部署到面向用户的场景之前，应充分研究其潜在危害。

最后，提升机器学习系统完成原本由人类承担任务的能力，也会提高许多工作岗位被自动化替代的可能性，进而带来失业和社会冲击。如果没有合适的政策加以缓解，这同样可能造成显著社会危害。

致谢

作者感谢多位同事与合作人员在标注者招募、项目早期讨论、预训练模型训练与评估、计算基础设施、GPU 内核实现、实验设计、图示设计、论文反馈以及模型卡撰写等方面提供支持；同时也感谢大量外包标注人员为本文模型训练提供了至关重要的人类反馈数据。

6 附录主要内容摘译

本节对原论文附录 A–H 的核心内容做结构化翻译与整理，尽量保持与原文顺序一致。

6.1 附录 A: TL;DR 数据集细节

作者首先对 Reddit TL;DR 数据集进行了多轮预处理。主要步骤包括：

1. 删除重复帖子。通过检查正文文本，发现约有 2 万条完全重复的帖子。
2. 重新解析 TL;DR 字段，并只保留顶层帖子，不保留评论。
3. 仅保留位于白名单 subreddit 中的帖子。
4. 去除标题以“Edit”、“Update”等变体开头的帖子，以及通过启发式规则检测出的某些不适宜主题（例如露骨性内容、自杀等）。
5. 为适配模型上下文长度，去除正文超过 512 token 的帖子。

经过正文层面的过滤后，得到 287,790 条帖子，其中约 5% 作为验证集。由于 RL 训练不依赖参考摘要，这部分数据就足以用于 RL。

随后，作者还对用于监督学习的参考摘要做进一步过滤：去除 TL;DR 摘要中以“Edit”、“Update”、“P.S.”等开头的样本，通过启发式规则去除一定程度的粗俗表达，并且仅保留长度在 24 到 48 token 之间的摘要。这样做一方面是为了与 RL 模型生成的摘要长度分布有足够重叠，从而进行长度控制分析；另一方面，作者也发现短于 16 token 的摘要通常质量较差。最终用于监督训练的 TL;DR 数据集规模为 123,169 条样本，其中同样约 5% 作为验证集。

作者还指出，从 subreddit 分布来看，大约三分之二的数据来自“关系 / 情感建议”相关主题，因此数据领域相对集中。不过，该模型在 CNN/DM 上的强迁移性能表明，其能力并没有被不合理地局限在情感建议这一狭窄领域。

6.2 附录 B: 进一步的模型训练细节

所有模型都采用标准 Transformer 结构，具有 2048 个可学习位置嵌入。训练时使用 fp16 激活和 Adam 优化器，大多数监督基线、奖励模型和 RL 模型使用 fp32 权重；只有 TL;DR 监督基线因历史原因使用 fp16 权重。词表采用与 GPT-2/GPT-3 相同的 BPE 编码。

预训练。预训练语料由 CommonCrawl、WebText、Books 和 Wikipedia 构成，总训练量约 2000 至 3000 亿 token。学习率采用带短 warmup 的 cosine schedule，并最终衰减到峰值的 10%。批大小会逐渐增大，每个输入长度为 2048 token。

监督微调。从预训练模型出发，学习率通过对数线性扫描选取，再采用 cosine 衰减。TL;DR 上 1.3B、3B、6.7B、13B 模型分别使用 6.35×10^{-5} 、 5.66×10^{-5} 、 2.83×10^{-5} 、 2.83×10^{-5} ；CNN/DM 上 6.7B 模型使用 2.38×10^{-5} 。批大小为 128，训练 1 个 epoch。

奖励模型。奖励模型初始化自监督基线，并在顶部增加一个线性奖励头。奖励头权重按 $\mathcal{N}(0, 1/(d_{model} + 1))$ 初始化。作者训练 1 个 epoch，也采用 cosine 衰减。为了降低训练顺序和奖励头初始化带来的影响，他们会扫描 3–10 个随机种子，并在验证集开发集上选取表现最好的模型。最终主结果中，1.3B 和 6.7B 奖励模型的学习率分别为 1.5×10^{-5} 与 5×10^{-6} ，批大小为 64。

PPO。 PPO 中策略与价值网络分离。策略初始化为监督基线，价值函数初始化为奖励模型。超参数为 $\gamma = 1$ ，GAE 中 $\lambda = 0.95$ ，每批 rollout 做 4 个 epoch 的优化。学习率线性衰减，1.3B 初始学习率为 1.5×10^{-5} ，6.7B 为 7×10^{-6} 。主实验中 KL 系数均设为 0.05。批大小方面，1.3B 使用 512，6.7B 使用 256，总共训练 100 万个 episode。

输入格式。 模型总是接收固定长度的 BPE 编码字符串。若输入过短，则在开头补 padding token；若过长，则在换行位置截断正文或文章。对于仅预训练、未在 TL;DR 上微调的模型，作者不是用 padding token 补齐，而是在前面填入若干“帖子/文章 + 高质量摘要”的示例，尽可能把上下文塞满。

6.3 附录 C：人类数据采集细节

作者为确保高质量人类数据，使用了四步流程。

第 0 步：研究者自己先理解任务。 研究者首先亲自做大量摘要比较，并与少量早期标注者讨论分歧，在此基础上撰写更大规模标注人员的说明文档。

第 1 步：标注者入职培训。 标注者来自 Upwork、Scale 和 Lionbridge。入职前需完成付费训练流程，在共享数据集上做标签。部分题目会立即收到研究者选择及原因反馈，以帮助其校准标准。只有在速度和一致率上达到阈值的标注者会被保留。

第 2 步：采集比较数据。 标注者在作者自建的网站上完成大批量比较。在直接比较两个摘要之前，他们会先写出“只读摘要、不读原文时的朴素理解”，这有助于暴露摘要中的歧义。之后，标注者用一个 9 点置信度量表给出“摘要 A 比摘要 B 更好”还是相反。

第 3 步：向标注者反馈。 作者会基于共享校准题统计标注者之间的一致率，并向其展示分歧案例，帮助其改进判断。

第 4 步：研究者校准。 研究者自己也会定期参与同一任务，以测量“标注者—研究者一致率”。作者还会为每个标注者估算高置信阈值，使得高于该阈值的标签期望上有 80% 的时间与研究一致。

最终，在 1.3B 监督基线比较子集上，标注者与研究者的一致率达到 $77\% \pm 2\%$ ，研究者之间一致率为 $73\% \pm 4\%$ 。整个训练语料库上的平均一致率约为 $73\% \pm 3\%$ ，标注者彼此之间一致率约为 72%。作者也注意到，若每个比较由 3 名标注者投票取众数，则与研究的一致率可从 72% 提升到 77%；但由于成本原因，大多数比较仍只收集一个标签。

标注者人口统计。 问卷结果显示：标注者在民族、国籍、年龄、性别和教育背景上具有一定多样性，但整体上更可能是白人、美国人。样本中女性约占 61.9%，男性约占 38.1%；本科及以上学历占多数。

标注网站。 由于作者自己招募和培训标注者，而不是使用亚马逊 MTurk 这类众包平台，所以自建了一个统一、可定制的标注网站。每位标注者拥有独立账户，网站支持不同类型任务，例如朴素理解、摘要比较以及多维度 Likert 打分，并允许标注者写下疑虑或解释。

给标注者的核心说明。 作者告诉标注者，一个好的摘要应当是原文精华的更短表达，应尽量在本质信息、清晰度、准确性、目的对齐、简洁性和风格等方面与原文保持一致，其中靠前的维度权重更高。对于 7 分 Likert 评价，作者分别给出连贯性、准确性、覆盖度和总体质量四个维度的打分 rubric。

标注数据构成。 在项目过程中，作者训练了多代监督基线、奖励模型和 PPO 策略。每

一批送去标注的摘要，都来自多种不同策略，选择方式带有较强探索性质，而不是完全系统化的设计。每次训练新的奖励模型时，作者都会使用截至当时为止收集到的全部标签。随着训练推进，后续模型还受益于更好的超参数与更干净的数据。

6.4 附录 D：基线选择

作者指出，若要与监督学习方法完全公平比较，本应再投入与“人类反馈数据收集”同等规模的人力，专门收集高质量人工示范，再在此基础上训练监督模型。但这在现实中成本过高，因此论文并未提供这样的基线。作者转而使用自身的监督模型和零样本模型作为主要对照，并补充使用 T5。作者也专门检查了监督模型在 ROUGE 上的表现，以确认其确实是强基线。

6.5 附录 E：CNN/DM 中 lead-3 与参考摘要的比较

作者发现在 CNN/DM 数据集上，标注者显著偏好 lead-3（文章前 3 句）而不是参考摘要。部分原因在于 lead-3 更长，覆盖度更高；但即使用线性回归控制长度后，lead-3 的估计质量仍略高于参考摘要。作者进一步人工检查发现：许多参考摘要会遗漏关键点，或引入原文中没有的新信息。这是因为 CNN/DM 的“参考摘要”实际上是新闻站点上的 highlights，而不一定是严格意义上忠实对应正文的摘要。作者因此认为，把 CNN/DM highlights 直接视为理想参考摘要，本身是有问题的。

6.6 附录 F：控制摘要长度

由于摘要长度会显著影响人类对质量的判断，作者专门设计了长度控制分析。对于 TL;DR，他们训练一个 logistic 回归模型，以“两个策略的身份”与“摘要长度对数比”作为特征，预测哪一个摘要更受偏好。若要计算两个策略在长度控制条件下的偏好值，只需把长度对数比固定为 0，再输入两个策略 ID 即可。结果表明：控制长度后，人类反馈模型相对参考摘要的优势会缩小，但仍然保持明显领先。对于 CNN/DM，作者采用类似方法，只是改用线性回归去预测 1-7 分 Likert 评分，并估计“摘要每增加 100 个字符，平均质量提高多少”。

6.7 附录 G：更多实验结果

价值函数消融。作者比较了“价值函数与策略共享参数”和“价值函数与策略参数分离”两种设置。结果清晰表明，分离网络优于共享网络；不过，分离网络也会增加 RL 微调时的显存开销。其好处还在于可以直接把学习到的奖励模型参数用于初始化价值函数。

多维质量打分的完整结果。对 TL;DR 与 CNN/DM 两个数据集，作者都给出了连贯性、准确性、覆盖度和总体质量四个维度的完整 Likert 评分图。一个一致现象是：覆盖度与总体分高度相关，而几乎所有模型在连贯性上都得分较高。

best-of- N 优化研究。作者把 best-of- N 视为一种简单但低效的指标优化技术，用它来研究：如果不断朝着某个自动指标优化，最终对人类是否真的更好。结果显示，针对 ROUGE

做 best-of- N 优化明显不如针对奖励模型做优化，而且 ROUGE 在优化过头后退化得更快。

ROUGE 分数。在 TL;DR 上，人类反馈模型在 $T = 0$ 采样时的 ROUGE 略低于监督模型，这进一步说明 ROUGE 与人类偏好相关性不强。对于监督模型，降低采样温度对 ROUGE 的影响，甚至比扩大模型规模更大。在 CNN/DM 上，ROUGE 倒是与人工评估一样，表明人类反馈模型比 TL;DR 监督模型迁移得更好；但在绝对值上，专门在 CNN/DM 上监督训练的模型仍然取得更高 ROUGE。原文表 15 给出的一个例子是，作者的 6.7B 监督模型在 CNN/DM 上取得 ROUGE-1/2/L 为 42.49/19.84/39.53，略低于 T5，但高于当时一些 2019 年中期的摘要模型。

bigram overlap。为了衡量摘要从原文中拷贝的程度，作者计算了“摘要与原文之间最长公共二元组子序列所占比例”。结果表明：无论是否在 CNN/DM 上训练，只要在 CNN/DM 上评测，模型都更倾向于拷贝；而监督模型与人类反馈模型的拷贝比例又普遍低于仅预训练模型。

奖励模型验证集。作者构造了若干人工验证集来测试奖励模型。例如，让标注者对摘要做小幅改写使其更优，并比较奖励模型和人类是否偏好编辑后版本。67 亿奖励模型在这项任务上已经接近人类水平。模型还能够检测句子打乱、角色颠倒等扰动；但也会对一些糟糕的人工摘要显示出不合理偏好，例如重复标题、或在摘要末尾添加“我该怎么办？”等模式。

不同评价指标间的一致率。作者分别在 TL;DR 监督模型样本、TL;DR 人类反馈模型样本以及 CNN/DM 监督模型样本上，统计了研究者、标注者、标注者集成、长度、拷贝比例、ROUGE、监督模型对数概率与奖励模型之间的一致率矩阵。总体结论是：67 亿奖励模型通常与标注者的一致程度，已经接近其他标注者与该标注者的一致程度；而 ROUGE、监督模型 log probability 等指标的表现普遍较差，有时甚至和简单启发式长度、拷贝比例差不多。

6.8 附录 H：样本

附录最后给出了一批非挑选式的模型样本，既包括 TL;DR，也包括 CNN/DM。同时，作者还展示了“过度优化某个早期奖励模型”后产生的一些失败样本。这些摘要通常冗长、低质，并带有明显古怪措辞，但往往仍然隐约保留了原帖的大意。这些例子很好地说明了：一旦策略过度针对奖励模型漏洞进行优化，表面奖励可以继续升高，但人类感知质量却会严重下降。

7 简要结语

这篇论文之所以经常被视为 RLHF 路线中的“起点性工作”，核心不在于它第一次提出了某个全新的算法，而在于它把一条完整范式明确展示出来：**先收集人类偏好，再训练奖励模型，最后用强化学习优化语言模型，使模型直接朝着人类偏好而不是代理指标前进。**在摘要任务这一相对可控的场景中，作者用大量实验说明了这一路线确实能得到优于监督微调与 ROUGE 优化的结果，也系统暴露了奖励模型过优化、长度偏置、数据采集成本高

等现实问题。后续大量 RLHF、RLAIF、DPO、IPO、GRPO 等工作，基本都可以看作在这一范式上的延展、替代或重构。