

1 HSTU(Meta)

1.1 现有算法存在问题：

- 传统推荐系统扩展性的瓶颈——即性能提升饱和的问题
- 推荐系统中的特征通常缺乏类似自然语言那样的显式结构
- 推荐系统面对的是持续变化的十亿级词表
- 计算成本是支撑大规模序列模型的主要瓶颈

1.2 算法简介：

- 将召回任务建模成一个序列预测问题，根据用户过去的交互历史，从当前的候选物品池选出预测概率最高的物料。当下一个token是负样本或者不是item，则对应掩码设置为0
- 不再将 item 和 action 视为一个整体事件，而是将它们拆分并交错插入到时间序列中，在item位置进行预测，在action位置，Loss进行掩码，不进行预测
- 逐点聚合注意力、通过Stochastic Length (SL, 主动对长历史进行稀疏抽样) 增加稀疏性、简化Transformer结构
- M-FALCON使模型复杂度能够随着候选数线性扩展




图 1: HSTU算法框架图

1.3 创新点：

- 把推荐重新表述成生成式的序列转导任务，再用 HSTU 作为统一编码器
- 将异构的稀疏特征、行为序列与部分数值信息统一到一个可被序列模型处理的结构化时间序列
- softmax 更适合静态、相对稳定的词表，而对推荐这种非平稳、持续变化的词表并不理想；pointwise 设计能够更好保留“相关历史出现了多少次”这种强信号，也更适合流式动态词表

- 在注意力机制角度，HSTU放弃 Softmax，以保留对推荐至关重要的“强度”信息，同时引入门控 U，以一种极为高效的方式实现了复杂的特征交互

2 OneRec (快手)

2.1 现有算法存在问题：

- 将各级排序器视为相互独立的模块，每个独立阶段的效果都会成为后续阶段性能的上界，从而限制了整个排序系统的最终表现
- 当前生成模型仍主要扮演召回阶段的选择器角色，因为它们的推荐精度尚不能达到精心设计的多级级联排序系统的水平
- RLHF（基于人类反馈的强化学习）存在训练不稳定和效率较低等问题

2.2 算法简介：

- OneRec将用户的正向历史行为序列H作为输入，输出是一个视频列表，即一个会话S。对于输入的每一个视频 v_i ，使用与真实用户-物品行为分布对齐的多模态嵌入 e_i 进行表示。（现有生成式推荐框架通常在预训练多模态表示的基础上，使用 RQ-VAE 将嵌入编码为语义 token。然而，这种方法由于编码分布不平衡，会出现所谓的“沙漏现象”：RQ 量化后的码字使用非常不均衡，很多 code 几乎没人用，少数 code 被大量样本挤占）本文采用多层均衡量化机制，利用残差 K-means 量化算法对 e_i 进行变换
- 会话级生成方法：在解码器中的前馈神经网络FNN替换为MoE架构，在目标会话语义ID上使用交叉熵损失进行next-token prediction
- 奖励模型训练： $R(u, S)$ 表示用户u对会话S的偏好程度，u和 v_i 依次逐点相乘得到目标感知h，再通过自注意力层相互交互，以融合不同物品间的必要信息，使用不同tower对多个目标奖励进行预测
- 迭代偏好对齐：先对每个用户u通过beam search（束搜索）生成 N 个不同响应 S_u^n ，随后利用奖励模型为每一个响应计算奖励，选择奖励值最高和最低的构造偏好数据集。在给定这些偏好对后，我们训练新模型 M_{t+1} ，结合DPO损失目标函数从偏好对中学习。




图 2: OneRec算法框架图

2.3 创新点:

- 提出OneRec，一种单阶段生成式推荐框架，这是工业界最早一批能够使用统一生成模型处理物品推荐、并显著超过传统多阶段排序流水线的方案之一。
- 通过会话级生成方式强调了模型容量与目标物品上下文信息的重要性，该方式既提高了预测准确性，也增强了生成物品的多样性
- 提出一种基于个性化奖励模型的自困难负样本选择策略，并结合直接偏好优化，提高了OneRec在更广泛用户偏好上的泛化能力

3 OneRec-V2

3.1 现有算法存在问题:

- V1的编码器-解码器架构中的计算分配低效，其中97.66%的资源消耗在序列上下文编码而非生成阶段，这限制了模型扩展
- 仅依赖奖励模型的强化学习存在局限，包括采样效率较低（只能对一小部分用户采样，以近似全局行为），以及由于智能体奖励信号而引发潜在的奖励黑客问题（略模型可能学到的不是“真正让用户更满意的行为”，而是“如何利用奖励模型的偏差、漏洞或伪相关特征，把分数刷高”）

3.2 惰性仅解码器架构简介:

- 上下文处理器：用户画像与行为等异构输入会被拼接成统一序列，即上下文（ $\text{context}=[C_0, \dots, C_{S_{kv} \cdot L_{kv}-1}]$ ）。随后，上下文表示会被变换为供注意力机制使用的分层键值对。我们沿特征维度切分上下文张量，以生成 L_{kv} 组键值对 $\{(k_0, v_0), \dots, (k_{L_{kv}-1}, v_{L_{kv}-1})\}$

- **Tokenizer:** 对于每个目标物品，我们采用语义分词器生成3个语义ID，以刻画物品的多方面属性在训练过程中，我们使用前2个ID，并在序列前加上起始符BOS
- **块结构:** 惰性解码器Transformer块包含：交叉注意力、自注意力与前馈网络（在较深层中用MoE模块替换稠密前馈网络）
- **惰性交叉注意力:** KV共享，多个惰性解码器块共享同一组由上下文处理器产生的键值对，对于第 l 层，对应索引为：

$$l_{kv} = \lfloor \frac{l \cdot L_{kv}}{N_{layer}} \rfloor$$

- **分组查询注意力:** 查询投影仍保持 $H_q = d_{model}/d_{head}$ 个注意力头，而键值对仅使用 $G_{kv} < H_q$ 个头。
- 在训练时，我们最大化目标物品语义ID序列 $[s_1, s_2, s_3]$ 的似然。




图 3: OneRec-V2算法——惰性仅解码器架构框架图

3.3 基于真实用户交互的偏好对齐简介：

- **时长感知奖励塑形:** 将目标视频的播放时长，与同一用户历史中“时长相近”的视频进行比较，对播放时长进行归一化。（将视频按时长进行分桶，计算桶内分位数作为得分，25%分位点以上且没有点踩作为正样本 $A_i = +1$ ，点踩为负样本 $A_i = -1$ ，其余样本被过滤掉 $A_i = 0$ ）
- **强化学习:** 提出新的强化学习方法GBPO（Gradient-Bounded Policy Optimization，梯度有界策略优化）——传统强化学习token概率 π_θ 越小，梯度越大（因为Loss要对 θ 求梯度），正样本情况下这是合理的，但在负样本情况下梯度过大容易崩塌。——GBPO在负样本情况下，当 π_θ 很小时，增大分母；在正样本情况下，当 π_θ 很大时，分母也变大。




图 4: OneRec-V2算法——时长感知奖励塑形框架图

3.4 创新点:

- 惰性仅解码器架构 (Lazy Decoder-Only Architecture): 该架构采用精简的仅解码器设计, 消除了编码器瓶颈并简化了交叉注意力, 使总计算量降低94%、训练资源降低90%。这种效率使模型能够成功扩展到8B参数规模; 更重要的是, 其收敛损失与经验扩展律高度吻合
- 基于真实用户交互的偏好对齐 (Preference Alignment with Real-World User Interactions)——该框架以用户反馈为驱动
- 时长感知奖励塑形: 通过考虑视频时长差异, 缓解原始观看时长信号中的固有偏差, 使奖励更准确地反映内容质量而非时长本身
- 自适应比率裁剪: 在保证策略优化收敛性的同时有效降低训练方差, 样本完全利用——保留所有样本的梯度, 鼓励模型进行更丰富的探索; 有界梯度稳定化——用BCE (二元交叉熵) 损失中更稳定的梯度为强化学习梯度设界, 从而增强训练稳定性。

4 MTGR (美团)

4.1 现有算法存在问题:

- 生成式推荐放弃传统模型中精心构造的交叉特征 (候选项与用户之间), 这种做法会显著损害模型性能
- 扩展用户模块, 不能增强用户与物品之间的特征交互
- 扩展交叉模块, 计算开销会随着候选项数量线性增长, 系统时延不可接受

4.2 算法简介:

- 传统第 i 个用户-候选项样本可表示为 $D_i = [U, S, R, C_i, I_i]$, 其中 U 表示用户画像特征, U_i 都是标量; S 是历史交互序列, S_i 是一个embedding向量; R 是最近交互; C 是交叉特征; I 是候选项特征, 在不同用户之间共享

- 对于候选样本中第*i*个样本，将特征组织为 $D_i = [U, S, R, [C_i, I_i]]$ ，具体而言，把交叉特征C看作候选项特征的一部分，聚合后的样本共享一份用户表示 (U, S, R) ，形式化的，同一用户的特征表示为：

$$D = [U, S, R, [C, I]_1, \dots, [C, I]_k]$$

全部转换为统一维度的token，连接形成一个长token序列 $Feat_D \in R^{(N_U + N_S + N_R + N_I) \times d_{model}}$

- 统一HSTU编码器：输入序列X按照不同域进行“组层归一化”，然后对归一化后的输入进行4组不同投影得到KQVU，Value计算如下：

$$V' = \frac{silu(K^T Q)}{(N_U + N_S + N_R + N_I)} MV$$

其中M为定制掩码，随后用U和V ‘点乘，再次组层归一化，加入残差模块后接上一个MLP：

$$X = MLP(GroupLN(V' \odot U)) + X$$

- 动态掩码使用因果掩码进行序列建模效果无提升且会造成信息泄露。静态信息（U，S）来自聚合窗口之前，不会引发因果性错误，而R是动态的，会实时纳入用户交互信息。因此，MTGR对静态序列使用全注意力，对R使用带动态掩码的自回归注意力（每个token只对其之后出现的token 可见，这其中也包括候选项token），而对候选项之间使用对角掩码。
- 动态哈希表：采用解耦哈希表架构，将Key存储与Value存储分离。
- 负载均衡（拼接短序列）：常规做法是序列打包技术，将多个短序列拼接为更长序列。然而，这种方法要求仔细调整掩码，实现代价较高。算法引入动态BS，根据输入数据的实际序列长度动态调整每张GPU的本地BS，从而使各GPU的计算负载保持相近。调整了梯度聚合策略，使每张GPU的梯度按照其BS加权，从而保证与固定BS情形下的计算逻辑一致




图 5: MTGR算法框架图

4.3 创新点:

- 保留原始深度学习推荐模型（DLRM）的特征，包括交叉特征
- 通过用户级压缩实现训练与推理加速，从而保证高效扩展
- 组层归一化（Group-Layer Normalization, GLN），以增强不同语义空间中的编码效果
- 提出动态掩码策略以避免信息泄漏

5 RankMixer（字节）

5.1 现有算法存在问题

- (1) 工业级推荐系统在训练与在线服务中同时面临严格的延迟约束与极高的 QPS（系统每秒处理请求数）压力，因此模型扩展不能简单照搬 NLP 领域“大参数换效果”的思路，必须兼顾效果与推理成本。
- (2) 大量人工设计的交叉特征模块继承自 CPU 时代，其核心算子往往更偏向访存密集而非计算密集，难以充分发挥 GPU 的并行计算能力，导致模型 MFU（Model FLOPs Utilization）较低，扩展性较差。

- (3) 推荐系统输入由用户、物品、序列、交叉等多种异构特征构成，不同特征处于不同语义子空间。传统统一式特征交互结构难以同时建模跨特征交互与各子空间内部差异，限制了大规模模型的扩展收益。

5.2 算法简介

- (1) RankMixer 首先将多种异构特征按语义分组并拼接，再通过 tokenization 映射为多个 feature token，从而将推荐系统中的多字段特征组织为适合 GPU 并行计算的统一表示形式。
- (2) 在主干结构中，RankMixer 采用多层 RankMixer Block 堆叠。每个 Block 由两部分组成：其一是 Multi-head Token Mixing，用于在不同 token 之间进行高效的信息混合与跨特征交互；其二是 Per-token FFN，用于对每个 token 所对应的特征子空间进行独立建模。
- (3) 为进一步提升大模型扩展收益，RankMixer 将 Per-token FFN 扩展为 Sparse-MoE 形式，并结合 ReLU Routing 与 Dense-training / Sparse-inference 策略，使高信息 token 能够动态激活更多专家，在控制推理成本的同时提升模型容量。

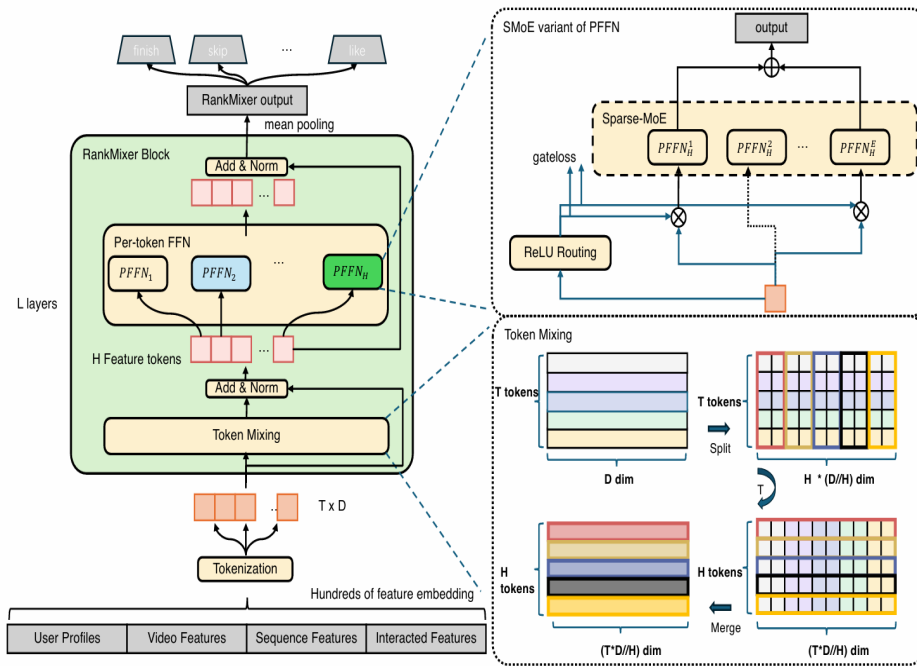


图 6: RankMixer 算法框架图

5.3 创新点

- (1) 提出面向硬件友好的统一特征交互架构 RankMixer，以 Token Mixing 取代传统自注意力中的二次复杂度交互方式，在保持较强并行性的同时显著提升计算效率与 GPU 利用率。
- (2) 提出 Per-token FFN 机制，为不同 feature token 分配彼此独立的参数空间，从结构上缓解高频特征对低频或长尾特征的淹没问题，更适合推荐系统中异构特征子空间的建模需求。

- (3) 针对 RankMixer 中直接使用 Vanilla Sparse-MoE 易出现的统一 top-k 路由不合理与专家训练不足问题，设计了 ReLU Routing 与双路由器的 DTSL-MoE 方案，在保证稀疏推理成本可控的同时提升专家利用率与模型扩展能力。

6 LONGER (字节)

6.1 现有算法存在问题

- **两阶段检索方法存在链路割裂问题。** 现有工业界常用做法是先从超长用户行为序列中检索出与当前候选物品最相关的 Top- k 行为，再交给短序列模型进行端到端建模。该方式虽然降低了计算成本，但会导致上游检索与下游排序目标不一致，难以充分保留原始超长序列中的完整信息。
- **预训练用户表征方法属于间接建模。** 一类常见方案是先从源模型中对长序列进行预训练，再压缩得到用户表征向量并迁移到下游推荐模型中。这种方法本质上并不是对原始超长行为序列进行直接建模，而是通过中间用户向量间接感知用户兴趣，因此容易损失细粒度行为信息。
- **记忆增强方法和直接长序列建模都面临效率瓶颈。** 记忆网络类方法通常需要较长时间训练才能在记忆槽中积累较高命中率，而直接使用标准 Transformer 处理长序列时，自注意力复杂度随序列长度平方增长，计算与显存开销过高，因此大规模工业场景下难以高效部署。

6.2 算法简介

- **LONGER 是面向工业推荐的端到端超长序列建模框架。** 该方法全称为 Long-sequence Optimized traNsformer for GPU-Efficient Recommenders，目标是在工业推荐系统中直接建模超长用户行为序列，并将可建模的序列长度扩展到万级。
- **模型主体由全局标记、Token Merge 与混合注意力组成。** LONGER 将输入组织为 Global Tokens 与原始用户行为序列两部分，其中 Global Tokens 用于聚合候选物品、用户身份及上下文等全局信息；随后利用 Token Merge 将相邻行为分组压缩，并在组内引入轻量级 InnerTrans 建模局部交互；在主干结构上，先通过 Cross Causal Attention 用压缩查询关注整段序列，再堆叠 Self Causal Attention 建模更高阶依赖关系。
- **系统层面进一步配套训练与部署优化。** 为了支持工业级上线，LONGER 设计了全同步 GPU 训练框架，并结合混合精度训练、激活重计算和 KV Cache Serving 等工程优化手段，以降低训练显存占用和在线推理延迟，提升整体吞吐效率。




图 7: LONGER 算法框架图

6.3 创新点

- 提出 **Global Tokens 机制**。通过在输入端加入候选物品表征、UID embedding、可学习 CLS token 等全局标记，LONGER 能够在长序列中建立稳定的信息锚点，增强用户历史、候选物品与上下文特征之间的交互，同时缓解长上下文注意力中的注意力塌陷问题。
- 提出 **Token Merge + InnerTrans + Hybrid Attention** 的高效长序列建模方案。LONGER 先利用 Token Merge 对长序列做分组压缩，再用 InnerTrans 捕捉组内局部模式，最后结合 Cross-Attention 与 Self-Attention 兼顾全局依赖和局部信息，在基本不损失效果的前提下显著降低计算量，论文中指出该设计可减少约 50% 的 FLOPs。
- 提出面向工业部署的一整套 **GPU 高效优化框架**。LONGER 不仅是模型结构创新，还包含统一稠密与稀疏参数更新的全同步训练框架、混合精度与重计算策略，以及面向多候选打分场景的 KV Cache Serving 机制，从而使超长序列模型能够真正落地到广告和电商等大规模工业推荐场景。

7 Tiger(谷歌)

7.1 现有算法存在问题

- 传统推荐检索通常采用双塔结构，将用户侧与物品侧映射到同一向量空间，再依赖 ANN/MIPS 进行候选召回；这类方式本质上仍是“表示学习 + 近邻检索”的范式，检索过程与索引构建成本较高。

- 许多现有方法使用随机的原子式 item ID 或为每个物品单独学习 embedding，这种表示缺乏显式语义结构，难以在语义相近物品之间共享知识，也更容易受到推荐系统反馈回路的影响。
- 当物品库规模持续增大时，传统方法往往需要为每个 item 维护独立 embedding 或建立额外索引，存储与服务成本随物品数线性增长；同时，对新上架或低频物品的泛化能力较弱，冷启动表现受限。

7.2 算法简介

- TIGER 首先利用预训练内容编码器将物品标题、品牌、类别等内容特征映射为语义向量，再通过 RQ-VAE 对连续语义向量进行残差量化，为每个物品生成长度为 4 的 Semantic ID。
- 在序列推荐任务中，用户历史交互序列会被转换为一串 Semantic ID token 序列，并输入 Transformer 编码器-解码器模型；模型以自回归方式逐 token 预测用户下一次可能交互物品的 Semantic ID。
- 推理阶段不再显式构建传统 ANN 检索索引，而是由生成模型直接输出目标物品的 Semantic ID，再通过查找表映射回具体 item，从而将推荐召回过程改写为生成式检索过程。




图 8: TIGER算法框架图

7.3 创新点

- 提出了面向序列推荐的生成式检索框架 TIGER，不再采用传统“用户向量-物品向量匹配 + ANN 检索”的召回方式，而是直接生成下一物品的 Semantic ID。
- 设计了基于内容语义的层次化 Semantic ID 表示方法，通过 RQ-VAE 将 item 内容量化为多级离散 code，使语义相近的物品能够共享部分前缀表示，从而增强模型的泛化能力。
- 该框架除提升 Recall 与 NDCG 指标外，还天然带来两项重要能力：一是利用语义信息改善新物品与低频物品的冷启动推荐；二是借助分层 token 与温度采样机制，更灵活地控制推荐结果的多样性。