

GPR：迈向大规模广告推荐的生成式预训练单模型范式

Jun Zhang, Yi Li, Yue Liu, Changping Wang, Yuan Wang, Yuling Xiong, Xun Liu, Haiyang Wu, Qian Li, Enming Zhang, Jiawei Sun, Xin Xu, Zishuai Zhang, Ruoran Liu, Suyuan Huang, Zhaoxin Zhang, Zhengkai Guo, Shuojin Yang, Meng-Hao Guo, Huan Yu, Jie Jiang, Shi-Min Hu

腾讯公司，中国；清华大学，中国

说明 本文档依据用户提供的论文《GPR: Towards a Generative Pre-trained One-Model Paradigm for Large-Scale Advertising Recommendation》逐段翻译整理而成。

摘要

作为连接用户与商业内容的智能基础设施，广告推荐系统在数字经济中的信息流转与价值创造过程中发挥着核心作用。然而，现有多阶段广告推荐系统存在目标不一致与误差传播问题，因此难以实现全局最优；而统一式生成推荐模型在满足真实工业应用需求方面仍然面临困难。为解决这些问题，我们提出 GPR（Generative Pre-trained Recommender，生成式预训练推荐器）——这是首个将广告推荐重新定义为端到端生成任务的单模型框架，用统一的生成式方法替代传统级联范式。

为实现 GPR，我们围绕统一表示、网络结构与训练策略提出了三项关键创新。首先，我们针对广告场景设计了统一输入模式与分词方法，将广告与自然内容共同映射到共享的多层语义 ID 空间，从而增强异构数据之间的语义对齐与建模一致性。其次，我们提出异构层次解码器（HHD，Heterogeneous Hierarchical Decoder），这是一种双解码器架构，将用户意图建模与广告生成解耦，在保持较强建模能力的同时兼顾训练效率与推理灵活性。最后，我们提出多阶段联合训练策略，将多 Token 预测（MTP）、价值感知微调（Value-Aware Fine-Tuning）与层次增强策略优化算法（HEPO）整合为一条完整的生成式推荐训练流水线，从而统一兴趣建模、价值对齐与策略优化。

GPR 已在腾讯视频视频号广告系统中完成全面部署，并显著提升了包括商品交易总额（GMV）与 CTCVR 在内的关键业务指标，清晰表明即使面对一个高度优化、已经十分成熟的级联式系统，GPR 依然保持了很强的竞争力。

1. 引言

在线广告推荐是数字经济的重要组成部分，其核心任务是依据用户历史行为，将合适的广告精准匹配给合适的用户。这类系统必须在严格的实时、低时延要求下运行，服务数亿用户以及数千万动态广告。因此，系统性能的时效性与稳定性直接决定着一个数十亿美元规模生态系统的运转。如何在用户体验、广告主投资回报率（ROI）与平台收入之间实现动态平衡，已经成为这一领域中的关键挑战。

传统广告推荐系统通常采用“召回—粗排—精排”的多阶段级联流水线，如图 1(a) 所示。然而，这种流水线在不同阶段之间存在优化目标不一致的问题：召回阶段强调覆盖率优化，而最终排序阶段关注业务结果预测。这种目标失配使系统难以达到全局最优。此外，前期召回模型的表示能力有限，往往会过早淘汰潜在高质量候选项，从而限制后续排序模型对深层特征交互的充分挖掘，形成信息瓶颈。再者，级联式架构依赖十分复杂的工程实现，需要投入大量资源维持跨阶段一致性，进而阻碍算法的快速迭代与系统扩展。

近年来，随着大语言模型 (LLMs) 的快速发展，尤其是其在生成能力方面取得突破，推荐系统的研究范式也在持续演进。HSTU 将生成建模引入传统级联架构，如图 1(b) 所示，进一步推动了推荐系统从多阶段流水线向统一生成式推荐框架的转变。此类模型能够基于对用户兴趣与语义上下文的整体理解，直接生成最优推荐结果，从而保证优化目标的一致性。然而，由于广告推荐任务本身具有高度复杂性，现有生成式模型在真实工业应用中仍面临多方面挑战。

第一，数据与行为具有极端异构性。广告通常与短视频、社交内容、新闻文章等自然内容交织出现，从而在序列层面与条目层面同时表现出异构性，用户行为类型也十分多样。系统不仅要处理用户对广告的交互，还要同时处理用户对非广告内容的交互，例如点击、转化、观看与阅读，这使数据分布高度噪声化且复杂。这样的极端异构性显著增加了用户兴趣建模与语义对齐的难度，对模型的统一表示能力与多模态建模能力提出了严格要求。

第二，系统存在效率与灵活性之间的矛盾。在工业级广告推荐中，模型不仅要支持高效训练，以适应大规模数据更新，还必须具备灵活的解码能力，以便实时处理超长用户行为序列，并在定向、出价、预算等多重约束下完成广告匹配。Decoder-only 架构能够支持高效的序列级训练，但解码灵活性有限；而 encoder-decoder 架构虽然具备较强推理灵活性，却由于点式损失目标带来过高训练成本，因此并不适合实时广告系统。如何平衡训练效率与推理灵活性，仍然是一个核心难题。

第三，广告推荐必须优化收入以及多方价值。广告推荐系统需要在多个利益相关方之间最大化整体生态价值，即同时兼顾用户体验、广告主 ROI 与平台收入。而现有预训练方法往往仅围绕简化的单一目标独立优化，例如最大化预测点击率或转化率。这种割裂式优化不可避免地带来目标失配与局部最优问题，因而难以实现真正意义上的全局业务价值最优。

为应对上述挑战，我们提出 GPR。通过在统一分词方式、解码器架构与训练策略上的系统性创新，GPR 能够有效统一异构数据，在系统效率与解码灵活性之间取得平衡，并对业务价值进行精确刻画，从而优化多方参与者的全局目标。据我们所知，GPR 是首个成功部署到大规模真实广告系统中的端到端生成式广告推荐框架，如图 1(c) 所示。本文的主要贡献如下。

其一，我们提出统一输入模式与分词方法，使用四类 Token 表示用户的完整行为轨迹，并引入新型 RQ-Kmeans+ 量化模型，将内容与广告共同映射到共享语义空间，从而实现异构且超长序列数据的高效建模。

其二，我们提出基于双解码器的生成式架构 HHD，从层次上分别建模用户理解与推荐条目生成，以获得更细粒度的兴趣表示和更准确的推荐结果。在解码阶段，HHD 融合 Trie 约束、价值引导与高效多阶段剪枝，显著提升了生成精度与可靠性。

其三，我们提出多阶段联合训练策略，将多 Token 预测 (MTP)、价值感知微调 (VAFT)

以及层次增强策略优化算法 (HEPO) 整合起来, 构建出一条完整的生成式推荐训练流水线, 实现兴趣建模、价值对齐与策略优化的无缝统一。

其四, 我们已将 GPR 完整部署到腾讯微信视频号广告系统中。大规模在线 A/B 测试表明, 该方法显著提升了包括 GMV 与 CTCVR 在内的关键业务指标, 清楚证明了 GPR 在面对一个高度优化且成熟的级联系统时依然具备很强竞争力。

2. 生成式预训练推荐器

本节介绍 GPR——一个能够在单一生成模型中同时生成推荐条目及拍卖价值的统一框架。针对用户行为数据噪声大、异构性强且序列极长的特点, 我们首先提出一种新的输入模式 (Input Schema), 将用户长期行为表示为一条统一且连续的 Token 序列。在这一表示基础上, 我们设计了一种新的量化器 RQ-Kmeans+, 它显著提高了码本利用效率, 有效缓解常见的码本塌缩问题, 同时保留潜空间的灵活性。随后, 我们构建了基于双解码器的生成框架——异构层次解码器 (HHD), 用于深入理解复杂用户行为模式, 并准确预测目标条目及其对应业务价值。最后, 我们设计了带价值引导的基于 Trie 的 beam search 算法, 以提升推理效率与性能。整体结构见图 2。

2.1 输入模式与处理

GPR 需要处理噪声大、异构且超长的用户信息, 因为现实中的广告平台通常覆盖多种不同场景, 例如微信视频号、朋友圈与公众号等。此外, 用户在这些平台上的行为序列可能跨越很长时间, 积累出极长的历史, 这进一步增加了模型需要处理与理解的信息复杂度。因此, 我们为 GPR 提出统一输入模式, 用来表示用户的完整旅程。该模式由用户 Token (U-Token)、自然内容 Token (O-Token)、环境 Token (E-Token) 与条目 Token (I-Token) 构成。具体而言, U-Token 表示用户属性与偏好; O-Token 封装用户接触的自然内容, 例如短视频与文章; E-Token 编码广告请求发生时的即时上下文; I-Token 则表示用户发生过交互的广告条目。

此外, 已有生成式推荐模型表明, 将条目嵌入量化为语义 ID, 既能够提取条目中的关键信息, 又能生成离散化条目表示, 从而更好适配生成模型范式。因此, 我们将 O-Token 中的所有内容以及 I-Token 中的所有条目都转换为离散语义 ID。RQ-VAE 与 RQ-Kmeans 是两类常见方法, 但它们都存在“码本塌缩”与“潜空间鲁棒性不足”等问题, 导致语义空间利用率不高、表示能力受限。为解决这些问题, 我们提出新的量化模型 RQ-Kmeans+, 其由编码器、残差码本与解码器构成。

我们认为, 码本塌缩主要源于随机初始化: 一些向量在训练过程中几乎不会被激活, 最终成为“死向量”, 造成码本利用率低下。为此, 如图 3 所示, RQ-Kmeans+ 首先利用 RQ-Kmeans 生成高质量码本, 并将其作为初始化权重。之后, 码本再使用与 RQ-VAE 相同的损失函数进行更新, 以适应当前可学习潜空间。此外, 我们在编码器侧引入残差连接, 以确保训练早期输出分布保持接近输入分布, 从而加速收敛并稳定潜空间对齐。最终, RQ-Kmeans+ 在保持潜空间灵活性的同时, 显著提升了码本利用率, 有效缓解了塌缩问题。

2.2 异构层次解码器

我们提出一种 decoder-only 生成架构，称为异构层次解码器 (HHD)，其由异构序列级解码器模块 (HSD)、渐进式 Token 级解码器模块 (PTD) 以及层次 Token 级评估器模块 (HTE) 组成，如图 2(a) 所示。这种层次结构将用户行为理解与下一条目标预测解耦，从而能够更细粒度地理解用户偏好，并进一步提升下一条条目预测的准确性。具体而言，HSD 模块利用混合注意力机制、Token 感知归一化与前馈网络来充分理解用户行为并生成高质量意图嵌入；同时引入 Mixture-of-Recursions (MoR) 策略，以降低内存消耗并提升模型推理深度。在这些意图嵌入的引导下，PTD 模块遵循 “Thinking-Refining-Generation” 的范式预测下一条条目，从而借助 thinking token 与 refining token 获得更准确的预测结果。在生成过程中，HTE 模块会输出每个语义码以及最终条目的估计价值，用于剪枝与拍卖。

异构序列级解码器 (HSD) HSD 模块是主解码器，它堆叠 HSTU block，并以统一 Token 序列为输入，用于理解用户行为并生成意图嵌入。在基础 HSTU block 之上，我们引入若干关键增强，形成用于 HSD 的模块，包括混合注意力机制、Token 感知归一化以及改进的前馈网络，如图 2(b) 所示。

与标准注意力机制不同，HSD 的注意力机制额外引入嵌入 U ，它能够自适应调制注意力权重 W 。这种调制使 HSD 能够更有效地聚焦于与当前任务更相关的用户行为，同时主动削弱信息量较低的交互。此外，由于我们的输入模式中 U-Token、O-Token 与 E-Token 共同作为条目预测的提示前缀，在这一前缀区域内直接使用标准因果 mask 会显得过于受限。为了解决这一问题，我们提出混合注意力 mask M_{hybrid} 。在前缀块内部，各 Token 之间允许双向可见。这样的设计使模型能够充分利用提示 Token 之间的上下文交互，从而在预测前构建更完整的上下文先验。其形式为：

$$\text{HybridAttn}(\cdot) = \text{Softmax} \left(\frac{QK^\top}{\sqrt{d}} + M_{hybrid} \right) V \odot U.$$

其中，当前缀中两个 Token 都属于 U/O/E-Token 时，可双向可见；否则遵循自回归约束。

此外，考虑到不同类型 Token 具有不同特性，HSD 模块为每一类 Token 分别设置独立的归一化层与前馈网络，将它们投影到各自的语义子空间，从而更充分地捕获异构序列中的语义多样性。同时，我们引入 Mixture-of-Recursions (MoR) 机制，在不增加额外参数的前提下提升模型深度与推理能力。为了进一步增强推理能力，模型还引入了来自微调大语言模型的外部知识：LLM 先生成关于用户潜在兴趣的文本 “思考过程”，然后将其分词后融入意图嵌入，以增强语义理解与推理能力。

渐进式 Token 级解码器 (PTD) 在 HSD 生成意图嵌入后，PTD 模块作为第二级解码器，采用传统 Transformer decoder 结构来生成目标条目。尽管意图嵌入已经包含了对用户行为的综合表示，但其中仍可能存在冗余信息，从而影响条目预测精度。为此，PTD 模块提出一种新的 “Thinking-Refining-Generation” 范式，用于预测下一条目标的语义 ID。具体而言，PTD 使用交叉注意力机制，其中意图嵌入同时充当 key 和 value。基于这些意图嵌入，我们首先强制 PTD 生成 K 个 thinking token，这些 token 用于提炼关键信息并过滤掉意

图嵌入中的无关成分。

进一步地，受到近期大语言模型推理研究工作的启发，我们在 PTD 中集成了 refining module，以进一步增强其认知能力与生成能力。图 2(c) 展示了该模块，其建立在扩散范式之上，由噪声生成器以及用 Markov 链建模的逆过程组成。在逆过程中，噪声由一个条件去噪模块迭代去除，该模块采用 Transformer 架构。前缀 thinking tokens 经过 Sum-Pooling 聚合后，作为去噪模块的条件输入。因此，refining module 可以对初始推理结果进行细化，并将细化后的表示传递给后续模块。

最后，PTD 结合 thinking tokens 与 refining token，生成表示下一条条目的语义码序列。在推理阶段，我们进一步使用基于 Trie 约束且带价值引导的 beam search，以高效解码出准确结果。其细节将在第 2.3 节介绍。

层次 Token 级评估器 (HTE) 与传统内容推荐系统不同，在线广告系统需要同时优化用户参与度与平台收入。这意味着系统需要为每个候选广告联合预测多个业务指标，包括点击率 (CTR)、转化率 (CVR) 与千次展示收益 (eCPM)。为了实现端到端优化，这些多维度预测必须被聚合为一个单一标量目标，以在用户体验与业务目标之间取得平衡。我们将这一聚合指标称为 `final_value`，并将其作为系统的主要优化目标。`final_value` 及其组成部分的具体公式会在强化学习部分的式 (5) 给出。

为了真正实现端到端广告生成，我们在层次化 GPR 模型上构建了集成式价值估计模块 HTE，将生成与价值估计结合起来。该模块能够在生成候选广告后，对其 `final_value` 进行估计。相较于传统多阶段系统，这种一体化、端到端的方法具有显著优势：它在表示层与目标层上提升了一致性，从而缓解了召回阶段与排序阶段之间的冲突；同时也提高了广告系统整体计算效率。除了在推理时用于价值预测之外，HTE 在强化学习后训练阶段还充当 critic 模型，用于基于价值的优势估计与策略优化。

2.3 价值引导的基于 Trie 的 Beam Search

PTD 预测得到的目标条目语义码，在广告场景下可能是无效或次优的，例如映射到并不存在的条目、定向条件不匹配当前用户的条目、预算已经耗尽的条目，或者价值较低的条目。虽然传统 beam search 可以通过后过滤与后排序移除无效结果并按价值重新排序，但这会带来难以接受的计算开销与时延。因此，我们提出价值引导的基于 Trie 的 beam search，将由用户画像生成的 Trie 约束与价值估计直接整合到解码过程中，以便尽早评估前缀。

具体来说，给定 HTE 对每个语义码的价值预测，我们会动态调整 beam 宽度：价值越高，下一层语义码就分配更宽的 beam，以提高潜在收益。随后，我们利用根据当前用户画像生成的 Trie 树对搜索空间进行剪枝。该 Trie 树通过广告系统中的用户定向策略构建，会根据年龄、性别等属性过滤候选项，因此仅保留与当前用户属性一致的候选路径，从而实现更早阶段的用户级定向过滤。

3. 多阶段训练

GPR 采用三阶段训练方案，以适配广告推荐中的稀疏信号、多业务目标与动态条目空间。首先，在预训练阶段使用多 Token 预测（MTP）来捕捉用户的全局、多兴趣模式。随后，在对齐阶段引入价值感知 MTP 损失，对高价值条目赋予更高更新权重，使优化方向更贴近业务优先级。最后，借助仿真环境中的 HEPO 强化学习，模型能够突破日志曝光数据的限制，在分布偏移条件下发现那些尚未得到充分服务但价值较高的候选项。完整流水线如图 4 所示。

3.1 基于多 Token 预测的预训练

预训练阶段旨在将广告场景知识注入 GPR 中，以应对广告交互信号相较自然流量更稀疏的问题，并学习用户的全局多兴趣表示。用户往往会同时沿着多个意图线程行动，而该阶段的目标就是以联合且一致的方式表示这些兴趣线程。我们使用来自腾讯广告平台的大规模工业数据集，覆盖一年时间、包含数亿匿名用户，同时包含广告交互数据（曝光、点击、转化）与自然内容交互数据。对于每个用户，我们依据统一四 Token 模式（U/O/E/I-Token）构造按时间排序的行为序列。

条目（广告）被编码为 L 层由粗到细的语义码，这些语义码来自残差向量量化，从而形成一种分层且紧凑的条目语义表示。作为基线，下一 Token 预测（NTP）根据用户历史与上下文来预测后续语义码。虽然 NTP 对单一路径动态建模有效，但它隐含地假设存在一个主导兴趣轨迹，容易对并行兴趣进行平均化处理，因此在广告场景中的覆盖能力受限。为了捕捉多个并发兴趣，如图 4(a) 所示，我们采用 MTP，通过为 decoder 扩展出 N 个并行 head（默认 $N = 4$ ），使每个 head 独立预测一个兴趣维度下完整的 L 层语义码路径。所有 head 共享主干状态，但拥有各自独立的投影层。这样的设计能够在互不干扰的情况下并行建模多个兴趣，并通过对每个 head 使用 masked decoding 保证层级合法性。

预训练目标会聚合各个 head、各个层级的似然项，并使用满足 simplex 约束的 head 权重 ω_j 自适应强调高质量兴趣线程：

$$L_{\text{MTP}} = - \sum_{j=1}^N \sum_{t=1}^T \sum_{\ell=1}^L \omega_j^H \log P_j(I_{j,t,\ell} \mid S, C, I_{j,t,1:\ell-1}).$$

其中， $I_{j,t,\ell}$ 表示第 j 个 head 在位置 t 输出的第 ℓ 层语义码； $P_j(\cdot)$ 为该层合法候选集合上的条件概率； S 与 C 分别表示历史序列与上下文特征。我们将 ω_j 初始化为 $1/N$ ，并允许后续阶段通过下游监督对不同 head 的有效重要性进行调整。这一目标使主干模型能够编码广泛且解耦的兴趣结构，为后续业务对齐与强化学习提供稳定基础。

3.2 价值感知微调（VAFT）

这一阶段旨在连接多兴趣预训练与变现目标，通过将行为价值与 eCPM 感知注入 MTP 框架，使模型在保持相关性的同时优先关注高价值广告。尽管 MTP 能有效捕捉多兴趣，但它与广告目标之间仍存在偏差：其一，它对经济价值差异很大的广告赋予相同损失权重，导

致低 eCPM 的长尾条目可能主导梯度；其二，它将曝光、点击、转化等行为类型一视同仁，忽略了转化高于点击、点击高于曝光这一业务价值层级。

为此，我们引入位置与 head 相关的权重 $\omega_{j,t}^V$ ，通过结合行为类型与广告的 eCPM 来编码业务价值，如图 4(b) 所示。该权重按照“转化 > 点击 > 曝光”的层级区分不同行为，并使用归一化 eCPM 进行缩放，以避免量级失真与伪梯度。该项与预训练阶段中的 head 级重要性 ω_j^H 相结合，后者用于强调高质量兴趣线程。于是，价值对齐的 MTP 损失可写为：

$$L_{\text{eCPM-MTP}} = - \sum_{j=1}^N \sum_{t=1}^T \sum_{\ell=1}^L (\omega_j^H \omega_{j,t}^V) \log P_j(I_{j,t,\ell} | S, C, I_{j,t,1:\ell-1}).$$

其中，复合权重 $\omega_j^H \omega_{j,t}^V$ 同时融合了兴趣线程质量与位置级业务价值，从而使更新更偏向于高 eCPM 行为，同时保留多兴趣覆盖能力。其他符号含义与式 (3) 相同。在实际中， $\omega_{j,t}^V$ 使用经过校准或归一化的 eCPM，并结合单调变换、可选裁剪以及固定的行为类型系数，以稳定梯度、避免极端值过度放大，并强化与收入目标的对齐。

文中进一步给出了不同类型行为对应的分母设计，使其与广告业务价值层级一致。对于曝光 ($i = 1$)，分母为 1，因此 $\omega_{j,t}^V \propto \text{eCPM}$ ，反映基础收益贡献；对于点击 ($i = 2$)，分母为 pCTR，从而使 $\omega_{j,t}^V \propto \text{eCPM}/\text{pCTR}$ ，用于鼓励高点击质量广告；对于转化 ($i = 3$)，分母为 pCTR $\times$ pCVR，因此 $\omega_{j,t}^V \propto \text{eCPM}/(\text{pCTR} \times \text{pCVR})$ ，用于优先关注真正驱动转化的广告。

3.3 使用 HEPO 的后训练

监督式预训练能够通过历史曝光与交互日志学习到较强基础能力，但仅基于似然的训练存在天然局限：日志数据所覆盖的动作有限。模型只能观察历史策略产生的序列，大量可能具有更高价值的替代候选并未被探索到。由于缺乏反事实评估，策略只能模仿过去决策，而难以发现更优方案。强化学习则通过构建高保真仿真环境，支持对策略生成序列进行反事实评估，从而突破历史分布的动作覆盖限制，使模型在上线前就能探索新的高价值广告候选。

在生成式推荐设定中，状态 s 包含用户交互历史、设备、时间、场景等上下文信号、已经生成出的多层语义码以及每一层对应的合法 mask。动作 a 是由一个 L 层解码器产生的层次决策：在每一层中，策略从该层合法候选集合中选择一个量化语义码，最终层则确定具体曝光广告。奖励分配在最终决定曝光的最后一步，必要时也可对更早层级附加少量同源 shaping 奖励，以保留粗粒度意图。一个 episode 对应一次请求或一次 session，在单次曝光情形下会在最终层决策后立即结束。

GPR 模型包括一个异构序列级解码器 HSD，用于从用户上下文 s 中生成意图嵌入 $h = \text{HSD}_\theta(s)$ ；渐进式 Token 级解码器 PTD 负责分层解码，并在每一层生成语义 token z_ℓ 的动作概率 $\pi_\theta(z_\ell)$ ，其中参数 θ 同时包含 HSD 与 PTD。用于 eCPM 估计的层次塔模块 HTE 在强化学习中充当价值函数 V_ϕ ，其输出为期望回报 $v_\ell = V_\phi(s, z_{1:\ell-1})$ ，其中 $z_{1:\ell-1}$ 表示前面层级已选 token 序列。价值函数作用在 $\text{stopgrad}(h)$ 上，以保证价值梯度不会更新主干，从而维持训练稳定性。

基于仿真环境的奖励生成 强化学习要求对策略生成的每个候选序列都获得奖励信号，但若在实时环境中用生产排序模型去评估全部候选，将带来难以接受的计算成本与线上时延。因此，我们构建了一个高保真仿真环境，用来离线评估奖励，并尽可能复现线上投放系统。该仿真环境基于带有小时间滞后的生产快照构建，保留了完整基础设施，包括召回索引、特征处理流水线与业务约束规则。环境中集成两类更新频率不同的模型：pCTR/pCVR 排序模型直接从线上系统复制，以确保奖励保真度；GPR 策略模型则由训练流水线周期性推送，以评估不断演化的策略。

对每个用户请求上下文 s ，仿真器使用当前部署的 GPR 模型进行 beam search，生成 K 个候选广告（通常 $K = 40$ ），每个候选都通过 L 层语义 ID 的层次解码得到。随后，排序模型会对每个候选进行评估，得到其预测奖励：

$$R = \text{final_value}(s, \{z_\ell\}_{\ell=1}^L) = \text{eCPM}(s, \{z_\ell\}_{\ell=1}^L) + \frac{1}{N} \sum_{i=1}^N \alpha_i \text{target}_i(s, \{z_\ell\}_{\ell=1}^L).$$

其中， $\{z_\ell\}_{\ell=1}^L$ 表示唯一标识该候选的 token 序列；eCPM 表示预测千次展示收益； target_i 表示 pCTR、pCVR 等辅助目标，对应权重为 α_i 。仿真环境还会记录各层解码时的生成概率 $\pi_{\theta_{old}}(z_\ell)$ ，作为离策略校正时的行为策略概率。

层次过程奖励 如果奖励只在最终曝光层分配，那么中间层级决策就无法获得直接监督信号，从而产生 credit assignment 问题：粗层级决策只能依靠 bootstrap 价值估计来判断其对最终结果的贡献，导致高层的学习信号较弱且方差较大。论文举了一个例子：若用户对智能手机有兴趣，却拒绝了“手机 $\rightarrow$ 品牌 A $\rightarrow$ 条目 X”的推荐，那么如果只有最终负奖励，就会同时降低“手机”这一类别的概率，尽管真正错误可能只发生在品牌层而非类别层。为此，作者提出 HEPO (Hierarchical Enhanced Policy Optimization)，利用用户特定偏好模式构造过程奖励，从而为每个层级提供直接监督。

对于每一层 ℓ ，作者根据用户历史中的成功交互构造 token 级流行度得分 $P_\ell(t) \in [0, 1]$ ，用于表示 token t 在导向正反馈的推荐中出现的频率。对于当前选中的 token z_ℓ ，通过将其流行度与该层所有合法候选集合 S_ℓ 的平均流行度比较，定义偏好信号：

$$\Delta_\ell = P_\ell(z_\ell) - \frac{1}{|S_\ell|} \sum_{t \in S_\ell} P_\ell(t).$$

这种减去基线的方式保证了当所有候选流行度相等时信号均值为零，避免系统性偏置。于是每层步奖励定义为：当 $\ell < L$ 时， $r_\ell = \alpha_\ell \max(0, \Delta_\ell)$ ；当 $\ell = L$ 时， $r_L = R$ 。其中 R 为式 (5) 中的仿真器终端奖励， α_ℓ 为较小缩放系数，用于确保过程奖励能够起到引导作用，但又不会压过最终奖励。

优势估计与损失函数 在中间层级，过程奖励必须通过学习到的价值函数与长期业务结果连接起来，以实现跨层级的合理 credit assignment。而在最终曝光层，终端奖励在不同请求之间的方差很大，使基于 critic 的价值估计变得不稳定。由于最终曝光决策直接决定展示广告，且需要稳定优化，因此作者改用请求内的 z-score 标准化。具体来说，对每个请求，仿

真环境会生成 K 个候选，并通过对这一组候选内的奖励做标准化来评估相对优势。

对于粗层级 $\ell < L$ ，作者使用广义优势估计 (GAE) 结合式 (7) 中的过程奖励来计算优势。累计回报写为 $G_\ell = \sum_{k=0}^{L-\ell} \gamma^k r_{\ell+k}$ ，时序差分误差为 $\delta_\ell = r_\ell + \gamma V_\phi(s, z_{1:\ell}) - V_\phi(s, z_{1:\ell-1})$ 。对于最终层，则在 K 个候选上应用 z-score 标准化。因此，每层的优势定义为：当 $\ell < L$ 时，使用 GAE 形式；当 $\ell = L$ 时， $A_L = (R - \mu_K)/(\sigma_K + \epsilon)$ ，其中 μ_K 与 σ_K 分别为候选集合上的均值与标准差。

策略模型参数 θ 通过最小化剪切 PPO 形式的目标进行更新：

$$L_\theta = \mathbb{E} \left[\sum_{\ell=1}^L c_\ell \min(\rho_\ell A_\ell, \text{clip}(\rho_\ell, 1 - \epsilon, 1 + \epsilon) A_\ell) \right],$$

其中 $\rho_\ell = \pi_\theta(z_\ell)/\pi_{\theta_{old}}(z_\ell)$ 为重要性比率， $\pi_{\theta_{old}}$ 为仿真采样时使用的行为策略。价值函数则通过所有层上的均方误差进行训练：

$$L_\phi = \mathbb{E} \left[\sum_{\ell=1}^L (V_\phi(s, z_{1:\ell-1}) - G_\ell)^2 \right].$$

预期请求演练 (ARR) 广告生态是高度动态的：用户兴趣会变化，优质创意库存也会每日更新。若模型仅基于历史数据训练，就可能表现得“被动响应”，而不是“主动预判”。为此，作者提出 ARR (Anticipatory Request Rehearsal)，通过生成能够近似用户未来请求状态的合成训练样本，使模型具备前瞻性适应能力。

ARR 并不直接使用陈旧历史上下文，而是基于每个用户当前状态构造合成请求，使其更接近用户下一次真实交互。采样频率会根据用户活跃度自适应调整：对于高活跃用户，在高峰期每 2 小时生成一次合成样本，在低峰期每 4 小时生成一次；对于低活跃用户，则按其请求频率成比例拉长间隔。每个合成请求均由当前状态构造而来：Organic token 由用户最近浏览过的自然内容重建，以反映其兴趣演变；对于高活跃用户，User token 直接复用前一次请求中的用户特征，因为短时间尺度内这些特征通常稳定；Environment token 则实时查询得到，包括广告位置、投放位类型与隐私设置等，以反映最新系统状态。随后，这些合成样本会像真实样本一样进入仿真环境：部署中的 GPR 生成候选，排序模型评估其价值，并按标准流程计算优势。

4. 实验

作者按照四个层次验证 GPR。首先，评估所提出的 RQ-Kmeans+ tokenizer 在真实广告与自然内容上的表现，检验其是否能够学习到紧凑且语义一致的编码，并支持统一表示空间。其次，研究所提出的 HHD 架构在建模长时程、长序列且异构的用户行为时，是否优于强基线 HSTU 与 OneRec。第三，验证价值对齐训练策略，即 eCPM-aware MTP 与 HEPO，是否在面向变现目标的任务上优于 NTP 与 DPO。最后，在大规模在线 A/B 测试中将端到端 GPR 与成熟级联流水线比较，以检验其在生产环境中的实际经济收益与泛化能力。

4.1 多模态分词性能

实验设置。作者构建了来自腾讯广告平台的大规模语料，覆盖广告与自然媒体内容（短视频、社交、新闻）。该语料包含异构多模态信号——文本元数据（标题、标签、描述）与视觉内容（缩略图与采样帧），并在条目级与 session 级完成对齐。作者过滤掉近重复样本以降低冗余，并平衡类别分布以减小采样偏差。数据按 80% / 20% 划分为训练集与测试集。RQ-KMeans+ 与两种已有 tokenizer 比较：RQ-VAE（标准离散 tokenizer，容易产生死码）与 RQ-KMeans（仅用 K-means 初始化、但不进行 VAE 式细化）。评估使用三项指标：Collision Rate 衡量被映射到相同编码的条目比例，越低越好；一层码本使用率 CUR_{L1} 衡量活跃编码比例，越高越好；Path Average Similarity (PAS) 衡量共享同一路径编码条目之间的平均嵌入相似度，越高表示碰撞更具语义一致性。

结果与分析。表 1 表明，RQ-KMeans+ 在总体编码质量上最好。其 Collision Rate 为 20.60%，相较 RQ-VAE 的 23.21% 下降了 11.2%，相较 RQ-KMeans 的 21.40% 下降了 3.7%。同时，一层码本使用率达到 99.36%，接近 RQ-KMeans 的 100%，并比 RQ-VAE 高 7.2 个百分点，说明碰撞率降低并不是通过闲置部分编码实现的。更重要的是，PAS 达到 0.992，而基线仅为 0.985 / 0.986，这意味着剩余碰撞对应的条目在语义上更一致。这说明经由 RQ-Kmeans+ 分配到相同语义 ID 的条目，更可能属于相同类别且更相似，因此碰撞更加合理。

模型	Collision (%) ↓	CUR_{L1} (%) ↑	PAS↑
RQ-VAE	23.21	92.13	0.985
RQ-Kmeans	21.40	100.00	0.986
RQ-KMeans+ (本文)	20.60	99.36	0.992

表 1: 不同 tokenizer 的性能比较（对应原文表 1）

4.2 用户行为建模性能

实验设置。作者使用腾讯广告大规模数据集，其中包含用户对广告和自然内容的交互。训练集使用一年匿名用户交互数据，验证集使用其后一天数据。历史序列严格按照时间顺序序列化，并采用统一四 Token 模式 (U/O/E/I)。所有模型共享同一 tokenizer (RQ-KMeans+) 与特征处理流水线。比较基线为 HSTU (decoder-only) 与 OneRec (encoder-decoder)。任务是预测下一次交互条目，要求每个模型在包含数百万条目的完整条目快照上输出 top-100 结果。HitRate@100 的定义是：若真实广告出现在 top-100 候选中，则记为命中。该指标避免了过于严格的编码完全一致要求，而是关注生成出的语义码是否能在嵌入空间中准确定位正确条目。

结果与分析。表 2 给出了核心结果。完整 GPR（即采用 HHD）取得了 27.32% 的 HitR@100，相较 HSTU 提升 43.9%，相较 OneRec 提升 37.6%。OneRec 本身超过 HSTU，是因为它可以接收非纯序列输入，并融合更丰富特征视图，因此比严格自回归 decoder 获得更强条件信息。但代价是推理时通用性较弱，因为它依赖预先结构化字段与候选模式，而不像 decoder 那样能够对任意序列化历史进行条件建模。

消融实验将性能提升归因于三部分。首先，HSD 强化了对长而异构历史上的用户意图编码。Hybrid Attention 放宽了非生成前缀上的因果 mask，带来 8.3% 提升；Token-Aware FFN / Layer Norm 减少了跨类型干扰，分别带来 15.8% 与 9.4% 提升；Mixture of Recursions 在参数共享下提高有效深度，贡献 5.9%；引入 LLM 生成的“思维过程” token 进一步丰富了意图表示，带来 6.1% 提升。其次，PTD 改善了生成质量与多样性，其中 thinking 机制带来 14.6% 提升，refining 带来 3.3% 提升。HTE 将 HitR@100 提升至 19.91%，表明显式价值预测能改善候选排序，并为后续拍卖场景做好准备。Multi-Token Prediction 的增益最大，达到 17.9%，支持了“用户兴趣是多线程并发存在”的假设。

最后，作者还研究了 GPR 的 scaling 性质，在 0.02B、0.1B、0.2B、0.5B、1B 与 2B 六种稠密参数规模下比较训练损失曲线。结果表明，参数规模越大，训练过程中损失越低，展示出稳健的 scaling law。作者同时指出，不同于典型大语言模型，GPR 的总参数规模主要由约 80B 的稀疏参数主导。

模型	HitR@100 (%)	相对 HSTU 提升
HSTU (Decoder-only)	18.98	—
OneRec (Encoder-Decoder)	19.85	+4.6%
+ Hybrid Attention	20.56	+8.3%
+ Token-Aware FFN	21.98	+15.8%
+ Token-Aware Layer Norm	20.76	+9.4%
+ Mixture of Recursions	20.09	+5.9%
+ External Knowledge	20.13	+6.1%
+ Thinking	21.75	+14.6%
+ Refining	19.61	+3.3%
+ HTE	19.91	+4.9%
+ Multi-Token Prediction	22.38	+17.9%
GPR (完整)	27.32	+43.9%

表 2: HHD 架构实验（对应原文表 2）

4.3 业务对齐性能

实验设置。本节评估联合训练策略——MTP 预训练、eCPM-aware 微调与 HEPO——是否能够提升与变现目标的一致性。数据集沿用第 4.2 节设定，即一年训练、后一天验证。除序列信号外，标签还包含 eCPM 与行为类型（曝光、点击、转化），以体现价值层级。比较方法包括：MTP，即仅基于似然、且对 head 和位置采用统一权重的多 Token 预测基线；MTP+VAFT，即在 MTP 基础上引入价值感知加权；MTP+DPO，即在预测奖励构造出的成对偏好上进行 preference-based fine-tuning；以及 MTP+HEPO。评价指标包括 nDCG 与 OPR。nDCG 衡量排序列表质量，并对靠前位置赋予更大权重；OPR 衡量条目对之间的排序正确比例。这两项指标均基于以 eCPM 为导向的排序结果计算。

同时，作者还报告了在固定自然日上，由仿真环境计算得到的平均 final_value 与最大 final_value。具体而言，对每个请求，仿真器生成 K 个候选，收集所有请求、所有候选

上的 `final_value` 分数, 并对整体集合进行 min-max 归一化 (因为 `final_value` 可能为正也可能为负)。出于保密考虑, 文中仅报告归一化后的值, 而不披露原始尺度。随后, 作者基于归一化值计算每个请求的平均 `final_value` (对 K 个候选取均值) 与最大 `final_value` (对 K 个候选取最大), 再在所有评估请求上聚合这些统计量。作者同时强调, 仿真环境中的 `final_value` 提升并不直接等价于线上收入提升。

结果与分析。表 3 显示, 相比基础 MTP, MTP+VAFT 将 nDCG 从 0.3868 提升到 0.3925, 将 OPR 从 0.5292 提升到 0.5348。这说明基于行为类型与归一化 eCPM 的损失加权, 能够在保持相关性的同时, 使学习更偏向高价值曝光。强化学习通过在仿真环境中评估策略生成序列, 使监督与序列级奖励对齐, 并能够安全地执行反事实探索。DPO 通过在相同上下文下偏好高价值条目, 改善了局部排序, 将 nDCG 提升到 0.4383, 同时将归一化平均 `final_value` 从 0.2412 提高到 0.2442, 将最大 `final_value` 从 0.6201 提高到 0.6659。HEPO 进一步超过 DPO, 取得 nDCG 0.4413、OPR 0.5509、平均 `final_value` 0.2630 以及最大 `final_value` 0.7619。

模型	nDCG	OPR	平均 <code>final_value</code>	最大 <code>final_value</code>
MTP (base)	0.3868	0.5292	0.2412	0.6201
+ VAFT	0.3925	0.5348	—	—
+ DPO	0.4383	0.5463	0.2442	0.6659
+ HEPO	0.4413	0.5509	0.2630	0.7619

表 3: 训练与业务对齐实验 (对应原文表 3)

4.4 在线效果

实验设置。作者在微信视频号这一拥有数亿活跃用户、数千万动态广告的生产广告平台上评估并部署 GPR。对比基线为成熟的多阶段级联系统, 该系统包含多种召回方法与定制化策略。主要线上指标包括 GMV、Costs 与 CTCVR, 其中 GMV 是首要 KPI, 因为它最直接反映业务回报。作者进行了五轮依次推进的在线 A/B 实验, 每一轮都经过严格验证, 并在主指标上相对前一版本取得统计显著且稳定的增益。具体版本如下: v0.1 为 HSD + NTP + DPO, 是 GPR 的首次部署版本; v0.2 在不使用 ARR 的条件下引入 HEPO; v0.3 增加 MTP 与 Thinking; v0.4 引入 PTD; v0.5 则在 HEPO 基础上进一步加入 ARR。

结果与分析。表 4 汇总了五轮实验的线上效果。首次大规模上线版本(HSD+NTP+DPO)带来 +2.11% 的 GMV 提升与 +3.29% 的 Costs 提升。第二轮以 HEPO 取代 DPO (但不使用 ARR) 后, 又额外带来 +0.70% 的 GMV 与 +0.36% 的 Costs 增长。之后的大规模实验继续验证了稳定的增量收益: 加入 MTP+Thinking 带来 +0.63% GMV, 加入 PTD 进一步提升, 最终加入带 ARR 的 HEPO 又带来新的 +0.58% GMV 增益。总体来看, 在保持时延与稳定性约束不变的前提下, GMV 与 GMV-Normal 在各轮实验中都持续上升, 说明 GPR 能够在生产环境中持续提升变现能力。

基于首轮上线版本 v0.1 的分层分析结果见表 5。对不同用户群体与广告群体, 系统都表现出一致收益。UG1 与 UG2 代表低活跃用户, 增益尤其明显, 例如 UG1 的 GMV 提升 3.56%, CTR 提升 2.51%, CVR 提升 0.82%, CTCVR 提升 3.72%。中等活跃组 UG3 与

UG4 在参与度和效率上也都有提升，其中 UG3 的 CTCVR 提升最高，达到 4.63%。UG5 表示高活跃用户，其 CTR 与 CVR 变化较小，但 GMV 仍提升了 3.68%，说明即使面对重度用户，系统也能够更好地将流量分配给高价值广告。对于库存层面，新上线广告（不超过 3 天）优于成熟广告（超过 3 天），GMV 增益分别为 2.97% 与 1.65%，CTCVR 增益分别为 4.02% 与 2.78%。这说明 GPR 在保持成熟广告效果的同时，对冷启动广告具有更强处理能力。

5. 相关工作

本节回顾与 GPR 相关的四个方向：作为生成式排序器的大语言模型、生成式推荐模型、端到端推荐框架以及强化学习在推荐中的应用。

作为生成式排序器的大语言模型 近两年来，研究者开始探索将大语言模型应用到推荐系统中，主要利用其生成下一条推荐结果的能力。在这类工作中，用户行为序列通常先被转换为文本序列，再由大语言模型根据这些文本输入生成下一条推荐结果。然而，这一思路的核心局限在于大语言模型具有固定词表，因此难以适应现代广告推荐场景中动态变化且规模巨大的条目集合。

生成式推荐模型 受大语言模型成功经验推动，推荐系统领域近年来显著转向生成式推荐。TIGER 使用语义 ID，并采用 sequence-to-sequence 框架生成这些语义 ID；HLLM 利用预训练大语言模型能力，通过双层结构分别建模条目表示与用户兴趣；HSTU 则采用 decoder-only 架构处理超长用户历史并生成推荐结果。这些工作表明，生成模型有潜力统一不同推荐任务并处理长用户序列。MTGR 在保留原有深度学习推荐模型特征的同时采用 HSTU 架构；COBRA 则通过级联方式结合稀疏语义 ID 与稠密向量。GPR 延续了这一生成式趋势，但提出了新的 HHD 架构。与此前将用户表示与条目生成纠缠在一起的方法不同，GPR 通过层次化结构将这两项任务解耦，并提出“理解—思考—细化—生成”的新范式。

端到端推荐框架 近期研究尝试构建更加统一的端到端推荐系统，例如 OneRec。OneRec 通过 encoder-decoder 架构与偏好对齐算法（如 DPO）统一召回与排序，并应用于视频推荐系统。相比之下，GPR 是首个成功部署到大规模广告系统中的端到端生成式方案。广告系统所面对的行为异构性与稀疏性、多目标优化、精确价值预测等挑战，都比一般内容推荐更复杂。

推荐系统中的强化学习 在传统推荐系统中，强化学习主要用于优化 slate / page 层面的决策以及长期价值，而不仅仅追求下一条条目预测精度。Seq2Slate 将重排建模为自回归的 slate 生成任务，并通过策略梯度训练，使模型可以对整个列表分配 credit，而不是将条目视为彼此独立；SlateQ 则在一定用户选择假设下，将 slate 的长期价值分解为逐条目的项，从而使基于时序差分的页面级优化可行。YouTube 等超大规模系统还引入 Top-K 离策略校正，从日志式隐反馈中学习推荐策略，并通过行为策略模型矫正数据偏差。在混合广告流场景中，强化学习的必要性更为突出，因为系统需要在平台收入、广告主 ROI 与用户体验之

间进行列表级平衡。DEAR 将广告插入视为联合决策问题，使用 DQN 优化长期价值。为了降低线上风险，工业团队通常会先从离线强化学习开始，其中一个常见方法是 Conservative Q-Learning (CQL)，它通过惩罚分布外动作来避免对未见选择的价值过估计。

生成式推荐中的强化学习 在生成式推荐中，强化学习用于将序列生成策略与用户偏好及业务偏好对齐。GeMS 学习 slate 的变分潜空间，使 RL agent 可以先在连续潜空间中动作，再解码为完整列表，从而避免组合爆炸；当人工设计奖励不够可靠时，PrefRec 先从人类或轨迹偏好中学习奖励模型，再基于该模型优化策略，以改进长期用户参与度。DPO 风格目标则进一步将成对偏好转化为稳定训练损失，可用于替代或补充后训练中的强化学习。近期一些工业系统将这些思想端到端结合，例如 OneRec-V1 用生成器与 DPO 式迭代偏好对齐统一召回与排序，并报告了 1.6% 的线上观看时长提升；OneRec-V2 则转向惰性 decoder-only 堆栈，并利用真实用户反馈上的强化学习，通过持续时长感知奖励 shaping 与自适应 ratio clipping 优化长期参与度。

6. 结论

本文提出 GPR (Generative Pre-trained Recommender) ——首个将广告推荐建模为端到端生成任务的单模型框架，以统一的生成范式替代传统多阶段级联流水线。不同于传统系统中跨阶段目标不一致与误差累积的问题，GPR 在单一整体模型中实现了全局优化与长期价值对齐。围绕统一表示、架构设计与训练策略三个方面，本文提出了系统性创新。这些进展有效应对了工业推荐系统中的长期挑战，包括异构数据建模、训练与推理之间的效率权衡，以及长期收益优化不足等问题。

大规模实验与真实线上 A/B 测试表明，GPR 在 GMV 与 CTCVR 等指标上取得显著提升。其完全生成式、统一化的设计进一步推动广告推荐系统从阶段式优化走向端到端智能决策，使系统能够以更统一、更自适应的方式理解用户意图、优化长期价值，并持续推动数字经济生态的智能化演进。

致谢

作者感谢以下人员作出的重要贡献（按字母顺序排列）：Chenchen Yu, Dekai Sun, He Wei, Jiacheng Han, Jiafan Zhou, Jingwen Wang, Junbang Huo, Juntong Yan, Ke Cheng, Longfei Lu, Roger Jin, Siao Li, Wei Cao, Yankuan Liang, Yifei Liu, Yihang Su, Yimin Wang, Zhenmao Li, Zhennan Pang。

参考文献说明

原文第 11–12 页给出了完整参考文献列表。由于参考文献主要由论文题目、作者与出版信息构成，且保持原文形式更便于后续检索，本文 PDF 中不逐条翻译参考文献，仅保留正文翻译内容。