

OneRec: 通过生成式推荐器与偏好对齐统一召回与排序

中文逐段翻译稿

Jiaxin Deng, Shiyao Wang, Kuo Cai, Lejian Ren, Qigen Hu, Weifeng Ding, Qiang Luo,
Guorui Zhou

依据用户提供论文《OneRec (快手).pdf》整理翻译

说明 本文档按照原论文的章节顺序，对正文内容进行逐段中文翻译，并尽量保留原文中的公式、算法、表格与图注信息。为避免引文条目中的作者、会议名与题名发生信息失真，文末参考文献保留原文条目，不逐项翻译。

摘要

近年来，基于生成式检索的推荐系统 (Generative Retrieval-based Recommendation Systems, GRs) 作为一种有前景的范式逐渐兴起，其核心思想是以自回归方式直接生成候选视频。然而，大多数现代推荐系统仍采用“召回 + 排序”的策略，在这一框架下，生成模型通常只在召回阶段充当候选选择器。本文提出 OneRec，用统一的生成模型替代级联式学习框架。据我们所知，这是首个在真实工业场景中能够显著超过当前复杂且精心设计推荐系统的端到端生成式模型。具体而言，OneRec 包含以下几个方面：1) 编码器 - 解码器结构，用于对用户历史行为序列进行编码，并逐步解码出用户可能感兴趣的视频。我们采用稀疏混合专家 (Sparse Mixture-of-Experts, MoE) 以扩展模型容量，同时避免计算 FLOPs 按比例增长。2) 会话级生成方法。与传统的下一物品预测不同，我们提出会话级生成方式；相较于依赖人工规则将点对点生成结果进行组合的做法，该方法更加自然，也更具有上下文一致性。3) 结合直接偏好优化 (Direct Preference Optimization, DPO) 的迭代偏好对齐模块，用于提升生成结果质量。不同于自然语言处理中的 DPO，推荐系统对每次用户浏览请求通常只有一次展示机会，因此无法同时获得正样本与负样本。为解决这一限制，我们设计了奖励模型来模拟用户反馈，并根据推荐系统在线学习的属性定制采样策略。大量实验表明，只需少量 DPO 样本，就能够对齐用户兴趣偏好，并显著提升生成结果质量。我们已将 OneRec 部署到快手主场景中；快手是一个日活用户数以亿计的短视频推荐平台。线上结果显示，OneRec 将观看时长提升了 1.6%，取得了显著收益。

1 引言

为了在效率与效果之间取得平衡，大多数现代推荐系统采用级联排序策略。图 1(b) 所示的典型级联排序系统通常包含三阶段流水线：召回、粗排和精排。每一个阶段负责从输

从物品集合中选出 top- k 结果并传递给下一阶段，从而在系统响应时延与排序精度之间实现整体折中。

尽管这一范式在实践中较为高效，但现有方法通常将各级排序器视为相互独立的模块，其中每个独立阶段的效果都会成为后续阶段性能的上界，从而限制了整个排序系统的最终表现。尽管已有一些工作尝试通过增强不同排序器之间的交互来提升整体推荐性能，但它们本质上仍然维持了传统的级联排序范式。近年来，生成式检索推荐系统（GRs）作为一种新兴范式受到关注，其通过自回归序列生成方式直接生成候选物品标识符。通过使用量化后的语义 ID 对物品进行索引，推荐模型能够利用物品内部蕴含的丰富语义信息。生成式检索天然适合通过 beam search 解码直接选择候选物品，并输出更具多样性的推荐结果。然而，当前生成模型仍主要扮演召回阶段的选择器角色，因为它们的推荐精度尚不能达到精心设计的多级级联排序系统的水平。

为了解决上述挑战，我们提出一种用于单阶段推荐的统一端到端生成框架 OneRec。首先，我们设计了编码器 - 解码器架构。受大语言模型训练中 scaling law 的启发，我们发现扩展推荐模型容量同样能够稳定提升性能。因此，我们基于 MoE 结构扩展模型参数规模，从而显著增强模型刻画用户兴趣的能力。其次，与传统逐点预测下一物品的方法不同，我们提出会话级列表生成方式，使模型能够同时考虑同一会话中各个物品的相对内容与排列顺序。逐点生成方法通常需要手工策略来保证生成结果的连贯性和多样性；相比之下，会话级学习过程通过向模型输入高质量偏好数据，使模型能够自动学习最优会话结构。最后，我们探索了基于 DPO 的偏好学习，以进一步提升生成结果质量。在构建偏好对时，我们借鉴 hard negative sampling 的思想，不采用随机采样，而是从 beam search 结果中构造自困难（self-hard）的拒绝样本。进一步地，我们提出迭代偏好对齐（Iterative Preference Alignment, IPA）策略，根据预训练奖励模型（Reward Model, RM）打分对采样响应排序，选出最佳 “chosen” 样本与最差 “rejected” 样本。基于大规模工业数据集的实验表明，该方法具有显著优越性。

本文的主要贡献如下：

- 为突破级联排序的局限，本文提出 OneRec，一种单阶段生成式推荐框架。据我们所知，这是工业界最早一批能够使用统一生成模型处理物品推荐、并显著超过传统多阶段排序流水线的方案之一。
- 我们通过会话级生成方式强调了模型容量与目标物品上下文信息的重要性，该方式既提高了预测准确性，也增强了生成物品的多样性。
- 我们提出一种基于个性化奖励模型的自困难负样本选择策略，并结合直接偏好优化，提高了 OneRec 在更广泛用户偏好上的泛化能力。大量离线实验与线上 A/B 测试验证了该方法的有效性与效率。

图 1（原图略） 图 1(a) 展示了本文提出的统一端到端生成架构；图 1(b) 展示了典型级联排序系统的三阶段结构，包括召回、粗排和精排。

2 相关工作

2.1 生成式推荐

近年来，随着生成模型的快速发展，生成式推荐逐渐受到越来越多关注。不同于传统基于嵌入的召回方法，后者通常依赖双塔模型计算候选物品的相关性分数，并借助高效的 MIPS 或 ANN 搜索系统检索 top- k 相关物品，生成式检索 (Generative Retrieval, GR) 则将数据库中相关文档的检索问题表述为一个序列生成任务，通过逐步生成相关文档 token 的方式完成检索。这些文档 token 可以是文档标题、文档 ID，或者预训练语义 ID。GENRE 首次采用 Transformer 架构进行实体检索，在给定上下文条件下，以自回归方式生成实体名称。DSI 首次提出为文档分配结构化语义 ID，并训练编码器 - 解码器模型用于生成式文档检索。沿着这一思路，TIGER 将生成式物品检索模型正式引入推荐系统。

除了生成框架本身，如何对物品进行索引也同样受到广泛关注。近期研究主要聚焦于语义索引技术，其目标是根据内容信息为物品构造索引。具体而言，TIGER 与 LC-Rec 将残差量化 (RQ-VAE) 应用于由物品标题和描述得到的文本嵌入，以实现 token 化；Recforest 则对物品文本嵌入进行分层 k-means 聚类，并将聚类索引作为 token；此外，EAGER 等近期工作还探索了在 token 化过程中联合引入语义信息与协同过滤信息。

2.2 语言模型的偏好对齐

在大语言模型的后训练阶段，基于人类反馈的强化学习 (Reinforcement Learning from Human Feedback, RLHF) 是一种主流方法，其通过奖励模型刻画人类反馈，并利用强化学习技术使模型与人类价值观对齐。然而，RLHF 存在训练不稳定和效率较低等问题。DPO 由此被提出，该方法可在闭式形式下推导最优策略，并直接使用偏好数据进行优化。在此基础上，又出现了多种变体以进一步改进原始 DPO。例如，IPO 使用更一般的目标函数，规避了 DPO 中的两个近似；cDPO 通过引入超参数 ϵ 缓解噪声标签带来的影响；rDPO 则设计了对原始二元交叉熵损失的无偏估计。除此之外，CPO、simDPO 等方法也从不同角度增强或扩展了 DPO。

然而，与传统自然语言处理任务中由人工显式标注偏好数据不同，推荐系统中的偏好学习面临一个独特挑战，即用户 - 物品交互数据极度稀疏。因此，如何将 DPO 适配到推荐场景中，仍然远未被充分探索。与主要关注在基于语言模型的推荐器中引入多负样本偏好数据的 S-DPO 不同，本文训练了一个奖励模型，并依据奖励模型输出的分数，为不同用户选择个性化偏好数据。

3 方法

本节提出 OneRec，这是一种通过单阶段检索方式直接生成目标物品的端到端框架。第 3.1 节首先从特征工程角度介绍工业场景下单阶段生成式推荐流水线的构建方式；第 3.2 节

正式定义会话级生成任务，并给出 OneRec 模型架构；第 3.3 节进一步介绍基于个性化奖励模型的自困难负样本采样方法，以及如何通过 DPO 迭代提升模型性能。OneRec 的整体框架如图 2 所示。

图 2 (原图略) 图 2 展示了 OneRec 的整体框架，包含两个阶段：其一是会话训练阶段，利用会话级数据训练 OneRec；其二是 IPA 阶段，通过带有自困难负样本的迭代式直接偏好优化进一步提升模型效果。

3.1 预备知识

本节从特征工程角度介绍单阶段生成式推荐流水线的构建方式。对于用户侧特征，OneRec 将用户的正向历史行为序列 $H_u = \{v_1^h, v_2^h, \dots, v_n^h\}$ 作为输入，其中 v 表示用户有效观看或发生交互（点赞、关注、分享）的视频， n 为行为序列长度。OneRec 的输出是一个视频列表，即一个会话 $S = \{v_1, v_2, \dots, v_m\}$ ，其中 m 为一个会话内的视频数量。关于“会话”的详细定义见第 3.2 节。

对于每一个视频 v_i ，我们使用与真实用户 - 物品行为分布对齐的多模态嵌入 $e_i \in \mathbb{R}^d$ 对其进行表示。现有生成式推荐框架通常在预训练多模态表示的基础上，使用 RQ-VAE 将嵌入编码为语义 token。然而，这种方法由于编码分布不平衡，会出现所谓的“沙漏现象” (hourglass phenomenon)，因此并非最优。本文采用多层均衡量化机制，利用残差 K-means 量化算法对 e_i 进行变换。当第一层 ($l = 1$) 时，初始残差定义为 $r_i^1 = e_i$ 。在每一层 l 上，我们都有一个码本 $C_l = \{c_1^l, \dots, c_K^l\}$ ，其中 K 为码本大小。最接近的聚类中心索引通过

$$s_i^l = \arg \min_k \|r_i^l - c_k^l\|_2^2 \quad (1)$$

得到，而下一层 $l + 1$ 的残差则定义为

$$r_i^{l+1} = r_i^l - c_{s_i^l}^l. \quad (2)$$

因此，相应的码本 token 可通过如下分层索引方式生成：

$$s_i^1 = \arg \min_k \|r_i^1 - c_k^1\|_2^2, \quad r_i^2 = r_i^1 - c_{s_i^1}^1, \quad (3)$$

$$s_i^2 = \arg \min_k \|r_i^2 - c_k^2\|_2^2, \quad r_i^3 = r_i^2 - c_{s_i^2}^2, \quad (4)$$

⋮

$$s_i^L = \arg \min_k \|r_i^L - c_k^L\|_2^2. \quad (6)$$

其中 L 为语义 ID 的总层数。

为了构造平衡码本 $C_l = \{c_1^l, \dots, c_K^l\}$ ，我们采用算法 1 所示的 Balanced K-means 对物品集合进行划分。给定全部视频集合 V ，该算法将其划分为 K 个簇，且每个簇都恰好包含 $w = |V|/K$ 个视频。在迭代过程中，每个质心按顺序分配其最近的、尚未被分配的 w 个视

频，然后使用这些已分配视频的均值向量重新计算质心。当簇分配结果收敛时，算法终止。

算法 1: 平衡 K-means 聚类

输入: 物品集合 V ，聚类数 K 。

1. 计算 $w \leftarrow |V|/K$;
2. 通过随机选择初始化质心 $C_l = \{c_1^l, \dots, c_K^l\}$;
3. 重复以下过程直到分配结果收敛:
 - 3.1. 初始化未分配集合 $U \leftarrow V$;
 - 3.2. 对每个簇 $k \in \{1, \dots, K\}$:
 - 3.2.1. 按照与质心 c_k^l 的欧氏距离从小到大对 U 排序;
 - 3.2.2. 分配 $V_k \leftarrow U[0 : w - 1]$;
 - 3.2.3. 用已分配样本的均值更新质心:

$$c_k^l \leftarrow \frac{1}{w} \sum_{r^l \in V_k} r^l;$$

- 3.2.4. 将已分配样本从未分配集合中移除: $U \leftarrow U \setminus V_k$ 。

输出: 优化后的码本 $C_l = \{c_1^l, \dots, c_K^l\}$ 。

3.2 会话级列表生成

与传统只预测下一个视频的逐点推荐方法不同，会话级生成旨在根据用户历史交互序列生成高价值会话列表，从而使推荐模型能够捕获推荐列表中视频之间的依赖关系。具体来说，会话是指针对一次用户请求返回的一批短视频，通常包含 5 到 10 个视频。一个会话中的视频一般会同时考虑用户兴趣、一致性与多样性等因素。为识别高质量会话，本文设计了如下若干准则：

- 用户在该会话中实际观看的短视频数量不少于 5 个；
- 用户观看该会话的总时长超过某一阈值；
- 用户对会话中的视频产生了交互行为，例如点赞、收藏或分享。

这一做法确保我们的会话级模型能够从真实用户参与模式中学习，并捕获会话列表中更准确的上下文信息。因此，会话级模型 M 的目标可以形式化表示为

$$S := M(H_u), \tag{7}$$

其中 H_u 用语义 ID 表示为

$$H_u = \{(\mathbf{s}_1^1, \mathbf{s}_1^2, \dots, \mathbf{s}_1^L), (\mathbf{s}_2^1, \mathbf{s}_2^2, \dots, \mathbf{s}_2^L), \dots, (\mathbf{s}_n^1, \mathbf{s}_n^2, \dots, \mathbf{s}_n^L)\},$$

而

$$S = \{(\mathbf{s}_1^1, \mathbf{s}_1^2, \dots, \mathbf{s}_1^L), (\mathbf{s}_2^1, \mathbf{s}_2^2, \dots, \mathbf{s}_2^L), \dots, (\mathbf{s}_m^1, \mathbf{s}_m^2, \dots, \mathbf{s}_m^L)\}.$$

如图 2(a) 所示, 与 T5 架构一致, 本文模型采用基于 Transformer 的编码器 - 解码器框架。具体而言, 编码器使用堆叠的多头自注意力层与前馈层对输入序列 H_u 进行建模。记编码后的历史交互特征为

$$H = \text{Encoder}(H_u). \quad (8)$$

解码器以目标会话的语义 ID 为输入, 并以自回归方式生成目标列表。为了在合理的经济成本下训练更大规模模型, 我们在解码器中的前馈神经网络 (FFN) 部分采用了 Transformer 语言模型中常见的 MoE 架构, 将第 l 层 FFN 替换为:

$$H_t^{l+1} = \sum_{i=1}^{N_{\text{MoE}}} \left(g_{i,t} \text{FFN}_i(H_t^l) \right) + H_t^l, \quad (9)$$

$$g_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} \in \text{Topk}(\{s_{j,t} \mid 1 \leq j \leq N\}, K_{\text{MoE}}), \\ 0, & \text{otherwise}, \end{cases} \quad (10)$$

$$s_{i,t} = \text{Softmax}_i((H_t^l)^\top e_i^l), \quad (11)$$

其中 N_{MoE} 表示专家总数, $\text{FFN}_i(\cdot)$ 表示第 i 个专家前馈网络, $g_{i,t}$ 表示第 i 个专家的门控值。由于 $g_{i,t}$ 是稀疏的, 即在 N_{MoE} 个专家中仅有 K_{MoE} 个门控值非零, 因此 MoE 层具有较好的计算效率, 每个 token 仅需被路由到并计算于这 K_{MoE} 个专家中。

在训练阶段, 我们在各组编码前加入起始 token $\mathbf{s}_{[\text{BOS}]}$, 从而构造解码器输入:

$$\bar{S} = \{\mathbf{s}_{[\text{BOS}]}, \mathbf{s}_1^1, \mathbf{s}_1^2, \dots, \mathbf{s}_1^L, \mathbf{s}_{[\text{BOS}]}, \mathbf{s}_2^1, \mathbf{s}_2^2, \dots, \mathbf{s}_2^L, \dots, \mathbf{s}_{[\text{BOS}]}, \mathbf{s}_m^1, \mathbf{s}_m^2, \dots, \mathbf{s}_m^L\}. \quad (12)$$

我们在目标会话的语义 ID 上使用交叉熵损失进行 next-token prediction, 其损失函数 L_{NTP} 定义为:

$$L_{\text{NTP}} = - \sum_{i=1}^m \sum_{j=1}^L \log P\left(\mathbf{s}_i^{j+1} \mid [\mathbf{s}_{[\text{BOS}]}, \mathbf{s}_1^1, \mathbf{s}_1^2, \dots, \mathbf{s}_1^L, \dots, \mathbf{s}_{[\text{BOS}]}, \mathbf{s}_i^1, \dots, \mathbf{s}_i^j]; \Theta\right). \quad (13)$$

经过一段时间的会话级列表生成任务训练后, 我们获得种子模型 M_t 。

3.3 结合奖励模型的迭代偏好对齐

第 3.2 节定义的高质量会话能够为训练提供高价值数据, 使模型学习“什么样的会话是好的”, 从而保证生成视频质量。在此基础上, 本文进一步通过 DPO 增强模型能力。在

传统 NLP 场景中, 偏好数据通常由人工显式标注; 而推荐系统中的偏好学习由于用户 - 物品交互数据稀疏这一特性, 需要借助奖励模型。因此, 第 3.3.1 节介绍会话级奖励模型; 第 3.3.2 节在此基础上提出一种迭代式 DPO 训练策略, 使模型能够持续自我改进。

3.3.1 奖励模型训练

我们用 $R(\mathbf{u}, S)$ 表示为不同用户选择偏好数据的奖励模型, 其中输出 r 表示用户 u 对会话 $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m\}$ 的偏好程度。为了使 RM 具备对会话进行排序的能力, 我们首先提取会话中每个物品 $\mathbf{v}_i$ 的**目标感知**表示:

$$\mathbf{e}_i = \mathbf{v}_i \odot \mathbf{u}, \quad (14)$$

其中 $\odot$ 表示目标感知操作, 例如针对用户行为的 target attention。于是, 会话 S 对应的目标感知表示可写为 $\mathbf{h} = \{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_m\}$ 。随后, 会话内物品通过**自注意力层相互交互**, 以融合不同物品间的必要信息:

$$\mathbf{h}_f = \text{SelfAttention}(\mathbf{h}W_s^Q, \mathbf{h}W_s^K, \mathbf{h}W_s^V). \quad (15)$$

接着, 我们**使用不同的 tower 对多个目标奖励进行预测**, 并利用大量推荐数据对 RM 进行预训练:

$$\hat{r}_{\text{swt}} = \text{Tower}_{\text{swt}}(\text{Sum}(\mathbf{h}_f)), \quad \hat{r}_{\text{vtr}} = \text{Tower}_{\text{vtr}}(\text{Sum}(\mathbf{h}_f)), \quad (16)$$

$$\hat{r}_{\text{wtr}} = \text{Tower}_{\text{wtr}}(\text{Sum}(\mathbf{h}_f)), \quad \hat{r}_{\text{ltr}} = \text{Tower}_{\text{ltr}}(\text{Sum}(\mathbf{h}_f)), \quad (17)$$

其中

$$\text{Tower}(\cdot) = \text{Sigmoid}(\text{MLP}(\cdot)). \quad (18)$$

在得到各个会话的估计奖励 $\hat{r}_{\text{swt}}, \dots$ 以及真实标签 $y_{\text{swt}}, \dots$ 后, 我们通过最小化二元交叉熵损失训练 RM, 其损失函数 L_{RM} 为:

$$L_{\text{RM}} = - \sum_{x \in \{\text{swt}, \text{vtr}, \text{wtr}, \text{ltr}\}} [y_x \log(\hat{r}_x) + (1 - y_x) \log(1 - \hat{r}_x)]. \quad (19)$$

3.3.2 迭代偏好对齐

基于预训练好的奖励模型 $R(\mathbf{u}, S)$ 和当前 OneRec 模型 M_t , 我们首先对每个用户通过 beam search 生成 N 个不同响应:

$$S_u^n \sim M_t(H_u), \quad \forall u \in U, n \in [N], \quad (20)$$

其中 $[N]$ 表示集合 $\{1, 2, \dots, N\}$ 。

随后，利用奖励模型 $R(\mathbf{u}, S)$ 为每一个响应计算奖励：

$$r_u^n = R(\mathbf{u}, S_u^n). \quad (21)$$

接着，我们通过选择奖励值最高的“胜者”响应 (S_u^w, H_u) 和奖励值最低的“败者”响应 (S_u^l, H_u) ，构造偏好对数据集 $D_t^{\text{pairs}} = (S_u^w, S_u^l, H_u)$ 。在给定这些偏好对后，我们训练新模型 M_{t+1} ；该模型以 M_t 初始化，并使用结合 DPO 损失的目标函数从偏好对中学习。对每个偏好对，其 DPO 损失写为：

$$L_{\text{DPO}} = L_{\text{DPO}}(S_u^w, S_u^l \mid H_u) \quad (22)$$

$$= -\log \sigma \left(\beta \log \frac{M_{t+1}(S_u^w \mid H_u)}{M_t(S_u^w \mid H_u)} - \beta \log \frac{M_{t+1}(S_u^l \mid H_u)}{M_t(S_u^l \mid H_u)} \right). \quad (23)$$

如算法 2 与图 2(b) 所示，整体训练过程会依次得到模型序列 $M_t, \dots, M_T$ 。为降低 beam search 推理带来的计算负担，我们仅对随机采样得到的 $r_{\text{DPO}} = 1\%$ 数据执行偏好对齐。每一个后续模型 M_{t+1} 都以前一轮模型 M_t 为初始化，并使用由 M_t 生成的偏好数据 D_t^{pairs} 进行训练。

算法 2：迭代偏好对齐 (IPA)

输入： 响应数量 N ，预训练奖励模型 $R(\mathbf{u}, S)$ ，种子模型 M_t ，DPO 采样比例 r_{DPO} ，总训练轮数 T ，每轮样本数 N_{sample} 。

1. 对于 epoch = t 到 T ：
 - 1.1. 对于 sample = 1 到 N_{sample} ：
 - 1.1.1. 若 $\text{rand}() < r_{\text{DPO}}$ ，则：
 - 1.1.1.1. 利用 M_t 生成 N 个响应；
 - 1.1.1.2. 对每个响应 S_u^i 计算奖励 $r_u^i \leftarrow R(\mathbf{u}, S_u^i)$ ；
 - 1.1.1.3. 选择奖励最高的响应 S_u^w 与奖励最低的响应 S_u^l ；
 - 1.1.1.4. 计算联合损失 $L \leftarrow L_{\text{NTP}} + \lambda L_{\text{DPO}}$ 。
 - 1.1.2. 否则，仅计算 $L \leftarrow L_{\text{NTP}}$ 。
 - 1.1.3. 使用梯度下降更新参数： $\Theta \leftarrow \Theta - \alpha \nabla_{\Theta} L$ 。
 - 1.2. 更新模型快照： $M_{t+1} \leftarrow M_t$ 。

输出： 优化后的参数 Θ 。

4 系统部署

OneRec 已成功部署于真实工业场景中。为了兼顾稳定性与性能，我们在线上服务中部署 OneRec-1B。图 3 所示的部署架构包含三个核心组件：1) 训练系统，2) 在线服务系统，

3) DPO 采样服务器。系统首先处理收集到的交互日志，将其作为训练数据，初始阶段采用 next-token prediction 目标 L_{NTP} 训练种子模型。待模型收敛后，再加入 DPO 损失 L_{DPO} 进行偏好对齐，并结合 XLA 与 bfloat16 混合精度训练，以优化计算效率与显存利用率。训练得到的参数会同步到在线推理模块和 DPO 采样服务器，用于实时服务与基于偏好的数据选择。为提升推理性能，本文实现了两项关键优化：其一是结合 float16 量化的 key-value cache 解码机制，以降低 GPU 显存开销；其二是将 beam size 设置为 128，以在生成质量与推理时延之间取得平衡。此外，受益于 MoE 架构，在线推理时仅有 13% 的参数会被激活。

图 3 (原图略) 图 3 展示了 OneRec 的在线部署框架，包括 DPO 采样服务器、奖励模型、离线训练器与在线推理模块之间的参数同步与数据流。

5 实验

本节首先在离线设置下，将 OneRec 与逐点方法以及多种 DPO 变体进行比较；随后通过消融实验验证 OneRec 各模块的有效性；最后将 OneRec 部署到线上，在快手平台进行 A/B 测试，进一步验证其性能。

5.1 实验设置

5.1.1 实现细节

我们的模型使用 Adam 优化器进行训练，初始学习率设置为 2×10^{-4} 。OneRec 的训练使用 NVIDIA A800 GPU。训练过程中，DPO 采样比例 r_{DPO} 固定设置为 1%，并通过 beam search 为每个用户生成 $N = 128$ 个不同响应。语义标识符聚类过程中，每个码本层使用 $K = 8192$ 个簇，码本层数设置为 $L = 3$ 。MoE 架构包含 $N_{\text{MoE}} = 24$ 个专家，并在每次前向传播时通过 top- k 选择激活 $K_{\text{MoE}} = 2$ 个专家。对于会话建模，我们设置目标会话项数 $m = 5$ ，并采用 $n = 256$ 条历史行为作为上下文。

5.1.2 基线方法

本文选取以下具有代表性的推荐模型以及 DPO 及其变体作为对照基线：

- **SASRec**：使用单向 Transformer 架构对用户 - 物品交互中的序列依赖进行建模，以完成下一物品预测。
- **BERT4Rec**：利用双向 Transformer 与掩码语言模型，通过序列重建学习上下文化物品表示。
- **FDSA**：在异构推荐场景中通过双自注意力通路联合建模物品层转移模式和特征层变换模式。

- **TIGER**: 利用分层语义标识符与生成式检索技术, 通过自回归序列生成实现序列推荐。
- **DPO**: 通过由人类反馈数据隐式导出的闭式奖励函数来形式化偏好优化。
- **IPO**: 提出一种具有理论基础的偏好优化框架, 规避标准 DPO 中的近似问题。
- **cDPO**: 引入标签翻转率参数 ϵ , 以增强对噪声偏好标注的鲁棒性。
- **rDPO**: 通过重要性采样构造无偏损失估计, 以降低偏好优化中的方差。
- **CPO**: 将对比学习与偏好优化统一起来, 联合训练序列似然奖励与监督微调目标。
- **simPO**: 通过基于序列级奖励间隔的优化方式, 在消除参考模型依赖的同时进行偏好优化。
- **S-DPO**: 针对推荐系统改造 DPO, 引入 hard negative sampling 与多物品对比学习以提升排序精度。

5.1.3 评价指标

本文使用多个关键指标评估模型性能。每个指标从不同角度衡量模型输出效果, 并在每次迭代中于随机采样的测试样本上进行评估。为了估计不同用户 - 会话对下各种交互发生的概率, 我们使用预训练奖励模型对推荐会话的价值进行打分, 并计算不同目标的平均奖励, 包括会话观看时长 (swt)、播放概率 (vtr)、关注概率 (wtr) 与点赞概率 (ltr)。其中, swt 与 vtr 属于观看时长类指标, 而 wtr 与 ltr 属于交互类指标。

5.2 离线性能

表 1 给出了 OneRec 与多种基线方法的综合对比结果。对于观看类指标, 我们主要关注会话观看时长 (swt); 对于交互类指标, 则重点关注点赞概率 (ltr)。结果呈现出以下三个关键观察:

第一, 本文提出的会话级生成方式显著优于传统的点积式方法和 TIGER 这类逐点生成方法。与 TIGER-1B 相比, OneRec-1B 在最大 swt 上提升了 1.78%, 在最大 ltr 上提升了 3.36%。这表明, 会话级建模在保持推荐结果上下文连贯性方面具有明显优势, 而逐点方法则难以同时兼顾生成结果的一致性与多样性。

第二, 只需较小比例的 DPO 训练就能带来显著收益。在仅使用 1% DPO 训练比例 (r_{DPO}) 时, OneRec-1B+IPA 相对于基础版 OneRec-1B 在最大 swt 上提升了 4.04%, 在最大 ltr 上提升了 5.43%。这说明即使是有限的 DPO 训练, 也足以有效地将模型对齐到目标生成模式上。

第三, 本文提出的 IPA 策略优于多种现有 DPO 变体。表 1 显示, IPA 相比其他 DPO 实现取得了更好的表现。值得注意的是, 部分 DPO 基线甚至不如未进行偏好对齐的 OneRec-1B, 这表明, 相较于其他方法, 利用模型自生成输出进行迭代式偏好挖掘与选择更加有效。

表 1: OneRec 与多类基线方法的离线性能比较。带 $\uparrow$ 表示越大越好。

模型	swt $\uparrow$		vtr $\uparrow$		wtr $\uparrow$		ltr $\uparrow$	
	mean	max	mean	max	mean	max	mean	max
<i>Pointwise Discriminative Method</i>								
SASRec	0.0375 $\pm$ 0.002	0.0803 $\pm$ 0.005	0.4313 $\pm$ 0.013	0.5801 $\pm$ 0.013	0.00294 $\pm$ 0.001	0.00978 $\pm$ 0.001	0.0314 $\pm$ 0.002	0.0604 $\pm$ 0.004
BERT4Rec	0.0336 $\pm$ 0.002	0.0706 $\pm$ 0.004	0.4192 $\pm$ 0.014	0.5633 $\pm$ 0.013	0.00281 $\pm$ 0.001	0.00932 $\pm$ 0.001	0.0316 $\pm$ 0.002	0.0606 $\pm$ 0.004
FDSA	0.0325 $\pm$ 0.002	0.0683 $\pm$ 0.005	0.4145 $\pm$ 0.015	0.5588 $\pm$ 0.014	0.00271 $\pm$ 0.001	0.00921 $\pm$ 0.001	0.0313 $\pm$ 0.002	0.0604 $\pm$ 0.003
<i>Pointwise Generative Method</i>								
TIGER-0.1B	0.0879 $\pm$ 0.007	0.1286 $\pm$ 0.010	0.5826 $\pm$ 0.016	0.6625 $\pm$ 0.017	0.00277 $\pm$ 0.001	0.00671 $\pm$ 0.001	0.0316 $\pm$ 0.004	0.0541 $\pm$ 0.007
TIGER-1B	0.0873 $\pm$ 0.006	0.1368 $\pm$ 0.010	0.5827 $\pm$ 0.015	0.6776 $\pm$ 0.015	0.00292 $\pm$ 0.001	0.00758 $\pm$ 0.001	0.0323 $\pm$ 0.004	0.0579 $\pm$ 0.008
<i>Listwise Generative Method</i>								
OneRec-0.1B	0.0973 $\pm$ 0.010	0.1501 $\pm$ 0.015	0.6001 $\pm$ 0.021	0.6981 $\pm$ 0.021	0.00326 $\pm$ 0.001	0.00870 $\pm$ 0.001	0.0349 $\pm$ 0.009	0.0642 $\pm$ 0.015
OneRec-1B	0.0991 $\pm$ 0.008	0.1529 $\pm$ 0.012	0.6039 $\pm$ 0.020	0.7013 $\pm$ 0.020	0.00349 $\pm$ 0.001	0.00919 $\pm$ 0.002	0.0360 $\pm$ 0.005	0.0660 $\pm$ 0.008
<i>Listwise Generative Method with Preference Alignment</i>								
OneRec-1B+DPO	0.1014 $\pm$ 0.010	0.1595 $\pm$ 0.015	0.6127 $\pm$ 0.017	0.7116 $\pm$ 0.016	0.00339 $\pm$ 0.001	0.00896 $\pm$ 0.001	0.0351 $\pm$ 0.004	0.0644 $\pm$ 0.008
OneRec-1B+IPO	0.0979 $\pm$ 0.003	0.1528 $\pm$ 0.005	0.6000 $\pm$ 0.007	0.7012 $\pm$ 0.007	0.00335 $\pm$ 0.001	0.00905 $\pm$ 0.001	0.0350 $\pm$ 0.003	0.0654 $\pm$ 0.004
OneRec-1B+cDPO	0.0993 $\pm$ 0.006	0.1547 $\pm$ 0.008	0.6030 $\pm$ 0.011	0.7030 $\pm$ 0.009	0.00339 $\pm$ 0.001	0.00901 $\pm$ 0.001	0.0355 $\pm$ 0.006	0.0652 $\pm$ 0.009
OneRec-1B+rDPO	0.1005 $\pm$ 0.006	0.1555 $\pm$ 0.008	0.6071 $\pm$ 0.014	0.7059 $\pm$ 0.011	0.00339 $\pm$ 0.001	0.00899 $\pm$ 0.001	0.0357 $\pm$ 0.004	0.0657 $\pm$ 0.006
OneRec-1B+CPO	0.0993 $\pm$ 0.008	0.1538 $\pm$ 0.012	0.6045 $\pm$ 0.021	0.7029 $\pm$ 0.018	0.00343 $\pm$ 0.001	0.00911 $\pm$ 0.002	0.0357 $\pm$ 0.008	0.0659 $\pm$ 0.014
OneRec-1B+simPO	0.0995 $\pm$ 0.008	0.1536 $\pm$ 0.013	0.6047 $\pm$ 0.016	0.7022 $\pm$ 0.015	0.00349 $\pm$ 0.001	0.00918 $\pm$ 0.001	0.0360 $\pm$ 0.005	0.0659 $\pm$ 0.008
OneRec-1B+S-DPO	0.1021 $\pm$ 0.008	0.1575 $\pm$ 0.013	0.6096 $\pm$ 0.016	0.7070 $\pm$ 0.015	0.00345 $\pm$ 0.001	0.00909 $\pm$ 0.001	0.0361 $\pm$ 0.004	0.0659 $\pm$ 0.008
OneRec-1B+IPA	0.1025 $\pm$ 0.009	0.1933 $\pm$ 0.017	0.6141 $\pm$ 0.020	0.7646 $\pm$ 0.021	0.00354 $\pm$ 0.001	0.00992 $\pm$ 0.001	0.0397 $\pm$ 0.004	0.1203 $\pm$ 0.010

5.3 消融实验

5.3.1 DPO 采样比例消融

为了研究 DPO 训练中采样比例 r_{DPO} 的影响，本文在控制条件下将 DPO 采样比例从 1% 变化到 5%。图 4 的消融结果表明，随着采样比例增加，不同评价目标上的性能提升都较为有限。值得注意的是，即使计算开销增大，超过 1% 基线后的性能收益仍然并不显著。文中还指出，DPO 采样服务器推理阶段的 GPU 资源利用与采样比例近似呈线性关系：5% 采样比例约需要 1% 基线的 5 倍 GPU 资源。因此，在综合权衡计算效率与模型性能之后，本文最终采用 1% DPO 采样比例进行训练；这一设置能够达到观测到的最大性能约 95%，但只需要高采样比例方案约 20% 的计算资源。

图 4 (原图略) 图 4 展示了 DPO 采样比例 r_{DPO} 的消融实验结果。结论是：1% 的 DPO 训练比例已经能够带来显著收益，而进一步提高采样比例带来的提升较为有限。

5.3.2 模型规模消融

我们进一步评估了 OneRec 在模型规模提升时的表现。图 6 表明，当 OneRec 从 0.05B 扩展到 1B 时，模型精度稳定提升，体现出较好的 scaling 特性。具体地，与 OneRec-0.05B 相比，OneRec-0.1B 在准确率上取得了显著的 14.45% 最大增益；当模型继续扩展到 0.2B、0.5B 和 1B 时，还能分别额外获得 5.09%、5.70% 和 5.69% 的性能提升。

5.4 OneRec 的预测动态

如图 5 所示，本文给出了 8192 个语义 ID code 在不同层上的 softmax 输出概率分布，其中红色星号表示奖励值最高的物品对应的语义 ID。与 OneRec 基线相比，OneRec+IPA 在预测分布上呈现出显著的置信度迁移，这说明本文提出的偏好对齐策略能够有效促使基础模型产生更符合偏好的生成模式。

进一步地，作者观察到第一层的概率分布具有更大的发散程度（熵为 6.00），而后续层的分布则逐渐集中（第二层平均熵为 3.71，第三层熵为 0.048）。这种分层不确定性递减现象可归因于自回归解码机制：第一层的预测继承了前序解码步骤中的较高不确定性，而后续层则受益于不断累积的上下文信息，从而使决策空间逐渐收缩。

图 5 (原图略) 图 5 为各层语义 ID 的 softmax 概率分布可视化，红色星号表示奖励值最高物品的语义 ID。

图 6 (原图略) 图 6 展示了 OneRec 随模型参数规模增加而获得的持续性能提升。

5.5 线上 A/B 测试

为了评估 OneRec 的线上效果，本文在快手主页面视频推荐场景中进行了严格的线上 A/B 测试，并使用 1% 主流量对 OneRec 与当前多阶段推荐系统进行对比。评价指标包括总观看时长 (Total Watch Time)，即用户观看视频所花费的总时间，以及平均观看时长 (Average View Duration)，即用户在一次推荐请求所曝光的会话中，平均每个视频的观看时长。线上评估结果表明，OneRec 在总观看时长上提升了 1.68%，在平均观看时长上提升了 6.56%。这一结果表明，OneRec 能够显著改善推荐效果，并为平台带来可观收益增长。

表 2: OneRec 相对于当前多阶段系统在在线 A/B 测试中的绝对提升。

模型	总观看时长	平均观看时长
OneRec-0.1B	+0.57%	+4.26%
OneRec-1B	+1.21%	+5.01%
OneRec-1B+IPA	+1.68%	+6.56%

6 结论

本文聚焦于单阶段生成式推荐的工业级解决方案。整体而言，本文建立了三方面关键贡献。首先，借助 MoE 架构，在保持较高计算效率的同时有效扩展模型参数规模，为大规模工业推荐提供了一种可扩展蓝图。其次，作者发现，以会话级生成方式对目标物品的上下文信息进行建模是必要的，这证明了上下文序列建模相比孤立的逐点建模，更能内在地捕获用户偏好动态。再次，本文提出了迭代偏好对齐 (IPA) 策略，以提高 OneRec 在多样化用户偏好模式下的泛化能力。大量离线实验与线上 A/B 测试验证了 OneRec 的有效性与效率。

此外，作者对线上结果的分析还表明，除用户观看时长之外，该模型在点赞等交互指标上仍存在一定局限。未来工作将致力于增强端到端生成式推荐在多目标建模方面的能力，以进一步提升用户体验。

参考文献 (保留原文)

- [1] Mohammad Gheshlaghi Azar, Zhaohan Daniel Guo, Bilal Piot, Remi Munos, Mark Rowland, Michal Valko, and Daniele Calandriello. 2024. A general theoretical paradigm to understand learning from human preferences.
- [2] Christopher JC Burges. 2010. From ranknet to lambdarank to lambdamart: An overview.
- [3] Jianxin Chang, Chenbin Zhang, Zhiyi Fu, Xiaoxue Zang, Lin Guan, Jing Lu, Yiqun Hui, Dewei Leng, Yanan Niu, Yang Song, et al. 2023. TWIN: TWo-stage interest network for lifelong user behavior modeling in CTR prediction at kuaishou.

- [4] Yuxin Chen, Junfei Tan, An Zhang, Zhengyi Yang, Leheng Sheng, Enzhi Zhang, Xiang Wang, and Tat-Seng Chua. 2024. On Softmax Direct Preference Optimization for Recommendation.
- [5] Sayak Ray Chowdhury, Anush Kini, and Nagarajan Natarajan. 2024. Provably Robust DPO: Aligning Language Models with Noisy Feedback.
- [6] Paul Covington, Jay Adams, and Emre Sargin. 2016. Deep neural networks for youtube recommendations.
- [7] Damai Dai, Chengqi Deng, Chenggang Zhao, RX Xu, Huazuo Gao, Deli Chen, Jiashi Li, Wangding Zeng, Xingkai Yu, Y Wu, et al. 2024. Deepseekmoe: Towards ultimate expert specialization in mixture-of-experts language models.
- [8] Nicola De Cao, Gautier Izacard, Sebastian Riedel, and Fabio Petroni. 2020. Autoregressive entity retrieval.
- [9] Nan Du, Yanping Huang, Andrew M Dai, Simon Tong, Dmitry Lepikhin, Yuanzhong Xu, Maxim Krikun, Yanqi Zhou, Adams Wei Yu, Orhan Firat, et al. 2022. Glam: Efficient scaling of language models with mixture-of-experts.
- [10] Abhimanyu Dubey et al. 2024. The llama 3 herd of models.
- [11] Hongliang Fei, Jingyuan Zhang, Xingxuan Zhou, Junhao Zhao, Xinyang Qi, and Ping Li. 2021. GemNN: gating-enhanced multi-task neural networks with feature interaction learning for CTR prediction.
- [12] Chao Feng, Wuchao Li, Defu Lian, Zheng Liu, and Enhong Chen. 2022. Recommender forest for efficient retrieval.
- [13] Luke Gallagher, Ruey-Cheng Chen, Roi Blanco, and J Shane Culpepper. 2019. Joint optimization of cascade ranking models.
- [14] Tiezheng Ge, Kaiming He, Qifa Ke, and Jian Sun. 2013. Optimized product quantization.
- [15] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. 2017. DeepFM: a factorization-machine based neural network for CTR prediction.
- [16] B Hidasi. 2015. Session-based Recommendations with Recurrent Neural Networks.
- [17] Michael E Houle and Michael Nett. 2014. Rank-based similarity search: Reducing the dimensional dependence.
- [18] Jiri Hron, Karl Krauth, Michael Jordan, and Niki Kilbertus. 2021. On component interactions in two-stage recommender systems.
- [19] Po-Sen Huang, Xiaodong He, Jianfeng Gao, Li Deng, Alex Acero, and Larry Heck. 2013. Learning deep structured semantic models for web search using clickthrough data.
- [20] Xu Huang, Defu Lian, Jin Chen, Liu Zheng, Xing Xie, and Enhong Chen. 2023. Cooperative Retriever and Ranker in Deep Recommenders.

- [21] Herve Jegou, Matthijs Douze, and Cordelia Schmid. 2010. Product quantization for nearest neighbor search.
- [22] Wang-Cheng Kang and Julian McAuley. 2018. Self-attentive sequential recommendation.
- [23] Zhirui Kuai et al. 2024. Breaking the Hourglass Phenomenon of Residual Quantization: Enhancing the Upper Bound of Generative Retrieval.
- [24] Doyup Lee, Chiheon Kim, Saehoon Kim, Minsu Cho, and Wook-Shin Han. 2022. Autoregressive image generation using residual quantization.
- [25] Han Liu, Yinwei Wei, Xuemeng Song, Weili Guan, Yuan-Fang Li, and Liqiang Nie. 2024. MMGRec: Multimodal Generative Recommendation with Transformer Model.
- [26] Shichen Liu, Fei Xiao, Wenwu Ou, and Luo Si. 2017. Cascade ranking for operational e-commerce search.
- [27] Xinchun Luo et al. 2024. QARM: Quantitative Alignment Multi-Modal Recommendation at Kuaishou.
- [28] Xu Ma et al. 2021. Towards a better tradeoff between effectiveness and efficiency in pre-ranking: A learnable feature selection based approach.
- [29] Yu Meng, Mengzhou Xia, and Danqi Chen. 2024. SimPO: Simple Preference Optimization with a Reference-Free Reward.
- [30] Eric Mitchell. 2023. A note on DPO with noisy preferences and relationship to IPO.
- [31] Marius Muja and David G Lowe. 2014. Scalable nearest neighbor algorithms for high dimensional data.
- [32] Long Ouyang et al. 2022. Training language models to follow instructions with human feedback.
- [33] Qi Pi et al. 2020. Search-based user interest modeling with lifelong sequential behavior data for click-through rate prediction.
- [34] Jiarui Qin et al. 2022. Rankflow: Joint optimization of multi-stage cascade ranking systems as flows.
- [35] Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D Manning, Stefano Ermon, and Chelsea Finn. 2024. Direct preference optimization: Your language model is secretly a reward model.
- [36] Shashank Rajput et al. 2023. Recommender systems with generative retrieval.
- [37] Wentao Shi et al. 2023. On the theories behind hard negative sampling for recommendation.
- [38] Anshumali Shrivastava and Ping Li. 2014. Asymmetric LSH (ALSH) for sublinear time maximum inner product search (MIPS).
- [39] Nisan Stiennon et al. 2020. Learning to summarize with human feedback.

- [40] Fei Sun et al. 2019. BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer.
- [41] Yubao Tang, Ruqing Zhang, Jiafeng Guo, and Maarten de Rijke. 2023. Recent advances in generative information retrieval.
- [42] Yi Tay et al. 2022. Transformer memory as a differentiable search index.
- [43] Lidan Wang, Jimmy Lin, and Donald Metzler. 2011. A cascade ranking model for efficient ranked retrieval.
- [44] Yunli Wang et al. 2024. Adaptive Neural Ranking Framework: Toward Maximized Business Goal for Cascade Ranking Systems.
- [45] Ye Wang et al. 2024. EAGER: Two-Stream Generative Recommender with Behavior-Semantic Collaboration.
- [46] Zhe Wang et al. 2020. Cold: Towards the next generation of pre-ranking system.
- [47] Haoran Xu et al. 2024. Contrastive preference optimization: Pushing the boundaries of llm performance in machine translation.
- [48] Shuyuan Xu, Wenyue Hua, and Yongfeng Zhang. 2024. OpenP5: An open-source platform for developing, training, and evaluating llm-based recommender systems.
- [49] Neil Zeghidour et al. 2021. Soundstream: An end-to-end neural audio codec.
- [50] Tingting Zhang et al. 2019. Feature-level deeper self-attention network for sequential recommendation.
- [51] Bowen Zheng et al. 2024. Adapting large language models by integrating collaborative semantics for recommendation.
- [52] Guorui Zhou et al. 2019. Deep interest evolution network for click-through rate prediction.
- [53] Guorui Zhou et al. 2018. Deep interest network for click-through rate prediction.
- [54] Han Zhu et al. 2018. Learning tree-based deep model for recommender systems.
- [55] Barret Zoph et al. 2022. Designing effective sparse expert models.