

PLUM：将预训练语言模型适配到工业规模生成式推荐中的方法

中文逐段翻译稿

根据用户上传论文整理

源文件：PLUM (Google) .pdf

说明：本文档根据用户提供的论文 PDF 整理为中文翻译稿，按原文段落与章节顺序翻译，公式、表格编号与图注尽量保持一致；参考文献条目保留英文原题，不逐条翻译，以便后续检索。

目录

论文信息	3
摘要	3
1 引言	3
1.1 相关工作	5
1.1.1 序列推荐	5
1.1.2 Semantic ID 与量化	5
1.1.3 生成式检索与对齐	6
2 PLUM 框架	6
2.1 Semantic ID	6
2.1.1 融合式多模态内容表示	6
2.1.2 量化层级结构的改进	7
2.1.3 带共现对比正则的 RQ-VAE	7
2.1.4 SID 训练损失	7
2.2 持续预训练	8

2.3 生成式检索	9
3 实验	10
3.1 生成式检索性能	10
3.1.1 实验设置	10
3.1.2 实验结果	10
3.2 Semantic ID 消融实验	11
3.3 持续预训练的影响	12
3.3.1 实验设置	12
3.3.2 实验结果	12
3.4 规模化研究	13
3.4.1 实验设置	13
3.4.2 实验结果	14
3.4.3 局限性讨论	15
4 结论与未来工作	15
5 致谢	16
6 附录	16
6.1 规模化先导实验	16
6.1.1 实验设置	16
6.1.2 结果	17
6.2 上下文学习示例	17
参考文献（保留原文题目）	18

论文信息

题目: PLUM: Adapting Pre-trained Language Models for Industrial-scale Generative Recommendations

作者: Ruining He, Lukasz Heldt, Lichan Hong, Raghunandan Keshavan, Shifan Mao, Nikhil Mehta, Zhengyang Su, Alicia Tsai, Yueqi Wang, Shao-Chuan Wang, Xinyang Yi, Lexi Baugher, Baykal Cakici, Ed Chi, Cristos Goodrow, Ningren Han, He Ma, Romer Rosales, Abby Van Soest, Devansh Tandon, Su-Lin Wu, Weilong Yang, Yilin Zheng.

摘要

大语言模型 (LLM) 为信息任务带来了新的建模与计算范式。推荐系统是一个关键应用领域，天然有望受益于这类大模型所具备的序列建模能力以及其内含的世界知识。本文提出了 **PLUM**，一个用于将预训练 LLM 适配到工业规模推荐任务中的框架。PLUM 由三部分构成：基于 Semantic ID 的物品标记化、面向领域数据的持续预训练 (continued pre-training, CPT)，以及针对推荐目标的任务特定微调。

在微调阶段，本文特别关注生成式检索 (generative retrieval)：模型直接根据用户上下文生成推荐物品的 Semantic ID。我们在大规模内部视频推荐数据集上开展了系统实验。结果表明，相比于一个经过深度工程优化、依赖大规模 embedding 表的生产级模型，PLUM 在检索任务上取得了显著提升。我们还进一步给出了模型检索性能的规模化研究、关于 CPT 的经验结论、若干针对 Semantic ID 的增强方法，以及使这一框架最终能够在 YouTube 面向数十亿用户上线的训练与推理方法概览。

1 引言

推荐系统是现代数字平台中的关键基础设施，它深刻影响着用户发现内容、接触内容并与内容交互的方式。过去几十年中，深度学习模型在推荐系统的召回与排序两个阶段都取得了显著成功。尽管神经网络已经被广泛使用，但工业界推荐系统的主流范式依然依赖于海量 embedding 表，以表示高基数离散特征，例如 item ID (可参见文献 [5,6,17,19])。在这类大 embedding 模型 (Large Embedding Models, LEMs) 中，绝大部分参数都集中在 embedding 表内部。

这种结构在记忆用户—物品交互方面非常有效，但同时也抑制了更深、更复杂神经网络结构所能带来的潜在收益 (例如 [3,8])。这种主要依赖不断扩展 embedding 表来实现规模化的方法，与 LLM 的扩展路径形成鲜明对比；后者更强调扩大神经网络主体规模，以学习紧凑输入 token 之间的组合关系。

LLM 的成功催生了一种构建推荐模型的新范式 [4,7,21,23,36,40]。LLM 天然具备的

序列建模能力，以及其中蕴含的大量世界知识，为构建更智能、更个性化的推荐系统提供了机会。然而，将 LLM 适配到推荐任务并不简单。首要挑战在于如何弥合领域差距：LLM 的预训练阶段通常并未接触目标领域中的用户行为数据和物品语料，因此它们更难从用户活动中理解偏好，也更难捕捉物品质量中的细微差别。正因如此，直接将现成的通用 LLM 应用于推荐任务，即使在较小的公开数据集上，也持续存在明显性能差距 [12]。

第二个挑战在于传统的大 embedding 表输入表示方式本身存在扩展性瓶颈。这类表格需要大量训练数据才能学习充分，而这使得训练大规模 Transformer 架构的代价非常高。

本文朝着“教会 LLM 解决推荐任务”的方向迈出了一步。我们提出 **PLUM**，一个用于将预训练 LLM 有效适配到工业规模生成式推荐中的框架。PLUM 包含三个关键阶段：

- **物品标记化 (Item tokenization)**。语料中的每个物品都表示为一串离散 token，称为 Semantic ID (SID)。在 RQ-VAE [23,24] 的既有工作基础上，我们提出一组新技术（统称为 SID-v2），用于引入用户行为信号、多模态内容 embedding，并通过多分辨率码本与渐进遮罩提升层次结构完整性。
- **持续预训练 (CPT)**。在这一阶段，我们扩展预训练 LLM 的词表，将新的 SID token 纳入其中。随后，模型在领域相关的物品数据、用户序列数据以及通用文本数据的混合语料上继续预训练，以使新的 SID 模态与模型已有知识对齐。
- **任务特定微调**。最后，模型针对具体推荐目标进行微调。尽管 PLUM 可以支持多种下游任务，但本文重点研究生成式检索，即训练一个 decoder-only 模型，根据用户上文自回归地生成用户下一步最可能交互物品的 SID。生成式检索不需要维护独立的物品索引，也绕开了基于 embedding 检索中的点积限制 [29]。

PLUM 的设计正是为解决上述挑战而提出。持续预训练通过引入领域语料和用户行为模式，弥补了预训练 LLM 与推荐领域之间的差距。我们观察到，完成 CPT 之后，模型已经能够基于 SID 输入展现基本的 few-shot 文本生成能力。与此同时，基于 SID 的输入表示也绕开了大 embedding 模型的扩展瓶颈。

实验结果表明，当模型复杂度从输入 embedding 转移到神经网络主体之后，基于 PLUM 的生成式检索在样本效率方面显著优于生产环境中的大型 embedding Transformer 检索模型。正因如此，虽然 PLUM 的检索模型在稠密参数量上比 LEM 高出约 100 倍，但由于收敛更快，其整体训练成本与之相当。我们还观察到明显的规模化收益：随着模型增大，检索性能持续提升，直到一个激活参数量超过 9 亿、总参数量约 42 亿的 Mixture-of-Experts (MoE) 模型。

除了上述贡献外，我们还将分享在大规模生产环境中部署 PLUM 检索系统的实践经验，特别是 PLUM 检索与基于 LEM 的检索在在线 A/B 测试中的对比结果。PLUM 框架已被用于 YouTube 的推荐系统，在多个核心产品表面上为长视频与短视频提供在线和离线检索服务。

1.1 相关工作

受 LLM 最新进展启发, 目前主要存在两条研究路线。第一条路线聚焦于使用 Transformer 或其变体放大 LEM 中的神经网络主体, 我们在第 1.1.1 节讨论这一方向。第二条路线则聚焦于基于 token 的生成式推荐, 如第 1.1.2 节与第 1.1.3 节所述, 它将推荐召回重新表述为 seq2seq 转导任务。

1.1.1 序列推荐

对用户序列与特征交互的建模, 一直是改进推荐模型的关键方向, 相关方法从经典的序列神经网络 [10,15], 一直延伸到专门设计的特征交互组件 [28,37]。近年来, 更突出的趋势是利用类 Transformer 架构, 将用户历史行为与异构特征统一编码到一个序列之中 [9,13,36], 并展现出优于传统 MLP 架构的扩展性。

与此同时, 训练范式本身也开始向 LLM 靠拢, 一些工作采用自监督预训练目标, 再接任务特定微调 [4,20]。但这些方法的共同点在于, 它们仍然持续依赖大规模 embedding 表来表示离散类别特征。我们的工作则跳出了这一范式, 用紧凑的输入 token 取代大 embedding 表。除了 SID 之外, 我们还利用 LLM 处理异构特征, 例如将数值特征 token 化, 或直接把稠密 embedding 作为软 token 输入。

1.1.2 Semantic ID 与量化

将物品表示为离散 token 序列, 即 Semantic ID (SID), 已经成为传统 ID embedding 的一种有力替代方案。该方法使物品能够被当作一种“语言”来处理, 并交由序列模型学习。早期研究证明了从头训练检索模型来预测 SID 的可行性 [23]; 后续研究进一步表明, SID 可以通过哈希方式替代随机 item ID embedding, 从而提升排序模型的泛化能力 [24,39]。

近期大量研究聚焦于提升 SID 的质量与表达能力, 方法包括在量化过程中融合多模态内容特征 [30], 以及引入用户行为中的协同过滤信号 [16,22,33,34]。PLUM 也是沿着这一方向展开的并行探索。与 MMQ [30] 为不同模态分别生成不同 token 的做法不同, 我们直接将多个内容 embedding 先拼接, 再通过一个 MLP 进行编码, 这种方式更灵活, 能够支持更多 embedding 来源。

在融入用户行为方面, 现有多数方法是在量化时将协同过滤 (CF) 得到的 item embedding 与内容 embedding 融合。然而, CF 型 item embedding 会随着物品热度变化而动态变化, 这意味着量化器和下游模型需要频繁重训。为避免这一问题, 我们并不直接把 CF embedding 当作量化输入, 而是通过对比学习目标, 将 CF 信号作为指导, 使量化器从内容信息中提炼出更有用的结构。此外, 我们还提出了两项改进, 用于进一步增强 SID 训练与生成式检索之间的一致性。

1.1.3 生成式检索与对齐

生成式检索将推荐召回重新表述为序列到序列任务：模型以自回归方式直接生成相关物品的 SID。这一思想自文档搜索 [25] 与推荐 [23] 的奠基性工作以来，已经在工业界得到广泛关注（例如 [14,18,21,27]）。例如，OneRec [40] 使用 encoder-decoder 架构生成视频 SID，并借助奖励模型进行强化学习训练以提升质量。其他工作 [31,32] 则提出同时生成 SID 与稠密 embedding 的混合模型，以缓解量化带来的信息损失。

这类方法的共同点在于，大多聚焦于从头训练生成模型。我们的工作则更强调如何让 SID 与 LLM 对齐，并研究 LLM 预训练以及 CPT 对生成式检索性能的影响。虽然已有一些研究 [1,7] 探索了 LLM 与推荐任务之间的对齐，但它们的重点主要在语言交互接口层面，而对如何高效地将 SID 作为一种新模态纳入模型的研究仍然较少。

2 PLUM 框架

2.1 Semantic ID

Semantic ID (SID) 可以被理解为一个由离散码字组成的元组，这些码字来源于物品底层内容特征的量化表示。其生成过程包含两个主要阶段：第一，将高层内容特征编码为稠密语义 embedding；第二，将该 embedding 量化为具有层级结构的码字元组。生成式检索模型的效果，在根本上依赖于 SID 的语义丰富性与结构完整性。

在基础的 TIGER 框架中，SID 是通过残差量化变分自编码器 (RQ-VAE) 构建的。本文在此基础上对生成过程进行了一系列重要增强。早期方法主要受限于只依赖单一内容 embedding 源，而且在 ID 结构中没有引入协同信号。我们的目标则是生成更全面、与用户行为更一致、且层次结构更清晰的 SID。图 1 展示了我们训练 SID 模型的整体设计。

2.1.1 融合式多模态内容表示

仅依赖单一内容表示的做法 [23] 存在一个主要局限：它天然无法捕捉复杂媒体物品的多面性。以视频为例，其完整语义往往是文本元数据、视觉内容与音频信息共同作用的结果。单模态表示按定义就会忽略许多丰富且互补的信息来源。

为此，我们设计的框架并不依赖特定的输入来源数目或类型，而是能够接收并融合多个异构表示。对于每个物品，模型输入为一组不同的 embedding 向量 $\{x_m\}_{m=1}^M$ 。每个模态先通过独立的编码器 E_m 映射到潜向量 z_m ，然后将这些向量拼接为 $\tilde{z} = [z_1, \dots, z_M]$ 并进一步投影，得到统一的特征表示 z 。通过整合多模态信息，我们为后续的 RQ-VAE 量化过程提供了更优质的输入，从而保证生成出来的 SID 建立在对物品内容更完整的理解之上。

2.1.2 量化层级结构的改进

我们还进一步改进了 RQ-VAE 本身，以构建更高效、更有意义的层次化表示。具体包括以下两项创新：

- **多分辨率码本 (Multi-Resolution Codebooks)**。先前工作 [23] 采用统一分辨率的固定码本，这在参数使用上可能并不高效，会导致 SID 空间非常庞大而且极度稀疏，大多数潜在码字组合事实上都不会被分配到任何物品。我们改用多分辨率码本结构：前几层 SID 具有更高分辨率和更强区分性，而后续层则用较低分辨率编码低熵残差。具体来说，第 $level$ 层的码本基数设为 $2048/2^{level-1}$ ，从而得到更紧凑、更高效的 SID 表示。
- **渐进遮罩 (Progressive Masking)**。为了在残差量化中施加更严格、也更易解释的层次结构，我们引入渐进遮罩机制。设二值掩码标量 $m_l \in \{0, 1\}$ ，其中 l 表示码本层级，定义为 $m_l = \mathbf{1}_{l < r}$ ，这里 $r \in [1, L]$ 为随机整数， L 为总层数。该掩码在训练时用于选取前 r 个码本层级。

2.1.3 带共现对比正则的 RQ-VAE

如果 SID 仅由物品自身内容推导而来，那么它未必能够完整刻画用户在推荐场景中感受到的“相似性”。用户行为为视频之间的相关性提供了强有力的外部信号：经常被一起观看的视频，在语义上往往存在联系。为缩小内容相似性与行为相似性之间的差距，我们在 ID 生成阶段直接引入协同信号，在 RQ-VAE 训练目标中增加一个共现对比损失项 L_{con} 。

这一目标函数的设计目的，是根据用户交互序列中物品的共现模式来塑造 embedding 空间。该损失鼓励模型为经常共同出现的物品生成相似的 SID 表示，同时将不共同出现的物品在表示空间中拉开。具体而言，对比损失定义为：

$$L_{con} = - \sum_{i=1}^{2N_b} \frac{\exp(\text{sim}(p_i, p_i^+))}{\sum_{j=1}^{2N_b} \exp(\text{sim}(p_i, p_j))}, \quad (1)$$

其中， p_i 表示一个 batch 中第 i 个视频表示，batch 大小为 N_b ； p_i^+ 表示与视频 i 在用户序列中共现的视频表示； $\text{sim}(p_i, p_j)$ 表示视频 i 与视频 j 之间的点积相似度。

图 1 (原文示意图)：Semantic ID 模型示意。模型以两个视频的多模态 embedding 为输入，经编码后通过残差量化器压缩为量化 ID；训练目标同时要求该 ID 能够重构原始输入，并通过对比损失将共现视频聚类到更接近的语义空间中。

图 1: Semantic ID 模型示意图 (中文说明)

2.1.4 SID 训练损失

除了文献 [24] 中已有的训练损失之外，我们额外引入了共现对比损失项。于是，总体损失写为：

$$L = L_{recon} + L_{rq} + L_{con}, \quad (2)$$

其中,

$$L_{recon} = \sum_{m=1}^M \|x_m - \hat{x}_m\|^2 \quad (3)$$

表示各个多模态 embedding 的重构损失, 而

$$L_{rq} = \sum_{l=1}^L \beta \|r_l - sg[e_l^*]\|^2 + \|sg[r_l] - e_l^*\|^2. \quad (4)$$

这里, e_l^* 表示第 l 层码本中距离当前表示最近的码字, $r_l = r_{l-1} - e_l^*$ 表示逐层递归计算得到的残差, 且初始 $r_0 = z$; sg 表示 stop-gradient 操作。

如图 1 所示, 最终量化向量 $\hat{z}$ 在渐进遮罩作用下, 由各层被选中码字求和得到:

$$\hat{z} = \sum_{l=1}^L m_l e_l^*. \quad (5)$$

随后, 该量化向量作为各个解码器 D_m 的输入, 用于重构原始 embedding $\hat{x}_m$ 。

2.2 持续预训练

在构建出 SID 词表之后, 持续预训练 (CPT) 阶段的一个核心目标, 是得到一个新的基础模型 checkpoint, 使 SID token 具备明确语义, 并与原始语言模型中的文本 token 对齐。为此, 我们在一大规模语料上采用 next-token prediction 目标继续训练模型。该语料主要由以下两类数据构成:

- **用户行为数据。**这一部分对于个性化建模与观看历史建模至关重要。训练时, 每个样本使用用户的观看历史及其他观看相关特征, 用以建模用户行为序列。
- **视频元数据语料。**这一大规模语料用于在 SID 与其对应文本特征之间建立强关联。每个样本包含视频的 SID、标题、描述、ASR 字幕、频道名称, 以及合成生成的数据。

表 1 给出了 CPT 阶段训练样本的示例格式。

数据混合与训练。 CPT 阶段的训练集由用户行为数据和视频元数据语料混合构成, 两类数据各占 50% 的训练样本。CPT 共进行 100 万步训练, batch size 为 16, 总 token 数约为 2600 亿。我们构建了多种评估方式, 用于衡量模型基于用户历史生成 SID 的能力、在保留视频元数据语料上联合建模 SID 与自然语言的能力, 以及模型在标准文本基准上的通用语言能力退化情况。

表 1: 持续预训练中使用的样本格式示例

类别	示例
用户行为训练数据	wh = <sid_1> <channel_name> <watch_ratio> <watch_time> <hours_since_final_watch> <sid_2> <channel_name> ... <sid_n>
SID + 视频标题	Video <sid> has title (en): <video_title>
SID + 视频主题	The topics in video <sid> are: <topics>

上下文学习。 由于 CPT 模型是在 SID 与自然语言混合语料上训练得到的，因此它保留了自由文本生成能力，也具备基于上下文的 few-shot 学习能力。附录 A.2 给出了若干示例。

2.3 生成式检索

尽管持续预训练阶段已经使模型能够根据用户历史生成下一视频的 SID，但若要将其专门优化为检索模型，还需要进一步进行监督微调（Supervised Fine-Tuning, SFT）。该阶段使模型能够接入更丰富的特征，尤其是实时上下文特征，并能够直接面向与用户体验一致的奖励信号进行优化。

图 2（原文示意图）：用于“下一视频推荐”的生成式检索。输入提示由 SID token、文本 token 以及表示数值特征的自定义 token 交错组成。

图 2: 下一视频推荐中的生成式检索示意（中文说明）

这一微调阶段采用标准的自回归最大似然目标。模型学习去预测真实视频的 SID token，其中真实视频由用户日志中、在给定上下文和历史条件下实际被点击的视频定义。具体而言，训练损失为：

$$L_{SFT} = - \sum_{t=1}^L r(user, v_{click}) \cdot \log P(sid_t | Context_{user}, History_{user}, sid_{<t}), \quad (6)$$

其中， $[sid_1, \dots, sid_L]$ 表示被点击视频 v_{click} 的 SID， $r(user, v_{click})$ 表示该次点击对应的人工设计奖励信号。在实践中，考虑到训练成本较高，我们会根据该奖励对训练样本进行采样，随后在损失中对采样后的样本赋予相同权重。

如图 2 所示，输入提示不仅包含 SID token 和用于数值特征的自定义 token，还包含其他能够被预训练 LLM 自然编码的文本特征。

在推理阶段，我们使用 beam search 解码出多个 SID 序列，并将其作为召回候选集合。随后，每个生成出来的 SID 都会映射到我们十亿规模视频库中的真实视频。尽管这种生成过程理论上可能产生无效 SID（即“幻觉”）或出现 SID 到视频的一对多碰撞，但我们观察到，SFT 之后的幻觉率很低（小于 5%），而且 SID 到视频映射的唯一性仍然较高（见表 4）。

3 实验

本节通过一组系统实验来验证 PLUM 框架的有效性。我们首先将基于 PLUM 的生成式检索模型，与一个基于 Transformer 且依赖大 embedding 表、在生产环境中贡献了大部分曝光的检索模型进行对比（第 3.1 节）。随后，第 3.2 节展示我们提出的 SID 增强方法的有效性。之后，我们分别针对 PLUM 中两个关键组成部分开展消融研究：第 3.3 节量化持续预训练阶段以及从预训练 LLM 初始化两者的实际收益。最后，第 3.4 节给出一个详细的规模化研究，以分析模型大小、计算量与检索性能之间的关系。

3.1 生成式检索性能

传统推荐系统通常使用大 embedding 模型来召回候选。然而，生成式检索相较传统系统具有多方面优势。本节在 YouTube 的生产级设置上研究生成式检索的有效性。

3.1.1 实验设置

模型。 在以下实验中，我们使用 Gemini-1.5 Mixture-of-Experts (MoE) 家族中的一个 9 亿激活参数 PLUM 模型，在长视频 (Long Form Video, LFV) 和 Shorts 两个场景上进行训练。模型由 Gemini checkpoint 热启动，并按照前文所述方式在新的 engagement 数据上持续微调。训练数据由最新数据与历史数据混合构成。在线服务时，目标序列通过 beam search 解码。在我们的实验中，beam search 的表现优于随机解码，不过代价是多样性有所下降。

基线。 我们将上述模型与传统的 LEM 检索模型进行比较。该基线是当前生产环境中的最佳检索模型之一，并且自 Chen 等人的早期工作 [2] 以来已经经过长期深度优化。这个基线同样基于 Transformer 架构，但绝大多数参数位于 embedding 层中，其输入与输出 item ID 词表规模均在千万级。具体来看，LEM 的神经网络主体只占总参数的 0.4%，而 PLUM 中神经网络主体则占约 90%。

3.1.2 实验结果

推荐质量。 我们从多个维度评估推荐质量。首先，我们用“有效词表规模 (effective vocab size)”来衡量推荐器：即覆盖 95% 曝光所需的唯一视频数量。较大的有效词表通常更有利于个性化发现小众内容，也表明模型具有更强的泛化能力。其次，我们用点击率 (CTR) 以及推荐接受度 (Recommendation Acceptance) 来评估推荐效果。对于接受度，我们同时比较观看时长 (WT/View) 和观看比例 (WF/View)。表 2 中所有数值均表示 900M MoE 模型相对 LEM 的指标比值。

我们观察到，PLUM 模型能够显著扩大有效词表规模，同时在用户反应相关指标上与 LEM 保持竞争力。

表 2: 推荐质量对比: 表中每个数值均为 PLUM 指标除以 LEM 指标所得比值

指标	LFV	Shorts
有效词表规模	2.60×	13.24×
CTR	1.42×	1.33×
WT/View	0.72×	1.13×
WF/View	1.32×	1.03×

在线实验。 我们通过将 PLUM 模型的推荐结果加入候选池来开展线上实验。为了公平比较, 我们同时按相同幅度提高了当前生产环境中表现最好的检索模型的 quota, 并将这一改造后的基线记为 LEM+。表 3 报告了相对于 LEM+ 而言, 在 LFV 和 Shorts 两个场景下四个关键指标的变化幅度。结果表明, 即便不使用大 embedding 表, 基于 PLUM 的检索仍然能在现有系统之上提供额外价值。

表 3: 参与度对比: 加入 PLUM 相对于 LEM+ 的百分比变化

指标	LFV	Shorts
活跃用户数 (Engaged Users)	+0.07%	+0.28%
面板 CTR (Panel CTR)	+0.76%	+4.96%
观看量 (Views)	+0.80%	+0.39%
满意度 (Satisfaction)	+0.06%	+0.39%

样本效率。 在我们的研究中, PLUM 模型展现出非常高的样本效率。900M MoE 模型每天大约训练 2.5 亿样本, 而传统 LEM 每天需要训练数十亿样本。尽管 PLUM 单样本训练成本更高, 但这种高样本效率使其依然具备生产部署可行性。与 LEM 相比, 900M MoE 模型的训练 FLOPs 小于其 0.55 倍。

3.2 Semantic ID 消融实验

表 4 讨论了我们相较于此前 SID [23] 所引入的若干改动的重要性。我们将此前的方法记为 SIDv1, 将本文方法记为 SIDv2。由于不同 SID 模型会导出不同的索引结构, 因此我们同时报告 SID 空间中的索引唯一性 (即语料库中有多少视频能够被唯一表示), 以及在该 SID 上训练生成式检索模型后得到的视频级 Recall@10。这里的 Video Recall@K, 指的是在给定 PLUM 预测出的 top-K SID 序列的情况下, 成功召回某个具体视频的概率。当一个 SID 对应多个视频时, 我们在计算 recall 时随机采样其中一个视频。

我们在一个较简化的实验环境中进行了这些消融实验: 使用 900M MoE PLUM 检索模型, 不进行 CPT, 并且在提示中移除观看历史。表 4 显示了这些实验对 Semantic ID 唯一性以及下游生成式检索 Video Recall@10 的影响。结果表明, 所有改动都提升了生成式物品检索的 recall, 其中引入“共现对齐任务”对 Semantic ID 的唯一性和 recall 都带来了最明显提升。

表 4: SIDv2 相关改动的消融实验

SID 模型	SID 唯一性	VID Recall@10
SIDv1 (基线)	94.0%	12.3%
SIDv2 (本文)	96.7%	14.4%
去掉多分辨率结构	94.8%	13.2%
去掉多 embedding 融合	96.9%	12.8%
去掉共现信号	91.8%	12.6%

3.3 持续预训练的影响

为了衡量持续预训练阶段的重要性，我们评估了 CPT 对生成式检索最终模型训练效率与检索性能的影响。

3.3.1 实验设置

我们的训练流程分为两个阶段：持续预训练和生成式检索微调。两个阶段分别对应不同的学习目标与一组专门的超参数设置。为了区分这两步各自的贡献，我们设计了一个受控的 2×2 消融实验，共包含四种模型配置，它们共享相同的 decoder-only Transformer 架构。这里我们使用 MoE-900M 架构。四种模型定义如下：

- **R1**：仅做 retrieval SFT（随机初始化）。Transformer 模型随机初始化后，直接在生成式检索任务上训练。
- **R2**：retrieval SFT（LLM 初始化）。模型从一个预训练 LLM checkpoint 初始化，但跳过 CPT 阶段。
- **CR1**：CPT（随机初始化）+ retrieval SFT。模型按照两阶段 PLUM 流程训练，但 CPT 所用模型从随机参数开始。
- **CR2**：CPT（LLM 初始化）+ retrieval SFT。这是本文提出框架的完整实现形式。

3.3.2 实验结果

持续预训练的影响。 主要结果总结于表 5。结合后续规模化研究中的设置，我们在一个大规模、留出的“次日”数据集上评估四种模型，并报告 Recall@10 作为检索指标。R1 与 CR1（以及 R2 与 CR2）之间存在明显性能差距，这说明 CPT 对后续检索微调具有实际收益。此外，图 3 还展示了第 8 天 Recall@10 和训练损失随训练步数变化的曲线。从图中可以清楚看出，经过 CPT 的模型收敛更快。因此，CPT 不仅提升最终性能，也能显著提高任务特定微调的训练效率，尤其是在多个下游任务共享同一个 CPT 模型时更是如此。

预训练 LLM 的影响。 接下来我们考察：与随机初始化相比，从一个通用 LLM 开始训练究竟有何收益。表 5 中的结果体现出一个一致模式：无论是否使用 CPT，从预训练 LLM 初

表 5: 四种模型配置在生成式检索任务上的主要性能

模型	预训练 LLM	CPT	Recall@10 (第 8 天)
R1	否	否	0.19
R2	是	否	0.23
CR1	否	是	0.27
CR2	是	是	0.28

始化的模型都持续优于随机初始化的对应模型。我们推测，这种优势主要来自预训练 LLM 已经具备的自然语言理解能力，或者说，大规模 LLM 预训练所学到的一般序列处理能力本身就能直接帮助推荐建模。对于这一观察更深入的研究超出了本文范围。

图 3 (原文曲线图): 左图为“第 8 天 Recall@10 随 retrieval SFT 训练步数变化”, 右图为“训练损失随训练步数变化”。总体趋势是: 带 CPT 的模型在同等训练步数下 Recall@10 更高, 训练损失下降也更快。

图 3: 第 8 天 Recall@10 与训练损失随 retrieval SFT 训练步数变化 (中文说明)

3.4 规模化研究

本节使用 YouTube 生产数据, 对生成式检索模型进行规模化研究。我们使用 Gemini-1.5 [26] Mixture-of-Experts (MoE) 家族中的四个不同规模: MoE-110M、MoE-370M、MoE-900M 和 MoE-3B (这里的规模指每个 token 激活的参数数目), 其总参数量从不足 10 亿一直跨越到超过 100 亿。我们主要希望回答三个问题: 第一, 损失如何随模型大小和计算量缩放; 第二, 检索指标如何随模型大小和计算量缩放; 第三, 在给定计算预算下, 最优模型规模应当如何选择。

3.4.1 实验设置

数据集。 我们的研究基于一个真实生产数据集, 该数据来自 YouTube 某核心产品表面, 用于在用户当前观看某个视频并结合其他上下文信号 (如观看历史) 时, 推荐其下一步可能观看的视频 (可参见 [38] 图 4)。这一推荐系统采用多阶段架构, 包含候选生成、预排序、排序等多个环节。本文研究聚焦于候选生成阶段, 针对一个包含数十亿视频的完整视频库评估检索性能。

训练与评估。 我们的输入提示格式为: `watch history | user features | context video features`。其中, 观看历史是一个按时间顺序排列的观看序列, 每次观看都表示为 SID token 与其他特征 token 的拼接。该实验中, 输入序列长度固定为 1536 个 token, 能够覆盖用户最近约 100 次观看以及其他相关特征。SFT 标签选取的是用户在 YouTube 上的下一次观看行为, 并通过一个基于用户参与度与满意度信号的下采样机制进行筛选。下一次观看视频的 SID token 被作为预测目标。训练时, 我们随机打乱连续 7 天 (2025 年 7 月) 的数据; 评估则在后续第 8 天上进行。实验运行在 1024 个 Google v6e TPU 上, 每个

TPU 具有 32GB 高带宽内存 (HBM)；我们并行运行 4 个训练器，每个训练器使用 256 个 TPU。

超参数选择。 我们首先使用 MoE-900M 模型进行了一个先导实验，以评估模型对 global batch size 与 learning rate 的敏感性 (附录 A.1 给出细节)。根据这一先导实验的经验，我们在正式实验中尽量把 batch size 设到接近 HBM 饱和，因为结果显示较大 batch size 更优。学习率方面，以 MoE-900M 使用的 5×10^{-5} 为锚点，我们为更小模型略微提高学习率，而为更大模型略微降低学习率。不同于自然语言处理中典型的 scaling law 研究 (如 [11])，我们采用常数学习率。这样做有两个原因：其一，生产模型的持续训练通常并不存在一个明确的停止步数；其二，常数学习率能够使训练过程中所有中间数据点都可以被精确插值与比较。不同规模模型的超参数配置如表 6 所示。所有模型均从各自对应的 CPT checkpoint 热启动 (这些 CPT 模型的预训练 FLOPs 均为 1×10^{22} Iso-FLOPs)。本节所有 FLOPs 数字均不计入 CPT 阶段的计算量。

表 6: 规模化研究中的模型配置

模型规模	学习率	全局 batch size
MoE-110M	1×10^{-4}	25,600
MoE-370M	7×10^{-5}	15,360
MoE-900M	5×10^{-5}	7,680
MoE-3B	2×10^{-5}	3,584

3.4.2 实验结果

损失随计算量和模型规模的变化。 图 4 展示了训练/评估损失 (在第 8 天上计算) 与训练 Iso-FLOPs 之间的关系。图 4(a) 显示，对于每个模型规模，Iso-FLOPs 与训练损失之间都存在明显的幂律关系。随着 Iso-FLOPs 的增加，表示训练损失前沿的最优模型规模也不断右移：先是 MoE-110M (红线)，再到 MoE-370M (绿线)，接着是 MoE-900M (紫线)，并被推测最终会移动到 MoE-3B (蓝线)。

图 4(b) 则说明，在评估损失上也存在类似的幂律关系，只不过当训练足够充分后，评估损失会开始趋于饱和。作者将其归因于训练已经相当充分。另一个观察是，评估损失前沿向更大模型移动的速度，明显快于训练损失前沿，这提示较大模型对于未来数据分布具有更好的泛化能力。

检索指标随计算量和模型规模的变化。 类似地，图 5 给出了训练/评估 Recall@10 (第 8 天) 与训练 Iso-FLOPs 的关系，并将两个坐标轴都以对数尺度表示。整体现象与图 4 类似，但评估 Recall@10 的增长放缓迹象更少，这意味着模型仍在持续提升生成准确、完整序列的能力，从而更准确地定位正确文档。

此外，三种较小模型都已经看过超过一个 epoch 的训练数据，其中 MoE-110M 甚至训练到了 4.24 个 epoch，但依然没有出现明显过拟合现象 (见图 5(b))。

固定 Iso-FLOPS 预算下的最优模型规模。 图 6 展示了当给定 Iso-FLOPS 预算逐步增加时，最优模型规模如何逐渐向更大模型迁移。由于我们对每个模型都采用常数学习率，因此可以通过一次完整训练直接评估任意 Iso-FLOPS 预算下的模型性能。与 Chinchilla 论文 [11] 类似，在图 6(b) 中，大多数计算预算下都存在一个最优峰值。

图 4: 训练损失与评估损失随训练 Iso-FLOPS 增长的变化; 图 5: 训练 Recall@10 与评估 Recall@10 随训练 Iso-FLOPS 增长的变化; 图 6: 在固定计算预算下, 不同模型规模对应的训练损失与评估 Recall@10 曲线。总体结论是: 随着计算预算增加, 性能最优值逐步向更大的模型迁移。

图 4: 规模化研究图 4-图 6 的中文概述说明

3.4.3 局限性讨论

我们注意到，在本文所考虑的计算预算范围内，MoE-3B 并未超过 MoE-900M。当前这项规模化研究受到计算资源约束，而次优的超参数设置可能是一个重要原因。例如，先导实验表明，对同一模型而言，更大的 batch size 往往对应更高的训练效率。由于我们为每个模型分配了相同训练资源，并将 batch size 设为尽量填满 HBM（见表 6），因此更大的模型天然会因为 batch size 更小而处于不利位置。

事实上，在训练结束时，MoE-3B 只处理了 0.57 个 epoch 的训练数据（约 50 亿样本），比第二大模型少了两倍以上。我们在生成式检索任务上的规模化研究说明，要实现计算最优训练，需要同步扩大训练样本规模与模型规模，而不能仅仅扩大其中之一。

4 结论与未来工作

本文提出了 PLUM，一个用于将预训练 LLM 适配到大规模推荐任务中的框架。我们的方法通过 SIDv2 增强了物品 token 化过程，利用大规模 CPT 使 LLM 对齐用户行为模式并将 SID 扎根于文本语义之中，随后再通过监督微调使模型在生成式检索任务上表现优异。

作为已经在 YouTube 上线的平台，PLUM 在不依赖大 embedding 表的前提下，为现有推荐系统带来了独特价值，这也是我们第一个不再建立在大 embedding 表之上的神经推荐模型。本文的消融实验验证了 CPT 阶段的价值、从预训练 LLM 初始化的收益，以及我们提出的 SID 技术本身的有效性。

从更广义上看，本文可被视为一项将 LLM 与真实世界推荐系统对齐的初步研究，它也开启了若干未来研究方向，例如：将 PLUM 拓展到排序、个性化搜索等其他任务；设计能够提升候选多样性的全新解码策略；以及实现 SID 与自然语言之间更加无缝的一体化生成。

5 致谢

作者感谢以下人员在将本文所述技术应用到多种产品表面与使用场景中的努力与反馈 (按字母顺序): Saksham Agarwal, Sriraj Badam, Sourabh Bansod, Xilun Chen, Yi Chen, Bernardo Cunha, Onkar Dalal, Mingyan Gao, Elad Ganmor, Danfeng Guo, Pooja Gupta, Ralf Gutsche, Yuan Hao, Chuan He, Lily He, Yan Huang, Kate Jones, Jiewen Lang, Pengfei Li, Wen Li, Li Wei, Sean Liew, Qiguang Liu, Sunny Liu, Yang Liu, Jianan Lu, Yilong Luan, Shifan Mao, Tomer Margolin, Radwa Metwali, Aniruddh Nath, Hardik Patel, Amy Pu, Vasin Punyakanok, Murphy Ren, Yuji Roh, Yuan Shao, Ajay Shekhawat, Fabio Soldo, Yanwei Song, Qian Sun, Jiayi Tang, Aahan Tyagi, Diego Uribe, Jacky Wang, Ting Wang, Siqi Wu, Bo Yan, Shuhao Ye, Likang Yin, Qiao Zhang, Rein Zhang, Sai Zhang, Vivian Zhang, Yaping Zhang, Gwendolyn Zhao, Zelong Zhao, Zhile Zou, Dav Zimak。作者还特别感谢 Mahesh Sathiamoorthy 与 Anima Singh, 他们对该项目概念形成与早期开发作出了深刻贡献。

6 附录

6.1 规模化先导实验

作为正式规模化研究的前置步骤, 作者使用 MoE-900M 模型进行了一个先导实验, 以判断模型对两个超参数——全局 batch size 与学习率——的敏感性。该先导实验的结果随后用于指导更大规模实验中的超参数选择, 从而保证计算资源得到更有效的利用。

6.1.1 实验设置

作者运行了 4 个训练器, 每个训练器使用 256 个 TPU, 并都从同一个预训练 checkpoint 初始化。先导实验持续约两周, 这一时长足以观察出清晰的性能趋势。基准配置 (Trainer A) 采用常数学习率 1×10^{-4} , 并将 batch size 设为接近 HBM 饱和; 其余配置则系统性地改变其中一个超参数。

表 7: MoE-900M 先导实验配置

训练器	学习率	Batch Size
A (基准)	1×10^{-4}	饱和 HBM
B	1×10^{-4}	0.5× 饱和 HBM
C	2×10^{-4}	饱和 HBM
D	5×10^{-5}	饱和 HBM

6.1.2 结果

学习率敏感性。 实验结果表明，在一个合理范围内，训练过程对学习率是相对鲁棒的。具体而言，在先导实验持续时间内，基准学习率 1×10^{-4} (Trainer A) 与较低学习率 5×10^{-5} (Trainer D) 之间的性能差异并不显著。然而，将学习率加倍到 2×10^{-4} (Trainer C) 会导致性能明显变差，这表明该学习率已经超出这一模型与数据集的较优范围。

Batch size 敏感性。 较小的 batch size 会显著损害训练效率。将 batch size 减半后，需要超过两倍的训练步数，才能达到可比性能。这说明，对于追求计算最优训练而言，应尽可能把 batch size 推高到硬件内存允许的上限。

6.2 上下文学习示例

表 8 给出了一些示例，用来展示在引入 Semantic ID 并完成 CPT 之后，模型所具备的上下文 few-shot 学习能力。基于预训练 LLM 初始化并完成 CPT 的模型，能够按照 few-shot 提示要求，用语义上合适的短语正确补全文本。相比之下，如果在随机初始化模型上执行同样的推荐预训练，模型则难以形成连贯短语，也无法清楚地区分 SID token 与文本 token。

表 8: 上下文 few-shot 学习的定性示例（中文整理）

示例 1	
Few-shot 输入	The video A1991 ... H10 is about health and pain management. The video A364 ... H37 is about the basics of quantum physics. The video A37 ... H25 is about
LLM 初始化 + CPT 输出	psychology and mind
随机初始化 + CPT 输出	100% video A252 H7
示例 2	
Few-shot 输入	Video A37 ... H41 answers the question: do you really need 8 hours of sleep? Video A1926 ... H8 answers the question: how buy-now pay-later loan business makes profit? Video A1882 ... H32 answers the question:
LLM 初始化 + CPT 输出	the impact of language in your life.
随机初始化 + CPT 输出	- - - 100% -1999-11-16

参考文献（保留原文题目）

本文参考文献数量较多，为方便后续学术检索与 BibTeX 整理，本翻译稿不对参考文献逐条做中文翻译，建议直接结合原论文 PDF 中的 References 部分使用。