

MiniOneRec：用于扩展生成式推荐的开源框架

原文： *MiniOneRec: An Open-Source Framework for Scaling Generative Recommendation*

Xiaoyu Kong, Leheng Sheng, Junfei Tan, Yuxin Chen, Jiancan Wu, An Zhang, Xiang Wang, Xiangnan He

中国科学技术大学；新加坡国立大学

说明：本文档依据用户提供的原始 PDF 逐段翻译整理，尽量保留原文的段落结构、公式、图注与表格数值。为保证文档可读性，参考文献题录未逐条翻译，建议与原文对应查看。图 1 至图 4 使用原文图像裁剪版，其余附录示例以中文文字形式整理。

生成时间：2026 年 4 月 2 日

目录

摘要	3
1 引言	3
2 背景与相关工作	5
2.1 生成式推荐	5
2.2 LLM 与 RL	5
3 建模方法	6
3.1 任务形式化	6
3.2 物品分词	7
3.3 与 LLM 的对齐	8
3.4 强化偏好优化	8
3.4.1 采样策略	9
3.4.2 奖励设计	10
4 训练细节	10
5 实验评估	11
5.1 评估设置	11
5.2 规模化规律	11
5.3 性能比较	12
5.4 迁移能力	13
5.5 消融实验	14
5.5.1 对齐策略	14
5.5.2 采样策略	14
5.5.3 奖励设计	14
5.6 预训练 LLM 的影响	15
6 结论	15
A 对齐提示词	16
A.1 总体说明	16
A.2 推荐任务	16
A.3 对齐任务	17

MiniOneRec 中文翻译	2
B 数据集	17
参考文献说明	18

摘要

近年来，大语言模型（LLMs）的成功再次引发了人们对推荐系统能否获得类似规模化收益的关注。传统推荐模型通常由大规模嵌入表主导，随着嵌入维度增长，其性能往往趋于饱和。与之相比，新兴的生成式范式利用自回归 Transformer 产生的紧凑语义 ID（Semantic ID, SID）序列来替代嵌入表示。然而，目前大多数工业部署仍然是闭源的，这使两个基础问题仍未得到回答：（1）预期的规模律是否也适用于公开基准数据集？（2）实现有竞争力性能所需的最小后训练配方究竟是什么？

本文提出 MiniOneRec。据我们所知，这是首个完全开源的生成式推荐框架，提供了一个覆盖 SID 构建、监督微调以及面向推荐的强化学习的端到端流程。我们通过残差量化 VAE（Residual Quantized VAE, RQ-VAE）生成 SID，并在 Amazon Review 数据集上对参数规模从 0.5B 到 7B 的 Qwen 主干模型进行后训练。实验表明，随着模型规模增加，训练损失与评估损失均呈现稳定下降趋势，从而验证了生成式方法的参数效率。为进一步提升性能，我们提出了一个轻量但有效的后训练流程：（1）在整个流程中强制执行 SID 对齐；（2）结合受约束解码与混合奖励进行强化学习。两项技术共同显著提升了排序准确率与候选多样性。




图 1: 左: 从 0.5B 到 7B 参数规模的扩展曲线。右: 世界知识对模型性能的影响。MiniOneRec-W/O ALIGN 使用预训练 LLM 权重，但不进行 SID-文本对齐；MiniOneRec-Scratch 从随机初始化开始训练，且同样不进行对齐。

1 引言

近年来，推荐模型的规模化行为受到了广泛关注（Deng 等，2025；Wang 等，2025；Zhai 等，2024；Zhang 等，2024；Jiang 等，2025；Zhu 等，2025；Chen 等，2024a；Dai 等，2025）。这一趋势在很大程度上受到大语言模型成功经验的驱动，因为大语言模型已经证明：随着模型规模增大，其性能能够呈现出可预测的提升（Brown 等，2020；Achiam 等，2023；DeepSeek-AI 等，2024；Yang 等，2024；Jiang 等，2023；Dubey 等，2024；Touvron 等，2023；DeepSeek-AI 等，2025）。然而，传统推荐模型始终难以展现出类似的规模律（Kang 和 McAuley，2018；Hidasi 等，2016；Tang 和 Wang，2018；Wu 等，2021；Fang 等，2020）。

这些系统通常将绝大多数参数分配给大型嵌入表，用于存储用户与物品表示，而最终预测阶段只采用内积或浅层打分网络。以嵌入表为主导的设计会导致性能平台期：即便继续增大嵌入维度或表规模，性能提升也会在中等尺度之后迅速减弱（Zhou 等，2018；Covington 等，2016；Wang 等，2021；Guo 等，2017）。

生成式推荐带来了根本性的范式转变。它通过量化技术将物品压缩为离散的语义 ID (SID) 序列（Luo 等，2024；Zeghidour 等，2022），从而使用紧凑词表，并将大部分参数重新分配给深层自回归 Transformer，由其负责生成 SID 序列（Rajput 等，2023；Zheng 等，2024；Qu 等，2024；Deng 等，2025；Dai 等，2025）。这种设计使其更接近语言模型的扩展行为：模型越深、容量越大，性能收益越稳定（Deng 等，2025）。

近期的一些工业级部署已经展示了生成式范式的潜力。OneRec（Deng 等，2025；Zhou 等，2025a）在快手平台这一拥有 4 亿日活用户的场景中取得了显著改进；OneRec-V2（Zhou 等，2025b）则进一步通过惰性解码器结构与偏好对齐机制获得提升。OnePiece（Dai 等，2025）将 LLM 风格的上下文工程与推理能力同时引入工业级级联流水线中的召回与排序模型。然而，这些结果依赖海量私有数据且并未开源，因此对研究社区而言仍有两个关键问题没有答案：

- 生成式推荐的规模化优势，是否能够迁移到公开数据集之上？
- 要获得较强性能，所需的最小后训练方案究竟是什么？

在本文中，我们提出 MiniOneRec。这是首个完全开源的生成式推荐框架，提供了一个覆盖 SID 生成、模型监督微调（SFT）以及推荐驱动强化学习（RL）的端到端工作流。我们的发布内容包括完整源代码、可复现实验流程以及公开可用的模型检查点。我们采用残差量化变分自编码器（RQ-VAE）构建 SID，这与 TIGER（Rajput 等，2023；Deng 等，2025）等已有工作保持一致。我们在 Amazon Review Dataset 的公开基准上，对基于 Qwen 的生成式模型进行了多种尺度的后训练，参数规模覆盖 0.5B 至 7B。借鉴 OneRec 成功的两阶段后训练流程，我们先在用户-物品交互序列上进行 SFT，再使用群组相对策略梯度（Group Relative Policy Gradient, GRPO）（DeepSeek-AI 等，2025；Shao 等，2024）完成对齐。本文的主要贡献如下：

- **验证生成式推荐的规模律。**据我们所知，本文首次系统研究了生成式推荐模型在公开数据上的扩展规律。具体而言，我们在 Amazon Review 语料（Hou 等，2024）上，以完全一致的数据划分与超参数设置训练了四个 MiniOneRec 变体，参数规模从 0.5B 到 7B。最终训练损失和保留验证集上的评估损失均随着模型规模增大而持续下降（见图 1 左和图 3），由此突出了生成式范式更高的参数效率。
- **优化生成式推荐的后训练策略。**我们设计了一个轻量但完整的后训练流程，将全流程 SID 对齐与强化偏好优化紧密结合。首先，我们验证了世界知识对生成式推荐性能的影响（见图 1 右），并通过向词表中加入专用 SID token、在两阶段优化过程中持续施加辅助对齐目标来增强模型。其次，在 RL 阶段，我们直接塑造生成过程本身：通过屏蔽非法 token，保证每一步都生成合法物品；采用 beam search 高效探索多样化候

选；同时引入结合规则精度与排序感知惩罚的奖励信号，使模型远离难负样本。最终，MiniOneRec 给出了一个简洁但有效的方案，将带有基于价值排序信号的强化学习引入生成式推荐之中，并同时改善候选多样性与排序保真度。

本文其余部分组织如下：第 2 节回顾生成式推荐以及推荐系统中 LLM 与 RL 结合的相关背景；第 3 节介绍我们提出的 MiniOneRec，包括任务建模、物品分词与后训练流程；第 4 节给出训练细节；第 5 节汇报全面的实验结果；第 6 节总结全文并讨论未来方向。

2 背景与相关工作

2.1 生成式推荐

在过去几年中，将推荐问题表述为序列生成问题已成为一个十分活跃的研究方向 (Rajput 等, 2023; Hou 等, 2025)。在这一视角下，推荐器以端到端方式预测下一个物品对应的 token，主干通常为 Transformer (Vaswani 等, 2017)。这种设计摆脱了传统基于检索的推荐系统中僵化的 “matching-ranking” 多阶段流水线 (Kang 和 McAuley, 2018; Hidasi 等, 2016)，因此提升了性能上界。

早期探索揭示了两个关键组成部分：(1) 将物品转换为离散代码 (即 SID)；(2) 令模型生成该代码。TIGER (Rajput 等, 2023) 利用 RQ-VAE (Zeghidour 等, 2022) 将标题和描述的文本嵌入映射为 SID。HSTU (Zhai 等, 2024) 提出了适合处理高基数、非平稳日志的流式架构。LC-Rec (Zheng 等, 2024) 则通过多任务学习将 LLM 与 SID 对齐，使模型能够在生成过程中 “理解” 这些符号。

后续工作进一步聚焦于更优编码设计。RecForest (Feng 等, 2022) 通过层次化 k-means 对物品进行聚类，并将聚类索引用作 token。EAGER (Wang 等, 2024) 与 TokenRec (Qu 等, 2024) 则在 tokenizer 中直接融合协同信息与语义信息。

在工业规模场景中，生成式推荐器已经开始取代沉重的级联系统。MTGR (Wang 等, 2025) 保留原始 DLRM 特征，同时增加用户级压缩，并加速训练与推理。OneRec (Zhou 等, 2025b) 通过惰性 decoder-only 布局降低服务成本，并通过改进的 RL 算法稳定优化。OnePiece (Dai 等, 2025) 发现，在潜空间中进行推理还能进一步提升生成式推荐性能。

2.2 LLM 与 RL

强化学习 (RL) 旨在通过与环境的反复交互最大化累计奖励 (Kaelbling 等, 1996)。在对 LLM 进行微调时，基于人类反馈的强化学习 (RLHF) 已成为常见方案，其中 PPO (Schulman 等, 2017) 是使用最广泛的优化器，但在十亿级参数规模上会带来较高内存开销。

为降低成本，直接偏好优化 (Direct Preference Optimization, DPO) (Rafailov 等, 2023) 去除了单独的价值网络，通过最大化 “偏好输出” 与 “非偏好输出” 之间的对数似然差来完成优化。S-DPO (Chen 等, 2024b) 将这一思想迁移到推荐场景中，把基于 softmax 的负采样视为隐式的成对偏好。然而，基于偏好的目标通常是离策略的，并且可能过早收敛。

因此，研究者提出了更加轻量的在线方法。GRPO (Shao 等, 2024) 在一小批 rollout 内对奖励进行归一化，并用基于规则的信号取代学习式奖励模型，在数学与代码生成任务上取得了较强效果。

3 建模方法




图 2: MiniOneRec 框架。RQ-VAE 构建物品 SID 码本。随后，我们通过 SFT 预热 LLM 并得到初始对齐。在 RL 阶段，结合受约束解码的 beam search 使模型按序生成一个由不同且合法 SID 组成的排序列表。GRPO 用于更新策略，同时在端到端流程中持续施加 SID 对齐约束。该对齐目标在 SFT 与 RL 两个阶段均被保留，从而促进更深层的语义理解。

本节介绍 MiniOneRec 的建模策略，如图 2 所示。MiniOneRec 首先使用 RQ-VAE tokenizer 将文本信息转换为 SID (第 3.2 节)。为了更好地利用 LLM 中蕴含的大规模世界知识 (Liao 等, 2023)，MiniOneRec 在原始 OneRec 架构基础上进一步引入与 LLM 的对齐机制 (第 3.3 节)。在训练阶段，MiniOneRec 先通过下一 token 预测进行优化，随后再进行强化偏好优化 (第 3.4 节)。

3.1 任务形式化

我们首先将推荐问题表述为一个序列生成问题。对于每个用户 u ，其交互过的物品按照时间顺序排列形成序列

$$H_u = [i_1, i_2, \dots, i_T].$$

序列中的每个物品 i_t 都被编码为一个三层结构化 ID

$$\{c_0^{i_t}, c_1^{i_t}, c_2^{i_t}\}.$$

这样的结构化 ID 通常被称为 SID。借助基于语义嵌入的量化技术 (Rajput 等, 2023), SID 能够保留层次化语义信息。

一个生成策略 π_θ 由带参数 θ 的自回归模型实现。它读取完整历史 H_u , 并学习预测下一个物品 i^+ , 即在全部候选物品中最符合用户 u 偏好的那个物品。在推理阶段, 模型递归生成物品 token; 我们使用标准 beam search 保留最有希望的 k 条候选路径, 并将它们作为推荐列表返回。模型性能使用生成式推荐领域常见的评估指标进行报告。

3.2 物品分词

在基于 SID 的生成式推荐器中, 首要任务是将每个物品转换为一个离散 token 序列。遵循 TIGER (Rajput 等, 2023) 的做法, 我们采用 RQ-VAE (Zeghidour 等, 2022) 完成该过程。具体流程如下:

1. 对于每个物品 i , 将其标题与文本描述拼接为一个完整句子;
2. 将该句子输入冻结的文本编码器 (Sheng 等, 2025), 得到一个 d 维语义向量 $\mathbf{x} \in \mathbb{R}^d$;
3. 对 $\mathbf{x}$ 应用 RQ-VAE。在每一层 l ($0 \leq l < L$) 处, 都有一个独立码本

$$C_l = \{\mathbf{e}_k^{(l)}\}_{k=1}^K,$$

其中 K 为码本大小。本文设置 $L = 3$ 、 $K = 256$, 因此每个物品可由 3 个字节表示。该设计总共提供 2^{24} 个可能编码, 对于包含数亿商品的目录而言已经足够, 同时又能保持词表紧凑。

残差向量初始化为 $\mathbf{r}_0 = \mathbf{x}$, 并按照如下方式更新:

$$c_l = \arg \min_k \|\mathbf{r}_l - \mathbf{e}_k^{(l)}\|_2^2, \quad \mathbf{r}_{l+1} = \mathbf{r}_l - \mathbf{e}_{c_l}^{(l)}.$$

最终收集各层索引 $(c_0, \dots, c_{L-1})$ 作为物品 i 的离散 token 序列; 这些索引就是后续生成式推荐器所消费的物品 token。

量化后的潜变量重构为

$$\mathbf{z}_q = \sum_{l=0}^{L-1} \mathbf{e}_{c_l}^{(l)}, \quad \hat{\mathbf{x}} = D(\mathbf{z}_q),$$

其中 $D(\cdot)$ 为解码器。码本、编码器和解码器是联合训练的, 而文本编码器保持冻结。训练目标由重构项与 RQ 正则项组成:

$$\mathcal{L}(\mathbf{x}) = \underbrace{\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2}_{\mathcal{L}_{\text{RECO}}} + \sum_{l=0}^{L-1} \underbrace{(\|\text{sg}[\mathbf{r}_l] - \mathbf{e}_{c_l}^{(l)}\|_2^2 + \beta \|\mathbf{r}_l - \text{sg}[\mathbf{e}_{c_l}^{(l)}]\|_2^2)}_{\mathcal{L}_{\text{RQ}}},$$

其中 $\text{sg}[\cdot]$ 表示 stop-gradient 操作, β 为控制 commitment 项强度的超参数。

为了避免码本坍塌, 我们遵循已有工作中的 warm-start 技巧 (Zeghidour 等, 2022; Zheng 等, 2024), 使用首个训练 batch 上的 k-means 聚类中心来初始化各层码本。

3.3 与 LLM 的对齐

LLM 对世界知识与人类行为具有广泛理解 (Sheng 等, 2025), 这可以作为推荐系统中协同信号的有效补充 (Ren 等, 2024)。已有研究表明, 将 LLM 的世界知识与 SID 表示建立联系, 能够显著增强生成式推荐能力 (Liao 等, 2023; Zheng 等, 2024)。因此, 与仅在 SID 空间上训练的先前工作 (Rajput 等, 2023; Deng 等, 2025; Wang 等, 2025) 不同, 我们引入了一系列对齐目标, 将自然语言空间与 SID 信号连接起来。我们主要采用两大类任务:

- **推荐任务:** 模型接收按时间排序的用户历史以及清晰的指令, 并被要求预测用户下一步可能交互物品的 SID。
- **对齐任务:** 通过一组桥接任务, 在自然语言与 SID 空间之间建立双向映射, 使离散代码能够锚定于文本语义之中, 同时也把语言知识注入对应嵌入表示。

这两类任务会在 SFT 阶段以及随后的 RL 阶段中联合优化。在 RL 过程中, 我们采用受约束解码, 使模型只能从一个预定义列表中生成 token, 该列表包含每个物品的 SID 及其规范标题。这样的限制既保证了输出合法, 也使得基于规则的奖励计算变得直接可行。更详细的提示词示例见附录 A。

3.4 强化偏好优化

在完成 SFT 之后, 我们进一步使用 GRPO (Shao 等, 2024; DeepSeek-AI 等, 2024) 来打磨策略。GRPO 与经典 RLHF 的不同之处在于: 它会针对同一个提示采样多个候选, 并在组内对奖励进行归一化, 从而降低梯度方差。

其步骤如下: (1) 对于每个提示 $x \sim \mathcal{D}$, 冻结策略 $\pi_{\theta_{\text{old}}}$ rollout G 次, 得到

$$Y(x) = \{y^{(1)}, \dots, y^{(G)}\};$$

(2) 每个候选 $y^{(i)}$ 被赋予一个标量分数 S_i ; (3) 在组内标准化优势:

$$\hat{A}_i = \frac{S_i - \mu_{1:G}}{\sigma_{1:G}},$$

其中 $\mu_{1:G}$ 和 $\sigma_{1:G}$ 分别表示这 G 个奖励的均值与标准差。

于是，代理目标函数为

$$J_{\text{GRPO}}(\theta) = \mathbb{E}_{x, y^{(i)}} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y^{(i)}|} \sum_{t=1}^{|y^{(i)}|} \left(\min(w_{i,t} \hat{A}_{i,t}, \text{clip}(w_{i,t}, 1 - \epsilon, 1 + \epsilon) \hat{A}_{i,t}) - \beta \text{KL}_{\pi_{\theta} \parallel \pi_{\text{ref}}} \right) \right],$$

其中 token 级重要性比率为

$$w_{i,t} = \frac{\pi_{\theta}(y_t^{(i)} \mid x, y_{<t}^{(i)})}{\pi_{\theta_{\text{old}}}(y_t^{(i)} \mid x, y_{<t}^{(i)})}.$$

参数 ϵ 用于控制裁剪范围，而 β 则通过 KL 项约束更新后的策略不要偏离参考模型过远。

将带可验证奖励的强化学习（RLVR）用于推荐任务会遇到两个障碍：

- **独特的生成空间。** 动作空间是一个封闭的物品 SID 集合，其规模远小于自然语言词表。对同一提示重复采样时很容易产生重复结果，造成计算浪费。因此，我们结合动态采样（Yu 等，2025）与受约束 beam search，以在保证输出合法的同时扩大覆盖范围。
- **稀疏的排序监督。** 若只采用硬二值奖励（正确物品得 1，其余得 0），则对排序质量的指导非常有限。为此，我们引入一个辅助的、与排序相关的奖励，对更难的负样本施加更强惩罚。此外，我们还探索使用语义相似度与协同过滤得分等稠密信号来提供更丰富监督。

3.4.1 采样策略

当将 RLVR 迁移到推荐场景时，一个现实障碍在于：由于动作空间有限，采样多样性通常很差。对同一提示多次查询策略，往往会返回相同物品，因此模型能够观察到的不同负样本很少。本文用如下指标度量多样性：

$$\text{Div}(\{e_k\}_{k=1}^G) = \frac{|\text{Unique}(\{e_k\}_{k=1}^G)|}{G},$$

其中分子统计 G 个生成结果中的唯一物品数。该值越高，说明监督越丰富。

我们研究了两种互补的缓解方式：

- **动态采样**（Yu 等，2025）：先进行过采样，再从中挑选一个子集，该子集既必须包含真实物品，又要尽可能提升内部多样性。虽然这种方法有帮助，但需要额外前向计算，并且其效果会随着训练推进而逐渐退化。
- **Beam Search**：最终我们改为使用不带长度归一化的 beam search（Bao 等，2024；Tan 等，2025）。该方法天然保证各 beam 互不相同，因此能够在每组内实现零重复，并在多样性与效率之间取得更好的折中。

基于实验结果，MiniOneRec 最终采用受约束 beam search 作为默认采样器，从而确保每个生成物品都合法，同时仍能提供多样化的候选轨迹集合。

3.4.2 奖励设计

推荐模型通常使用 NDCG 等排序指标进行评估。相比之下，标准 GRPO 设置只提供二值奖励：真实物品为 1，其余候选均为 0。这样的策略将所有负样本视为“同样有害”。已有研究（Wu 等，2021；Chen 等，2024b）表明，关注难负样本能够得到更强的排序模型。受此启发，我们引入排序感知奖励，根据一个负样本在模型自身排序中的位置，为其分配不同的惩罚强度（Tan 等，2025）。

设负候选为 e_k ，其生成概率对应的排序位置为 ρ_k （其中 $\rho = 1$ 表示概率最高），则有

$$\tilde{R}_{\text{rank}}(e_k, e_t) = \begin{cases} 0, & e_k = e_t, \\ -\frac{1}{\log(\rho_k + 1)}, & \text{否则}, \end{cases} \quad R_{\text{rank}}(e_k, e_t) = -\frac{\tilde{R}_{\text{rank}}(e_k, e_t)}{\sum_{j=1}^G \tilde{R}_{\text{rank}}(e_j, e_t)}.$$

因此，模型置信度很高的负样本（即 ρ_k 较小）将受到更强惩罚。

最终奖励结合规则项与排序项：

$$R(e_k, e_t) = R_{\text{rule}}(e_k, e_t) + R_{\text{rank}}(e_k, e_t),$$

其中规则奖励定义为

$$R_{\text{rule}}(e_k, e_t) = \begin{cases} 1, & e_k = e_t, \\ 0, & \text{否则}. \end{cases}$$

上述混合奖励同时利用了二值正确性与平滑的排序信号，使 LLM 能更好地区分难负样本。不过，推荐数据中还存在其他尚未充分利用的信息。为检验这些信息能否增强甚至替代规则奖励，我们还实验了协同过滤奖励：对于策略提出的每个物品，使用一个预训练协同过滤模型的 logit 作为奖励反馈，以注入历史用户-物品交互中提取出的知识。最终，MiniOneRec 选择“排序奖励 + 规则奖励”的组合作为默认方案。

4 训练细节

MiniOneRec 首先将物品文本转换为离散编码。标题与描述先由 Qwen3-Embedding-4B 编码器嵌入，然后再由 RQ-VAE 进行残差量化。该 tokenizer 在单张 GPU 上训练，batch size 为 20480，学习率为 1×10^{-3} ，训练轮数为 10000。得到的 SID 词表随后被接入 Qwen2.5-Instruct 主干模型。

SFT 在 8 张 NVIDIA H100 上进行，每张卡容纳 128 个样本。训练最多持续 10 个 epoch，并采用 early stopping（容忍度为 1 个 epoch）。初始学习率为 3×10^{-4} ，并使用 cosine decay 调度。以 SFT 检查点为起点，我们再进行 2 个 epoch 的 GRPO 训练，期间保持 KL 权重 β 不变。在 rollout 阶段，beam search 的宽度设置为 16，因此每个输入都会生成 16 条不同的候选序列。

在与现有推荐方法的性能比较中，传统推荐模型使用二元交叉熵与 Adam 优化器进行

训练;学习率从 $\{10^{-2}, 10^{-3}, 10^{-4}\}$ 中选择,权重衰减从 $\{10^{-2}, 10^{-3}, 10^{-4}, 10^{-5}, 10^{-6}\}$ 中扫描, batch size 为 1024。对于 TIGER, 我们采用 T5 encoder-decoder, 并复用 Qwen3-Embedding-4B 作为物品嵌入编码器。所有基于 LLM 的系统 (包括本文方法) 共享 Qwen2.5-Instruct 主干并使用 AdamW。SFT 与偏好对齐的 batch size 为 128, RL 阶段 batch size 为 512。SFT 学习率为 3×10^{-4} , 而 S-DPO 与 RL 均使用 1×10^{-5} 。S-DPO 训练 1 个 epoch, $\beta = 0.1$, 并采样 3 个负样本; D³ 则尝试插值系数 $\alpha \in \{0.8, 0.9, 1.0\}$ 。

5 实验评估

本节给出实证研究结果。首先,我们在两个真实世界基准 (Hou 等, 2024) 上考察 MiniOneRec 的规模化行为,分析随着模型规模增大,其损失曲线如何变化。随后,我们将 MiniOneRec 与三类基线进行比较:传统顺序推荐器、基于 SID 的生成模型以及近期的 LLM 驱动方法。为评估模型的跨域泛化能力,我们把 SID 的下一物品预测视为“推荐规则发现”任务,并在训练期间从未出现过的领域上进行测试。随后给出全面的消融实验,以定位框架中对最终效果贡献最大的组成部分。最后,我们分析预训练 LLM 权重中蕴含的广义知识对生成式推荐的影响。概括而言,本节围绕以下问题展开:

- MiniOneRec 的损失如何随模型规模变化而变化?
- 与其他基线方法相比,MiniOneRec 的性能表现如何?
- 在完全未见过的领域上,MiniOneRec 的表现如何?
- 所设计的各个组件对 MiniOneRec 的推荐效率有何贡献?
- LLM 的预训练权重如何影响生成式推荐性能?

5.1 评估设置

实验在 Amazon Review 数据集 (Hou 等, 2024) 的两个真实子集上进行,分别是 Office 与 Industrial。为了衡量 top- K 推荐准确率,我们遵循标准做法,计算 Hit Rate (HR@K) 以及 Normalized Discounted Cumulative Gain (NDCG@K)。

5.2 规模化规律

我们展示了 MiniOneRec 的规模化能力:随着模型规模增大,收敛损失持续下降。正如图 1 所示,在生成式推荐范式下,模型规模与损失之间存在清晰关联。随着 LLM 规模提升,收敛损失不断降低。此外,图 3 记录了 SFT 训练过程中每 0.5 个 epoch 的评估损失。可以看到,参数规模更大的模型几乎在整个训练过程中都保持更低的评估损失,并且收敛速度更快。这种优良的扩展效应展示了生成式推荐器作为下一代推荐模型的潜力。




图 3: 评估损失随 SFT 训练轮数的变化。

5.3 性能比较

我们的基线分为三类：(1) 传统推荐模型，包括 GRU4Rec (Hidasi 等, 2016)、Caser (Tang 和 Wang, 2018)、SASRec (Kang 和 McAuley, 2018)；(2) 生成式推荐模型，包括 HSTU (Zhai 等, 2024)、TIGER (Rajput 等, 2023)、LC-Rec (Zheng 等, 2024)；(3) 基于 LLM 的推荐模型，包括 BIGRec (Bao 等, 2023)、D³ (Bao 等, 2024) 以及 S-DPO (Chen 等, 2024b)。

我们在 Industrial 与 Office 两个基准上评估 MiniOneRec，并将结果汇总于表 1。可以得到两点主要结论：

- **LLM 世界知识的有效性。** 由 LLM 驱动的推荐器，如 BIGRec 与 D³，明显优于 GRU4Rec 与 Caser 这类传统方法，说明 LLM 中蕴含的广义知识能够转化为更高的推荐准确率。
- **MiniOneRec 的有效性。** MiniOneRec 在此基础上更进一步：通过使整个生成过程与任务目标对齐，并在 RL 阶段使用强化偏好优化，它在大多数报告指标上都稳定超过已有的生成式方案。此外，由于在紧凑的 SID 空间中工作，而不是直接生成冗长的文本标题，MiniOneRec 所需上下文 token 更少、推理更快，进而在服务阶段带来更低延迟与更小内存开销。

表 1: MiniOneRec 与传统方法、生成式方法及基于 LLM 的方法的性能比较

数据集	方法	HR@3	NDCG@3	HR@5	NDCG@5	HR@10	NDCG@10
Industrial	GRU4Rec	0.0638	0.0542	0.0774	0.0598	0.0999	0.0669
	Caser	0.0618	0.0514	0.0717	0.0555	0.0942	0.0628
	SASRec	0.0790	0.0700	0.0909	0.0748	0.1088	0.0806
	HSTU	0.0927	0.0885	0.1037	0.0918	0.1163	0.0958
	TIGER	0.0852	0.0742	0.1010	0.0807	0.1321	0.0908
	LCRec	0.0915	0.0805	0.1057	0.0862	0.1332	0.0952
	BIGRec	0.0931	0.0841	0.1092	0.0907	0.1370	0.0997
	D ³	0.1024	0.0991	0.1213	0.0989	0.1500	0.1082
	S-DPO	0.1032	0.0906	0.1238	0.0991	0.1524	0.1082
	MiniOneRec	0.1143	0.1011	0.1321	0.1084	0.1586	0.1167
Office	GRU4Rec	0.0629	0.0528	0.0789	0.0595	0.1019	0.0669
	Caser	0.0748	0.0615	0.0865	0.0664	0.1093	0.0737
	SASRec	0.0861	0.0769	0.0949	0.0805	0.1120	0.0858
	HSTU	0.1134	0.1031	0.1252	0.1079	0.1400	0.1126
	TIGER	0.0986	0.0852	0.1163	0.0960	0.1408	0.1002
	LCRec	0.0921	0.0807	0.1048	0.0859	0.1237	0.0920
	BIGRec	0.1069	0.0961	0.1204	0.1017	0.1434	0.1091
	D ³	0.1204	0.1055	0.1406	0.1139	0.1634	0.1213
	S-DPO	0.1169	0.1033	0.1356	0.1110	0.1587	0.1255
	MiniOneRec	0.1217	0.1088	0.1420	0.1172	0.1634	0.1242

5.4 迁移能力

我们通过一个称为 *SID pattern discovery* 的实验来评估 MiniOneRec 的分布外 (OOD) 鲁棒性。模型仅在 Industrial 域上训练，然后在不做任何额外调优的条件下，直接部署到从未见过的 Office 域。已有工作 (Jin 等, 2025; Yue 等, 2025; Yoshihara 等, 2025; Cheng 等, 2025) 指出, SFT 可能会对源域过拟合并损害迁移能力, 因此我们额外加入一个仅使用 RL 的变体 MiniOneRec-w/ RL-OOD, 它完全跳过 SFT, 以强调泛化性能。

比较对象共有四种系统: (1) GRU4Rec, 在 Office 域内训练并测试; (2) Qwen-Text, 用纯文本句子表示用户历史, 并直接预测下一物品标题, 不进行额外微调; (3) Qwen-SID, 用 SID token 编码同样的历史, 并在不做额外微调的前提下预测下一个 SID; (4) MiniOneRec-w/ RL-OOD, 仅在 Industrial 上通过 GRPO 训练, 再直接在 Office 上评估, 以测试其 OOD 性能。

表 2 给出了结果。Qwen-Text 表现很差, 而 Qwen-SID 明显更好, 这说明结构化 SID 词表更容易被 LLM 利用。虽然 MiniOneRec-w/ RL-OOD 的域内得分不如完整的 MiniOneRec, 但其仅依靠强化学习的训练方式赋予了它优良的迁移能力, 使其在未见过的目录上仍获得了具有竞争力的准确率。即便存在明显领域偏移以及 SID 语义漂移的可能, MiniOneRec 依然成功发现了可复用的交互模式, 从而体现出该框架在跨域推荐中的潜力。

表 2: MiniOneRec 及其变体在完全未见过的推荐域上的性能

数据集	方法	HR@3	NDCG@3	HR@5	NDCG@5	HR@10	NDCG@10
Office	GRU4Rec	0.0629	0.0528	0.0789	0.0595	0.1019	0.0669
	Qwen-Text	0.0031	0.0021	0.0044	0.0026	0.0057	0.0030
	Qwen-SID	0.0300	0.0214	0.0456	0.0282	0.0733	0.0373
	MiniOneRec-w/ RL-OOD	0.0553	0.0433	0.0691	0.0489	0.0892	0.0553

5.5 消融实验

为了验证 MiniOneRec 各组件的有效性，我们将其与若干替代方案进行比较。

5.5.1 对齐策略

为了隔离各组件的影响，我们将完整的 MiniOneRec 与三个简化变体进行比较：(1) MiniOneRec-W/O ALIGN：移除任何语言-SID 对齐，仅将推荐视为纯 SID 到 SID 的任务；(2) MiniOneRec-W/ SFTALIGN：仅在 SFT 阶段保留对齐目标，RL 阶段只使用 SID 数据；(3) MiniOneRec-W/ RLALIGN：SFT 完全依赖 SID 监督，而对齐任务在 RL 阶段才被引入。

图 4(a) 总结了结果。完整的 MiniOneRec 在整个流程中始终保持对齐，因此在所有指标上都取得了最高分。MiniOneRec-W/O ALIGN 的表现最差，这表明：将 SID 生成锚定到世界知识之中是十分关键的。

5.5.2 采样策略

我们只替换轨迹生成器而保持其余部分不变，以研究不同 rollout 方法对 MiniOneRec 的影响：(1) MiniOneRec-COMMON 使用普通 Top- k 解码器，生成恰好所需数量的路径；(2) MiniOneRec-DYNAMIC 采用两阶段采样器，先采样为预算的 1.5 倍，再尽可能保留唯一物品用于 RL；完整模型则采用宽度为 16 的 beam search。

如图 4(b) 所示，完整的 MiniOneRec 在使用大约动态采样变体三分之二样本量的情况下，仍取得了最高准确率，这表明 beam search 是所测试策略中性价比最高的选择。

5.5.3 奖励设计

我们比较三种变体：(1) MiniOneRec-W/ ACC，仅依赖二值正确性信号；(2) MiniOneRec-W/ Collaborative，用冻结 SASRec 模型输出的 logit 替换排序项，以提供协同线索；(3) 完整的 MiniOneRec。

如图 4(c) 所示，完整的 MiniOneRec 整体性能最佳。值得注意的是，将协同奖励信息注入 RL 过程反而导致显著退化。作者推测，这种现象源于 *reward hacking*：即使推荐准确率下降，奖励却仍在增加，从而暴露出该协同奖励信号与真实优化目标之间存在失配。




图 4: MiniOneRec 各组成部分有效性分析。(a) 不同对齐策略下的性能；(b) 不同采样策略的比较；(c) 不同奖励设计对性能的影响。

5.6 预训练 LLM 的影响

为了隔离预训练 LLM 对生成式推荐的影响，我们构造了两个 MiniOneRec 变体：一个从通用预训练 LLM 初始化，另一个则从随机权重开始训练。如表 3 所示，在两个基准数据集上的实验都呈现出一致结论：以预训练权重初始化的模型显著优于随机初始化的对应模型。作者推测，这主要来自两方面原因：(1) 在大规模语言预训练中获得的一般推理能力，使模型能够将“下一 SID 预测”视作一种模式发现任务，这一点与第 5.4 节的讨论相呼应；(2) LLM 已经编码的真实世界知识，为理解每个 SID 背后的现实语义提供了良好起点，其中一部分能力可以迁移到推荐场景中。

表 3: 使用预训练权重初始化与随机初始化的 MiniOneRec 在两个领域上的性能比较

数据集	方法	HR@3	NDCG@3	HR@5	NDCG@5	HR@10	NDCG@10
Industrial	MiniOneRec-scratch	0.0757	0.0672	0.0891	0.0726	0.1134	0.0804
	MiniOneRec	0.1125	0.0988	0.1259	0.1046	0.1546	0.1139
Office	MiniOneRec-scratch	0.0959	0.0855	0.1057	0.0896	0.1196	0.0941
	MiniOneRec	0.1217	0.1088	0.1420	0.1172	0.1634	0.1242

6 结论

本文介绍了 MiniOneRec。据我们所知，这是首个完全开源的生成式推荐框架，提供了一个覆盖 SID 构建、SFT 与面向推荐的 RL 的端到端工作流。通过在公开基准上系统验证规模律，我们表明：规模更大的生成式推荐器能够取得更低的训练损失与评估损失，这印证了基于 SID 的生成式范式相对于传统“嵌入表中心”模型更具参数效率。在此基础上，本文进一步提出两类后训练技术：(1) 全流程 SID 对齐，即将 SID token 嵌入模型词表，并在 SFT 与 RL 两阶段都施加辅助对齐任务；(2) 强化偏好优化，即结合受约束解码、基于 beam 的采样以及混合奖励设计。Amazon Review 上的大量实验表明，MiniOneRec 在保持较轻后训练代价的同时，能够稳定超过强有力的顺序推荐、生成式推荐与基于 LLM 的基线方法。

展望未来，作者团队将持续维护并扩展 MiniOneRec 代码库。公开路线图将用于指导后续开发，同时也欢迎社区贡献。计划中的更新包括：加入新的数据集、更先进的 tokenization

方案、更大的主干模型以及更完善的训练流水线，从而使 MiniOneRec 持续成为大规模生成式推荐研究与实践的重要参考平台。

A 对齐提示词

A.1 总体说明

本节介绍作者如何将 LLM 的世界知识与 SID 空间进行对齐，使得模型能够被直接用于生成式推荐。

作者在原始 tokenizer 词表上追加了一个三层码本，每层包含 256 个唯一 SID。新增代码被视为不可再分的原子 token，从而使 LLM 能够在不发生子词切分的前提下读取和生成 SID 序列。随后，作者引入一组辅助 **对齐任务**，用于弥合文本词表与新增 SID 之间的语义鸿沟；同时还设计了专门的 **推荐任务**，用来教模型根据用户历史预测下一物品的 SID。

A.2 推荐任务

1. **生成式检索**。这是生成式推荐的核心任务。LLM 接收一个按时间顺序排列的 SID 序列，用以表示用户近期交互历史，同时附带一条显式指令，例如“推荐下一件物品”。模型需要预测用户下一步可能交互物品的 SID。一个示例提示可表述为：

输入：用户按时间顺序交互过如下物品：<a_13><b_197><c_1>、<a_52><b_17><c_113>、<a_13><b_201><c_34>。请预测该用户下一步最可能交互的物品。

输出：<a_13><b_72><c_149>

2. **非对称物品预测**。(a) 给定文本形式的用户历史，预测下一物品的 SID；(b) 给定仅由 SID 构成的历史，生成下一物品的文本标题。示例可表述为：

输入：用户按时间顺序交互过如下物品标题：Kreg SML-C150-100 Pocket Screws 1-1/2-Inch, 8 Coarse, Washer-Head, 100-Count; 3M flap disc 566A, T29, 4-1/2" Diameter, 40 Grit, 5/8"-11 Thread (Pack of 1)。请预测该用户下一步可能交互物品的 SID。

输出：<a_104><b_60><c_152>

输入：用户按时间顺序交互过如下 SID：<a_71><b_44><c_249>、<a_71><b_114><c_136>、<a_67><b_244><c_35>。请预测该用户下一步可能交互物品的标题。

输出：How the Grinch Stole Christmas!: Mini Edition (Dr Seuss Miniature Edition)

A.3 对齐任务

1. **SID-文本语义对齐**。(a) 由 SID 预测物品标题；(b) 由物品标题预测其 SID。示例：

输入：<a_24><b_141><c_73> 的标题是什么？

输出：Oral-B Deep Sweep Toothbrush

输入：哪一个物品的标题是 *Nashua Stretch & Seal Self-Fusing Silicone Tape*?

输出：<a_202><b_202><c_29>

2. **物品描述重建**。为了让 SID 锚定到更丰富的语义信息中，作者要求模型根据单个 SID 生成物品描述；反向地，也要求模型根据描述推断对应 SID。由于描述空间较大且较为开放，这一任务仅在 SFT 阶段使用。示例：

输入：一个物品可描述为：Relay/CAPACITOR hard start kit 500% incr starting torque, increased compressor starting torque. Designed for use on permanent split CAPACITOR single phase a/c and heat pump systems. Multiple use includes: room air conditioner units, residential or commercial psc AC units. the country of origin is China. 该描述对应哪个物品？

输出：<a_113><b_16><c_2>

3. **用户偏好摘要**。给定一段 SID 序列，模型输出一段简短自然语言画像，以总结用户兴趣。由于原始数据集中缺少显式偏好标签，作者使用 DeepSeek (DeepSeek-AI 等, 2024) 从物品元数据和用户文本评论中抽取摘要，并将其作为伪标签。由于输出空间开放，该任务同样只在 SFT 阶段使用。示例：

输入：用户按时间顺序交互过如下 SID: <a_39><b_41><c_1>、<a_39><b_28><c_16>、<a_67><b_142><c_35>。请总结该用户的偏好。

输出：基于已购买物品，该用户明显偏好耐用、高性能且偏实用的动手类用品，偏向电工作业、日常维修等场景，因此需要可靠的个体防护装备与精密工具。

B 数据集

作者在 Amazon Review 的两个子集上评估模型：Industrial_and_Scientific 与 Office_Products。为了控制计算成本，他们采用了 Bao 等 (2024) 使用的裁剪策略。主要步骤如下：(1) 移除交互次数少于 5 的用户与物品；(2) 对于 Toys_and_Games，保留 2016 年 10 月至 2018 年 11 月的事件；(3) 对于规模较小的 Industrial_and_Scientific，保留 1996 年 10 月至 2018 年 11 月之间的全部事件；(4) 将每个用户历史截断到最多 10 个物品；(5) 最终按时间顺序以 8:1:1 划分训练、验证与测试集。所得训练集的关键统计量如表 4 所示。

表 4: 数据集统计信息

数据集统计	Industrial	Office
Items	3,685	3,459
Train	36,259	38,924
Valid	4,532	4,866
Test	4,533	4,866

参考文献说明

原文参考文献页较长，且题录以英文作者名、英文题名与会议/期刊信息为主。为避免在中文翻译稿中重复堆叠大量英文条目，本文档未逐条翻译参考文献；如需完整题录，请直接对照原始 PDF 第 13–17 页查看。