

Rec-R1：通过强化学习连接生成式大语言模型与以用户为中心的推荐系统

中文翻译稿

原文作者：Jiacheng Lin, Tian Wang, Kun Qian

说明：本文依据用户上传论文整理为中文 L^AT_EX 译稿。正文与主要附录内容已译为中文；参考文献条目保留原文英文信息，便于后续核对与引用。

摘要

我们提出 Rec-R1，这是一种通用的强化学习框架，用于通过闭环优化将大语言模型（LLM）与推荐系统连接起来。不同于提示式方法与监督微调（SFT），Rec-R1 直接利用固定的、黑盒的推荐模型所返回的反馈来优化 LLM 的生成过程，而不依赖于由 GPT-4o 等专有模型构造的合成式 SFT 数据。这避免了数据蒸馏所需要的大量成本与人力投入。为了验证 Rec-R1 的有效性，我们在三个具有代表性的任务上进行评测：商品搜索、序列推荐以及商品重排序。实验结果表明，Rec-R1 不仅稳定优于基于提示和基于 SFT 的方法，而且即便与 BM25 这类简单检索器结合使用，也能够相较于强判别式基线取得显著提升。更重要的是，Rec-R1 能够保留 LLM 的通用能力，而 SFT 往往会损害指令遵循与推理能力。这些结果表明，Rec-R1 有望成为一种适用于持续任务适配、且不引发灾难性遗忘的基础方法。数据与代码见：<https://github.com/linjc16/Rec-R1>。

1 引言

推荐系统已经成为多种现实应用中的核心组成部分，覆盖了电子商务、视频平台、新闻分发以及社交媒体等多个场景。尽管推荐系统在过去数十年中取得了显著进展，但现代系统仍然存在一些根本性局限。其中最突出的一点在于，它们缺乏开放域世界知识，同时难以真正理解用户更深层次的动机与偏好。这些不足往往会导致推荐性能不理想，尤其是在用户意图是隐含表达的，或是通过自然语言给出的复杂场景中，这种问题更加明显。

近年来，生成式大语言模型的快速发展为增强推荐系统带来了新的可能性。LLM 在大规模网络语料上训练，因此具备丰富的开放世界知识，并拥有较强的自然语言理解与推理能力。正因如此，LLM 特别适用于以用户为中心的推荐场景，因为这类场景的关键挑战恰恰在于：理解语言驱动的输入、捕获隐含的用户意图，并使推荐结果与用户需求相一致。

图 1 给出了生成式 LLM 在推荐系统中应用方式的分类示意。上半部分表示将 LLM 用于特征工程，包括：（1）查询改写，即用 LLM 对输入查询进行重写，以提升检索效果；（2）用户/物品级特征增强，即将用户信息或物品信息编码成更丰富的文本表示，并送入下游模型。下半部分表示将

LLM 直接用作打分/排序函数，包括：(3) 闭集物品生成，即对给定候选列表进行排序；(4) 开集物品生成，即 LLM 直接生成候选物品，再与商品池进行匹配。需要注意的是，这幅图主要反映的是推理时设定，因此其中的 LLM 均被冻结；而本文提出的 Rec-R1 与上述四类范式均兼容。

因此，近期研究已开始在推荐流程的多个阶段中使用 LLM，例如查询改写、用户意图摘要等，以提升检索和排序等下游推荐任务的性能。现有方法通常采用零样本/少样本提示，或者监督微调，以使 LLM 适配推荐任务。图 1 展示了 LLM 在推荐系统中的主要应用范式。

然而，多数现有方法仍然将 LLM 与推荐模型视作相互割裂的两个组件，LLM 的生成结果与推荐性能之间并没有形成真正的闭环反馈。因此，LLM 通常是通过代理目标进行优化，而不是直接根据推荐系统的反馈进行训练；这与提升推荐质量这一最终目标往往并不一致。进一步地，为中间任务（如查询改写）构造高质量监督数据，通常需要人工标注、商用 LLM API（如 GPT-4）或者从历史交互日志中挖掘数据。然而，这些来源很少能够真正生成与最优推荐性能一致的数据。更糟的是，若要大规模生成这类数据，无论依赖人工还是商业模型，时间成本和经济成本都相当高。图 2 给出了一个概念验证实验，说明了 SFT 在效果与开销两个方面的局限。

为了解决上述问题，我们提出 Rec-R1。该方法利用强化学习，通过闭环优化，将生成式 LLM 与下游黑盒推荐系统桥接起来。与依赖静态数据和代理监督的现有方法不同，Rec-R1 允许 LLM 直接从推荐反馈（如检索指标、排序指标）中学习，从而使生成过程与“提升推荐质量”这一真正目标对齐。具体而言，对于任意与推荐相关的输入，例如用户查询或行为历史，LLM 生成一段文本输出，并由下游推荐模型消费。该文本在不同任务下形式不同，例如改写后的查询、综合得到的用户画像，或者增强过的物品文本描述。随后，推荐系统利用基于规则的性能指标（如 NDCG、Recall）对 LLM 生成文本进行评价，并将这些指标转化为强化学习的奖励信号，用以优化 LLM。通过与推荐系统进行反复交互，LLM 会逐渐学会生成更符合系统目标的输入，从而在不依赖次优中间监督的情况下，提升推荐性能。

Rec-R1 与推荐模型的具体架构无关，也对任务具有很强的灵活性。它可以与稀疏检索器（如 BM25）、稠密判别式模型以及混合型推荐流水线结合，而无需修改这些系统的内部结构。只要生成文本能够被下游推荐系统消费，Rec-R1 就能支持多样化的生成任务。并且，由于 Rec-R1 仅依赖推荐性能指标这一黑盒反馈，并不要求访问模型梯度或内部参数，因此它很容易叠加部署到已有生产系统之上。与此同时，它也消除了构造 SFT 数据的需要，使得生成模型能够通过交互直接得到优化。

本文在三个代表性推荐场景上评估了 Rec-R1：商品搜索、序列推荐以及商品重排序，以验证其有效性。实验表明，在商品搜索任务上，Rec-R1 显著提升了整体推荐性能，并在相关基准上取得了最先进结果；在序列推荐中，Rec-R1 也能够持续取得增益，尤其是在缺乏用户画像信息的冷启动场景中，优于常见的序列推荐基线；在商品重排序中，Rec-R1 同样明显优于强交叉编码器与基于 LLM 的重排序基线。除性能提升外，本文还进一步考察了 Rec-R1 是否能够保留底层语言模型的通用能力。结果显示，在衡量指令遵循能力的 IFEval 基准上，Rec-R1 不仅没有退化，反而略有提升，而 SFT 则下降了 27 分以上。

本文贡献

1. 提出 Rec-R1，一种通过奖励驱动优化将生成式 LLM 与推荐系统连接起来的通用强化学习框架。该方法对推荐系统模型无关，并支持多种任务。

2. 在商品搜索、序列推荐、商品重排序三类代表性任务上进行了充分实验，证明 Rec-R1 能够在不同推荐架构下显著提升性能。尤其是在商品搜索上，相比对应基线，Rec-R1 对 BM25 检索器的 NDCG@100 最高提升达 21.45 个点，对稠密判别式模型最高提升达 18.76 个点。
3. Rec-R1 在获得强任务特化性能的同时，仍能保留初始化 LLM 的通用能力；在推荐效果与指令遵循泛化能力上均优于监督微调。

2 Rec-R1

2.1 问题表述

我们首先对 LLM 在推荐系统中的使用方式进行建模。在这一通用设定下，LLM 接收一个输入 $s \in S$ ，它可以表示用户查询、行为历史或者上下文信息。随后，LLM 生成一个文本输出 $a \in A$ ，例如重写后的查询、增强后的物品描述或者综合生成的用户画像。该输出被送入下游推荐模型，并得到一个基于性能的评价 $f(a|s) \in \mathbb{R}$ ，例如 NDCG、Recall 或其他任务特定指标。

LLM 的行为由条件生成策略 $\pi_\theta(a|s)$ 决定，其中 θ 表示生成式 LLM 的参数。其优化目标是寻找一个能够最大化期望推荐性能的策略：

$$\max_{\theta} \mathbb{E}_{s \sim p(s), a \sim \pi_\theta(a|s)} [f(a|s)].$$

其中， $p(s)$ 表示提供给 LLM 的与推荐相关输入的经验分布。

2.2 对现有范式局限性的理论分析

尽管面向推荐的 LLM 使用目标是最大化下游性能 $\mathbb{E}[f(a|s)]$ ，现有主流范式都没有直接优化这一目标。

基于提示的方法，包括零样本与少样本提示，将 LLM 视为冻结的生成器。这类方法依赖人工构造的提示词或少量示例来诱导模型输出期望结果。然而，由于模型参数 θ 没有被更新，策略 $\pi_\theta(a|s)$ 始终固定，无法根据任务相关反馈进行自适应，因此推荐性能往往不是最优的。

监督微调则强迫 LLM 去模仿由更强模型（如 GPT-4o）所产生的输出。从形式上看，这等价于在学习策略 π_θ 下最大化由数据生成策略 π_g 采样动作的对数似然：

$$\max_{\theta} \mathbb{E}_{s \sim p(s), a \sim \pi_g(a|s)} [\log \pi_\theta(a|s)].$$

这一最大似然目标鼓励学习到的策略模仿 π_g ，但在优化过程中并没有显式考虑下游性能 $f(a|s)$ 。作者进一步指出，这种训练方式天然存在性能上界。

事实 1 (SFT 收敛到数据生成策略) 设 $\pi_g(a|s)$ 为固定的数据生成策略，并考虑监督微调目标

$$\pi_\theta^* = \arg \max_{\theta} \mathbb{E}_{s \sim p(s), a \sim \pi_g(a|s)} [\log \pi_\theta(a|s)].$$

若满足：(1) 策略类有足够表达能力，可以逼近 π_g ；(2) 优化过程收敛到全局最优；(3) 训练样本足够多，使经验分布收敛到真实分布，则最优策略 π_θ^* 等价于最小化相对于 π_g 的 KL 散度：

$$\pi_\theta^* = \arg \min_{\theta} \mathbb{E}_{s \sim p(s)} [D_{\text{KL}}(\pi_g(\cdot|s) \parallel \pi_\theta(\cdot|s))].$$

附录给出的证明说明：SFT 所学到的策略本质上被限制为对数据生成策略进行模仿。因此，SFT 训练得到的模型，其推荐性能至多只能接近——而无法超越——用于生成训练数据的教师策略（例如 GPT-4o）。文中的 ESCI 实验也验证了这一点：SFT 模型性能虽然接近 GPT-4o，但并未超过它。而 GPT-4o 本身又并没有针对具体下游推荐任务做过显式优化，因此其性能通常并不是最优的。

2.3 Rec-R1 框架

为了克服提示法与 SFT 的限制，本文提出 Rec-R1。该方法通过强化学习，把生成式 LLM 与推荐系统桥接起来。与其去模仿某个静态的数据生成策略，Rec-R1 直接根据下游推荐器反馈来优化 LLM 策略 π_θ ，从而使生成过程与真正目标——最大化推荐性能——保持一致。

Rec-R1 的核心思想是将 LLM 与推荐系统之间的交互建模为一个闭环优化过程：LLM 产生文本（例如重写查询、用户画像、物品描述），推荐模型利用任务特定指标对这一结果进行评估，再将评估值转化为标量奖励，用于通过强化学习进行策略更新。

其中奖励被形式化为标量 $r = f(a|s) \in \mathbb{R}$ ，用以刻画在给定输入 s 下，LLM 生成输出 a 在下游任务中的表现。奖励函数既可以使用可微指标，也可以使用不可微指标，例如 NDCG@K 与 Recall@K。优化目标为

$$\max_{\theta} \mathbb{E}_{s \sim p(s), a \sim \pi_\theta(a|s)} [f(a|s)].$$

与 SFT 不同，这一目标不依赖人工标注监督，也不要求模仿某个固定策略。相反，它允许模型持续根据下游推荐任务的表现调整自身行为。若从优化目标角度看，SFT 优化的是与推荐质量间接相关的代理损失，而 Rec-R1 直接优化真实的推荐目标，因此与下游评测指标更加一致。

实现上，作者借鉴 DeepSeek-R1，采用 Group Relative Policy Optimization (GRPO) 来优化 LLM 策略。与传统 PPO 相比，GRPO 在保持竞争力性能的同时显著降低了训练显存开销。与此同时，本文使用由标准评测指标直接构造的基于规则的奖励函数，而不是另行训练一个奖励模型，从而避免奖励劫持并减少额外偏置。

3 实验

为了验证 Rec-R1 的有效性，作者在三个代表性推荐场景中进行了实验：商品搜索、序列推荐和商品重排序，并额外分析了模型训练后的泛化能力。

3.1 商品搜索

3.1.1 实验设置

在商品搜索任务中，用户给出自然语言查询 $s \in S$ ，用于表达某种信息需求，例如“适合徒步的防水相机”。推荐系统的目标是检索一个最匹配该查询的有序物品列表。为了提升检索质量，LLM 会生成一个文本变换 $a \in A$ ，例如被改写或澄清后的查询，再将其送入下游检索器。

检索器根据文本输入 a 返回候选物品排序列表，系统则利用相关性字典 D 对结果进行评估，其中 D 把原始输入 s 映射到其对应的真实相关物品列表。奖励函数 $f(a|s)$ 通过比较由 a 检索得到的结果与 $D(s)$ 之间的一致性来计算。训练中使用 NDCG@100 作为评测指标。作者说明，虽然实验中

D 由数据集提供，但在真实系统中，它同样可以由近期用户交互日志或点击数据构造，因此 Rec-R1 具有面向生产级推荐系统的潜力。

数据方面，作者考虑了两类商品搜索场景：(1) 传统商品搜索，即输入查询较短，通常是关键字式表达；(2) 复杂商品搜索，即输入为较长的自然语言上下文，常常包含隐式偏好或使用场景。为此，实验分别采用 ESCI 数据集与 Amazon-C4 数据集。所有实验都报告在验证集上表现最优的检查点在测试集上的结果。

基线方面，作者与一系列方法进行了比较。对于稀疏检索，采用 BM25 以及由冻结 LLM (GPT-4o 或 Qwen-2.5-3B-Instruct) 先进行查询改写后再检索的版本。对于稠密检索，则采用 RoBERTa、SimCSE、BLAIR 等判别式模型，并分别考察是否加入基于提示的查询改写。相比之下，Rec-R1 从 Qwen-2.5-3B-Instruct 出发，通过强化学习训练生成直接优化检索性能的改写查询。

3.1.2 结果

表 1 给出了 ESCI 基准上的 NDCG@100。可以看到，Rec-R1 在四个商品域以及不同检索架构下都持续提升检索性能。即便只与稀疏 BM25 结合，Rec-R1 在 Video Games 域上也带来了高达 21.45 个点的提升，说明它能够显著增强经典词法检索系统。对于 BLAIR 这类稠密检索器，Rec-R1 相比基础模型最高可提升 18.76 个点，并且稳定优于使用 GPT-4o 进行提示式改写的方案。总体而言，Rec-R1 在全部四个类别上都取得了最佳表现。

表 1: 传统商品搜索 (ESCI) 任务上的 NDCG@100

模型	Video Games	Baby Products	Office Products	Sports & Outdoors
BM25	12.44	15.12	23.96	19.48
GPT-4o+BM25	26.06	23.05	27.98	27.38
Qwen-2.5-3B-Instruct+BM25	19.63	16.03	19.96	21.36
BLAIR _{BASE}	9.75	15.20	17.19	17.08
BLAIR _{LARGE}	15.88	15.96	21.17	18.30
GPT-4o+BLAIR-BASE	20.13	24.57	21.83	22.97
GPT-4o+BLAIR-LARGE	23.99	24.10	22.99	24.67
Rec-R1-3B+BM25	33.89	29.27	34.61	31.92
Rec-R1-3B+BLAIR-BASE	28.51	29.24	33.98	30.71
Rec-R1-3B+BLAIR-LARGE	31.41	28.76	34.12	32.49

进一步地，作者在 Amazon-C4 这一复杂商品搜索数据集上评估了 Rec-R1。该数据集中的查询是更长、更自然语言化的商品需求描述，因此还可以检验模型的跨领域泛化能力：训练时使用除四个测试域以外的所有类别，测试时只在未见过的四个域上评估。结果表明，Rec-R1 在全部四个域以及所有检索架构上都取得最优结果，说明它能够有效从训练类别泛化到未见类别。相比之下，冻结 LLM 的提示式查询改写常常改进有限，甚至会使稠密检索器性能退化；而与 Rec-R1 结合后，无论 BM25 还是稠密模型都能得到明显提升，说明基于交互反馈的学习方式具有更高价值。

作者还指出，表格中没有单独报告 SFT 结果，因为理论分析已经说明：在数据充分、优化充分时，SFT 学到的策略会收敛到数据生成模型。因此，GPT-4o 的性能可以视作 SFT 的实际参考上

表 2: 复杂商品搜索 (Amazon-C4) 任务上的 NDCG@100

模型	Video Games	Baby Products	Office Products	Sports & Outdoors
BM25	7.82	6.39	8.70	7.28
GPT-4o+BM25	13.02	12.45	12.64	11.59
Qwen-2.5-3B-Instruct+BM25	10.33	8.62	9.61	9.05
BLAIR _{BASE}	19.14	19.53	17.43	20.02
BLAIR _{LARGE}	24.86	22.44	18.92	24.54
GPT-4o+BLAIR-LARGE	23.40	21.00	18.69	25.74
Rec-R1-3B+BM25	18.91	20.55	19.24	20.06
Rec-R1-3B+BLAIR-BASE	21.69	25.62	22.17	24.22
Rec-R1-3B+BLAIR-LARGE	26.51	27.04	23.10	27.40

界。而在 ESCI 与 Amazon-C4 上, Rec-R1 都稳定优于基于 GPT-4o 的提示式方法, 这表明它确实有潜力突破 SFT 范式在性能与适应性上的限制。

3.2 序列推荐

3.2.1 实验设置

在序列推荐任务中, 模型接收用户历史交互序列 $s \in S$, 例如先前浏览或购买过的物品列表, 并需要推荐最相关的下一个物品。为此, LLM 会生成一段文本 $a \in A$, 其含义类似于“用户接下来可能会购买什么”的查询描述, 可以包含关键属性、商品类型或使用场景。系统定义一个相关性字典 D , 把每段历史序列映射到真实的下一个物品; 奖励函数 $f(a|s)$ 则通过比较由 a 检索出的物品与目标物品之间的一致性来计算。实现上, 训练奖励采用 NDCG@K, 而在真实系统中, D 也可以由购买序列、交互日志等行为数据构造。

实验数据采用 Amazon Beauty 数据集, 并按照绝对时间戳划分训练集、验证集和测试集。为了考察不同泛化能力, 作者进一步区分了两种测试设定: 其一是传导式设定, 此时测试序列中的所有候选物品都在训练集中出现过; 其二是归纳式设定, 此时测试时出现的物品在训练阶段完全未见。基线方面, 作者比较了两类方法: 一类是文本感知的序列推荐模型, 如 SASRec 与 UniSRec, 并用 BLAIR 作为物品编码器; 另一类是提示式查询改写方法, 即用冻结的 GPT-4o 或 Qwen-2.5-3B-Instruct 从用户历史中生成查询, 然后送入 BM25 等检索器。

3.2.2 结果

表 3 给出了两种设定下的结果。作者观察到, 冻结 LLM 的提示式基线在该任务上整体表现很差, 说明对通用 LLM 而言, 仅靠原始能力很难完成这一任务。然而, 在 Rec-R1 框架下训练后的 Qwen-2.5-3B-Instruct 得到了显著提升, 尤其是在归纳式设定中提升更为明显。以 Recall@10 和 NDCG@50 为例, Rec-R1 相比初始化策略分别提高了 4.20 与 2.64 个点, 并且在归纳设定下超过了强序列推荐基线 UniSRec, 显示出其在冷启动或未见物品场景中的优势。

在传导式设定下, Rec-R1 虽然仍具竞争力, 但不如专门的序列推荐模型。这并不令人意外, 因

表 3: Amazon Beauty 序列推荐结果

模型	传导式				归纳式			
	R@10	N@10	R@50	N@50	R@10	N@10	R@50	N@50
UniSRec+BLAIR-BASE	4.09	2.23	8.74	3.21	3.70	2.08	6.20	2.61
Qwen-2.5-3B-Instruct+BM25	1.30	0.75	2.41	0.98	1.80	0.84	3.60	1.25
Rec-R1-3B+BM25	3.53	1.74	5.76	2.22	6.00	3.38	8.30	3.89

为传统序列推荐方法直接在大规模用户—物品序列上训练，擅长建模顺序依赖；而 Rec-R1 则是借助 LLM 去生成“用户下一步可能买什么”的自然语言查询，更依赖于语义推理与泛化。然而，仅基于交互历史进行下一物品预测并不总是一个适合在语言空间中显式推理的任务，过去物品与未来物品之间的关系可能很弱，甚至并不具有因果性，因此对 LLM 来说本身就较难。

3.3 商品重排序

3.3.1 实验设置

在商品重排序任务中，输入由自然语言查询与一个初始候选列表组成，可写作 $s = (q, C)$ ，其中 q 是用户查询， $C = [i_1, \dots, i_m]$ 是候选集合。任务目标是在候选集合内部重新排序，使得与查询更相关的物品排在更前面。LLM 输出一个候选列表的排列 $a = [i_{\pi(1)}, \dots, i_{\pi(m)}]$ ，系统则将其与真实相关物品列表进行比较，并用 NDCG@10 作为奖励。

数据采用 ESCI。候选列表由前一阶段训练得到的 Rec-R1 检索器与 BM25 联合产生，并统一截取前 16 个候选，以保证不同重排序模型之间的公平比较。比较对象包括两类：其一是传统交叉编码器重排序器，这里采用开源的 Qwen3-Reranker 系列；其二是基于 LLM 的重排序器，包括 GPT-4o 与 Qwen2.5-3B-Instruct，它们直接根据查询和候选集合生成排序结果。

3.3.2 结果

表 4 展示了不同模型在 ESCI 上的重排序结果。Rec-R1 在全部四个领域上都取得了最佳整体表现。尤其是与初始化的 Qwen2.5-3B-Instruct 相比，Rec-R1 提升极其明显；与最先进的开源嵌入/重排序模型 Qwen3-Reranker 系列相比，也表现出显著优势。这表明，Rec-R1 的优化框架同样适用于 LLM4Rec 中的闭集物品生成范式，从而进一步支持作者“Rec-R1 为连接 LLM 与推荐系统提供了一条通用途径”这一主张。

3.4 Rec-R1 会遗忘吗：泛化能力分析

除了推荐性能以外，一个关键问题是：Rec-R1 是否能够保留底层语言模型的通用能力？为此，作者比较了三类模型：（1）原始 Qwen-2.5-3B-Instruct；（2）用 GPT-4o 生成的 ESCI 查询改写数据进行监督微调后的 Qwen-2.5-3B-Instruct (SFT)；（3）在同一 ESCI 任务上、但不访问 GPT-4o 输出、直接通过 RL 训练得到的 Rec-R1-3B。

评测覆盖六个任务：ESCI（推荐）、MMLU（事实知识）、IFEval（指令遵循）、GSM8K（数学

表 4: ESCI 上的商品重排序 NDCG@10

模型	Video Games	Baby Products	Office Products	Sports & Outdoors
Qwen3-Reranker-4B	44.29	46.41	48.06	47.42
Qwen3-Reranker-8B	44.28	44.95	47.73	44.51
Qwen2.5-3B-Instruct	5.38	9.21	4.26	4.37
GPT-4o	61.57	56.18	53.62	53.62
Rec-R1-3B	53.04	57.08	60.91	62.91

推理)、MBPP 与 HumanEval (代码生成)。结果表明：在 ESCI 上，SFT 相比基础模型有提升，但 Rec-R1 的提升更大，而且不依赖 GPT-4o 合成数据；在 MMLU 上，三者表现相近，说明无论 SFT 还是 Rec-R1 都没有明显损害一般知识能力。

真正显著的差异出现在 IFEval 上：SFT 出现了剧烈退化，分数下降超过 27 点；而 Rec-R1 不仅没有退化，甚至略高于原始模型。这说明 Rec-R1 的一个关键优势在于：它是直接围绕任务目标进行优化，而不是通过下一个 token 预测去覆盖模型原有生成分布，因此更能保留指令遵循能力。在 GSM8K 上也观察到了相似趋势：Rec-R1 优于初始化模型，而 SFT 则明显落后。至于代码任务 MBPP 与 HumanEval，SFT 与 Rec-R1 都保持了较强表现，作者推测这可能与其 SFT 数据使用了 JSON 风格输出、不会过多干扰代码生成能力有关。整体而言，这些结果说明 Rec-R1 有望成为一种新的 LLM 适配范式：既能够实现强任务特化提升，又不牺牲一般能力。

4 结论

本文提出了 Rec-R1，这是一种通过直接反馈将 LLM 与推荐系统连接起来的强化学习框架。实验表明，Rec-R1 在多种任务与多类检索器上都能取得很强性能，同时保留模型的通用能力，因此为替代提示式方法与监督微调提供了一种更具可扩展性的选择。

A 将 Rec-R1 应用于多种推荐范式

图 1 给出了生成式 LLM 融入推荐系统的分类框架，作者在实验中验证了 Rec-R1 对四种主要范式的适用性。

第一，**查询改写**：在商品搜索任务中，作者以 BM25 作为检索器，让 LLM 生成改写后的用户查询，以提升检索效果。这对应于图 1 左上角的范式，体现了 Rec-R1 在文本查询改写方面的能力。

第二，**用户级特征增强**：当与 BLAIR 等稠密判别式模型结合时，LLM 会对输入查询进行语义扩展，形成更丰富的用户意图表达。这对应于图 1 右上角范式，即将 LLM 作为文本特征生成器供下游排序模型使用。

第三，**开集物品生成**：在序列推荐任务中，LLM 仅获得用户侧信息（例如购买历史），并被要求生成对下一件物品的文本预测，再将其与商品池匹配。这对应图 1 右下角范式。

第四，**闭集物品生成**：在商品重排序任务中，LLM 在给定查询与候选集合的前提下，通过排序质量相关奖励来学习排序/打分。这对应图 1 左下角范式。作者指出，既有工作在该方向上多依赖提

示法或 SFT，而这类方法可能导致灾难性遗忘；相比之下，Rec-R1 在保持领域性能的同时还能保留通用能力，因此更为稳健。

这些结果共同说明，Rec-R1 具有很强的通用性：它适用于多种推荐范式，并且与检索器或打分模型的具体架构无关。进一步地，作者认为，由于该方法能够跨范式工作且能保留模型的一般能力，因此它为“持续的、基于强化学习的 LLM 与推荐目标对齐”提供了良好基础，未来有望扩展到更多任务，最终形成可在新任务和新领域中持续适应的“终身推荐智能体”。

B 相关工作

B.1 用于推荐任务的生成式 LLM

近年来，LLM 凭借其强泛化、推理与语义理解能力，对推荐系统产生了显著影响。相关工作大体可分为几类。其一是**特征工程与增强**：LLM 被用于补充推荐数据，生成辅助特征，增强用户画像与物品理解，从而缓解数据稀疏并提升推荐质量。其二是**把 LLM 作为打分与排序函数**：例如 P5、M6-Rec、InstructRec 等工作尝试让 LLM 统一处理打分、生成与重排序等多个推荐子任务。其三是**对话式与交互式推荐**：LLM 通过会话代理加强用户与推荐系统之间的交互，提升用户参与度与推荐可解释性。作者强调，Rec-R1 并不针对某个具体应用场景或某种特定检索器，而是提供了一种通过闭环学习来使 LLM 与推荐任务对齐的通用建模与优化框架。

B.2 推荐系统中的强化学习

在大语言模型时代之前，强化学习已经被用于推荐系统，用于优化长期满意度和序列决策等目标。多数工作将推荐建模为马尔可夫决策过程，使智能体能够从用户交互序列中学习。例如，有工作将 DDPG 扩展到会话推荐，或引入自监督 RL、负采样、对比学习和奖励建模等机制。与这些直接优化推荐模型本身的方法不同，本文将推荐器视作黑盒环境，并用其反馈来训练 LLM 的生成策略，因此无需改变底层推荐器。

随着 LLM 的兴起，近期也出现了一些将 RL 与 LLM 结合以改进推荐系统的研究。例如，有工作使用类似 RLHF 的方式，使语言模型在电影推荐中同时兼顾事实性、个性化与吸引力。但这类方法通常依赖离线训练的奖励模型，未形成与推荐器的在线闭环，因此既缺乏对系统反馈的实时适应，也可能出现奖励劫持。相比之下，Rec-R1 直接使用推荐系统实时返回的奖励来优化 LLM，在任务适用范围与反馈对齐程度上都更进一步。

B.3 用于查询改写的 LLM

已有大量工作研究了如何使用 LLM 进行检索任务中的查询改写。这些方法或通过零样本提示，或通过监督微调，使模型生成语义更丰富、与下游检索器更一致的查询，从而提高召回率与排序质量。本文与其最主要的区别在于：第一，Rec-R1 使用来自下游推荐模型的真实评价指标（如 NDCG、Recall）作为奖励，真正形成了闭环反馈；第二，以往很多方法诞生于 LLM 之前，使用的模型规模和能力较弱，而本文明确针对开放域大模型进行任务适配；第三，本文的任务范围更宽，并不限于搜索查询改写。

C 定理与证明

C.1 事实 1 的证明

附录首先给出一个引理：**最大似然估计等价于最小化 KL 散度**。设 $\pi_g(a|s)$ 为固定目标策略， $\pi_\theta(a|s)$ 为参数化策略类，则最大化

$$\max_{\theta} \mathbb{E}_{s \sim p(s), a \sim \pi_g(a|s)} [\log \pi_\theta(a|s)]$$

等价于最小化

$$\min_{\theta} \mathbb{E}_{s \sim p(s)} [D_{\text{KL}}(\pi_g(\cdot|s) \parallel \pi_\theta(\cdot|s))].$$

其证明思路是：对数似然的负期望可以写成交叉熵，而交叉熵又可以拆分为 KL 散度加上目标分布熵；由于目标分布熵与 θ 无关，因此最大化对数似然即等价于最小化 KL 散度。由此进一步推出正文中的事实 1：当数据足够、模型可表达、优化足够充分时，SFT 所得到的最优策略会收敛到最小化相对于教师策略的 KL 散度的解。

C.2 从 KL 散度角度看 SFT 的性能上界

作者进一步讨论了 SFT 策略 π_{SFT} 与教师策略 π_g 之间的性能差距。设下游指标 $f(a|s)$ 有界于 $[0, R_{\max}]$ ，定义策略性能为

$$J(\pi) = \mathbb{E}_{s \sim p(s)} \mathbb{E}_{a \sim \pi(\cdot|s)} [f(a|s)].$$

则可以得到如下结论：对任意策略 π ，其相对于教师策略的性能差距满足

$$|J(\pi) - J(\pi_g)| \leq R_{\max} \sqrt{\frac{1}{2} \mathbb{E}_{s \sim p(s)} [D_{\text{KL}}(\pi_g(\cdot|s) \parallel \pi(\cdot|s))]}.$$

证明思路是先将每个状态下的奖励差写成两个分布在有界函数上的期望差，再利用全变差距离的对偶表示以及 Pinsker 不等式，把总差距界到 KL 散度上。由此可知，只要 π_{SFT} 是通过最小化相对于 π_g 的 KL 散度得到的，那么其性能至多只能在 $O(\sqrt{\kappa})$ 的范围内逼近教师，其中

$$\kappa = \mathbb{E}_{s \sim p(s)} [D_{\text{KL}}(\pi_g(\cdot|s) \parallel \pi_{\text{SFT}}(\cdot|s))].$$

C.3 RL 目标相对于 SFT 的优势

接着，作者比较了 RL 解 π_{RL} 与 SFT 解 π_{SFT} 的性能。若定义

$$J(\pi) = \mathbb{E}_{s \sim p(s), a \sim \pi(\cdot|s)} [f(a|s)],$$

并令 π_{RL} 为策略类 Π 中使 $J(\pi)$ 最大的解，而 π_{SFT} 为通过最小化教师 KL 散度得到的解，则有

$$J(\pi_{\text{RL}}) \geq J(\pi_{\text{SFT}}).$$

这一定理本质上是由定义直接推出的：既然 π_{RL} 就是在同一策略类中最大化真实任务回报的策略，而 π_{SFT} 属于该策略类，那么 RL 的性能自然不会差于 SFT。该结论说明，Rec-R1 由于显式优化下游目标，因此理论上至少不会比 SFT 更差，并且在探索与奖励优化的帮助下，还有可能超越教师策略。

D 补充实验与实现细节（节选翻译）

D.1 SFT 数据生成成本与 Rec-R1 训练成本

作者比较了依赖 GPT-4o 生成指令数据的 SFT 流水线与 Rec-R1 的成本。对于 SFT，首先需用 GPT-4o 生成 5,408 条样本，成本约为 10.82 美元；随后在两张 NVIDIA A100 GPU 上训练 35 分钟，额外成本约 4.78 美元，总成本约 15.60 美元。相比之下，Rec-R1 不需要额外数据生成，而是在学习过程中在线产生训练所需信号；仅需约 210 秒训练时间，花费约 0.48 美元，就已经能够达到甚至超过 SFT 模型的性能，并且随着训练继续，效果还会进一步提升。作者据此指出，Rec-R1 以不到 SFT 流水线成本三十分之一的代价，实现了更优性能。

D.2 商品搜索的补充细节

传统商品搜索使用经 Hou 等人处理后的 ESCI 数据集，涵盖 Video Games、Baby Products、Office Products、Sports and Outdoors 四个类别；复杂商品搜索使用 Amazon-C4 数据集，并以跨类别方式构造训练/验证/测试划分。实现上，Rec-R1 基于 VeRL，在两张 A100 80GB GPU 上训练；稀疏检索采用 Pyserini + BM25，稠密检索使用基于 HNSW 的 FAISS 索引。训练算法为 GRPO，初始模型为 Qwen-2.5-3B-Instruct，KL 正则系数为 0.001；每个提示采样 12 个响应，top- p 采样取 $p = 0.95$ 、温度为 0.6；训练 5 个 epoch，学习率为 10^{-6} 。训练时使用 NDCG@1000 作为奖励，以减弱稀疏性并稳定学习。

作者还分析了**提示设计与探索的重要性**。对于稠密检索器，尤其是 BLAIR 这种利用用户评论和商品元数据做对比学习预训练的模型，若让 LLM 生成更贴近“用户评论”风格的文本，则更可能与检索器预训练分布对齐。实验表明，单纯依靠提示把查询改写成评论风格并不总能立即提升性能，但在 Rec-R1 的 RL 训练下，模型会逐渐学会产生真正有用的评论式查询，从而显著提升检索效果。这也从侧面说明了在巨大动作空间的语言生成任务中，合理的引导式探索非常关键。

在与其他微调策略的比较中，作者考察了拒绝采样微调与 DPO。结果显示，虽然拒绝采样有一定效果，但仍不如 Rec-R1；而 DPO 由于只依赖静态偏好对、缺乏与下游环境的闭环反馈，在复杂排序场景中的表现明显较差。进一步地，作者还验证了 Rec-R1 在不同骨干模型上的适用性，包括更小的 Qwen-2.5-0.5B、1.5B，以及不同家族的 LLaMA-3.2-3B，结果都显示 Rec-R1 能够在不同尺寸与架构上稳定带来性能提升。

D.3 序列推荐与重排序的补充细节

序列推荐实验使用 Amazon Beauty 数据集，并将用户历史交互转化为自然语言格式作为 LLM 输入；为适应输入长度限制，只保留最近的 10 个历史物品。整体训练设置与商品搜索基本一致，但将最大提示长度扩大到 512。作者解释了为什么 Rec-R1 在归纳设定下优于传导设定：在传导设定中，传统模型可以依靠物品重合进行记忆，而 Rec-R1 更依赖语义与意图建模；当测试物品完全未见时，模型只能依靠可迁移的语义模式，因此更符合 Rec-R1 的学习机制。

重排序数据则基于 ESCI 构造：先用商品搜索任务中训练好的 Rec-R1 检索器与 BM25 得到候选列表，保留前 16 个候选，再过滤掉上游检索性能为零的样本。重排序专用提示会将查询和候选物品的元数据同时给到模型，要求其输出一个按相关性排序后的 item_id 列表。训练时相应增大输入

与输出长度上限。

D.4 遗忘与泛化的补充分析

作者进一步分析了 SFT 中“推理链”和 JSON 输出格式的影响。实验对四种 SFT 变体进行比较：是否包含中间推理步骤，以及答案是否采用 JSON 包裹。结果显示，在 ESCI 这一任务上，所有 SFT 变体都优于基础模型，但都不如 Rec-R1；在 MMLU 上，它们与基础模型接近；但在 IFEval 上，四种 SFT 变体全部出现了 20-30 分的严重退化，说明窄任务 SFT 容易引发灾难性遗忘。一个较有意思的现象是：不包含推理、但使用 JSON 输出格式的变体在 GSM8K 上反而有所提升，作者推测 JSON 这种严格格式起到了“隔离”作用，没有严重干扰模型自身的推理过程。相比之下，Rec-R1 在任务性能提升的同时，仍能更好地保留知识、推理与代码能力。

D.5 标准 IR 基准与 RL-for-Search 对比

在 MS MARCO、BEIR (NFCorpus、FEVER) 以及 TREC DL'19/20 等标准信息检索基准上，Rec-R1 也持续优于基线，说明它的鲁棒性并不局限于本文主打的推荐任务。作者还将其与 Search-R1、ConvSearch-R1 等 RL-for-search 方法比较，指出这些工作要么只依赖精确匹配奖励，要么使用分段定义的代理奖励，而 Rec-R1 直接使用下游推荐评价指标作为奖励，因此与真正任务目标更加一致。实验结果也表明，Rec-R1 在 ESCI 与 Amazon-C4 上都显著优于这些方法。

D.6 多目标奖励优化

Rec-R1 的奖励结构具有通用性与灵活性。形式上，奖励定义为 $f(a|s)$ ，完全可以通过线性组合扩展成多目标优化。作者在额外实验中将三类奖励联合起来使用：下游指标奖励（如 Recall、NDCG）、格式奖励，以及类别一致性奖励。结果表明，在多奖励设定下，Rec-R1 仍然能够稳定训练并显著优于基础 LLM，这说明该框架并不限于单指标优化，而可以自然扩展到多目标推荐场景。

E 讨论与未来方向

作者在实验基础上总结了若干值得关注的现象。

首先，**LLM 即便不知道商品空间，也能学会帮助推荐**。在商品搜索实验中，Rec-R1 并不知道下游商品库中到底有哪些物品，它只接收用户查询并输出改写后的查询。然而即便如此，它依然在多个领域上取得强表现。这一现象与真实用户搜索商品时的行为有相似之处：用户往往并不了解平台库存的准确内容，而是通过模糊目标与系统反馈不断修正查询。Rec-R1 正是在闭环强化学习中学会了这一“用户侧推理”过程。

其次，**序列推荐还需要更紧密的结合方式**。当前设定把 LLM 作为“下一物品预测器”，让它从历史标题生成自然语言猜测，再送入检索器。在归纳场景中这很有效，但在传导场景中不如传统序列模型。作者据此提出一个可能的方向：不再把 LLM 作为纯生成代理，而是让它为历史中的每个物品补充更丰富的描述或上下文信息，再用 BLAIR 之类的文本编码器编码，并交给标准序列推荐模型处理。这样有望把 LLM 的语义理解能力与序列模型的建模能力结合起来。

第三，**初始化 LLM 的能力非常关键**。类似于围棋、MOBA 等高复杂度环境中的 RL 系统往往依赖模仿学习提供强初始行为一样，Rec-R1 也明显依赖一个高质量初始模型。在实验中，Qwen-2.5-3B-Instruct 作为通用基础很有效；但作者也指出，通用能力强并不意味着对所有特定领域任务都已有良好先验。例如在序列推荐中，基础模型此前并没有“从用户历史预测下一物品”的经验，因此 RL 的起点就相对较弱。未来可以考虑结合领域预训练或指令微调，使模型先具备某种推荐任务先验，再用 Rec-R1 做进一步对齐。

最后，**Rec-R1 既适用于静态日志反馈，也适用于在线实时反馈**。本文实验中的反馈来自历史交互日志，但在现实部署中，平台本身会持续收集用户交互，因此可以不断维护最新日志，使 Rec-R1 与变化中的用户偏好与内容趋势保持同步。更进一步，它还可以直接在线推荐引擎上使用实时反馈信号（例如参与度、转化率）进行训练，从而成为一种能够随真实使用过程持续演化的 LLM 推荐框架。

F 案例分析

为了更直观地理解 Rec-R1 的行为，作者展示了两个案例。

F.1 商品搜索案例：ESCI

在 ESCI 的 Video Games 域中，一个用户原始查询仅为“play station 3”。直接使用 BM25 时，无法检索到相关物品，NDCG@100 为 0。使用 GPT-4o 改写后，虽然加入了“Slim”“controller”“games”等关键词，但缺乏针对具体商品术语的充分落地，因此只得到有限提升，NDCG@100 为 7.42。相比之下，Rec-R1 生成了一个非常详细、上下文丰富的查询，它更接近真实人类在商品搜索中的表达方式，纳入了存储容量、“Blu-ray”、“二手/全新”等具体配置与变体信息，并保持了整体语义一致性，因此能够成功检索到大多数目标物品，NDCG@100 提升到 78.53。作者借此说明，Rec-R1 更擅长把生成过程与下游相关性信号对齐。

F.2 序列推荐案例：Amazon Beauty

在 Amazon Beauty 数据集中，给定用户此前购买的一组商品，目标是预测其下一件可能购买的物品。GPT-4o 生成的是一个较宽泛、偏模糊的布尔查询，其中包含诸如“makeup brushes”或“serum”之类的高层类别，但没有捕捉到用户意图在时间上的连续性，因此检索结果中没有任何目标物品，NDCG@10 为 0。Rec-R1 则生成了一段更像“用户伪评论”的自然文本，在保持与用户历史语义一致的同时，更准确地收缩到可能的下一类物品，例如 winged eyeliner 及相关化妆工具，因此成功检索到了真实目标物品，NDCG@10 达到 43.06。这个案例进一步说明，Rec-R1 在“把用户历史转化为更有效的检索语言”方面更具优势。

参考文献说明

由于用户当前需求主要是中文阅读与后续写作整理，本译稿未对原始英文参考文献列表逐条翻译；若需要，我可以在下一轮继续补充“参考文献标题中文对照版”或“逐页完整附录扩展版”。