

宏观问题

1 强化学习发展流程与热门算法

1.1 强化学习发展历程

强化学习的发展大致可以概括为几个阶段。早期研究主要建立在动态规划、Bellman方程、值迭代、策略迭代以及时序差分学习等理论基础之上，核心目标是刻画智能体如何通过与环境交互不断改进决策。此后，无模型强化学习逐渐兴起，其中 Q-learning 具有代表性意义，它使得智能体无需显式环境模型即可直接学习状态—动作价值函数。

进入深度学习时代后，强化学习迎来重要突破。DQN 将深度神经网络用于价值函数近似，并结合经验回放和目标网络，使强化学习在高维复杂任务中展现出更强能力。之后，Double DQN、Dueling DQN、Rainbow 等方法进一步提升了训练稳定性和效果。

再往后，策略梯度与 Actor-Critic 方法逐渐成为主流方向。TRPO、PPO 更强调稳定的策略更新，DDPG、TD3、SAC 则在连续动作控制问题中表现突出。与此同时，多智能体强化学习和离线强化学习也快速发展，代表性方法包括 MADDPG、QMIX、QTRAN、CQL 和 IQL 等。

近年来，强化学习又开始与大模型和生成式建模结合。一方面，RLHF 使强化学习成为大模型对齐的重要工具；另一方面，Decision Transformer 和 Diffusion Policy 等工作也在尝试用新的建模方式重新理解策略学习问题。总体来看，强化学习的发展并不是简单替代，而是在不断扩展理论边界和应用场景。

2 To B与To C业务的区别

2.1 To C业务（面向消费者）

To C 业务面向海量个人用户，产品通常追求标准化、便捷性和极致体验，依靠规模效应实现增长。其核心特点在于用户数量大、决策链路短、行为反馈快，因此系统设计往往更加关注高并发、高可用和实时响应能力。对于推荐系统而言，To C 场景拥有丰富的用户行为数据，优化目标通常集中在点击率、停留时长、转化率和 GMV 等指标上，同时需要兼顾个性化与内容多样性。

2.2 To B业务（面向企业）

To B 业务面向企业客户，客户数量相对有限，但单客价值更高，决策周期也更长。与 To C 相比，To B 更强调业务价值、系统稳定性、数据安全和定制化能力。推荐系统在 To B 场景中通常不仅要给出结果，还要能够说明原因，并与企业现有业务流程、规则体系和部署要求相适配。因此，这类系统往往更加重视可解释性、迁移能力和定制化建模。

2.3 核心区别与岗位影响

总体而言，To C 更强调规模化、自动化和快速迭代，To B 更强调业务理解、系统可靠性与长期服务能力。这种差异也会直接影响推荐算法工程师的工作重点。前者通常更关注大规模数据处理、在线推理性能和 A/B 测试，后者则更关注业务理解、可解释性、数据安全和客户需求对接。简而言之，To C 更偏向规模优化，To B 更偏向业务落地。

3 传统推荐系统与大模型推荐系统

3.1 传统推荐系统

传统推荐系统经过长期工业实践，已经形成较成熟的多阶段架构，通常包括召回、粗排、精排和重排等环节。它依赖特征工程、ID Embedding、CTR/CVR 预估和协同过滤等方法，在大规模场景中能够较好地兼顾效果、效率与可控性，因此至今仍是工业界主流方案。

不过，传统推荐系统也存在明显局限。它较为依赖历史行为数据和人工特征设计，在冷启动、新场景迁移以及深层语义理解方面能力有限；同时，多阶段架构也会带来误差累积问题，一旦前序环节漏掉候选，后续排序很难弥补。

3.2 大模型推荐系统

大模型推荐系统为推荐问题提供了新的思路。与传统推荐方法相比，它更强调语义理解、生成能力和自然语言交互，能够更好地处理文本、图像、视频等多模态内容，并在一定程度上提升零样本、少样本和可解释推荐能力。这使得它在对话式推荐、推荐理由生成、内容理解增强等场景中具有较强潜力。

但大模型推荐系统目前仍面临推理成本高、时延大、生成不稳定以及幻觉等问题，工程体系和大规模部署经验也尚未完全成熟。因此，在现阶段，大模型更适合作为增强模块融入推荐系统，而不是完全取代传统架构。

3.3 融合趋势与职业思考

从当前发展趋势看，传统推荐系统与大模型推荐系统更可能长期共存，并形成混合架构。传统系统继续承担高效召回与稳定排序，大模型则更多用于语义理解、特征增强、结果解释和对话交互。这种分工既保留了传统推荐的效率优势，也发挥了大模型在理解与生成方面的能力。

基于这一趋势，我更希望进入在生成式推荐方向有深入探索的团队。对我而言，强化学习背景有助于理解长期价值优化与反馈建模问题，元学习经验也能够支持对少样本适应能力的思考。我倾向于认为，未来真正有竞争力的能力，不是只懂传统推荐或只懂大模型，而是能够把两者结合起来理解和落地。

4 如何把强化学习背景融入到生成式推荐中去

强化学习背景融入生成式推荐，关键不在于简单套用某个强化学习算法，而在于用强化学习的视角重新理解推荐问题。生成式推荐不仅要回答“当前该推荐什么”，还要考虑这次推荐对用户后续点击、停留、留存和满意度的长期影响，因此它本质上可以被看作一个连续决策问题，而不是一次性的静态匹配问题。

4.1 强化学习要素与推荐的对应关系

如果从强化学习框架来理解推荐系统，那么用户当前的兴趣状态、历史行为、上下文环境以及对话信息可以对应为状态；系统给出的推荐结果、推荐列表乃至生成式回复可以对应为动作；用户产生的点击、停留、转化、留存以及长期活跃度等反馈则可以对应为奖励；而推荐模型本身则可以理解为策略。这样一来，推荐过程就不再只是单步排序问题，而是一个随着用户反馈不断演化的序列决策过程。

这种对应关系对生成式推荐尤其重要。传统推荐更偏向于做单次打分和排序，而生成式推荐往往涉及多轮交互、自然语言生成和持续反馈，因此更适合用强化学习的方式来理解其长期优化目标。也就是说，大模型负责理解和生成，强化学习则提供“如何根据反馈不断调整策略”的框架。

4.2 强化学习在大模型后训练中的作用

由于生成式推荐通常需要依赖大模型，因此强化学习背景还能够自然延伸到大模型后训练阶段。以典型的大模型后训练流程来看，通常会先通过监督微调让模型学会基本任务形式，再基于人类偏好数据训练奖励模型或构造偏好优化目标，最后进一步优化模型输出，使其更符合用户偏好与任务目标。这里的核心思想，本质上仍然是利用反馈信号不断修正策略，只不过策略不再是传统意义上的控制器，而是语言模型本身。

从这个角度看，强化学习在大模型后训练中的价值主要体现在两个方面。其一，它提供了一种从“会生成”走向“生成得更符合目标”的优化机制，使模型能够朝着更高质量、更符合人类偏好的方向调整；其二，它强调长期目标和反馈学习，这与生成式推荐中“既要生成相关内容，又要兼顾长期用户价值”的要求是高度一致的。因此，无论是经典的 RLHF，还是更轻量的偏好优化方法，其本质都体现了强化学习关于策略改进和反馈驱动学习的思想。

4.3 如何将我的强化学习背景用于生成式推荐

强化学习并不是只能用于推荐系统中的某一个固定模块，而是凡是具有“连续决策”、“用户反馈闭环”以及“长期收益优化”特征的环节，理论上都可以引入强化学习进行建模。从工业实践来看，其最适合落地的位置通常不是最前端的大规模候选召回，而是探索分发（要不要给新物料或新作者一些曝光机会）、重排优化（在高分物料中再做一次兼顾多样性、新颖性和约束的排序）、整页推荐（不是决定单条内容，而是决定整页内容如何组合展示）、Feed 流式推荐（用户不断下滑时，下一条该推什么）以及跨场景联合优化（首页、详情页、相关推荐页之间如何协同）等更符合序列决策特征的环节。

在召回阶段，强化学习的应用通常体现为对不同召回通道的流量分配、新内容探索以及冷启动物料曝光控制。这一阶段面对的动作空间极大，因此工业中更常采用 contextual bandit 一类方法（把“大动作空间”压缩成“有限个策略臂”，例如选哪个内容池或簇去抽样、选哪个召回通道），而不是直接使用完整的长期强化学习框架。其核心目标是在保证整体效果稳定的前提下，提升新物料发现能力与候选池多样性。

在粗排和精排阶段，工业系统仍然主要依赖监督学习或多任务学习模型，直接预测点击率、转化率、观看时长等短期目标。强化学习虽然也可以用于排序策略优化，但由于该阶段吞吐要求高、反馈噪声大、训练稳定性要求强，因此实际落地难度较高。

对于信息流推荐或短视频推荐场景，强化学习同样非常适合。原因在于用户行为本质上是一个连续交互过程，用户是否点击、是否停留、是否继续下滑、是否退出页面，都会共同决定系统的长期收益。因此，推荐系统可以不再只优化单次点击，而是将会话时长、停留时长、复访率甚至长期留存作为累计奖励，从而学习能够提升长期用户满意度的推荐策略。

如果业务系统包含首页、详情页、相关推荐页、消息触达等多个连续场景，则还可以进一步构建全链路强化学习模型。在这种设定下，不同场景不再各自独立优化，而是共享用户状态表示，并共同以整条链路上的总收益为目标。这样可以避免局部最优，使系统从全局角度协调各个推荐场景之间的策略分工。

从统一建模角度来看，推荐系统中的强化学习通常可以表示为一个马尔可夫决策过程。其中，状态 s_t 表示用户在时刻 t 的综合信息，包括用户画像、历史行为序列、当前上下文、已曝光内容以及候选集信息等；动作 a_t 表示系统在当前时刻做出的推荐决策，可以是选择某个物料、生成一个 Top- K 列表、分配召回通道流量，或者生成整页内容布局；奖励 r_t 则由用户反馈构成，既可以是点击、点赞、购买等即时反馈，也可以是停留时长、会话深度、复访率、留存率等长期反馈。系统最终学习一个策略 $\pi(a|s)$ ，使长期累计回报

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^T \gamma^t r_t \right]$$

最大化。

4.4 强化学习在重排阶段的建模方法

在推荐链路中，重排阶段比召回阶段更适合采用强化学习方法。其原因在于，召回阶段通常面对海量候选集合，更强调高覆盖率与高吞吐率；而重排阶段已经将候选集合缩小到一个相对可控的范围内，此时系统需要进一步决定最终展示给用户的列表内容及其顺序。这使得问题不再只是对单个候选物料进行独立打分，而是需要同时考虑列表内部各物料之间的相互作用、位置偏置、多样性、新颖性、以及用户后续行为所带来的长期收益。因此，重排问题更适合被建模为一个序列决策问题。

从形式上看，可以将重排过程表示为一个马尔可夫决策过程。在时刻 t ，系统观察到用户当前状态 s_t ，并基于策略 π 生成最终展示列表，随后根据用户反馈获得奖励 r_t ，并转移到下一状态 s_{t+1} 。系统的目标是学习策略 $\pi(a | s)$ ，使得长期累计回报

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^T \gamma^t r_t \right]$$

最大化。

在重排场景中，状态 s_t 的设计通常比普通排序更加复杂。它不仅包含用户静态画像与历史行为序列，还应包含当前请求对应的候选集合信息、已经曝光过的内容、当前场景上下文、以及必要时的会话级信息。更具体地说，可将状态写为

$$s_t = (u_t, h_t, c_t, \mathcal{D}_t, e_t),$$

其中， u_t 表示用户静态特征， h_t 表示近期行为序列表示， c_t 表示当前上下文信息， $\mathcal{D}_t = \{d_1, d_2, \dots, d_N\}$ 表示本轮待重排候选集合， e_t 表示已经曝光内容及其反馈摘要。若系统采用逐位生成列表的方式，则状态中还可显式加入当前已选择前缀

$$p_t = (a_1, a_2, \dots, a_{k-1}),$$

从而使后续位置的决策能够感知前面已经放入列表中的内容。

在动作建模方面，重排阶段通常有两种方式。第一种方式是将整个展示列表视为一个联合动作，即直接令动作 a_t 表示一个长度为 K 的列表

$$a_t = (i_1, i_2, \dots, i_K), \quad i_j \in \mathcal{D}_t.$$

这种建模最符合“整页推荐”或“列表级优化”的目标，因为系统可以直接优化整个 slate 的整体效果。但其困难在于动作空间呈组合爆炸增长，当候选集规模较大时，直接学习整个列表动作会非常困难。

第二种方式是采用逐位决策的序列化建模。此时系统在第 k 个位置上基于状态 $s_t^{(k)}$ 与已选前缀 $p_t^{(k-1)}$ ，从剩余候选中选择一个物料

$$a_t^{(k)} \sim \pi(\cdot | s_t^{(k)}, p_t^{(k-1)}), \quad k = 1, 2, \dots, K.$$

最终得到完整列表

$$a_t = (a_t^{(1)}, a_t^{(2)}, \dots, a_t^{(K)}).$$

这种方式的优点在于，它将原本的组合优化问题分解为多个条件决策问题，更容易结合注意力机制、指针网络、Transformer 编码器或自回归策略网络实现，并能够自然地建模位置之间的依赖关系。

奖励函数是重排强化学习建模中的核心。若仍然只使用单次点击作为奖励，则模型很容易退化为短视的点击优化器，难以体现强化学习相对于传统监督排序的优势。因此在重排中，奖励通常需要同时包含即时反馈与长期反馈。一个常见的写法为

$$r_t = \lambda_1 \cdot \text{Click}_t + \lambda_2 \cdot \text{DwellTime}_t + \lambda_3 \cdot \text{Conversion}_t + \lambda_4 \cdot \text{Revisit}_t - \lambda_5 \cdot \text{Skip}_t - \lambda_6 \cdot \text{Quit}_t.$$

如果系统希望在重排阶段显式加入多样性与新颖性约束，则还可以在奖励中进一步引入列表级正则项，例如

$$r_t^{\text{list}} = r_t + \beta_1 \cdot \text{Diversity}(a_t) + \beta_2 \cdot \text{Novelty}(a_t) - \beta_3 \cdot \text{Redundancy}(a_t).$$

这样做的含义是：系统不仅关心用户是否点击某个单独物料，还关心整份列表是否过于同质化，以及是否在满足相关性的同时保持内容覆盖与新鲜度。

- Click_t （点击）：表示用户是否点击当前推荐内容，是最基础的即时正反馈信号，反映推荐结果是否成功吸引了用户注意。
- DwellTime_t （停留时长）：表示用户在当前内容上的停留时长或观看时长，通常比单纯点击更能反映用户是否真正对内容感兴趣。
- Conversion_t （转化）：表示用户是否完成了更强的目标行为，如下单、购买、注册、加购或付费等，反映推荐结果是否带来了实际业务价值。
- Revisit_t （回访）：表示用户在后续是否再次回访平台或继续使用系统，用于刻画推荐结果对用户长期留存和长期满意度的影响。
- Skip_t （跳过）：表示用户对当前曝光内容进行了快速跳过或未产生有效交互，是一种负反馈信号，说明该内容未能引起用户兴趣。
- Quit_t （退出）：表示用户在当前推荐过程中直接退出页面、结束会话或离开系统，通常是更强的负反馈，说明当前推荐结果可能明显损害了用户体验。
- $\text{Diversity}(a_t)$ （多样性）：表示推荐列表 a_t 的多样性，即列表内部的内容是否足够丰富、差异是否足够大。该项越高，说明列表中不同主题、类别或风格的内容覆盖越充分。
- $\text{Novelty}(a_t)$ （新颖性）：表示推荐列表 a_t 的新颖性，即列表中的内容对用户而言是否具有新鲜感、是否属于用户过去较少接触但可能感兴趣的内容。该项更强调用户视角下的“新”。

- $\text{Redundancy}(a_t)$ (冗余性): 表示推荐列表 a_t 的冗余性, 即列表中是否存在大量重复、相似或信息重合的内容。该项越高, 说明列表越单调, 信息重复越严重。

在价值函数建模方面, 若采用值函数方法, 则可以学习状态价值函数 $V(s)$ 或动作价值函数 $Q(s, a)$ 。但由于重排动作通常对应一个列表, 直接学习

$$Q(s_t, a_t) = Q(s_t, (i_1, \dots, i_K))$$

的难度很高。因此实践中常见两类思路: 其一是采用策略梯度或 Actor-Critic 框架, 直接学习生成列表的策略; 其二是对列表价值进行分解近似, 将 slate 的长期价值写成若干 item 级价值的组合, 从而降低动作空间复杂度。如果采用逐位生成策略, 也可以使用

$$Q(s_t^{(k)}, a_t^{(k)})$$

来近似当前位置选择某个物料所带来的边际长期收益, 并通过贪心或 beam search 的方式构造最终列表。

与传统精排模型相比, 强化学习重排最关键的差异在于: 传统精排通常学习一个单物料打分函数

$$\hat{y}_i = f_\theta(s_t, d_i),$$

然后将所有候选按照 $\hat{y}_i$ 从高到低排序; 而强化学习重排更强调“当前选择会影响后续选择”, 以及“当前展示结果会影响用户后续状态”。因此, 其本质不再是独立样本上的 point-wise 或 pair-wise 预测问题, 而是带有状态转移与长期反馈的决策优化问题。

从工程实现角度看, 一个较现实的强化学习重排框架通常包括如下几个部分: 首先使用离线召回与基础排序模型生成候选集合; 然后由强化学习策略网络在候选集合上输出最终展示列表; 用户真实反馈被记录为训练样本, 用于更新价值网络或策略网络; 为了降低在线试错风险, 模型通常先基于历史日志进行离线预训练, 并结合反事实评估或小流量实验逐步上线。因此, 强化学习并不是替代整个推荐系统, 而是在已有召回与排序模型之上, 进一步承担列表级决策与长期价值优化的职责。

综合而言, 在重排阶段采用强化学习建模, 其核心思想可以概括为: 将最终展示列表视为策略输出, 将用户反馈视为奖励信号, 将重排过程视为一个兼顾相关性、多样性、位置效应与长期收益的序列决策过程。相较于传统独立打分式排序模型, 这种方法更适合优化整页效果、会话级满意度以及长期用户价值。

因此, 如果从工程角度总结推荐链路中的强化学习应用, 可以概括为: 监督学习负责高效召回与基础排序, bandit 负责探索与冷启动流量分发, 而强化学习主要负责重排、整页决策、长期价值优化以及跨场景联合优化。这也是目前工业界较为现实且可落地的整体技术路线。

4.5 推荐系统中的奖励模型设计

在强化学习推荐系统中, 奖励模型的设计并不是简单地将所有可观测用户行为直接相加, 而是需要围绕业务目标对不同反馈信号进行分层建模。由于推荐场景中同时存在点击、停留、转化、回访、跳过和退出等多种用户行为, 这些行为在反馈强度、反馈延迟、稀疏程度和业务含义上均存在差异, 因此奖励模型首先需要明确系统最终希望优化的核心目标, 再将不同反馈划分为主目标、辅助目标和约束项。

具体而言, 奖励模型设计的第一步是确定推荐系统的北极星目标。对于内容推荐场景, 系统可能更关注用户停留时长、会话深度和长期留存; 对于电商推荐场景, 系统可能更关注转化率、成交金额和用

户复购；对于资讯推荐场景，系统则可能同时关注点击、阅读完成度和内容消费质量。因此，奖励函数不应仅仅追求短期点击最大化，而应尽可能与平台长期价值和用户长期满意度保持一致。

在确定核心目标之后，可以将用户反馈信号划分为三类。第一类是主目标奖励，通常对应业务最关心的指标，例如转化、长期停留、复访或留存；第二类是辅助正反馈，例如点击、点赞、收藏、分享等，这些信号能够反映用户兴趣，但不一定等价于最终满意度；第三类是负反馈或约束项，例如快速跳过、重复曝光、投诉、取消关注以及会话退出等，用于抑制模型为了追求短期收益而损害用户体验。这种分层方式可以避免将所有行为信号简单并列处理，从而降低目标冲突和奖励偏移的风险。

在实际建模时，不同类型的反馈还需要进行量纲统一。点击、转化、跳过和退出通常可以建模为二值变量；停留时长、观看时长和成交金额等连续变量通常需要进行截断、分桶或对数变换，以避免长尾样本对奖励产生过强影响；回访和留存等延迟反馈则需要明确统计时间窗，例如一天、三天或七天内是否回访。只有在完成归一化和尺度校准之后，不同奖励项才能被放入同一个奖励函数中进行加权融合。

一个较常见的奖励函数可以写为

$$r_t = \lambda_1 \cdot \text{Click}_t + \lambda_2 \cdot \text{DwellTime}_t + \lambda_3 \cdot \text{Conversion}_t + \lambda_4 \cdot \text{Revisit}_t - \lambda_5 \cdot \text{Skip}_t - \lambda_6 \cdot \text{Quit}_t.$$

其中， Click_t 表示用户是否点击推荐内容， DwellTime_t 表示停留时长或观看时长， Conversion_t 表示购买、注册、加购等目标行为， Revisit_t 表示用户在给定时间窗内是否回访， Skip_t 表示用户是否快速跳过当前内容， Quit_t 表示用户是否在当前推荐之后退出页面或结束会话。系数 $\lambda_1, \lambda_2, \dots, \lambda_6$ 用于刻画不同反馈在最终奖励中的相对重要性。

如果奖励模型用于重排或整页推荐，还可以进一步引入列表级奖励，以刻画单个物料独立打分无法表达的整体效果。例如可以定义

$$r_t^{\text{list}} = r_t + \beta_1 \cdot \text{Diversity}(a_t) + \beta_2 \cdot \text{Novelty}(a_t) - \beta_3 \cdot \text{Redundancy}(a_t).$$

其中， $\text{Diversity}(a_t)$ 表示推荐列表内部的多样性，用于鼓励列表覆盖更多主题、类别或风格； $\text{Novelty}(a_t)$ 表示推荐结果对用户而言的新颖性，用于鼓励系统推荐用户过去较少接触但可能感兴趣的内容； $\text{Redundancy}(a_t)$ 表示列表内部的冗余程度，用于惩罚高度重复或过于相似的推荐结果。通过引入这些列表级指标，奖励模型不仅可以优化单个推荐内容的点击或转化，还可以提升整页推荐的丰富性和用户体验。

奖励权重的确定通常不应完全依赖人工经验，而应结合业务先验、离线数据分析和在线实验共同完成。在初始阶段，可以根据业务目标为关键指标设置较高权重；随后通过离线相关性分析，判断不同用户行为与长期留存、成交金额或用户满意度之间的关系；最终仍需通过小流量在线实验不断校准权重。如果奖励估计存在明显偏差，还可以采用奖励塑形、反事实评估或不确定性惩罚等方法，降低离线日志偏差和奖励误设对策略学习造成的影响。

综上，推荐系统中的奖励模型设计应遵循由业务目标到用户反馈、再到可训练奖励函数的建模路径。其关键不在于堆叠尽可能多的奖励项，而在于明确不同反馈信号的业务含义，处理好即时反馈与长期反馈之间的关系，并通过归一化、加权融合和在线校准，使强化学习策略真正朝着长期用户价值和平台目标一致的方向优化。

5 如何看待大模型和AI的发展对我们行业的冲击

我觉得大模型和 AI 对推荐行业的影响，不是简单替代，而是一次重构。一方面，它让推荐系统变得更强了。以前推荐更多是在做召回、排序和重排，核心是根据历史行为去预测用户会不会点；现在大模型进来以后，推荐系统不只是“猜用户会点什么”，还开始更重视理解用户意图、生成推荐理由、支

持多轮交互，甚至能够做对话式推荐。另一方面，它也确实提高了行业门槛。以后只会做传统特征工程、只会调排序模型，竞争力会被削弱；更有价值的是那些既懂传统推荐链路，又懂大模型能力，还能把它们结合到真实业务里的人。

我不认为大模型会把推荐系统完全替掉。因为推荐系统是一个很强工程化的领域，线上要考虑时延、吞吐、稳定性和成本。传统推荐链路在这些方面还是很成熟，所以未来更可能是传统推荐和大模型结合，而不是二选一。比如传统系统继续负责高效召回和排序，大模型去做语义理解、结果解释、对话交互和内容生成。

所以我会把这个变化看成机会，而不是单纯的冲击。因为推荐系统正在从“会排序”走向“更懂用户、会交互、会生成”，这意味着岗位要求更高了，但发展空间也更大了。谁能把传统推荐能力和大模型能力结合起来，谁就更有优势。

你在面试里最后可以用一句特别好记的话收住：

我觉得大模型不会让推荐行业消失，但会让推荐行业升级。未来更有竞争力的人，不是只会传统推荐，或者只会大模型，而是能把两者结合起来解决真实业务问题的人。

“我觉得 AI 对推荐行业的影响更像重构，不是替代。它一方面让推荐系统从单纯排序走向理解、生成和交互，另一方面也提高了岗位门槛。未来传统推荐链路不会消失，但会和大模型长期结合，所以真正有竞争力的人，应该同时懂推荐系统的工业逻辑和大模型的新能力。”

6 算法效果不佳时的问题判断

如果算法方案在离线测试或 A/B 测试中没有取得预期提升，不能立即认为算法设计本身无效，而应先判断评估过程是否可信，再判断算法是否真实生效，最后再回到模型结构、特征体系和目标函数本身进行分析。总体而言，离线测试和 A/B 测试的排查思路具有相似性，但二者关注重点并不完全相同。离线测试更关注数据集、标签、切分方式、负样本构造和评估指标是否合理；A/B 测试更关注实验分桶、流量比例、埋点统计、线上链路和统计显著性是否可靠。

6.1 离线测试效果不佳时的排查思路

对于离线测试效果不佳的情况，首先需要检查数据切分方式是否合理。推荐系统中应尽量采用按时间切分的方式，使用过去的训练数据训练模型，再用未来的数据验证模型效果。如果采用随机切分，可能会将用户未来行为泄漏到训练集中，从而导致离线评估结果失真。因此，如果离线指标没有提升，应先确认训练集、验证集和测试集之间是否存在时间穿越或数据泄漏。

其次，需要检查标签定义和样本构造是否合理。例如，点击、转化、停留时长等标签是否与业务目标一致，曝光未点击样本是否能够直接作为负样本，负采样比例是否合理，以及训练样本和测试样本的分布是否一致。如果标签本身不能准确反映业务目标，即使模型在训练集上收敛良好，也很难在离线测试或线上实验中体现真实收益。

再次，需要检查特征是否存在穿越问题。例如，某些统计特征是否使用了预测时刻之后的数据，用户历史序列是否包含了测试时间点之后的行为，全局点击率、转化率等统计特征是否按照时间回放方式构造。如果特征中包含未来信息，离线结果可能虚高；如果离线和线上特征构造不一致，则可能导致离线有效但线上无效。

然后，需要检查离线评估指标是否与业务目标一致。例如，AUC 更关注整体排序区分能力，但不一定能直接反映 Top-K 推荐效果；Recall@K、NDCG@K 更接近推荐列表质量，但也不一定能反映停留时长、转化率或长期留存。如果算法优化的是点击率，而业务目标更关注转化或长期留存，则可能出现

离线指标提升但实际业务指标无提升的情况。因此，离线测试效果不佳时，应判断是模型本身无效，还是评估指标没有准确对应业务目标。

最后，需要回到模型本身进行复盘。如果确认数据、标签、切分、特征和指标均没有明显问题，仍然没有获得离线收益，则应进一步检查模型是否收敛、特征是否有效、模型容量是否合适、目标函数是否与业务目标一致、正负样本构造是否合理，以及超参数设置是否合适。如果离线测试在整体上没有提升，还应进一步按照新老用户、活跃度、内容类别、物料冷热程度等维度进行分群分析，判断算法是整体无效，还是只在部分场景中有效。

6.2 A/B测试效果不佳时的排查思路

对于 A/B 测试效果不佳的情况，首先需要检查实验设计是否可靠。应确认实验组和对照组的分桶逻辑是否正确，流量比例是否符合预期，用户画像、活跃度、地域、设备和入口来源等分布是否基本一致。如果实验组和对照组出现样本比例不匹配，则说明实验随机性或流量分配链路可能存在问题，此时不能直接根据实验结果判断算法好坏。

其次，需要检查样本量、实验周期和统计显著性。A/B 测试没有提升可能只是因为样本量不足、指标方差过大或实验周期过短。因此需要观察主指标的置信区间、显著性水平和波动趋势，判断当前结果是真正没有收益，还是由于实验功效不足导致结论不稳定。同时，还应检查实验期间是否受到节假日、营销活动、版本发布或其他并行实验的干扰。

再次，需要检查埋点和数据统计链路。推荐系统中的曝光、点击、停留、转化和退出等行为都依赖日志记录。如果曝光埋点缺失、点击归因错误、转化窗口设置不合理，或者实验组和对照组的数据清洗口径不一致，都会导致实验结果无法真实反映算法效果。因此，需要确认实验组和对照组在日志采集、行为归因和指标计算上完全一致。

然后，需要检查线上推荐链路是否真实生效。推荐系统通常包含召回、粗排、精排、重排、规则过滤、缓存、多样性打散和广告混排等多个模块。新模型上线后，并不一定能够真正影响最终曝光结果。因此需要检查实验组是否确实调用了新模型，线上特征是否与离线特征一致，模型分数是否参与最终排序，后续规则是否覆盖了模型排序结果。可以进一步比较实验组和对照组的 Top-K 重合率、曝光物料分布、排序分数分布和品类分布。如果两组最终曝光结果差异很小，则说明算法虽然上线，但并没有真正作用到用户侧。

进一步地，需要分析离线指标与在线指标之间的关系。如果离线指标提升，但 A/B 测试没有提升，则更可能是离线评估与线上业务目标不一致、线上链路没有生效、特征在线离线不一致、或者后续规则覆盖了模型效果。如果离线指标没有提升，但 A/B 局部人群有提升，则说明整体评估可能掩盖了分群收益，需要进一步分析算法适用场景。因此，还应按照新老用户、活跃度、兴趣集中度、设备类型、入口场景、内容类别、物料冷热程度等维度拆分结果。如果算法只在部分人群或部分场景中有效，则可以考虑缩小模型适用范围，而不是直接否定整个算法方案。

最后，需要结合主指标和保护指标进行综合判断。A/B 测试不应只看单一主指标，还应观察保护指标是否受到损害。例如，点击率提升但停留时长下降，说明模型可能更偏向标题党内容；转化率提升但用户留存下降，说明模型可能牺牲了长期体验；成交金额提升但投诉率上升，说明模型可能带来了用户体验风险。只有在确认实验设计可靠、数据链路正确、线上模型真实生效之后，才能进一步判断问题是否来自模型结构、特征体系、目标函数或算法假设本身。

综上，当算法在离线测试和 A/B 测试中效果不佳时，应按照“评估可信度检查、数据与标签检查、特征与切分检查、指标一致性检查、线上链路检查、分群分析、模型假设复盘”的顺序逐步判断问题。离线测试重点判断评估协议是否合理，A/B 测试重点判断实验结果是否可信以及算法是否真实生效。只有

在排除数据、评估和工程链路问题之后，才能进一步判断算法设计本身是否存在缺陷。