

面试复盘

1 自我介绍

面试官您好，我是黄思铭，来自北京航空航天大学数学专业，数学与应用数学方向，目前研究生在读。我的研究方向是多智能体强化学习，同时对推荐系统有深入研究。技术方面，我熟练掌握Python和PyTorch，也熟悉C语言和MATLAB。数学基础比较扎实，在本研阶段，获得了数学分析课程99分，高等代数课程94分，深度学习课程95分的好成绩。接下来简单介绍一下简历里面提到的三个项目：

第一个是基于元学习的冷启动推荐系统项目。推荐系统中新上线的物品由于交互数据不足，导致ID embedding训练不好，推荐效果差。传统做法是随机初始化ID embedding，质量很差。我的项目设计了一个冷启动框架，用生成器根据物品的属性特征生成高质量的初始ID embedding。

核心创新是用元学习MAML的方式训练生成器。我把学习每个item的ID embedding当做一个任务，通过学习多个老item的任务，生成器掌握了为item生成好的embedding的能力。

此外还有两个辅助优化：一是基于对比学习优化特征空间，通过随机mask特征槽作为数据增强，增强生成器的泛化能力。二是用交互用户的平均embedding进行去噪，减轻噪声影响。

在MovieLens-1M数据集上，我的方法将新item的GAUC从0.84提升到0.85，提高了1个百分点。

第二个项目是：基于CVaR 正则的风险敏感多智能体训练框架。针对多智能体强化学习中的不确定性和高风险行为问题，我设计了基于 CVaR 正则 的训练框架，用集成评论家网络构建价值分布，引入条件风险价值惩罚高风险状态。算法在MPE各种环境中碰撞次数下降10%。

第三个项目是卫星对抗环境设计，体现了环境建模和工程实现能力。

以上就是我的自我介绍全部内容，谢谢！

2 项目介绍：基于元学习的冷启动推荐系统

对于新上线的物品，也就是冷启动item，它的数据不足，导致它的ID embedding训练得很差，进而导致推荐模型推不准。因为ID特征是每个item独有的，所以ID特征只能吃到自己的数据，在自己数据不足的情况下，就更新不好。但其他特征比如类别等于运动，这个特征可以吃到所有运动类item的数据，所以肯定更新得很好。

所以解决冷启动问题的本质，就是解决冷启动item的ID embedding训练不好的问题。传统做法是给新item随机初始化一个ID embedding，但这个embedding质量很差。我的项目就是设计一个冷启动框架，用生成器为新item生成一个良好的初始ID embedding，来替换随机初始化的较差的embedding，以此提高推荐效果。

具体来说，我的项目有三个核心优化点。第一个优化点是构建ID embedding生成器。生成器的输入是item的属性特征比如电影的上映年份标题类型等，输出是一个质量不错的ID embedding。这里的关键是，我用元学习MAML的方式来训练这个生成器。

什么是元学习呢？传统机器学习是一条条样本地训练，而元学习是以任务为单位训练，通过学习多个不同的任务，模型掌握了一种“学习的能力”，当新任务来临时，只需要少量数据就能快速适应。”。我把学习每个item的ID embedding当做一个任务，用多个老item的数据构造多个task，通过对不同task的学习，生成器就学会了如何在少样本情况下，为item生成好的ID embedding这个能力。

然而，在推荐系统中，毫无交互的物品连少量数据都没有，所以传统的元学习是不够的。传统MAML是怎么做的呢？它学习一个好的模型参数初始化，当新任务来临时，用少量样本对模型参数做梯度下降更新，然后在更新后的参数上计算loss，用这个loss反向传播去优化初始化参数。但这有个问题，推荐系统中很多新item是完全冷启动，连少量样本都没有，根本没机会做更新。

所以我做了改进。我不仅用更新后的loss，还同时用更新前的loss，把这两个loss加起来，一起反向传播去更新生成器的参数。并且，我不是更新整个冷启动生成器的参数，而是只更新ID embedding向量。具体训练流程是这样的：先用生成器为训练集的item生成初始ID embedding，在第一个batch数据上计算完全冷启动的loss，这时候还没有更新。然后用这个loss对ID embedding做一步梯度下降，得到更新后的ID embedding，再在第二个batch数据上计算预热阶段的loss。这样生成器在训练时就同时考虑了两个阶段，既能应对0样本的完全冷启动，也能应对有少量数据的预热阶段。当新item来临时，直接用生成器为它生成ID embedding，这个embedding质量就比随机初始化好很多。如果新item积累了少量数据，还可以在这些数据上对ID embedding做一步梯度下降，让它快速适应到新item的真实特征，进一步提升效果。

还有两个优化点相当于是辅助技巧。第一个是基于对比学习的特征空间优化。我把item的属性特征分成两个视图作为数据增强的手段，虽然这两个视图看到的信息不同，但它们描述的是同一部电影，所以应该生成相似的embedding，这是正样本对。同时，我把batch内其他item的视图作为负样本，强制当前item的embedding和其他item的embedding保持距离。通过InfoNCE Loss，拉近正样本对，推远负样本对，这样可以优化embedding空间的几何结构，让相似的item聚在一起，不相似的item分开，增强生成器的泛化能力。

第二个辅助技巧是嵌入去噪。对于冷启动item来说，交互用户数量本来就有限，噪声用户的影响会非常大。我的做法是用冷启动item的最近20个交互用户的平均id embedding来进行去噪。将其拼接t到生成器生成的id embedding上，再过一层MLP网络，可以减轻离群点的影响，从而起到降噪的作用。

训练流程分两个阶段。在讲训练流程之前，要先讲数据集进行处理，以MovieLens-1M电影评分数据集为例，我把交互数大于512的电影当做老item占90%，小于等于512的当做新item占10%作为冷启动

的测试集。而老item中再取90%的数据作为**基础DNN模型的训练集**，剩下10%分为两部分作为**冷启动训练集**。

第一阶段是**预训练推荐模型**，用老item的大量数据训练一个基础的DNN模型，这个阶段就是正常的推荐模型训练。第二阶段是**元学习训练生成器**，冻结第一阶段训练好的DNN参数，只训练生成器的参数。这里用的是MAML的训练方式，每个老item取两个batch的数据，第一个batch模拟**完全冷启动阶段**，用生成器生成的embedding进行预测，计算**冷启动损失**。然后让这个embedding在冷启动损失上梯度下降一步，模拟数据积累后embedding得到更新。再用第二个batch计算**预热损失**，评估更新后的embedding效果。最后用这两个损失加上**对比学习损失**，一起反向传播更新生成器的参数。

预测的时候，当新item来临，直接用生成器根据它的属性特征生成ID embedding，然后用这个embedding参与推荐。如果新item已经有了少量数据，还可以在这些数据上再做一步梯度下降，让embedding快速适应到新item的真实特征，进一步提升效果。

实验结果显示，不用冷启动框架的话，新item的**GAUC是0.84**。加入我的冷启动框架后，**GAUC提升到0.85**，提高了1个百分点。

3 问题1：为什么强化学习课题组要转投搜广推？

我在强化学习课题组期间，在学习过程中，我发现**推荐系统天然就是一个序列决策问题**：“状态”是系统当前能看到的用户上下文：用户画像、历史交互序列等信息。“动作”就是系统这一步“决定推荐什么、怎么推荐”。奖励就是你优化的业务目标：点击率、停留时长、观看时长、点赞、关注、分享等等。这让我意识到**强化学习和推荐系统有天然的契合点**，激发了我对搜广推领域的兴趣。

强化学习的思维方式对推荐系统很有帮助。首先是**探索利用平衡**，正好对应推荐系统中探索新item和推荐老item。其次是**长期价值优化**，不只看当前点击率，还要考虑用户留存。第三是**序列建模能力**，用户行为是序列的，需要捕捉时序依赖。我做的这个冷启动项目，虽然用的是元学习，但本质上也是在解决如何快速适应新任务的问题，和强化学习中的**few-shot** 思想是相通的。

近年来，我特别关注到**生成式推荐的发展趋势**。传统推荐范式是召回粗排精排重排的多阶段链路，每个阶段独立优化，存在信息损失，依赖大量人工特征工程。而生成式推荐可以**端到端生成推荐结果**，减少由于多阶段流水线拆分而额外引入的性能损失，大模型的涌现能力能更好理解用户意图，还可以**生成个性化的内容描述**，提升用户体验。

我注意到工业界已经在大规模应用RL到推荐系统，比如YouTube用DQN做视频推荐，阿里用虚拟淘宝环境训练推荐策略，字节用Contextual Bandit做冷启动，小红书快手在探索生成式推荐。这让我看到了**强化学习在搜广推领域的巨大应用价值**，也坚定了我转向这个方向的决心。

从就业角度，**搜广推是互联网公司的核心业务**，岗位需求大，技术栈成熟。而且我的强化学习背景是加分项，能带来差异化竞争力。特别是在生成式推荐这个新兴方向，强化学习的探索能力有用武之地。

4 问题2：对比学习的正样本构造与语义一致性

我理解面试官的核心疑问是：我把item的属性特征分成两个子集view1和view2，用这两个不完整的特征子集分别生成embedding，然后强制这两个embedding相似，但两个子集信息不同，生成的embedding凭什么要相似，这不是破坏了语义吗？

首先我解释一下对比学习的本质。对比学习的核心就是数据增强, 对同一个样本做不同的变换, 得到多个视图, 这些视图表面形式不同, 但本质语义相同。然后强制模型学习, 这些不同视图应该映射到相似的表示, 从而让模型忽略表面差异, 抓住本质特征。比如CV领域, 同一张猫的图片可以旋转裁剪变色, 表面像素不同, 但都是猫这个语义。通过对比学习, 模型学会不管角度颜色如何变, 都能识别出是猫。

我的方法本质上和标准对比学习的数据增强是一样的, 只是增强方式不同。CV可以用旋转裁剪, NLP可以用回译同义词替换, 但推荐系统的特征是离散的, 不能像图像那样连续变换。我采用的数据增强方式是随机mask掉一部分特征槽, 这样同一新item的两个视图看到的信息不同, 但它们描述的是同一部电影, 这就是数据增强。

但这里有个问题, 如果直接把某些特征mask成0, 可能会完全改变电影的属性表示, 相当于变成了另一部电影, 破坏了语义。为了解决这个问题, 我加入了一个SENet风格的注意力机制W-SENET。它的作用是, 当某些特征被mask成0之后, 模型可以自适应地调整剩余特征的权重, 给重要的特征更高的权重, 从而补偿被mask掉的信息。这样即使mask掉了一部分特征, 生成的embedding也不会完全偏离原来的语义, 而是保持在合理的范围内。

通过对比学习, 我强制生成器学习, 不管从哪个角度看, 也就是不管用view1还是view2, 都应该生成相似的ID embedding。这和CV中强制不同角度的图片生成相似的表示是一个道理。这样做的好处是什么呢? 生成器学会了从不完整信息中提取本质特征。当新item来临时, 即使某些特征缺失, 生成器也能生成合理的embedding, 这就提升了鲁棒性和泛化能力。

总结一下, 我的方法和标准对比学习的数据增强本质是一样的, 都是对同一个样本做不同的变换, 然后强制不同变换生成相似的表示。只是CV用旋转裁剪, 我用特征子集划分, 但核心思想是一致的。这不是破坏语义, 而是让模型学习语义的不变性, 从而提升泛化能力。

5 问题3: 冷启动是user-item, 为什么你做item-item?

冷启动问题确实是预测user-item交互, 但解决方案可以从不同角度切入。传统的user-item建模思路是协同过滤, 输入user id和item id, 输出预测评分或点击概率, 但问题是新item没有user交互历史, 协同过滤失效。而item-item建模的思路是内容增强, 核心是找相似老item迁移它们的知识, 输出新item的良好ID embedding, 然后用这个embedding参与user-item预测。

我的方案是item-item是手段, user-item是目标。完整流程分两个阶段。阶段一是item-item相似度, 也就是生成器训练, 新item找到K个相似老item, 生成新item的ID embedding。阶段二是user-item预测, 也就是推荐模型, 把user特征、新item的生成embedding、其他特征输入DNN, 预测点击率。

为什么强调item-item呢? 第一, 冷启动的本质是item端问题。新item没数据, user是有数据的, 问题出在item的ID embedding训练不足, 所以要从item端解决。第二, item-item是手段, user-item是目标。通过item相似性生成embedding是手段, 最终还是预测user对item的兴趣是目标。第三, 元学习的任务定义, 每个task是学习一个item的embedding, 不是学习一个user的偏好, 因为item是冷启动的, user不是。

总结一下, 不是只有item-item, 而是item-item相似生成item embedding, 然后user-item预测, 用item-item解决user-item问题。如果是user冷启动, 思路会反过来, user-user建模找相似老用户生成新用户的embedding, 然后用这个user embedding参与user-item预测。但我的项目聚焦item冷启动, 所以是item-item建模。

6 问题4: 机器学习中的损失函数

机器学习中的损失函数根据任务类型可以分为以下几类:

6.1 回归任务损失函数

- 均方误差(MSE): $L = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$, 对异常值敏感
- 平均绝对误差(MAE): $L = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$, 对异常值更鲁棒
- Huber Loss: 结合MSE和MAE的优点, 在误差较小时使用MSE, 误差较大时使用MAE
- Log-Cosh Loss: $L = \sum_{i=1}^n \log(\cosh(\hat{y}_i - y_i))$, 比MSE更平滑

6.2 分类任务损失函数

- 交叉熵损失(Cross Entropy):
 - 二分类: $L = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$
 - 多分类: $L = -\frac{1}{n} \sum_{i=1}^n \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c})$
- Hinge Loss: $L = \sum_{i=1}^n \max(0, 1 - y_i \hat{y}_i)$, 常用于SVM
- Focal Loss: $L = -\sum_{i=1}^n \alpha_i (1 - \hat{y}_i)^\gamma y_i \log(\hat{y}_i)$, 解决类别不平衡
- KL散度: $D_{KL}(P||Q) = \sum_i P(i) \log \frac{P(i)}{Q(i)}$, 衡量两个分布的差异

6.3 对比学习损失函数

- InfoNCE Loss: $L = -\log \frac{\exp(\text{sim}(z_i, z_i^+)/\tau)}{\sum_{j=1}^N \exp(\text{sim}(z_i, z_j)/\tau)}$
- Triplet Loss: $L = \max(0, d(a, p) - d(a, n) + \text{margin})$
- Contrastive Loss: 拉近正样本对, 推远负样本对

6.4 其他损失函数

- CTC Loss: 用于序列标注任务, 如语音识别
- Wasserstein Distance: 用于GAN训练
- Perceptual Loss: 用于图像生成, 基于特征空间的距离

7 问题5: 交叉熵作为损失函数的原理及相关概念

7.1 为什么交叉熵能作为损失函数

交叉熵能作为损失函数的核心原因有以下几点:

1. 信息论基础

交叉熵衡量的是用分布 Q 来编码分布 P 所需的平均比特数。在分类任务中, P 是真实标签分布(one-hot), Q 是模型预测分布。交叉熵越小,说明模型预测越接近真实分布。

数学定义: $H(P, Q) = -\sum_i P(i) \log Q(i)$

2. 最大似然估计的等价性

最小化交叉熵等价于最大化似然函数。假设样本独立同分布,似然函数为:

$$L(\theta) = \prod_{i=1}^n P(y_i|x_i; \theta)$$

取负对数得到:

$$-\log L(\theta) = -\sum_{i=1}^n \log P(y_i|x_i; \theta)$$

这正是交叉熵损失的形式。所以最小化交叉熵就是最大化似然,有坚实的统计学基础。

3. 梯度性质良好

交叉熵配合softmax激活函数,梯度形式简洁:

$$\frac{\partial L}{\partial z_i} = \hat{y}_i - y_i$$

梯度大小正好等于预测误差,不会出现梯度消失问题,训练稳定高效。

4. 凸优化性质

对于线性模型,交叉熵是凸函数,保证能找到全局最优解。

7.2 InfoNCE与交叉熵的关系

InfoNCE(Noise Contrastive Estimation)本质上是多分类交叉熵的一种特殊形式。

InfoNCE的形式:

$$L_{InfoNCE} = -\log \frac{\exp(\text{sim}(z_i, z_i^+)/\tau)}{\sum_{j=1}^N \exp(\text{sim}(z_i, z_j)/\tau)}$$

可以看出,这就是一个 N 分类的交叉熵:

- 正样本 z_i^+ 对应真实类别,标签为1
- 其他 $N-1$ 个负样本对应其他类别,标签为0
- 分母是softmax归一化

所以InfoNCE = 把对比学习转化为 N 分类问题,用交叉熵优化。核心思想是最大化正样本对的相似度,同时最小化负样本对的相似度。

7.3 KL散度与交叉熵的关系

KL散度和交叉熵有紧密的数学关系:

$$D_{KL}(P||Q) = \sum_i P(i) \log \frac{P(i)}{Q(i)} = \sum_i P(i) \log P(i) - \sum_i P(i) \log Q(i)$$

$$D_{KL}(P||Q) = -H(P) + H(P, Q)$$

其中 $H(P)$ 是 P 的熵, $H(P, Q)$ 是交叉熵。

关键结论:

- $KL散度 = 交叉熵 - 熵$
- 在分类任务中,真实标签 P 是固定的one-hot分布,熵 $H(P) = 0$
- 因此最小化交叉熵等价于最小化KL散度
- KL散度非负,当且仅当 $P=Q$ 时为0

所以在分类任务中,最小化交叉熵就是让模型预测分布 Q 尽可能接近真实分布 P ,这正是我们想要的。
区别:

- KL散度不对称: $D_{KL}(P||Q) \neq D_{KL}(Q||P)$
- 交叉熵也不对称,但在分类任务中 P 固定,只优化 Q
- KL散度更多用于分布匹配(如VAE),交叉熵更多用于分类任务

8 问题6: 强化学习发展流程与热门算法

8.1 强化学习发展历程

1. 早期阶段(1950s-1980s)

- 动态规划方法: Bellman方程,值迭代,策略迭代
- 时序差分学习: $TD(\lambda)$ 算法
- Q-Learning(1989): 第一个无模型的off-policy算法

2. 深度强化学习时代(2013-2016)

- **DQN(2013)**: DeepMind用深度神经网络近似Q函数,在Atari游戏上超越人类
- 关键技术: 经验回放(Experience Replay) + 目标网络(Target Network)
- **Double DQN, Dueling DQN, Rainbow**: DQN的改进版本

3. 策略梯度时代(2015-2017)

- **DDPG(2015)**: 连续动作空间的Actor-Critic算法
- **A3C(2016)**: 异步优势Actor-Critic,多线程并行训练
- **TRPO(2015)**: 信赖域策略优化,保证策略单调改进
- **PPO(2017)**: 近端策略优化,简化TRPO,成为最流行算法

4. 多智能体与离线强化学习(2017-2020)

- **MADDPG**: 多智能体DDPG
- **QMIX, QTRAN**: 值分解方法
- **SAC(2018)**: 软Actor-Critic,最大熵强化学习

- **TD3(2018)**: Twin Delayed DDPG,改进DDPG的稳定性
- 离线强化学习: CQL, IQL等,从固定数据集学习

5. 大模型时代(2020-至今)

- **RLHF**: 用强化学习对齐大模型,ChatGPT的核心技术
- **Decision Transformer**: 把RL转化为序列建模问题
- **Diffusion Policy**: 扩散模型用于策略学习

8.2 热门算法总结

基于值函数的算法:

- DQN系列: DQN, Double DQN, Dueling DQN, Rainbow
- 适用于离散动作空间

基于策略梯度的算法:

- REINFORCE: 最基础的策略梯度算法
- A2C/A3C: 优势Actor-Critic
- PPO: 工业界最常用,稳定性好
- TRPO: 理论保证强,但计算复杂

Actor-Critic算法:

- DDPG: 确定性策略梯度
- TD3: 改进DDPG的过估计问题
- SAC: 最大熵框架,探索性好

多智能体算法:

- MADDPG: 中心化训练,去中心化执行
- QMIX: 值分解,保证IGM性质
- MAPPO: 多智能体PPO

9 问题7: PPO算法详解及其在大模型后训练中的应用

9.1 PPO算法原理

PPO(Proximal Policy Optimization)是目前最流行的强化学习算法,由OpenAI在2017年提出。

核心思想: 在策略更新时,限制新策略和旧策略的差异不要太大,避免训练不稳定。

目标函数:

$$L^{CLIP}(\theta) = \mathbb{E}_t[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)]$$

其中:

- $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$ 是重要性采样比率
- $\hat{A}_t$ 是优势函数估计
- ϵ 是裁剪参数,通常取0.1或0.2

关键机制:

1. **裁剪(Clipping):** 当 r_t 超出 $[1 - \epsilon, 1 + \epsilon]$ 范围时,梯度被截断,防止策略更新过大
2. **优势函数:** 用GAE(Generalized Advantage Estimation)估计,减小方差
3. **多轮更新:** 同一批数据可以重复使用多次,提高样本效率

算法流程:

1. 用当前策略 $\pi_{\theta_{old}}$ 收集轨迹数据
2. 计算每个时间步的优势函数 $\hat{A}_t$
3. 用收集的数据更新策略,最大化 L^{CLIP}
4. 重复K轮(通常K=3-10)
5. 更新 $\theta_{old} \leftarrow \theta$,进入下一轮采样

9.2 为什么大模型后训练选择PPO

大模型的RLHF(Reinforcement Learning from Human Feedback)后训练几乎都选择PPO,原因如下:

1. 训练稳定性

- 大模型参数量巨大(几十亿到千亿),训练极其不稳定
- PPO的裁剪机制保证策略更新幅度可控,避免catastrophic forgetting
- 相比TRPO,PPO实现简单,不需要计算二阶导数和共轭梯度

2. 样本效率

- 大模型生成样本成本极高(需要推理生成文本)
- PPO是on-policy算法,但允许多轮更新同一批数据
- 相比纯on-policy的A2C,样本效率提升数倍
- 相比off-policy的SAC,PPO更稳定,不需要复杂的replay buffer

3. 超参数鲁棒性

- PPO对超参数不敏感,默认参数在多数任务上表现良好
- 大模型训练成本高,不能频繁调参,PPO的鲁棒性至关重要

4. 工程实现友好

- PPO代码简洁,易于分布式实现
- 支持批量并行采样,充分利用GPU集群
- 与大模型的生成式训练范式天然契合

5. 理论保证

- PPO有单调改进保证(在一定条件下)
- 裁剪机制提供了保守的策略更新,降低风险

9.3 RLHF中的PPO应用

在ChatGPT等大模型的RLHF训练中,PPO的具体应用流程:

阶段1: 监督微调(SFT)

- 用高质量人工标注数据微调预训练模型
- 得到初始策略 π_{SFT}

阶段2: 奖励模型训练(RM)

- 人工对模型生成的多个回复进行排序
- 训练奖励模型 $r_\phi(x, y)$ 预测人类偏好

阶段3: PPO强化学习

- 状态: 用户输入prompt x
- 动作: 模型生成的回复 $y \sim \pi_\theta(y|x)$
- 奖励: $r(x, y) = r_\phi(x, y) - \beta \log \frac{\pi_\theta(y|x)}{\pi_{SFT}(y|x)}$
- 第二项是KL惩罚,防止模型偏离SFT太远
- 用PPO最大化期望奖励

关键技巧:

- KL散度约束: 保持与SFT模型的接近,避免模型崩溃
- 值函数基线: 减小梯度方差
- 分布式训练: 多GPU并行采样和训练
- 经验回放: 虽然PPO是on-policy,但可以适度重用数据

为什么不用其他算法:

- DQN: 只适用于离散动作,大模型是连续的token生成
- SAC: off-policy,需要大量replay buffer,内存开销大
- TRPO: 计算复杂度高,大模型上不现实
- A2C: 样本效率低,需要更多生成样本

总结: PPO在稳定性、样本效率、实现简单性之间达到了最佳平衡,是大模型RLHF的不二之选。